

Você aprovaria estes quatro clientes?

Crédito pessoal, horizonte de 12 meses

Ana	Renda por mês R\$ 7.000	Comprometimento 22%	Histórico de atraso não	Utilização 30%	Relacionamento 36 meses
Bruno	Renda por mês R\$ 4.500	Comprometimento 38%	Histórico de atraso sim	Utilização 65%	Relacionamento 8 meses
Carla	Renda por mês R\$ 10.000	Comprometimento 48%	Histórico de atraso não	Utilização 85%	Relacionamento 60 meses
Diego	Renda por mês R\$ 3.500	Comprometimento 55%	Histórico de atraso sim	Utilização 90%	Relacionamento 4 meses

Que informação faria você mudar de ideia?

Aprovar exige estimar risco e definir uma política.
Esquema conceitual; sem dados

COMO USAR

Escolha uma opção por cliente. A seleção fica apenas neste dispositivo e não vira estatística da turma.

O desafio da aula

Estimar PD, comparar modelos e transformar risco em decisão.

O que sabemos no momento da proposta?

Seis características por cliente, com unidade e momento de observação

CLIENTE						
	7.000	22	36	30	0	Agência
	4.500	38	8	65	1	Digital
	10.000	48	60	85	0	Digital
	3.500	55	4	90	1	Parceiro

Cada variável descreve uma dimensão do risco. Nenhuma decide sozinha.
Esquema conceitual; sem dados

Ana
Renda **R\$ 7.000**
Comprometimento **22%**
Relacionamento **36 meses**
Utilização **30%**
Histórico **não**
Canal **Agência**
Perfil fictício, elegível, sem desfecho revelado.

DICIONÁRIO
Selecione um cabeçalho para ver unidade, definição e momento de observação da variável.

Probabilidade de quê, para quem e até quando?


Atraso superior a 90 dias em qualquer momento dos 12 meses após a contratação

Evento: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação.

População: solicitantes elegíveis, sem inadimplência corrente na proposta. Unidade: um contrato de crédito pessoal.

Data até a qual conhecemos os dados (mês desde a contratação)
mês 12

Atingir exatamente 90 dias não satisfaz a definição. O evento exige mais de 90.



Sem a mesma definição de inadimplência, duas PDs não são comparáveis.

Trajetórias ilustrativas de contratos fictícios; cálculo próprio

Eixo horizontal: meses desde a contratação. Eixo vertical: atraso em dias.

Esse dado existia quando o crédito foi aprovado?

Classifique cada informação pela data em que ela ficou disponível

Renda verificada: R\$ 4.500 por mês disponibilidade: documento verificado 3 dias antes da proposta	sem classificação
Histórico de atrasos: um atraso de 40 dias disponibilidade: apurado nos 12 meses anteriores à proposta	sem classificação
Utilização de limite: 65% disponibilidade: último extrato fechado antes da proposta	sem classificação
Comprometimento com a parcela proposta: 38% disponibilidade: calculado na simulação da própria proposta	sem classificação
Valor renegociado: R\$ 3.200 disponibilidade: registrado 3 meses depois da contratação	sem classificação
Atraso máximo nos 12 meses seguintes: 95 dias disponibilidade: apurado no fim da janela de 12 meses	sem classificação
Consulta de bureau: escore 480 disponibilidade: consultada 2 dias depois da inadimplência	sem classificação

Uma variável excelente depois do evento pode ser inútil para decidir antes dele.

A FRONTEIRA DA DECISÃO

Só entra no modelo o que já existia e já estava acessível no momento da proposta.


0 de 7 fichas classificadas corretamente.

A REGRA

Vale a data de disponibilidade da informação, não a data do fenômeno que ela descreve.

Aprender no passado, escolher sem olhar o teste

Quatro partições, cada uma com 12 meses de maturação antes de o alvo existir



MOMENTO DA DECISÃO

Com o alvo do teste completo, avaliamos uma única vez as regras já congeladas. O teste não escolhe nada.

Barra sólida: contratações. Barra clara: os 12 meses até o alvo existir. Uma faixa apagada indica alvo ainda desconhecido na data da decisão.

Separar por calendário só funciona se respeitarmos quando cada resultado ficou disponível.
Experimento sintético; semente e versões no notebook

O mesmo cliente, três formas de aprender o risco

A ficha de entrada é a mesma nos três mecanismos

Bruno R\$ 4.500 por mês · comprometimento 38% · relacionamento 8 meses · utilização 65% · histórico sim

Ordenar risco: o maior risco fica acima do menor?

Estimar probabilidades: 10% previsto vira cerca de 10% observado?

Apoiar a decisão: a política resultante melhora o resultado?

Regressão logística etapa 3 de 3

Combina efeitos em um escore


comprometimento

histórico

utilização

PD entre 0% e 100%

z



O escore vira probabilidade

Os dados e o objetivo são comuns. Muda a forma de construir a previsão.
Esquema conceitual; sem dados

Árvore de decisão etapa 3 de 3

Separa clientes por perguntas

histórico?

não

sim

comp.?

comp.?

≤

>

grupo

taxa

grupo

grupo



A taxa observada na folha

Gradient boosting etapa 3 de 3

Acrescenta correções sucessivas ao escore

escore F

0

-1

-2

início


árvore 1

árvore 2

árvore 3

escore somado


só agora vira PD



Só no fim o escore vira probabilidade

Cada informação altera o escore do cliente

Do perfil de referência às diferenças do cliente



Cliente

Perfil de referência: renda R\$ 5.000, comprometimento 30%, relacionamento 12 meses, utilização 40% e sem histórico de atraso. O intercepto vale para esse perfil.

CARACTERÍSTICA	CONTA	
	coeficiente × (valor – referência)	CONTRIBUIÇÃO no escore z
Comprometimento (p.p.)	0,04 × (38 – 30)	+0,320
Histórico de atraso (indicador)	0,80 × (1 – 0)	+0,800
Relacionamento (meses)	–0,02 × (8 – 12)	+0,080
Utilização (p.p.)	0,01 × (65 – 40)	+0,250
Renda (R\$)	–0,00005 × (4500 – 5000)	+0,025
Intercepto (perfil de referência)	–3,50	

$z = -2,025$


O sinal e o tamanho de cada contribuição dependem do coeficiente e da unidade da variável.

Exemplo didático de logit; cálculo próprio

-2,025 não é uma probabilidade


Uma previsão sem restrição pode sair do intervalo entre 0% e 100%

OS ESCORES DOS QUATRO CLIENTES



PRECISAMOS DE UMA TRANSFORMAÇÃO

Em vez de restringir a reta, modelamos uma escala livre e a convertemos por uma função que nunca sai do intervalo. É a curva logística do próximo slide.




A PD precisa permanecer entre 0% e 100%, qualquer que seja o escore.

Exemplo didático de logit; cálculo próprio

UMA RETA DIRETO NA PROBABILIDADE

exemplo do problema

$$p_{\text{reta}} = 0,10 + 0,03 (\text{comp} - 30)$$




Comprometimento

70%

previsão da reta: 130% · fora dos limites de probabilidade

Um escore, uma probabilidade entre 0% e 100%

A curva logística converte qualquer número real em probabilidade



A mesma variação de escore pode gerar mudanças muito diferentes de probabilidade.

Exemplo didático de logit; cálculo próprio

$$p = \frac{1}{1 + e^{-z}}$$

escore z **-2,025**

PD **11,66%**

Leitura: aproximadamente 11,7 eventos em 100 exposições semelhantes, e não uma contagem garantida.

Escore do perfil de Bruno.


Escore z

11,66%

10% de PD significa odds de 1 para 9

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes

FREQUÊNCIA ESPERADA EM 100 EXPOSIÇÕES



10 eventos e 90 não eventos.
Representação ilustrativa, não 100 contratos com resultado garantido.

PROBABILIDADE
10 / 100 = 10%
denominador: 100

ODDS
10 / 90 = 0,1111
denominador: 90

LOG ODDS
 $\ln(0,1111) = -2,197$
É exatamente a escala em que o logit soma as contribuições: o escore z.

Probabilidade de inadimplência
odds 0,1111
Referências

CONVERSÕES NOS DOIS SENTIDOS

$$\text{odds} = \frac{p}{1 - p}$$
$$p = \frac{\text{odds}}{1 + \text{odds}}$$
$$z = \ln\left(\frac{p}{1 - p}\right)$$
$$p = \frac{1}{1 + e^{-z}}$$

Conferência de ida e volta:
partindo de 10,00%, a volta por odds devolve 10,00% e a volta por log odds devolve 10,00%.


Nos limites 0% e 100% o log odds vai a infinito. Por isso a escala vai de 1% a 99%.

Odds comparam eventos e não eventos. Probabilidade compara eventos e total.
Exemplo didático de logit; cálculo próprio

Mais 10 pontos de comprometimento multiplicam as odds por 1,49

O mesmo multiplicador de odds gera mudanças diferentes de PD

$\Delta_{comp} = +10 \text{ p.p.}$ $\Delta z = 0,04 \times 10 = 0,4000$ razão de chances = $e^{0,40} \approx 1,4918$



MUDANÇA APLICADA

Exploração: variação de comprometimento
razão 1,4918

PD INICIAL	ODDS ANTES	ODDS DEPOIS	PD DEPOIS	PD DIFERENÇA p.p.
2%	0,0204	0,0304	2,95%	+0,95 p.p.
10%	0,1111	0,1658	14,22%	+4,22 p.p.
40%	0,6667	0,9945	49,86%	+9,86 p.p.

Razão de chances de 1,49 não significa risco 49% maior.
Odds e probabilidade são escalas diferentes.

Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.

Exemplo didático de logit; cálculo próprio

Bruno: como chegamos à PD de 11,66%?

Duas etapas auditáveis: somar o escore e aplicar a logística

FICHA DO CLIENTE

perfil original

Renda em R\$ por mês

R\$ 4.500

Comprometimento em %

38%

Relacionamento em meses

8 meses

Utilização em %

65%

Histórico de atraso de 15 a 89 dias

Canal: Digital. Informativo: não participa desta fórmula manual.


ETAPA 1: SOMAR O ESCORE		
PARCELA	CONTA	VALOR
Intercepto	perfil de referência	−3,500
Comprometimento	$0,04 \times (38 - 30)$	+0,320
Histórico de atraso	$0,80 \times (1 - 0)$	+0,800
Relacionamento	$-0,02 \times (8 - 12)$	+0,080
Utilização	$0,01 \times (65 - 40)$	+0,250
Renda	$-0,00005 \times (4500 - 5000)$	+0,025
Escore z	soma das parcelas	−2,025

ETAPA 2: APLICAR A LOGÍSTICA

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{2,025}}$$

11,66%

valor sem arredondamento: 0,1166029692




O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.

Exemplo didático de logit; cálculo próprio

O modelo aprende penalizando previsões incompatíveis com os dados

Perda logarítmica de uma observação, em função da probabilidade prevista



$$L = -[y \ln p + (1 - y) \ln(1 - p)]$$

observação **y = 1**
previsão **10,0%**
perda **2,3026**

Probabilidade prevista
perda 2,3026
Desfecho observado

OBSERVAÇÃO	y	p prevista	L
nº 1	0	5%	0,0513
nº 2	0	10%	0,1054
nº 3	0	20%	0,2231
nº 4	0	40%	0,5108
nº 5	1	60%	0,5108
nº 6	1	80%	0,2231


O QUE O AJUSTE MINIMIZA

$$L(\beta) = \frac{1}{n} \sum_{i=1}^n -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

A média das perdas dos 6 contratos, e não a perda de uma observação. Os coeficientes são os que dão o menor valor dela.

Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

O mesmo deslocamento horizontal produz alturas diferentes na sigmoide



$\Delta_{comp} = 10 \text{ p.p.} \Rightarrow \Delta z = 0,04 \times 10 = 0,400$
 $p : 10,00\% \longrightarrow 14,22\% \quad (4,22 \text{ p.p.})$

PD inicial
ou valor livre, de 1% a 60%
+4,22 p.p.
Mudança em comprometimento, em pontos
 $\Delta z = 0,400$

PD INICIAL	VARIAÇÃO EXATA p.p.	APROXIMAÇÃO LOCAL p.p.	DIFERENÇA p.p.
2%	+0,955 p.p.	+0,784 p.p.	−0,171 p.p.
10%	+4,219 p.p.	+3,600 p.p.	−0,619 p.p.
40%	+9,863 p.p.	+9,600 p.p.	−0,263 p.p.

$\frac{\partial p}{\partial_{comp}} = \beta p(1-p) = 0,04 p(1-p)$ em probabilidade por ponto percentual; vale para mudanças pequenas.

A resposta em probabilidade é mais intensa na região central da curva.

Exemplo didático de logit; cálculo próprio

Canal digital não significa duas vezes agência

Categorias entram por comparação com uma referência

REFERÊNCIA ATUAL: AGÊNCIA

extensão pedagógica da fórmula

$$z = -3,50 + 0,30 \, 1[\text{digital}] + 0,60 \, 1[\text{parceiro}]$$


CANAL	INDICADOR DIGITAL	INDICADOR PARCEIRO	CONTRIBUIÇÃO no escore	ESCORE Z	PD
Agência	0	0	0,00	-3,50	2,93%
Digital	1	0	+0,30	-3,20	3,92%
Parceiro	0	1	+0,60	-2,90	5,22%

O QUE 1, 2 E 3 IMPORIA

Usar canal = 1, 2 e 3 em uma única variável imporia que a diferença entre agência e digital é igual à diferença entre digital e parceiro, e que a ordem econômica existe. Nada nos dados garante isso.

O número atribuído a uma categoria não deve inventar uma ordem econômica.

Extensão pedagógica da fórmula manual; cálculo próprio





Canal do cliente

Trocar a referência muda o intercepto e os coeficientes. As três PDs permanecem 2,93%, 3,92% e 5,22% em qualquer parametrização.

O efeito pode se intensificar depois de um limite

Linearidade é nos parâmetros, não na forma das variáveis



$$z = -3,50 + 0,04 (comp - 30) + 0,04 \max(comp - 40, 0)$$

Comprometimento
13,01%

INCLINAÇÃO POR FAIXA	
FAIXA	INCLINAÇÃO NO ESCORE por ponto
comprometimento até 40%	0,04
comprometimento acima de 40%	0,08



No nó, as duas formas coincidem: contribuição 0,400 em ambos os casos. A função é contínua.

A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Cenário separado da fórmula manual; cálculo próprio

O comprometimento pesa igual para quem tem histórico de atraso?

Interação é diferença de inclinação na escala do escore



$$z = -3,50 + 0,80 \text{ hist} + (0,04 + \delta \text{ hist}) (\text{comp} - 30)$$

Comprometimento
termo 0,300



EM COMPROMETIMENTO DE 40%
inclinações **0,04 e 0,07 por ponto**
no escore
diferença no **1,100**
escore
diferença em **+7,61 p.p.**
PD
Mesmo sem interação, a diferença em PD varia com o comprometimento: a sigmoide é não linear.

Com interação, o efeito do comprometimento no escore depende do histórico.

Cenário separado da fórmula manual; cálculo próprio

Coeficientes extremos podem estar aprendendo ruído

Trajetórias de coeficientes e perdas, na grade de penalização efetivamente treinada



AMOSTRA REDUZIDA DO TREINO (600 CONTRATOS)

$$L_{pen} = L + \frac{1}{2C} \sum_j \beta_j^2$$

C e força	0,0100 · 100
log loss treino	0,32275
log loss validação	0,35472
AUC validação	0,7170

Penalização, apenas nos valores treinados

C = 0,0100


Com 600 contratos e a especificação flexível, a perda de treino continua caindo enquanto a de validação sobe. O mínimo de validação ocorre em C = 0,0100, com log loss 0,35472. O teste final não participa desta escolha.

A melhor explicação do treino pode ser sensível demais para funcionar fora dele.

Experimento sintético; semente e versões no notebook

Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Adequação do logit em três situações práticas



SITUAÇÃO

As características somam efeitos de forma estável e as faixas de risco crescem de forma regular.

PERGUNTA DE DIAGNÓSTICO

As curvas de risco por faixa são compatíveis com uma soma de efeitos na escala do escore?

Ação possível. Manter o logit como referência, documentar a especificação e verificar calibração fora do tempo.

FORÇAS

- função compacta e auditável
- interpretação condicionada à codificação
- previsão rápida e fácil de implantar
- regularização e transformações disponíveis

LIMITES

- a forma funcional é escolhida, não descoberta
- variáveis ausentes ou mal medidas continuam ausentes
- extrapolação fora da faixa observada é frágil
- correlação entre atributos dificulta a leitura de um coeficiente

Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exercício: acompanhar a escala do escore e a escala da probabilidade

Bruno

perfil original

Renda

R\$ 4.500

Comprometimento

38%

Relacionamento

8 meses

Utilização

65%

Histórico

sim

Canal

Digital

Uma única alteração: comprometimento de 38% para 48%.

REVISÃO RÁPIDA

A escolha feita aqui é preservada ao voltar.

ESCOLHA UMA ALTERNATIVA

A A PD sobe 10 pontos percentuais.

B O escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.

C A PD é multiplicada por e elevado a 0,40.

Correta.

A variação do escore é $0,04 \times 10 = 0,40$. As odds são multiplicadas por 1,4918 e a PD passa de 11,66% para 16,45%.

1. VARIAÇÃO DA CARACTERÍSTICA

comprometimento passa de 38% para 48%, ou seja $\Delta_{comp} = +10$ pontos

2. VARIAÇÃO DO ESCORE

$\Delta z = 0,04 \times 10 = 0,400$, de $-2,025$ para $-1,625$

3. EFEITO NAS ODDS

odds passam de 0,1320 para 0,1969, multiplicadas por 1,4918


4. NOVA PROBABILIDADE

$p = 1 / (1 + e^{1,625}) = 16,4516\%$, diferença de +4,79 p.p.

Entender o logit exige acompanhar a escala do escore e a escala da probabilidade.
Exemplo didático de logit; cálculo próprio

Houve atraso? Qual é o comprometimento?

Uma árvore organiza a previsão em perguntas sucessivas



As perguntas e seus limites são aprendidos dos dados. Aqui usamos uma árvore pequena para enxergar o mecanismo. As folhas ainda não mostram PD: primeiro a estrutura.

A árvore encaminha clientes semelhantes para uma mesma estimativa de risco.

Árvore didática de 1.000 contratos; cálculo próprio

Ana

Comprometimento **22%**

Histórico **não**

Só estas duas entram nas perguntas desta árvore.

Cliente

PERCURSO


1. A raiz pergunta pelo histórico.
2. Resposta de Ana: hist = 0.
3. Segundo nó: comp ≤ 40%. Chega à folha.

Regra completa da folha: hist = 0 e comp ≤ 40%.

Raiz: primeira pergunta. Nó: qualquer pergunta. Ramo: resposta que leva adiante. Folha: grupo final, onde a previsão é atribuída.

Nesta folha, 18 de 600 contratos ficaram inadimplentes

A PD da folha é a frequência observada no grupo



FOLHA	N	EVENTOS	PD
hist = 0 e comp ≤ 40%	600	18	3%
hist = 0 e comp > 40%	200	22	11%
hist = 1 e comp ≤ 40%	80	12	15%
hist = 1 e comp > 40%	120	48	40%
Soma das folhas	1.000	100	10%

A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.

Árvore didática de 1.000 contratos; cálculo próprio

FOLHA DE ANA

árvore didática

hist = 0 e comp ≤ 40%

$$\hat{p} = \frac{d}{n} = \frac{18}{600} = 3\%$$

3,0%

Barra vermelha: contratos com evento. Barra clara: contratos sem evento.

Cliente

CONFERÊNCIA

As quatro folhas somam 1.000 contratos e 100 eventos, exatamente os totais da raiz.

Mesma folha, mesma previsão: dois clientes com rendas diferentes recebem a mesma PD, porque a renda não participa das perguntas desta árvore.

Qual pergunta separa melhor os comportamentos observados?

Dois candidatos à primeira divisão, a partir da mesma raiz



Histórico de atraso

hist = 0 n = 800 · eventos 40 · taxa 5,00%



hist = 1

n = 200 · eventos 60 · taxa 30,00%



Comprometimento até 40%

comp ≤ 40% n = 680 · eventos 30 · taxa 4,41%



comp > 40%

n = 320 · eventos 70 · taxa 21,88%



EXPLORAÇÃO

Regra de escolha: a divisão escolhida é a de menor impureza ponderada, considerando ao mesmo tempo a mistura de classes em cada lado e o tamanho de cada lado.

O cálculo completo com o índice de Gini vem no próximo slide.

Os dois candidatos partem exatamente da mesma raiz: 1.000 contratos e 100 eventos.

Uma boa divisão cria grupos mais homogêneos segundo a função objetivo.

Árvore didática de 1.000 contratos; cálculo próprio

Histórico reduz o Gini de 0,180 para 0,160

Impureza da raiz, média ponderada dos filhos e ganho

1. IMPUREZA DA RAIZ

$$p = \frac{100}{1.000} = 10\%$$
$$G(\text{raiz}) = 2p(1 - p) = 0,180$$

2. IMPUREZA DE CADA FILHO

$$G_{\text{esq}} = 2p_{\text{esq}}(1 - p_{\text{esq}}) = 0,0950 \quad \text{hist} = 0, \quad p_{\text{esq}} = 5,00\%$$
$$G_{\text{dir}} = 2p_{\text{dir}}(1 - p_{\text{dir}}) = 0,4200 \quad \text{hist} = 1, \quad p_{\text{dir}} = 30,00\%$$

3. PONDERAÇÃO PELO TAMANHO

$$\tilde{G} = \frac{n_{\text{esq}}}{n} G_{\text{esq}} + \frac{n_{\text{dir}}}{n} G_{\text{dir}}$$
$$= \frac{800}{1.000} \cdot 0,0950 + \frac{200}{1.000} \cdot 0,4200$$
$$= 0,160000$$

4. GANHO E COMPARAÇÃO


$$\Delta G = G(\text{raiz}) - \tilde{G} = 0,180 - 0,160000 = 0,020000$$

candidato comprometimento até 40%: $\Delta G = 0,013272$

Não basta uma folha pura: importa como toda a amostra fica depois da divisão.


Árvore didática de 1.000 contratos; cálculo próprio

IMPUREZA BINÁRIA $G = 2p(1 - p)$



Duas folhas com PD de 10%. A evidência é igual?

Intervalo binomial descritivo de Wilson, nominal de 95%



FOLHA	EVENTOS	N	TAXA	INTERVALO DE WILSON
folha pequena	2	20	10,0%	2,8% a 30,1%
folha grande	100	1.000	10,0%	8,3% a 12,0%
folha sem eventos	0	20	0,0%	0,0% a 16,1%

10% em 20 contratos não oferece a mesma precisão que 10% em 1.000.

Pares binomiais ilustrativos; cálculo próprio

LEITURA

amplitude $\propto \sqrt{\hat{p}(1-\hat{p})/n}$ Mesma taxa, evidências diferentes: com 20 contratos a amplitude é 27,3 p.p.; com 1.000, 3,7 p.p..

Tamanho da folha pequena, mantendo a taxa em 10%
2 em 20

RESSALVA


Intervalo binomial descritivo. Não incorpora a escolha adaptativa das folhas.

Uma folha com zero eventos não prova risco zero: o limite superior permanece positivo.

É por isso que a árvore recebe um tamanho mínimo de folha como parâmetro.

O mesmo aumento de comprometimento pode mudar de folha

As regras da árvore dividem o espaço em regiões de previsão constante



Os efeitos dependem do caminho. Dentro de uma folha, a previsão é constante.
Árvore didática de 1.000 contratos; cálculo próprio





A árvore cresce. O resultado fora do treino acompanha?

Profundidade, perda de treino e perda de validação no experimento sintético

EXPERIMENTO AUXILIAR DE DUAS VARIÁVEIS: AS REGIÕES APRENDIDAS

experimento auxiliar, não o modelo completo




Profundidade máxima, apenas nos ajustes executados
4
16 folhas mediana de 366 contratos por folha
treino 0,3434 · validação 0,3496

Uma árvore que memoriza o treino pode produzir probabilidades frágeis fora dele.

Experimento sintético; semente e versões no notebook

Três controles, três formas de conter o excesso de divisões

Profundidade máxima, mínimo de contratos por folha e poda por complexidade




Nomes abreviados nas caixas: comp é comprometimento, hist é histórico, util é utilização, rel é relacionamento. Ramos além do nível mostrado aparecem resumidos. A árvore selecionada tem 24 folhas.

Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

Experimento sintético; semente e versões no notebook

Limita quantas perguntas em sequência a árvore pode fazer. Aqui o mínimo por folha fica fixo em 300 contratos.

Cenário treinado
profundidade 2
4 folhas mediana de 1.916 contratos por folha
validação 0,3619



RÉPLICA A: N° 1

comp ≤ 43,4
n = 16.000
PD 13,2%

sim

não

resumido

n = 13.445

PD 9,6%

resumido

n = 2.555

PD 32,2%

RÉPLICA B: N° 3

hist ≤ 0.5

$n = 16.000$

PD 13,5%

sim

não

resumido

n = 12.970

PD 9,7%

resumido

n = 3.030

PD 30,0%

PD NAS 20 RÉPLICAS

Ana

3,6% a 7,3%

Bruno

14,1% a 29,1%

Carla

13,3% a 19,9%

Diego

58,4% a 67,2%

0% 20% 40% 60%

Réplica A

Réplica B


Mesma complexidade nas 20 réplicas: profundidade 3 e mínimo de 300 contratos por folha.

Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Experimento sintético; semente e versões no notebook

Carla recebe qual PD nesta árvore?

Exercício: percorrer, calcular e questionar



Carla

R\$ 10.000 por mês · comprometimento 48% · relacionamento 60 meses · utilização 85% · histórico não · canal digital

Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

Árvore didática de 1.000 contratos; cálculo próprio

1. INDIQUE O CAMINHO

Caminho correto: Carla tem histórico 0 e comprometimento 48%, acima de 40%.

2. CALCULE A PD DA FOLHA



em porcentagem

Correto: 22 dividido por 200 resulta em 11%.

3. SE A RENDA DE CARLA DOBRASSE, MANTENDO FIXAS AS ENTRADAS USADAS NA ÁRVORE

E se uma árvore pequena ainda deixar estrutura nos erros?

Resíduos agregados por região, no experimento auxiliar de duas variáveis



O QUE SOBRA DEPOIS DA ÁRVORE RASA

regiões com resíduo positivo **13 de 36**
média dessas regiões **0,0567**
média das demais **-0,0325**
validação da árvore rasa **0,2752**

Os resíduos mostrados são do conjunto usado no ajuste desta árvore auxiliar, com duas variáveis. Nenhum resultado do teste participa.

Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos.
Experimento auxiliar de duas variáveis; cálculo próprio

A próxima árvore aprende a partir das previsões atuais

Um ciclo de atualização em quatro passos

novο escore = escore atual + taxa de aprendizagem × contribuição da árvore

$$F_m = F_{m-1} + \eta h_m$$

1. PREVER COM O QUE JÁ EXISTE

$$p = \sigma(F) = \frac{1}{1 + e^{-F}} = \frac{1}{1 + e^{1,3863}} = 20,0000\%$$

A previsão atual do grupo vem do escore acumulado até aqui, na mesma logística do slide 09.

2. CALCULAR A DIREÇÃO DE MELHORIA

$$r = -\frac{\partial L}{\partial F} = y - p = 0 - 0,2000 = -0,2000$$

O resíduo não é escolha de conveniência: para a perda logística do slide 13, o gradiente negativo em relação ao escore é exatamente y menos p. Por isso a técnica se chama gradient boosting.

3. AJUSTAR UMA ÁRVORE PEQUENA AOS R


$$h_1(\text{folha B}) = \bar{r}_B = 0,200000$$

A árvore devolve um número por folha, positivo ou negativo. Não é um voto.

4. ATUALIZAR O ESCORE

$$F_1 = F_0 + \eta h_1 = -1,3863 + 1 \times 0,200000 = -1,1863$$

Só depois de somar todas as contribuições aplicamos a função logística.



Cada árvore responde ao que ainda precisa melhorar na previsão atual.

Miniatura didática de 10 registros; cálculo próprio

Miniatura didática de 10 registros, com taxa de aprendizagem igual a 1 apenas para facilitar a leitura. O registro usado no passo 2 tem y = 0 e pertence ao grupo B.

Dois eventos em dez contratos: começamos em 20%

O melhor preditor constante da perda logarítmica no treino

previsão inicial 20,00% $F_0 = \ln\left(\frac{0,20}{0,80}\right) = -1,3863$ perda média 0,5004

miniatura didática, distinta da base de comparação

GRUPO A

comprometimento 30% · 0 eventos em 5


REGISTRO	y	p ₀	r = y - p ₀
nº 1	0	20,00%	
nº 2	0	20,00%	
nº 3	0	20,00%	
nº 4	0	20,00%	
nº 5	0	20,00%	

GRUPO B

comprometimento 50% · 2 eventos em 5

REGISTRO	y	p ₀	r = y - p ₀
nº 6	0	20,00%	
nº 7	0	20,00%	
nº 8	0	20,00%	
nº 9	1	20,00%	
nº 10	1	20,00%	

PERDA MÉDIA EM FUNÇÃO DA PREVISÃO CONSTANTE



Previsão constante

perda 0,5004

A curva é calculada diretamente com os dez rótulos, sem treinar biblioteca alguma. O mínimo ocorre na média empírica de y, igual a 20%.

Antes de usar características, a taxa observada fornece o ponto de partida do exemplo.

Miniatura didática de 10 registros; cálculo próprio

A primeira correção reduz A e aumenta B

Resíduos, média por folha e atualização do escore

OS DEZ REGISTROS						primeira ordem didática	
REGISTRO	GRUPO	y	p _{atual}	r = y - p	h(folha)	F _{novo}	p _{novo}
nº 1	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 2	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 3	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 4	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 5	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 6	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 7	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 8	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 9	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%
nº 10	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%

destacar um registro:

A ÁRVORE AJUSTADA AOS RESÍDUOS



POR GRUPO	A	B
escore inicial	-1,386294	-1,386294
contribuição da árvore	-0,200000	+0,200000
escore novo	-1,586294	-1,186294
PD	16,9906%	23,3922%

A árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha.


Miniatura didática de 10 registros; cálculo próprio

A primeira árvore mudou as previsões. Agora mudam os gradientes

A segunda correção é recalculada depois da primeira


OS MESMOS DEZ REGISTROS

REGISTRO	GRUPO	Y	P0	R0	P1	R1	F2	P2
nº 1	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%
nº 2	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%
nº 3	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%
nº 4	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%
nº 5	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%
nº 6	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%
nº 7	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%
nº 8	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%
nº 9	B	1	20,00%	0,8000	23,3922%	0,766078	-1,020217	26,4985%
nº 10	B	1	20,00%	0,8000	23,3922%	0,766078	-1,020217	26,4985%



No grupo B, o resíduo de quem teve evento caiu de 0,8 para 0,766078 e o de quem não teve ficou mais negativo, de -0,2 para -0,233922.

A SEGUNDA ÁRVORE




A exposição principal para em duas iterações. A correção média do grupo B continua positiva, mas caiu de 0,200000 para 0,166078.

A próxima correção é recalculada depois da anterior. Ela não repete mecanicamente o mesmo passo.

Miniatura didática de 10 registros; cálculo próprio

Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Somamos contribuições no escore e só então calculamos a probabilidade



$$F = -1,020217 \quad p = \sigma(F) = 26,4985\%$$

grupo A chegaria a -1,756200 e PD 14,7267%

SOLICITANTE NOVO

sem desfecho conhecido

Comprometimento do solicitante

grupo B · Diego

Nenhum campo de desfecho aparece nesta ficha: o y foi usado apenas no treinamento. Trocar η não reescala o resultado, porque os resíduos da segunda árvore são recalculados sobre o escore já atualizado pela primeira.

árvore 1

+0,200000

comprometimento 50% é maior que 40, portanto folha do grupo B

árvore 2

+0,166078

comprometimento 50% é maior que 40, portanto folha do grupo B




Para prever, o cliente percorre as árvores já aprendidas. Não precisamos conhecer seu desfecho.

Miniatura didática de 10 registros; cálculo próprio

Learning rate e número de árvores precisam ser escolhidos juntos

Trajetórias de perda treinadas com cada taxa, no experimento sintético



$$F_m = F_{m-1} + \eta h_m$$

taxa de aprendizagem	0,10
árvores usadas	106
log loss de validação	0,34460
melhor iteração desta taxa	106 com 0,34460

Taxa de aprendizagem treinada

Número de árvores, apenas em iterações calculadas

106 árvores · 0,34460


PD com 105 árvores: **Ana 5,00%** **Bruno 23,35%** **Carla 17,60%** **Diego 61,05%**
Trajetórias calculadas a cada cinco iterações e registradas no notebook.

Mudar o passo altera previsões, gradientes e, portanto, o que as próximas árvores aprendem.
Experimento sintético; semente e versões no notebook

Uma correção pode depender de uma característica ou da combinação de várias

Profundidade de cada árvore no experimento auxiliar de duas variáveis
MESMA ESCALA E MESMO DOMÍNIO NOS TRÊS PAINÉIS

experimento auxiliar de duas variáveis



escala de PD prevista 0% 60%

A regra do canto alto e alto: se comprometimento acima de 40% e utilização acima de 50%, o risco sobe mais do que a soma dos dois efeitos isolados. Taxa 0,1 e 150 árvores nos três painéis; muda apenas a profundidade.


Muitas regras simples somadas não são sempre equivalentes a regras que combinam condições.
Experimento auxiliar de duas variáveis; cálculo próprio

Cliente sintético: comprometimento 65%, utilização 80%, PD 46,66% na profundidade 1.

Comprometimento
65%
Utilização
80%

Continuar melhorando o treino pode deixar de ajudar a validação

Regra de parada com tolerância e paciência, definida antes de olhar o teste



REGRA DEFINIDA ANTES DE TREINAR
máximo de 300 iterações · tolerância 0,000100
· paciência 20 · escolha na validação fora do tempo

300 de 300 iterações reveladas · melhor validação até aqui 0,34467 · paciência 203 de 20
Curvas calculadas no notebook, reveladas em lotes de 20 iterações.

MELHOR ITERAÇÃO E ITERAÇÃO DE PARADA
Melhor iteração na validação: 106, com log loss 0,34460. A paciência encerraria em 89, depois do mínimo. O modelo servido é o da melhor iteração.
A curva do teste não aparece em nenhum seletor.

A melhor iteração é escolhida usando uma amostra destinada a essa escolha.
Experimento sintético; semente e versões no notebook

Mais flexibilidade exige mais disciplina de validação

Quatro situações, a pergunta de diagnóstico e a evidência que a responde

SINAL APROXIMADAMENTE ADITIVO

As características contribuem de forma estável e quase somável na escala do escore.

cuidado: Complexidade sem ganho é custo de manutenção sem retorno.

INTERAÇÕES RELEVANTES

O risco depende de combinações de condições, como comprometimento alto junto de utilização alta.

cuidado: Encontrar interação no treino é fácil. Reproduzir a interação fora do tempo é o teste.

O QUE VERIFICAR EM SINAL APROXIMADAMENTE ADITIVO

O boosting ganha da especificação linear bem construída, fora do tempo?

Qual evidência aceitar. Aceitar apenas ganho que persiste na validação fora do tempo contra um logit com transformações e interações plausíveis. Se o ganho não persiste, o logit basta.

POUCOS EVENTOS

Volume pequeno de inadimplências, faixas finas e estimativas instáveis.

cuidado: Flexibilidade com poucos eventos costuma ajustar ruído.

MUDANÇA DE POPULAÇÃO

A composição dos solicitantes muda ao longo do tempo.

cuidado: Nenhum algoritmo corrige sozinho mudança de população.

SENSIBILIDADE JÁ CALCULADA

validação, não o teste

MODELO	AUC VALIDAÇÃO	LOG LOSS VALIDAÇÃO
Logit regularizado	0,7379	0,34299
Logit flexível	0,7385	0,34395
Gradient boosting	0,7366	0,34460

Neste experimento os três ficam próximos na validação. Isso é o resultado observado aqui, não uma generalização de mercado.

GANHOS POSSÍVEIS

- relações não lineares sem especificação manual
- interações capturadas pela profundidade das árvores
- boa adaptação a dados tabulares com muitas colunas


CUSTOS

- ajuste de hiperparâmetros e orçamento de busca
- explicação menos direta que um coeficiente
- risco de sobreajuste quando a validação é frouxa
- manutenção, versionamento e verificação de calibração

Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.
Síntese conceitual, com um resultado calculado como exemplo

O que o modelo usa em geral? O que pesou para Bruno?

Importância global por permutação e contribuição local no escore



Uma variável importante na carteira não precisa ser o principal fator da previsão de todo cliente.

Experimento sintético; semente e versões no notebook

Carla caiu no grupo B. Qual é a previsão?

Exercício: somar em escore e converter uma única vez

O QUE JÁ SABEMOS	
cliente	Carla, comp 48% · grupo B
escore inicial F0	-1,386294
folha da árvore 1	+0,200000
folha da árvore 2	+0,166078
taxa de aprendizagem	1
PD final	26,4985%

PERGUNTA DE INTERPRETAÇÃO

Uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real?

Não. A contribuição explica a função preditiva aprendida com registros históricos. Ela não identifica o efeito de uma intervenção sobre o cadastro.


ESCOLHA O MÉTODO CORRETO

A Somar como pontos percentuais: 20% mais 20% mais 16,6078%.

B Somar ao escore e aplicar a função logística uma única vez.

C Tirar a média das duas folhas.

Correta. Escore final -1,386294 mais 0,200000 mais 0,166078 é igual a -1,020217. Aplicando a logística, PD de 26,4985%.



Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

Miniatura didática de 10 registros; cálculo próprio

Estamos comparando modelos ou comparando condições diferentes?

O protocolo precede qualquer métrica

CONDIÇÃO	LOGIT REGULARIZADO	ÁRVORE CONTROLADA	GRADIENT BOOSTING
Amostra e alvo mesmas coortes, mesmo evento e mesmo horizonte de 12 meses	comum		
Informação disponível as seis características, com a mesma regra de disponibilidade	comum		
Pré processamento tratamento próprio é permitido, sem vantagem de informação	padronização, mais a imputação comum	imputação pela mediana do treino e indicadores de ausência	
Escolha de complexidade sempre pela perda na validação fora do tempo	grade de penalização L2	profundidade, mínimo por folha e poda	taxa, profundidade e número de árvores
Avaliação final uma única passagem, com regras definidas antes	teste congelado		

DETECTAR COMPARAÇÃO INJUSTA

METADADOS DAS PARTIÇÕES

treino

jan/2018 a dez/2019 · n = 16.000 · 2.124 eventos · alvo completo em dez/2020

validação

jan/2021 a jun/2021 · n = 4.000 · 522 eventos · alvo completo em jun/2022

calibração e política

ago/2022 a dez/2022 · n = 3.000 · 464 eventos · alvo completo em dez/2023

teste

fev/2024 a jul/2024 · n = 5.000 · 712 eventos · alvo completo em jul/2025

semente 20.260.920 · numpy 2.4.6 · sklearn 1.9.1 · python 3.11.15

sha256 do arquivo de resultados: 819746e8a01e72c2e9974080...




Mesmo alvo, mesma informação e teste preservado são condições da comparação.
Experimento sintético; semente e versões no notebook

Quem aparece primeiro na fila de risco?

AUC contada por pares e curvas do experimento sintético

modelo teste, 5.000 contratos de fev a jul de 2024



AUC 0,7444 KS 0,3769 n = 5.000 contratos, 712 eventos



Mudar o corte não altera a AUC. A taxa de falsos positivos do eixo não é a inadimplência da carteira aprovada.

Um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada.

Microexemplo de ranking e experimento sintético, em abas identificadas

Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?

Média prevista contra frequência observada, faixa a faixa



FAIXA	N	EVENTOS	PREVISTA	OBSERVADA	WILSON
1	500	13	3,71%	2,60%	1,5% a 4,4%
2	501	25	5,40%	4,99%	3,4% a 7,3%
3	504	31	6,70%	6,15%	4,4% a 8,6%
4	495	50	7,98%	10,10%	7,7% a 13,1%
5	500	42	9,46%	8,40%	6,3% a 11,2%
6	500	50	11,17%	10,00%	7,7% a 12,9%
7	503	59	13,16%	11,73%	9,2% a 14,8%
8	497	105	16,24%	21,13%	17,8% a 24,9%
9	500	114	22,89%	22,80%	19,3% a 26,7%
10	500	223	46,40%	44,60%	40,3% a 49,0%

PREVISÕES ORIGINAIS

AUC
 0,744367

Brier
 0,10676

log loss
 0,35694

PD média prevista
 14,31%

taxa observada
 14,24%

Modelo

Versão das previsões


$\text{odds} \times 2 \iff z + \ln 2$: deslocamento constante no log odds não troca ninguém de lugar na fila, então a AUC permanece 0,744367. Brier e log loss mudam.

Calibrar é verificar a escala das probabilidades, não apenas a ordem dos clientes.

Experimento sintético; semente e versões no notebook



Até qual PD vamos aprovar?

O corte define quem entra na carteira e o que se observa depois



NO CORTE DE 20,0%	
partição de política	
aprovados	2.372 de 3.000
taxa de aprovação	79,1%
eventos entre aprovados	236
inadimplência entre aprovados	9,95%
PD média dos aprovados	9,86%

Corte de aprovação	
aprovação	79,1%




A mesma previsão pode sustentar políticas diferentes. A política é uma decisão adicional ao modelo.
Experimento sintético; semente e versões no notebook

A política é definida nesta partição, antes de qualquer olhar ao teste.

Com estas hipóteses, o equilíbrio ocorre em PD de 20%

Aproximação didática por operação, horizonte de 12 meses



HIPÓTESES

aproximação didática, 12 meses


$$E[\text{resultado}] = m - p \text{ LGD EAD} \quad p^* = \frac{m}{\text{LGD EAD}} = 20\%$$

margem antes da perda	R\$ 1.200
EAD	R\$ 10.000
LGD	60%
perda esperada	R\$ 600
resultado esperado	R\$ 600

PD do contrato

R\$ 600

MARGEM MENOS PERDA ESPERADA




Um bom ranking só gera valor quando probabilidades e política se conectam à economia da operação.

Economia didática declarada na tela; cálculo próprio

O que conseguimos monitorar agora? O que exige esperar?

Indicadores imediatos e indicadores que dependem da maturação do alvo



Data de observação

jul/2025

41 coortes com alvo completo nesta data.

CENÁRIOS SINTÉTICOS

Os dois primeiros indicadores de cada cenário aparecem no dia seguinte à contratação. Inadimplência, calibração e discriminação só existem depois dos 12 meses de maturação.

INDICADORES IMEDIATOS

comprometimento médio da coorte mais recente	35,5%
utilização média	45,8%
ausência de utilização	4,6%
taxa de aprovação no corte congelado	77,2%
PD média prevista	16,57%

INDICADORES COM ALVO MATURADO

inadimplência da coorte mais recente já maturada	14,63%
coorte correspondente	jul/2024
coortes já maturadas	41 de 41

Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

Experimento sintético; semente e versões no notebook

Defenda sua recomendação para o comitê

Desempenho, economia, estabilidade e capacidade de execução na mesma mesa

TESTE DE FEV A JUL DE 2024, 5.000 CONTRATOS E 712 EVENTOS			
base sintética			
EVIDÊNCIA NO TESTE	LOGIT	ÁRVORE	BOOSTING
AUC	0,7446	0,7392	0,7444
Brier, qualidade probabilística	0,10670	0,10823	0,10707
Taxa de aprovação	74,8%	77,7%	79,4%
Inadimplência entre aprovados	8,50%	9,32%	9,22%
Resultado por aprovado	R\$ 690	R\$ 641	R\$ 647
Resultado total da carteira	R\$ 2.578.800	R\$ 2.487.600	R\$ 2.565.600
Política congelada antes do teste: aprovar quando a PD calibrada não passa de 20%, que é o ponto de equilíbrio econômico do slide 47.			

Modelo candidato	Política
Restrição	
Sem restrição adicional declarada.	

ARGUMENTOS QUE A EVIDÊNCIA SUSTENTA

- A maior AUC no teste é de Logit, com 0,7446. A diferença para o menor é de 0,0054, pequena diante da variabilidade de uma única amostra.
- O maior resultado total sob a política escolhida é de Logit, com R\$ 2.578.800 em 3.739 aprovados.
- Aprovação e inadimplência entre aprovados mudam junto com o modelo: comparar apenas AUC esconde a diferença de volume.
- Manter o logit como referência operacional e avaliar outro método como desafiante é uma recomendação defensável, se a evidência sustentar.
- Nenhum resultado aqui autoriza reajustar o modelo neste mesmo teste e chamar a nova medida de avaliação independente.

SUA JUSTIFICATIVA

Por que este modelo e esta política?

Qual é o principal risco desta escolha?

Como monitorar depois da implantação?

O texto fica apenas neste dispositivo.

Uma recomendação precisa combinar desempenho, economia, estabilidade e capacidade de execução.
 Experimento sintético; semente e versões no notebook

Você consegue explicar, comparar e usar os três modelos?

Definir, estimar, validar e decidir são etapas conectadas

TÉCNICA	COMO CONSTRÓI A PD	PRINCIPAL CUIDADO	EVIDÊNCIA NECESSÁRIA
Regressão logística	soma funções das características em um escore e converte pela logística	especificação, unidade das variáveis e leitura dos coeficientes	validação da forma funcional e calibração fora do tempo
Árvore de decisão	aprende regras sucessivas e usa a frequência observada na folha	complexidade, tamanho de folha e instabilidade entre amostras	desempenho fora do tempo e estabilidade entre reamostragens
Gradient boosting	acrescenta contribuições sucessivas ao escore e converte no fim	trajetória de ajuste, complexidade de cada árvore e explicação	curva de validação, parada definida antes e verificação de calibração

Para os três: informação disponível na decisão, validação temporal, calibração das probabilidades e conexão com a decisão econômica.

OS MESMOS QUATRO CLIENTES DO COMEÇO				
as três PDs e a decisão no corte de 20%				
CLIENTE	LOGIT PD calibrada	ÁRVORE PD calibrada	BOOSTING PD calibrada	NO CORTE DE 20%
Ana	3,06%	5,62%	5,49%	aprovado nos três
Bruno	35,09%	24,00%	25,78%	recusado nos três
Carla	14,21%	17,80%	19,56%	aprovado nos três
Diego	68,51%	60,61%	64,91%	recusado nos três

TRÊS PERGUNTAS DE RECUPERAÇÃO

Odds multiplicadas por 2 significam PD multiplicada por 2?
Não. Odds e probabilidade são escalas diferentes: com odds dobradas, 10% vira 18,18% e 40% vira 57,14%.

A mesma folha pode conter clientes diferentes?
Sim. A folha agrupa todos os contratos que satisfazem as mesmas regras, e atribui a mesma previsão a todos eles.

As árvores do boosting somam probabilidades?
Não. A soma acontece no escore F, e a transformação logística é aplicada uma única vez no final.

APLICAR NO MEU TRABALHO

1. Alvo: qual evento, em qual horizonte e para qual população elegível.

2. Dados: o que existia e estava acessível na data da decisão.

3. Referência: um modelo simples bem especificado, que os demais precisam superar.

4. Protocolo: partições por data, maturação do alvo e regras congeladas antes do teste.

5. Comparação: mesmo conjunto de informação, mesma métrica e incerteza declarada.

6. Decisão: corte, economia da operação e plano de monitoramento com responsável.

Leve os seis passos para a sua carteira. A conclusão da aula está na linha de fechamento, abaixo.

Apêndice: notas do professor e respostas

Mesma ordem dos slides. Cada bloco traz condução, respostas, cuidados e transição.

01 · Você aprovaria estes quatro clientes?

Esquema conceitual; sem dados

CONDUÇÃO EM AULA

- Peça 20 segundos de avaliação silenciosa e registre uma opinião por perfil.
- Pergunte por que Carla, com a maior renda da mesa, ainda poderia exigir investigação.
- Se alguém pedir taxa, prazo e custos, reconheça que faltam elementos da política econômica. A conta aparece no slide 47.

CUIDADOS E LIMITES

- A seleção representa apenas a escolha neste dispositivo. Não existe contagem de turma nem resultado coletivo.
- Nenhuma proposta tem desfecho conhecido. Não atribua valor moral à renda nem ao nome do cliente.
- Um cliente de maior risco ainda pode ser economicamente aceitável sob certas condições. Cobrar mais não resolve qualquer risco.

TRANSIÇÃO

Antes de escolher uma técnica, precisamos conhecer os mesmos clientes e definir exatamente o que vamos prever.

02 · O que sabemos no momento da proposta?

Esquema conceitual; sem dados

CONDUÇÃO EM AULA

- Compare primeiro a renda de Carla e a de Bruno. Depois revele comprometimento e utilização.
- Contraste relacionamento e histórico por último.
- Pergunte: qual combinação parece mais informativa que uma variável isolada? Aceite hipóteses diferentes.

CUIDADOS E LIMITES

- Canal não é efeito causal nem evidência de qualidade moral. Uma variável útil para previsão pode refletir seleção.
- Comprometimento é a parcela total mensal já incluindo a nova operação, dividida pela renda verificada.
- Histórico registra atraso de 15 a 89 dias no passado. Não é inadimplência corrente.
- As unidades serão preservadas em toda a aula, especialmente percentual contra fração.

TRANSIÇÃO

Conhecer os atributos não basta: o que significa exatamente risco nesta aula?

03 · Probabilidade de quê, para quem e até quando?

Trajetórias ilustrativas de contratos fictícios; cálculo próprio

CONDUÇÃO EM AULA

- Peça a classificação do contrato C antes de mostrar o status.
- Separe explicitamente ainda não aconteceu de não acontecerá dentro da janela.
- Leve o controle até o mês 12 e consolide os três elementos: população elegível, evento e horizonte.

RESPOSTAS

- A atinge 95 dias no mês 8, portanto $y = 1$.
- B fecha os 12 meses com máximo de 88 dias, portanto $y = 0$.
- C tem apenas 6 meses observados e nenhum evento: alvo incompleto, nunca $y = 0$.
- Chegar exatamente a 90 dias não satisfaz superior a 90 dias. No mês 7 o contrato A ainda não tem evento.

CUIDADOS E LIMITES

- Esta é uma definição operacional didática. Não é transcrição de norma bancária.
- Mudar o limite de atraso ou o horizonte muda o alvo previsto, e portanto muda o modelo.

TRANSIÇÃO

Agora sabemos o que prever. Precisamos garantir que os dados usados para prever existiam antes do resultado.

04 · Esse dado existia quando o crédito foi aprovado?

Registros didáticos de disponibilidade; cálculo próprio

CONDUÇÃO EM AULA

- Classifique primeiro as três fáceis: renda verificada, histórico anterior e utilização conhecida.
- Use o atraso máximo dos 12 meses seguintes para estabelecer a regra.
- Termine com a consulta tardia de bureau: a informação pode descrever algo anterior, mas o acesso e a versão precisam existir na decisão.

RESPOSTAS

- Renda verificada, histórico anterior, utilização conhecida na data e comprometimento com a parcela proposta estão disponíveis na decisão.
- Valor renegociado três meses depois, atraso máximo dos 12 meses seguintes e consulta de bureau posterior à inadimplência são informação do futuro.
- O comprometimento com a parcela proposta é permitido porque a parcela é conhecida na simulação, e não depende de observar o desfecho.

CUIDADOS E LIMITES

- Data de referência e data de disponibilidade são coisas diferentes.
- Limpeza, imputação, seleção de variáveis e normalização também vazam informação se aprenderem com o teste.

TRANSIÇÃO

Além de separar passado e futuro dentro de cada proposta, precisamos separar as amostras usadas para aprender e avaliar.

05 · Aprender no passado, escolher sem olhar o teste

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Peça que o aluno aponte a diferença entre o fim das contratações e o fim da observação.
- Pergunte: podemos escolher o corte depois de ver os resultados finais? Revele que o teste avalia escolhas congeladas.
- Datas completas ficam aqui nas notas; a projeção mostra apenas os anos.

RESPOSTAS

- Treino: contratações de jan/2018 a dez/2019, alvo completo em dez/2020.
- Validação de ajuste: jan a jun/2021, alvo completo em jun/2022.
- Calibração e política: ago a dez/2022, alvo completo em dez/2023.
- Teste final: fev a jul/2024, alvo completo em jul/2025.

CUIDADOS E LIMITES

- Os espaços entre coortes tornam a maturação visível. Não são uma recomendação universal de desenho operacional.
- Divisão aleatória não é sempre inválida. Ela apenas não testa a generalização temporal buscada aqui.
- O modelo base é congelado antes da calibração, e a política antes do teste.

TRANSIÇÃO

Agora temos regras de comparação. Como cada técnica transforma os mesmos dados em uma PD?

06 · O mesmo cliente, três formas de aprender o risco

Esquema conceitual; sem dados

CONDUÇÃO EM AULA

- Passe rapidamente pelos três mecanismos, sem fórmulas.
- Pergunte qual parece mais fácil de explicar e se isso basta para escolher.
- Termine selecionando logit, que abre o próximo bloco.

CUIDADOS E LIMITES

- A árvore não é um conjunto de regras definidas pelo gestor: a estrutura é aprendida dos dados, embora o gestor imponha limites.
- Boosting não é votação majoritária nem soma de probabilidades.
- O logit não é incapaz de representar não linearidades.
- Nenhum painel traz PD de modelo: aqui só existe o mecanismo.

TRANSIÇÃO

Vamos começar pela ideia mais familiar: combinar características em um escore e converter esse escore em probabilidade.

07 · Cada informação altera o escore do cliente

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Comece no perfil de referência: renda R\$ 5.000, comprometimento 30%, relacionamento 12 meses, utilização 40% e sem histórico de atraso.
- Acrescente comprometimento e histórico. Pergunte qual teve maior contribuição neste cliente.
- Mostre que um coeficiente pequeno pode gerar efeito relevante quando a variável muda muito.
- Revele z e pergunte se esse número já é uma probabilidade.

CUIDADOS E LIMITES

- A contribuição exibida é relativa à codificação de referência escolhida. Não é decomposição causal nem medida universal de importância.
- Coeficiente e contribuição observada são coisas diferentes: a contribuição multiplica o coeficiente pelo desvio da variável.
- Centrar as variáveis facilita a interpretação do intercepto e não muda a classe de funções.

APROFUNDAMENTO

- Os números desta tela e os do capítulo 4 são de dois exemplos, não de dois modelos rivais. Aqui o escore usa seis variáveis na forma centrada, com intercepto −3,50 e comprometimento pesando 0,40 a cada 10 pontos, o que dá razão de chances 1,49. As páginas do capítulo usam duas variáveis na forma crua, com intercepto −5,6666 e utilização pesando 0,7453 a cada 10 pontos, razão de chances 2,11. O mecanismo é o mesmo; os números são de exemplos diferentes, e nenhum se converte no outro trocando de unidade.
- Material original, capítulo 4, página 13: o intercepto é âncora de nível, não coeficiente comum. Naquele exemplo, utilização zero e atraso zero não existem na carteira, então o intercepto não tem leitura como PD de um cliente real.
- Trocar o intercepto desloca a PD de todas as propostas e preserva a ordem de risco. É por isso que recalibrar um modelo cuja ordenação continua boa equivale a reestimar o nível, sem alterar a AUC. O mesmo fato aparece no slide 45.

TRANSIÇÃO

O escore pode ser qualquer número. Como converter esse escore em algo entre zero e um?

08 · −2,025 não é uma probabilidade

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Peça que o aluno calcule a reta simplificada em comprometimento de 20%.
- Revele o resultado negativo, leve o controle até 70% e mostre o excesso acima de 100%.
- Volte a Bruno e lembre que o escore dele não foi definido como probabilidade.

CUIDADOS E LIMITES

- A reta usada aqui existe para mostrar o problema. Não é modelo estimado.
- Não conclua que todo modelo linear de probabilidade é inútil. A mensagem é a dificuldade de garantir limites.
- Truncar em 0 e 1 altera a função de forma improvisada e não substitui um modelo probabilístico.

TRANSIÇÃO

A função logística faz exatamente essa conversão, preservando a ordem dos escores.

09 · Um escore, uma probabilidade entre 0% e 100%

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Comece em Bruno. Vá até $z = 0$ e pergunte o valor esperado antes de revelar.
- Compare o efeito de somar 1 ao escore em $z = -5$ e em $z = 0$.
- Termine em Ana e Bruno para mostrar que a função preserva a ordem dos escores.

CUIDADOS E LIMITES

- A sigmoide é estritamente crescente: a ordem de z e a ordem de p são a mesma.
- Um escore finito nunca produz exatamente 0 ou 1. A formatação pode arredondar para 0,00%, o que não significa impossibilidade.
- O ponto de 50% é referência matemática, não corte de aprovação.

APROFUNDAMENTO

- Material original, capítulo 4, página 6: probabilidade, odds, log odds e escore de bureau são quatro réguas da mesma ordem. Lá, PD de 5% corresponde a odds 0,053, log odds $-2,944$ e escore didático 865.
- Qualquer transformação monótona preserva a ordenação e, portanto, a AUC. O que muda é a régua de comunicação e de cálculo.

TRANSIÇÃO

Para interpretar os coeficientes, precisamos entender a escala em que a soma foi feita: o logaritmo das odds.

10 · 10% de PD significa odds de 1 para 9

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte 10 dividido por quê antes de revelar as odds.
- Mostre que trocar o denominador muda o conceito: 10 em 100 contra 10 para 90.
- Vá a 50% e depois a 20%. Termine lembrando que o escore z do logit é o log odds.

RESPOSTAS

- $p = 50\%$: odds 1 e log odds 0.
- $p = 20\%$: odds 0,25 e log odds aproximadamente $-1,386$.
- $p = 10\%$: odds 1/9 aproximadamente 0,1111 e log odds aproximadamente $-2,197$.

CUIDADOS E LIMITES

- Odds não são outra porcentagem de risco. Podem passar de 1 e não se limitam a 100%.
- Uma razão escrita 1 para 9 é diferente do número decimal 0,1111 apenas na forma de escrever.
- Em p igual a 0 ou 1 o log odds vai a infinito. Por isso a entrada principal vai de 1% a 99%.

TRANSIÇÃO

Agora conseguimos interpretar o que acontece quando um coeficiente aumenta o log odds.

11 · Mais 10 pontos de comprometimento multiplicam as odds por 1,49

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Peça que os alunos antecipem a PD quando as odds dobram, começando pelo cenário de 10%.
- Revele primeiro 10%, depois 2% e 40%.
- Explique que a leitura vale mantidas as outras variáveis do modelo.

RESPOSTAS

- Com odds multiplicadas por 2: 2% vira aproximadamente 3,92%; 10% vira 18,18%; 40% vira 57,14%.
- Com mais 10 pontos de comprometimento, o multiplicador é e elevado a 0,40, aproximadamente 1,4918.

CUIDADOS E LIMITES

- Razão de chances de 1,49 não significa que o risco aumenta 49%.
- Para uma mudança finita use a conversão exata, não o efeito marginal local.
- A leitura é associativa e condicionada às demais variáveis. Não é efeito causal.
- Os três riscos iniciais são cenários didáticos. Não são os quatro clientes.

APROFUNDAMENTO

- Material original, capítulo 4, página 11: naquele exemplo, utilização a cada 10 pontos tem razão de chances 2,1071 e atraso a cada 10 dias tem 4,0370. A leitura está correta como multiplicação das chances e não autoriza leitura causal.
- Página 14 do mesmo capítulo: trocar a unidade muda o coeficiente e não muda o modelo. A utilização vale 0,74530 por dezena de pontos, 0,07453 por ponto e 7,45300 por fração do limite, com PD prevista idêntica nos três casos.
- Disso decorre que comparar 1,3955 com 0,7453 para dizer qual variável pesa mais não significa nada: as unidades são diferentes. A comparação legítima usa um movimento realista de cada variável, como um desvio padrão, que é o que o slide 18 faz com coeficientes padronizados.

TRANSIÇÃO

Vamos aplicar essa interpretação a um cliente completo e conferir todas as etapas da conta.

12 · Bruno: como chegamos à PD de 11,66%?

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Reconstrua a conta passo a passo antes de mexer nos controles.
- Peça uma alteração que reduza a PD e outra que a aumente.
- Questione se a alteração seria factível: reduzir comprometimento sem mudar parcela ou renda é uma simulação abstrata.

RESPOSTAS

- Ana 1,10%, Bruno 11,66%, Carla 2,82% e Diego 27,59%, com a fórmula manual.
- O recurso descreve a sensibilidade do modelo, não a garantia de uma ação causal disponível ao cliente.

CUIDADOS E LIMITES

- Canal aparece na ficha e não participa desta fórmula manual.
- Esta PD é do exemplo didático. Não é previsão de modelo treinado.

TRANSIÇÃO

Esses coeficientes foram escolhidos para tornar a conta transparente. Como um modelo aprende coeficientes a partir dos dados?

13 · O modelo aprende penalizando previsões incompatíveis com os dados

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Escolha $y = 1$ com $p = 10\%$ e depois aumente p até 90% .
- Troque y para 0 mantendo $p = 90\%$ e pergunte por que a penalização aumenta.
- Mostre que uma observação não define sozinha os coeficientes: a perda total agrega todos os casos.

RESPOSTAS

- Para $y = 1$: $p = 0,10$ gera perda aproximadamente $2,3026$; $p = 0,90$ gera aproximadamente $0,1054$.
- Para $y = 0$ a relação se inverte: $p = 0,90$ gera aproximadamente $2,3026$.
- Minimizar a log loss equivale a maximizar a verossimilhança do modelo logístico.

CUIDADOS E LIMITES

- Classificar corretamente a partir de um corte não basta para medir a qualidade da probabilidade.
- A perda depende do grau de confiança, não apenas do lado do corte.
- A função objetivo do treino não garante o melhor desempenho futuro.
- Em p igual a 0 ou 1 a perda vai a infinito. As curvas são desenhadas entre $0,1\%$ e $99,9\%$.

APROFUNDAMENTO

- Material original, capítulo 4, páginas 15 a 17: a perda de cada observação determina os coeficientes, e a descida de gradiente percorre os parâmetros uma iteração por vez até a convergência.
- Nesta aula a descida aparece no bloco de boosting, slides 32 a 35, com a mesma mecânica de resíduo, passo e atualização do escore.
- Página 18 do original: navegador, Python com a mesma regra e sklearn chegam ao mesmo resultado, com diferença máxima de $0,000327$ no intercepto. A conferência equivalente aqui está nos metadados do slide 43 e no notebook.

TRANSIÇÃO

Mesmo com um coeficiente fixo, o efeito observado na PD muda ao longo da curva logística.

14 · Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Comece pelos três segmentos, todos com a mesma largura horizontal, e peça que comparem as alturas.
- Revele os valores e só então a derivada.
- Reduza a mudança para 1 ponto e mostre a aproximação local ficando mais próxima.

RESPOSTAS

- O efeito máximo da derivada da logística ocorre em p igual a $0,5$. Isso é matemática, não recomendação de operar perto de 50% de PD.
- A derivada é aproximação para mudanças pequenas. Para 10 pontos de comprometimento, use a conversão exata.

CUIDADOS E LIMITES

- A variação de z continua sendo o coeficiente vezes a variação da variável.
- Valores em pontos percentuais não podem ser lidos em unidade de odds.
- Em variação zero, os dois métodos dão exatamente zero.

TRANSIÇÃO

Até aqui usamos variáveis numéricas e um indicador. Como incluir uma característica com várias categorias?

15 · Canal digital não significa duas vezes agência

Extensão pedagógica da fórmula manual; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte o que ficaria implícito ao usar canal igual a 1, 2 e 3 diretamente.
- Mostre a tabela de indicadores e só então troque a referência.
- Use o momento para separar interpretação de coeficientes e previsão do modelo.

RESPOSTAS

- Com agência como referência: digital soma 0,30 e parceiro soma 0,60 ao escore.
- Com digital como referência: intercepto passa a −3,20, agência recebe −0,30 e parceiro +0,30. As PDs por categoria não mudam.
- Categoria omitida não é categoria ausente: ela está no intercepto.

CUIDADOS E LIMITES

- Este é um exemplo separado, que não altera a fórmula canônica dos slides 07 a 14 nem as PDs dos quatro clientes.
- Uma categoria nova em produção exige tratamento definido na codificação. Não invente coeficiente.
- Canal pode refletir seleção, não causalidade.
- Manter todas as indicadoras junto com o intercepto cria redundância na parametrização.

TRANSIÇÃO

A codificação determina a forma que o modelo enxerga a informação. Podemos também flexibilizar a forma das variáveis numéricas.

16 · O efeito pode se intensificar depois de um limite

Cenário separado da fórmula manual; cálculo próprio

CONDUÇÃO EM AULA

- Mostre primeiro a relação na escala do escore.
- Ative a transformação e peça que identifiquem onde a inclinação muda.
- Acompanhe a tradução para PD e pergunte como decidir se a flexibilidade ajudou: a resposta cita validação, não a beleza da curva.

RESPOSTAS

- Antes de 40% a inclinação é 0,04 por ponto. Depois de 40% passa a 0,08 por ponto.
- A função é contínua no nó: em comprometimento de 40% as duas formas coincidem.

CUIDADOS E LIMITES

- Escolher o nó olhando o teste vaza informação.
- Flexibilidade custa parâmetros e exige controle de complexidade.
- Este é um exemplo linear por partes, não uma spline cúbica.
- Árvores não são necessárias para representar toda não linearidade.

APROFUNDAMENTO

- Material original, capítulo 4, página 21: faixas devolvem flexibilidade sem trocar de família, ao custo de um coeficiente por faixa em vez de um por variável.
- As regras declaradas lá continuam válidas: volume mínimo por faixa, monotonicidade quando existe hipótese econômica de direção, estabilidade das fronteiras nas safras seguintes e fronteiras definidas antes de olhar o alvo.
- O WoE é esse mesmo tratamento com um valor específico por faixa, o logaritmo da razão entre a distribuição dos adimplentes e a dos inadimplentes. A mudança de inclinação deste slide é a alternativa contínua, com um parâmetro adicional apenas.

TRANSIÇÃO

Além de mudar a forma de um efeito, podemos permitir que ele dependa de outra característica.

17 · O comprometimento pesa igual para quem tem histórico de atraso?

Cenário separado da fórmula manual; cálculo próprio

CONDUÇÃO EM AULA

- Comece pelo escore, com as duas retas paralelas.
- Pergunte o que muda quando o termo cruzado é ativado. Só então observe a PD.
- Peça que o aluno separe efeito do histórico no escore de diferença de probabilidade.

RESPOSTAS

- Sem interação: inclinação 0,04 nos dois grupos, retas paralelas no escore.
- Com interação de 0,03: inclinação 0,04 para histórico zero e 0,07 para histórico um.
- Mesmo sem termo cruzado, a diferença de PD entre os grupos varia com o comprometimento, porque a sigmoide é não linear.

CUIDADOS E LIMITES

- Os coeficientes principais são condicionais ao valor de referência das demais variáveis.
- Com interação, o coeficiente do histórico não é efeito constante em qualquer comprometimento.
- A leitura é associativa e pode não representar uma intervenção viável.
- Ausência de termo cruzado não implica diferença constante de PD.

TRANSIÇÃO

Cada transformação ou interação acrescenta flexibilidade. Como evitar que isso capture particularidades da amostra?

18 · Coeficientes extremos podem estar aprendendo ruído

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Comece com penalização fraca, observe as magnitudes e a validação.
- Aumente a penalização e discuta o que melhora e o que piora.
- Compare os dois cenários: na amostra completa o efeito é pequeno; na amostra reduzida ele aparece com clareza.

CUIDADOS E LIMITES

- Regularização reduz variância em muitas situações. Não garante estabilidade em qualquer conjunto nem resolve mudança de população.
- Coeficientes padronizados não são os números da fórmula manual dos slides 07 a 14.
- A escolha da penalização faz parte do treinamento, e usa validação, nunca o teste.
- Com variáveis correlacionadas, nem todo coeficiente diminui de magnitude de forma monótona.
- A força da penalização mostrada é 1 dividido por C. C menor significa penalização maior.

TRANSIÇÃO

Podemos tornar o logit mais flexível e controlar sua complexidade. Em quais situações essa combinação é especialmente útil?

19 · Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Síntese conceitual aplicada; sem dados

CONDUÇÃO EM AULA

- Percorra as três situações olhando só o gráfico, e peça a resposta da pergunta de diagnóstico antes de revelar a ação. Na segunda, a abertura entre as faixas é visível: é o que uma interação omitida faz.
- Peça uma razão para manter o logit mesmo se outro algoritmo tiver AUC um pouco maior.
- Aceite manutenção, clareza de especificação e estabilidade, sempre condicionadas a evidência.
- Depois peça uma situação em que insistir em um logit mal especificado seria prejudicial.

CUIDADOS E LIMITES

- As faixas do gráfico são ilustrativas e servem para treinar a leitura, não para afirmar nada sobre a carteira. A figura está declarada como conceitual na fonte do slide.
- Interpretável depende da quantidade de termos, transformações, interações e do público. Um logit com centenas de variáveis não é automaticamente fácil de explicar.
- Coeficiente não é causa.
- O desempenho de uma formulação simples não é o limite de toda a classe.
- Produzir uma probabilidade não garante que ela esteja calibrada.

APROFUNDAMENTO

- Material original, capítulo 4, página 20: a linearidade em log odds é o limite da família. Um padrão não monótono na utilização não é representável sem transformar a variável.
- Página 19: a fronteira de decisão do logit é uma reta no plano das variáveis, porque o score é uma soma. Mudar o corte desloca a reta paralelamente e mudar um coeficiente gira a reta. A comparação com as regiões em degraus da árvore está no slide 26: o botão Sobrepor o logit desenha estas mesmas curvas por cima das quatro regiões, nos mesmos eixos.
- Página 22: a síntese do capítulo original é soma, curva e limite. Os três aparecem aqui nos slides 07, 09 e neste.

TRANSIÇÃO

Antes de mudar de técnica, vamos verificar se conseguimos usar o que aprendemos em uma decisão de interpretação.

20 · Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exemplo didático de logit; cálculo próprio

CONDUÇÃO EM AULA

- Dê um minuto em duplas. Peça a explicação de quem escolheu cada alternativa, sem expor pessoas.
- Use a solução para revisar a diferença entre coeficiente e alteração de PD.
- Pergunte oralmente: o que podemos afirmar sobre o efeito causal de reduzir o comprometimento?

RESPOSTAS

- A alternativa correta é a segunda: o score sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.
- Score original −2,025 e PD 11,66%. Novo score −1,625 e PD aproximadamente 16,45%. Diferença aproximada de 4,79 pontos.
- Sobre causalidade: o cálculo descreve o modelo mantendo as demais entradas fixas. Não identifica efeito causal.
- Desafio opcional: sem o histórico de atraso, o score de Bruno cai 0,80 e a PD passa de 11,66% para aproximadamente 5,66%.

CUIDADOS E LIMITES

- O que dobra são as odds, não a probabilidade. Converter odds em PD exige a volta pela logística.
- Os coeficientes deste exemplo foram escolhidos para ensinar, não estimados em dados. A ordem de grandeza é plausível; os valores não são um modelo.
- Uma PD de Bruno não diz o que acontecerá com Bruno. Diz a frequência esperada em exposições semelhantes.

TRANSIÇÃO

Agora imagine que o modelo não some características, mas faça perguntas sucessivas: houve atraso? O comprometimento é alto? Essa é a lógica de uma árvore.

21 · Houve atraso? Qual é o comprometimento?

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte qual informação a árvore consultará primeiro.
- Leve Ana à esquerda e então à folha de comprometimento até 40%.
- Mostre Diego no outro ramo para criar contraste. Só depois nomeie nó, ramo e folha.
- Não explique Gini neste slide.

RESPOSTAS

- Ana: histórico 0 e comprometimento 22%, portanto ramo esquerdo e folha de comprometimento até 40%.
- Bruno: histórico 1 e comprometimento 38%, portanto ramo direito e folha de comprometimento até 40%.
- Carla: histórico 0 e comprometimento 48%, folha de comprometimento acima de 40%.
- Diego: histórico 1 e comprometimento 55%, folha de comprometimento acima de 40%.
- Comprometimento exatamente igual a 40 vai para o ramo até 40.

CUIDADOS E LIMITES

- O percurso é determinístico, mas a previsão ao final é probabilística. Duas pessoas diferentes podem cair na mesma folha.
- As perguntas e os limites são aprendidos dos dados. O limite de 40% é regra deste exemplo, não norma de crédito.
- Esta árvore pequena serve para enxergar o mecanismo. Não é o resultado do experimento maior.

TRANSIÇÃO

Depois de encaminhar o cliente, precisamos atribuir uma PD ao grupo ao qual ele pertence.

22 · Nesta folha, 18 de 600 contratos ficaram inadimplentes

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Construa a conta de Ana em voz alta e peça a de Bruno.
- Pergunte se clientes da mesma folha terão a mesma previsão mesmo com rendas diferentes: sim, nesta árvore, porque a renda não entra nas perguntas.

RESPOSTAS

- Ana $18/600 = 3\%$. Bruno $12/80 = 15\%$. Carla $22/200 = 11\%$. Diego $48/120 = 40\%$.
- As folhas somam 1.000 contratos e 100 eventos, iguais à raiz.

CUIDADOS E LIMITES

- A taxa aparente da folha não comprova calibração futura.
- Este exemplo é sem pesos. Com ajuste ponderado, a fórmula da folha refletiria os pesos.
- Estas PDs são da árvore didática. Não são previsões do experimento estimado, e não devem ser comparadas com as PDs manuais do logit como se uma fosse mais correta.

TRANSIÇÃO

Por que a primeira pergunta foi sobre histórico, e não sobre renda ou comprometimento?

23 · Qual pergunta separa melhor os comportamentos observados?

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Peça que o aluno escolha visualmente e explique por quê.
- Se ele usar apenas a diferença entre taxas, pergunte o que aconteceria com uma folha de duas observações.
- Mostre o papel do tamanho do grupo antes de revelar a regra de escolha.

RESPOSTAS

- Histórico separa em 800 contratos com 5% e 200 contratos com 30%.
- Comprometimento separa em 680 contratos com aproximadamente 4,41% e 320 contratos com 21,88%.
- A regra de escolha é a menor impureza ponderada, calculada no próximo slide.

CUIDADOS E LIMITES

- Esta é a melhor divisão entre os candidatos comparados, não entre todas as variáveis possíveis.
- A busca é gulosa e local: a melhor divisão imediata não garante a árvore globalmente ótima.
- Com dados agregados não é possível varrer limiares intermediários sem inventar contagens.

TRANSIÇÃO

Vamos colocar essa comparação em números com o índice de Gini.

24 · Histórico reduz o Gini de 0,180 para 0,160

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Peça a conta do Gini da raiz antes de revelar.
- Antes de ponderar, pergunte por que não usar a média simples. Mostre a diferença entre 800 e 200 registros.
- Termine explicitando que o algoritmo compara vários candidatos, repete o procedimento em cada nó e precisa de uma regra para parar.

RESPOSTAS

- Raiz com 10% de eventos: Gini igual a 0,180.
- Por histórico: 0,8 vezes 0,095 mais 0,2 vezes 0,420 resulta em 0,160, com ganho de 0,020.
- Por comprometimento: impureza ponderada 0,166728 e ganho 0,013272.
- Impureza zero em grupo puro; máximo de 0,5 quando a taxa é 50%.

CUIDADOS E LIMITES

- Gini é critério de impureza no treino. Não é AUC, KS nem lucro.
- Outras perdas podem orientar árvores. Não misture entropia e Gini no mesmo cálculo.
- Ganho de impureza não é efeito causal do histórico.

APROFUNDAMENTO

- O capítulo 5 refaz esta mesma busca sobre outra base: dezesseis propostas com raiz em 0,500 de Gini, onde o corte vencedor é utilização $\leq 57,5\%$ com redução de 0,28125. Aqui a raiz é de mil contratos a 10% de eventos, com Gini 0,180 e ganho de 0,020 no histórico. A regra é a mesma, a aritmética não: nenhum dos dois números se converte no outro.
- Material original, capítulo 5, página 4: o Gini não é a taxa de erro do nó. O segundo nível daquela árvore derruba o Gini de 0,21875 para 0,12500 sem tirar um único erro, e é por isso que a taxa de erro não serve de critério.

TRANSIÇÃO

Ao dividir mais, as folhas parecem mais precisas. Mas quanto podemos confiar em uma taxa calculada com poucas observações?

25 · Duas folhas com PD de 10%. A evidência é igual?

Pares binomiais ilustrativos; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte qual folha transmitiria mais confiança e por quê.
- Aumente o tamanho da folha e peça que o aluno narre o que mudou.
- Mostre o caso de zero eventos e pergunte se o gestor poderia tratar o risco como impossível.

RESPOSTAS

- 2 em 20: intervalo aproximado de 2,8% a 30,1%.
- 100 em 1.000: intervalo aproximado de 8,3% a 12,0%.
- 0 em 20: o limite superior continua positivo, aproximadamente 16,1%. Zero evento não prova risco zero.

CUIDADOS E LIMITES

- O intervalo descreve a dimensão binomial. Não incorpora a escolha adaptativa das folhas, a seleção da população nem a mudança temporal.
- Não é correto dizer que a PD individual tem 95% de chance de cair nesse intervalo.
- A incerteza real da árvore inclui a busca pelos cortes, e é maior que a mostrada aqui.

APROFUNDAMENTO

- Fórmula do intervalo de Wilson, com z igual a 1,96 para 95% nominal: o centro é $(\hat{p} + z^2/2n)$ dividido por $(1 + z^2/n)$, e a meia amplitude é z vezes a raiz de $[\hat{p}(1-\hat{p})/n + z^2/4n^2]$, dividida pelo mesmo denominador.
- Wilson é preferível ao intervalo normal simples justamente no caso deste slide: taxa baixa e folha pequena, onde o intervalo normal produz limite inferior negativo.

TRANSIÇÃO

Folhas maiores estabilizam estimativas, mas a árvore também precisa capturar diferenças relevantes entre clientes.

26 · O mesmo aumento de comprometimento pode mudar de folha

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Mova Bruno de 38 para 41 e compare com Ana ao redor do mesmo limite.
- Depois clique em Sobrepor o logit. É a única tela da aula em que degrau e curva aparecem nos mesmos eixos. Pergunte qual das duas descreve melhor um cliente em 41%, e aceite que a tela não decide.
- A mudança é de 15% para 40% no ramo com histórico, e de 3% para 11% no ramo sem histórico.
- Pergunte se uma mudança pequena de risco verdadeiro deveria produzir esse salto: a descontinuidade é da aproximação do modelo.

CUIDADOS E LIMITES

- Árvores capturam interações porque a pergunta de um ramo depende das decisões anteriores. Isso não dispensa validação.
- Uma folha define uma região constante. Ensembles produzem funções mais detalhadas.
- O limite de 40% é deste exemplo. Não é política de crédito.
- Histórico é categórico: as duas faixas são categorias, não um eixo contínuo.

TRANSIÇÃO

Se continuarmos dividindo o espaço, podemos criar regiões cada vez menores. Quando isso começa a prejudicar?

27 · A árvore cresce. O resultado fora do treino acompanha?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Comece raso, aumente a complexidade e peça que comparem treino e validação.
- Mostre a mediana de contratos por folha como pista de fragilidade, não como prova isolada.
- A seleção usa a validação fora do tempo, nunca o teste final.

CUIDADOS E LIMITES

- Os mapas vêm de um experimento auxiliar com apenas duas variáveis. Não são projeção exata do modelo completo.
- A perda mostrada usa log loss com proteção numérica de 10 elevado a menos 6, porque árvores produzem probabilidades iguais a 0 ou 1 em folhas puras. O Brier está disponível na tabela.
- Desempenho de uma única amostra varia. Diferenças pequenas podem não ser robustas.
- Nem toda árvore profunda é ruim: a profundidade interage com tamanho de folha e poda.

TRANSIÇÃO

Podemos controlar o crescimento de mais de uma maneira. Cada parâmetro restringe uma parte diferente da árvore.

28 · Três controles, três formas de conter o excesso de divisões

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Mostre primeiro a profundidade, depois uma folha pequena que ainda existe mesmo em árvore rasa.
- Use essa folha para motivar o mínimo de contratos por folha.
- Por fim, explique que a poda considera retirar partes de uma árvore já crescida.

RESPOSTAS

- O parâmetro de folha é mínimo de observações, não mínimo de inadimplentes.
- O alfa da poda não tem unidade universal de nós removidos: ele é o preço por folha no critério de custo e complexidade.
- A seleção usa a perda de validação fora do tempo.

CUIDADOS E LIMITES

- Cada configuração corresponde a uma árvore realmente treinada, não a uma ocultação visual de nós.
- Aumentar o mínimo por folha não melhora calibração automaticamente.
- O critério final continua sendo desempenho fora da amostra de ajuste.

TRANSIÇÃO

Mesmo árvores de tamanho parecido podem mudar bastante quando mudamos a amostra usada para aprender.

29 · Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Pergunte qual das duas árvores é a verdadeira e use a pergunta para discutir estimativa e variabilidade.
- Compare estrutura e previsão: uma raiz diferente não significa mudança enorme de PD, e previsões podem variar mesmo com raízes iguais.

CUIDADOS E LIMITES

- O bootstrap ilustra sensibilidade ao treinamento. Não é intervalo preditivo calibrado do risco verdadeiro de um cliente.
- Não reamostramos o teste para treinar.
- As réplicas exibidas foram escolhidas por critério declarado: a primeira réplica de cada variável de raiz observada, e não a mais dramática.
- Este slide não é uma aula de random forest. Apenas situa por que ensembles exploram múltiplas funções.

TRANSIÇÃO

Antes de combinar várias árvores, vamos verificar se sabemos interpretar uma única árvore e suas limitações.

30 · Carla recebe qual PD nesta árvore?

Árvore didática de 1.000 contratos; cálculo próprio

CONDUÇÃO EM AULA

- Reserve dois minutos em duplas.
- Não revele a resposta ao primeiro clique em um ramo errado: explique a regra e permita corrigir.
- Conclua com a importância de tamanho de folha, validação e estabilidade. Este é um bom ponto para a pausa da aula.

RESPOSTAS

- Carla tem histórico 0 e comprometimento 48%, acima de 40%. Chega à folha de 22 eventos em 200 contratos, ou seja 11%.
- Dobrar a renda isoladamente, com o comprometimento mantido fixo, não altera esta árvore, porque a renda não é usada nas perguntas.
- Numa mudança econômica real o comprometimento poderia variar. A simulação é sobre a função do modelo.
- Desafio final: Bruno de 38% para 41% passa de 15% para 40%. Isso não prova um salto real de risco exatamente nesse limite: é uma descontinuidade da aproximação aprendida.

CUIDADOS E LIMITES

- A taxa de uma folha é estimativa com incerteza, e folhas pequenas têm intervalo largo. Ler a taxa sem o tamanho da folha é o erro mais comum aqui.
- A regra da árvore é associação aprendida na amostra, não relação causal: mudar a variável no cliente não move a PD dele pelo caminho da árvore.
- Esta árvore vem da miniatura de 1.000 contratos, separada da base do experimento. Não compare o desempenho dela com o dos modelos treinados.

APROFUNDAMENTO

- Quando a árvore é uma boa escolha, para fechar o bloco como o slide 19 fecha o do logit e o 40 o do boosting: quando o efeito de uma variável depende do valor de outra e a interação não precisa ser escrita à mão; quando a relação não é monótona e transformar a variável seria um chute; e quando a regra precisa virar política operacional, legível linha a linha. O preço é o que os slides 27 a 29 mostraram: a estrutura muda com uma observação, a taxa da folha não se lê sem o tamanho da folha, e a perda de treino não compara famílias. Não cabe em tela com o exercício revelado; está nos dois guias em PDF.

TRANSIÇÃO

Uma única árvore é clara, mas pode ser limitada ou instável. Podemos construir uma previsão melhor acrescentando várias árvores pequenas em sequência?

31 · E se uma árvore pequena ainda deixar estrutura nos erros?

Experimento auxiliar de duas variáveis; cálculo próprio

CONDUÇÃO EM AULA

- Retome o slide 27: aumentar uma única árvore não é a única opção.
- Mostre que há grupos em que a previsão ficou sistematicamente baixa ou alta.
- Pergunte como uma próxima função poderia atuar nesses grupos. Termine apresentando a palavra sequencial.

CUIDADOS E LIMITES

- Um resíduo individual não é padrão. A leitura só faz sentido na média por região.
- Subajuste e variabilidade não se resolvem com boosting em todos os casos: combinar árvores também acrescenta complexidade e pode sobreajustar.
- Os resíduos aqui vêm do conjunto usado no ajuste, nunca do teste.
- O título é uma hipótese a ilustrar com dados, não um diagnóstico automático.

TRANSIÇÃO

Vamos entender a regra de construção: partir de um escore simples, calcular a direção de melhoria e acrescentar uma árvore.

32 · A próxima árvore aprende a partir das previsões atuais

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte se cada árvore produz uma nova PD a ser somada.
- Revele que o objeto somado é F, um escore na escala de log odds neste caso.
- Reconecte ao slide 09: só ao final aplicamos a função logística.

RESPOSTAS

- Novo escore é igual ao escore atual mais a taxa de aprendizagem vezes a contribuição da árvore.
- A árvore de regressão devolve números positivos ou negativos, não um voto entre adimplente e inadimplente.
- Em combinação independente, os modelos são ajustados sem esse encadeamento e depois agregados.

CUIDADOS E LIMITES

- O algoritmo pode otimizar perdas diferentes. Aqui o alvo é binário e a perda é logística.
- O gradiente depende da função de perda escolhida.
- Esta é uma apresentação de primeira ordem, didaticamente válida. Implementações podem usar atualizações diferentes nas folhas.

TRANSIÇÃO

Antes de corrigir qualquer coisa, precisamos de uma previsão inicial. Qual seria a melhor se tratássemos todos igualmente?

33 · Dois eventos em dez contratos: começamos em 20%

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Pergunte qual PD seria razoável antes de olhar qualquer característica.
- Compare 10%, 20% e 40% na perda média.
- Revele que a média empírica minimiza a perda do modelo constante não ponderado, e conecte F0 à conversão do slide 10.
- Só então mostre os grupos A e B, anunciando que eles permitirão melhorar a previsão uniforme.

RESPOSTAS

- Média de y igual a 0,2, que é o mínimo da curva de perda.
- $F_0 = \ln(0,20 / 0,80) = -1,3863$, com logaritmo natural.

CUIDADOS E LIMITES

- O ponto inicial depende da perda, dos pesos e da implementação. Este exemplo é sem pesos e binário.
- A taxa de 20% descreve esta miniatura. Não descreve o mercado de crédito nem a base principal.
- Os desfechos aqui são atributos de treinamento conhecidos, não informação sobre um cliente novo.
- Ao avançar para a miniatura canônica, a previsão inicial volta a 20%.

APROFUNDAMENTO

- Material original, capítulo 6, página 13: o mesmo procedimento em classificação, escrito em cinco linhas, com $F_0 = \ln(\pi \div (1 - \pi))$, alvo $y - p$ e atualização $F \leftarrow F + \eta \times h$. Lá a base tem dezesseis propostas e η é 0,40; aqui a miniatura tem dez registros. O procedimento é idêntico, os números são de exemplos diferentes.

TRANSIÇÃO

Agora compare o que aconteceu com o que previmos: essa diferença indica a direção da primeira correção.

34 · A primeira correção reduz A e aumenta B

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Peça o resíduo de um evento e o de um não evento.
- Calcule a média do grupo B em voz alta.
- Pergunte por que três adimplentes do grupo B receberam aumento. Resposta: o modelo captura o risco do grupo, não reproduz cada rótulo.
- Localize os quatro clientes: com comprometimento 22 e 38, Ana e Bruno caem em A; com 48 e 55, Carla e Diego caem em B. Uma árvore só dá a mesma PD a Ana e a Bruno.

RESPOSTAS

- Em A, cinco resíduos de $-0,2$ e média $-0,2$.
- Em B, três resíduos de $-0,2$ e dois de $+0,8$, média $+0,2$.
- Com taxa de aprendizagem 1: F do grupo A vai a $-1,586294$ e PD a 16,9906%. F do grupo B vai a $-1,186294$ e PD a 23,3922%.

CUIDADOS E LIMITES

- y menos p é o gradiente negativo da perda logística em relação ao score nesta parametrização.
- Isso não significa que toda biblioteca use exatamente a média como valor final da folha.
- As contribuições estão em unidades de score, não em pontos percentuais de PD.
- Primeira ordem didática: a folha recebe a média do gradiente negativo, sem passo de Newton.

TRANSIÇÃO

Depois da atualização, os resíduos mudaram. Por isso a segunda árvore precisa olhar novamente para as previsões.

35 · A primeira árvore mudou as previsões. Agora mudam os gradientes

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Antes de revelar a média do grupo B, pergunte se ela continuará em mais 0,2.
- Faça a turma perceber que o resíduo de um $y = 1$ diminuiu e o de um $y = 0$ ficou mais negativo.
- Mostre que a correção média positiva persiste, mas mudou de tamanho.

RESPOSTAS

- No grupo A, $r1 = -0,1699058933$ e a média da folha é o mesmo valor.
- No grupo B, três resíduos de $-0,2339223413$ e dois de $+0,7660776587$, média $+0,1660776587$.
- Com taxa 1: F do grupo A vai a $-1,7562002544$ e PD a 14,7267%. F do grupo B vai a $-1,0202167024$ e PD a 26,4985%.

CUIDADOS E LIMITES

- Os resíduos da segunda rodada usam $p1$, nunca $p0$.
- A nova árvore poderia usar outro corte em dados mais ricos. Aqui o corte permanece por construção da miniatura, que só tem dois valores de comprometimento.
- Nem toda correção diminui, e as previsões individuais não caminham necessariamente de forma monótona. Isso acontece aqui pela simplicidade dos grupos.
- O objetivo é reduzir a perda agregada, não acertar cada rótulo.

TRANSIÇÃO

Somamos duas contribuições. Vamos olhar essa soma como uma função que também pode prever um cliente novo.

36 · Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Apresente o solicitante novo e pergunte onde está o y dele.
- Antes de trocar η , peça um palpite: se somarmos 40% de cada correção, a PD final é 40% do caminho? Depois troque para 0,40 e mostre que não.
- Mostre que y só foi usado no treinamento das duas árvores.
- Faça o percurso nas duas árvores, some e converta. Compare com o waterfall do logit: ambos somam em uma escala de escore, com funções diferentes.

RESPOSTAS

- Com $\eta = 1$, grupo B: $-1,386294$ mais $0,200000$ mais $0,166078$ é igual a $-1,020217$, e a PD é 26,4985%.
- Com $\eta = 1$, grupo A: $-1,386294$ menos $0,200000$ menos $0,169906$ é igual a $-1,756200$, e a PD é 14,7267%.
- Com $\eta = 0,40$ e as mesmas duas árvores: grupo A chega a 17,6347% e grupo B a 22,5912%.

CUIDADOS E LIMITES

- Não some as PDs de cada árvore nem chame as contribuições de probabilidades.
- Um conjunto real tem muitas árvores e padrões mais ricos. A miniatura de duas árvores só torna o mecanismo visível.
- Esta não é uma explicação por variável: é a decomposição exata da soma das árvores.
- Com taxa de aprendizagem diferente de 1, o que se soma é a taxa multiplicada pela contribuição.
- Multiplicar as duas contribuições de $\eta = 1$ por 0,40 não dá o resultado de $\eta = 0,40$: a segunda árvore é outra, porque partiu de outro escore.

TRANSIÇÃO

Se cada passo for menor, precisaremos de mais etapas. Como escolher o tamanho dos passos e o número de árvores?

37 · Learning rate e número de árvores precisam ser escolhidos juntos

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Compare as taxas no mesmo número de árvores e depois permita mais árvores para a taxa menor.
- Pergunte se taxa menor é sempre melhor. Não: há custo computacional, subajuste com poucas árvores e comportamento que depende dos dados.

RESPOSTAS

- Cada curva vem de um treinamento próprio com sua taxa. Não é a reescala de um conjunto fixo de árvores.
- Multiplicar as contribuições no fim não reproduz outro treinamento, porque os resíduos dependem do escore atualizado a cada passo.

CUIDADOS E LIMITES

- O produto entre taxa e número de árvores não determina sozinho o modelo final: a trajetória muda.
- A taxa se relaciona com regularização, mas não substitui validação temporal.
- O teste final continua fora de qualquer escolha.

TRANSIÇÃO

Além de quantos passos dar e do tamanho de cada passo, importa o que cada árvore consegue representar.

38 · Uma correção pode depender de uma característica ou da combinação de várias

Experimento auxiliar de duas variáveis; cálculo próprio

CONDUÇÃO EM AULA

- Mostre a combinação de comprometimento alto com utilização alta e pergunte que regra a descreve.
- Compare a representação por uma única condição e por duas condições.
- Revele que árvores mais profundas capturam estruturas mais complexas, e que cada passo também pode ajustar mais ruído.

CUIDADOS E LIMITES

- Profundidade máxima não é contagem universal e exata da ordem de interações. Profundidade 2 permite caminhos com duas condições, e implementações e repetição de variável importam.
- A soma de stumps é aditiva no score F. A transformação logística pode induzir não aditividade na escala da probabilidade. Não diga que stumps não produzem interação na PD.
- Este experimento auxiliar não fala sobre o desempenho na base de crédito principal.

TRANSIÇÃO

Temos vários controles de complexidade. O acompanhamento da validação ajuda a decidir quando interromper a construção.

39 · Continuar melhorando o treino pode deixar de ajudar a validação

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Peça que a turma sugira onde parar antes de revelar toda a curva.
- Compare o palpite com a regra: tolerância e paciência evitam reagir a variações pequenas.
- Mostre que o mínimo aparente pode ser ruidoso.

CUIDADOS E LIMITES

- Melhor iteração e iteração de parada são coisas diferentes. A parada acontece depois da paciência, não no mínimo.
- A validação usada é fora do tempo, definida no protocolo. Não é um corte aleatório interno da biblioteca.
- Escolher o número de árvores é seleção de hiperparâmetro, e usa a mesma amostra de validação.
- Um eventual reajuste com mais dados precisa respeitar a disponibilidade temporal e ser definido antes de calibrar e testar.

TRANSIÇÃO

Com esses controles, podemos avaliar em que condições a flexibilidade do boosting oferece ganhos e quais custos ela traz.

40 · Mais flexibilidade exige mais disciplina de validação

Síntese conceitual, com um resultado calculado como exemplo

CONDUÇÃO EM AULA

- Peça que a turma escolha uma situação em que começaria pelo logit e outra em que investigaria boosting.
- Discuta hipóteses e as evidências necessárias em cada caso.
- Não revele ainda a tabela final da comparação principal.

CUIDADOS E LIMITES

- Implementações como XGBoost, LightGBM e CatBoost existem e diferem entre si. Aqui não há catálogo de funcionalidades nem recomendação comercial.
- Suporte a dados ausentes e categóricos depende da implementação. Não é propriedade universal do método.
- A frase funciona bem em dados tabulares não substitui um experimento adequado no problema.
- Nenhuma nota subjetiva é atribuída aos algoritmos.

TRANSIÇÃO

Se o modelo usa muitas árvores, como explicar o que ele aprendeu e por que atribuiu determinada PD a um cliente?

41 · O que o modelo usa em geral? O que pesou para Bruno?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Peça a variável mais relevante na carteira e a que mais eleva a previsão de Bruno. Mostre que podem ser diferentes.
- Compare Bruno e Carla mantendo as escalas.
- Termine com a pergunta: se alterarmos essa variável, garantimos essa redução de risco? Resposta: explicação de previsão não identifica efeito causal.

RESPOSTAS

- As duas leituras respondem a perguntas diferentes: uma descreve a carteira, a outra descreve uma previsão.
- A soma da referência com as contribuições reproduz o escore do cliente, o que é conferido numericamente.

CUIDADOS E LIMITES

- Importância por permutação tem unidade própria, aqui queda de AUC na validação. Não é a mesma escala das contribuições locais, que estão em escore.
- Variáveis correlacionadas afetam atribuição e importância.
- Importância por redução de impureza tem limitações distintas das da permutação.
- As contribuições locais são valores de Shapley com expectativa intervencional sobre uma amostra de referência, calculados no notebook, e não um mecanismo econômico.

TRANSIÇÃO

Vamos verificar se conseguimos separar a construção da previsão de sua interpretação.

42 · Carla caiu no grupo B. Qual é a previsão?

Miniatura didática de 10 registros; cálculo próprio

CONDUÇÃO EM AULA

- Dê um minuto individual e outro em duplas.
- Lembre que Carla é a mesma do slide 01. Ana e Bruno cairiam no grupo A e receberiam a mesma PD entre si, o que já mostra por que duas árvores não bastam.
- Peça que verbalizem onde o desfecho y foi usado e onde deixou de ser necessário.
- Conclua o bloco conectando logit e boosting pela saída probabilística, com funções de escore diferentes.

RESPOSTAS

- Soma em escore: −1,386294 mais 0,200000 mais 0,166078 é igual a −1,020217. A PD é 26,4985%.
- Somar percentuais daria 20% mais 20% mais 16,6078%, o que não é a operação do modelo.
- A média das duas folhas ignoraria o escore inicial e a natureza aditiva da construção.
- Sobre causalidade: uma contribuição positiva do histórico não prova que remover o atraso do cadastro reduziria o risco real.
- Reduzir a taxa de aprendizagem exige recalcular as rodadas e os resíduos, não dividir a PD.

CUIDADOS E LIMITES

- A soma das árvores acontece na escala de log odds. Somar contribuições em probabilidade dá resultado errado.
- A miniatura tem 10 registros e serve para ver o mecanismo. Não é modelo ajustado nem sustenta comparação de desempenho.
- Reconstruir a previsão de um cliente novo não valida o modelo: validação exige amostra fora do tempo, no bloco seguinte.

TRANSIÇÃO

Sabemos como as três técnicas funcionam. Agora precisamos comparar as três em condições iguais e verificar o que cada métrica responde.

43 · Estamos comparando modelos ou comparando condições diferentes?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Recupere o slide 05 em miniatura na tira inferior.
- Pergunte por que usar todos os registros em todos os modelos ainda não garante justiça.
- Revele processamento e seleção, e só depois habilite a abertura dos resultados.

RESPOSTAS

- Boosting com variável futura: a comparação mede vazamento, não algoritmo. Correção: remover a variável e refazer o treinamento.
- Logit sem tratamento enquanto outros receberam engenharia: baseline artificialmente fraco. Correção: dar ao logit transformações e interações plausíveis, como a sensibilidade deste experimento.
- Configuração escolhida pela métrica do teste: o teste deixa de ser independente. Correção: escolher na validação e usar o teste uma única vez.

CUIDADOS E LIMITES

- Modelos especificados antes do teste podem ser comparados nele. Ajustes motivados por esse teste exigem nova avaliação independente.
- A exploração em aula não deve produzir um campeão otimizado depois de ver o resultado.
- Calibradores e cortes pertencem às partições definidas para isso.

TRANSIÇÃO

A primeira pergunta é se o modelo ordena corretamente os clientes de maior e menor risco.

44 · Quem aparece primeiro na fila de risco?

Microexemplo de ranking e experimento sintético, em abas identificadas

CONDUÇÃO EM AULA

- Comece pelo par, não pela integral.
- Pergunte se o escore 0,8 significa 80% de PD calibrada. Neste exemplo não há essa evidência.
- Revele as curvas como resumo da ordenação e diferencie taxa de falsos positivos de inadimplência entre aprovados.

RESPOSTAS

- São 9 pares, 7 corretamente ordenados: AUC igual a 7 dividido por 9, aproximadamente 0,7778.
- Empates contam meio par.
- Mudar o corte não muda a AUC: ela percorre todos os cortes.

CUIDADOS E LIMITES

- Orientação declarada: escore maior significa maior risco.
- AUC por pares não é acurácia, taxa de acerto de aprovados nem rentabilidade.
- KS e AUC resumem aspectos diferentes: um não determina o outro.
- Diferenças pequenas entre modelos podem exigir avaliação de incerteza.

TRANSIÇÃO

Mesmo que o ranking esteja certo, precisamos perguntar se uma previsão de 10% corresponde a cerca de 10% de eventos.

45 · Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Leia um ponto completo: probabilidade média, proporção observada, n e eventos.
- Aplique a perturbação das odds e pergunte o que deve acontecer com a AUC antes de revelar.
- Discuta por que PD em escala errada distorce perda esperada e política de corte.

RESPOSTAS

- A transformação multiplica as odds por dois e preserva a ordem, portanto a AUC permanece idêntica.
- A calibração e as perdas mudam, e a direção depende de como o modelo já estava calibrado.

CUIDADOS E LIMITES

- Wilson por faixa é descrição binomial aproximada e não incorpora toda a seleção e modelagem.
- Brier e log loss avaliam qualidade probabilística, mas não são medidas exclusivas de calibração.
- Número de faixas, calibrador e versão não devem ser escolhidos pelo teste final.
- O calibrador de Platt foi ajustado na partição de calibração e aplicado ao teste sem reajuste.

APROFUNDAMENTO

- O calibrador de Platt foi ajustado na partição de calibração e aplicado ao teste sem reajuste. O efeito observado na tela é o desse procedimento, não de um recalibrador ajustado no próprio teste.
- Platt é uma logística sobre o escore: $p_{calibrada} = \sigma(a \cdot z + b)$. Como a transformação é monotônica em z quando a é positivo, ela não altera a ordem nem a AUC, e é exatamente por isso que serve para corrigir nível sem estragar ordenação.

TRANSIÇÃO

Uma PD só vira ação quando definimos uma política. Vamos observar como um corte altera a carteira aprovada.

46 · Até qual PD vamos aprovar?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Reduza o corte e observe volume e composição.
- Pergunte se menor inadimplência implica melhor resultado. Não: pode haver perda de receita.
- Compare dois modelos no mesmo corte e depois no mesmo volume, e explique que são perguntas diferentes.

RESPOSTAS

- Taxa de aprovação é o número de aprovados dividido pelo total avaliado.
- Inadimplência entre aprovados é a soma de eventos entre aprovados dividida pelo número de aprovados. Contratos recusados não entram no denominador.
- Média das PDs aprovadas e taxa observada são coisas diferentes: a primeira é previsão, a segunda é desfecho.

CUIDADOS E LIMITES

- A avaliação usa contratos com desfecho conhecido da população sintética, o que permite simular recusa. Em dados reais de apenas concedidos, inferir o desempenho dos rejeitados exige hipóteses adicionais.
- Limite de crédito, preço e prazo permanecem fixos aqui, para isolar a decisão de aprovação.
- Empates na PD, comuns na árvore, seguem a regra de aprovar todos no limite. Nenhum desempate usa y.
- Se ninguém for aprovado, a inadimplência entre aprovados fica indefinida.

TRANSIÇÃO

Para escolher um corte, precisamos colocar receitas e perdas na mesma conta.

47 · Com estas hipóteses, o equilíbrio ocorre em PD de 20%

Economia didática declarada na tela; cálculo próprio

CONDUÇÃO EM AULA

- Construa a perda esperada, depois o resultado, depois o equilíbrio.
- Pergunte o efeito de aumentar a fração perdida mantendo a PD.
- Mostre que o mesmo cliente pode ser aceitável sob uma estrutura econômica e inviável sob outra, sem defender simplesmente aumento de taxa.

RESPOSTAS

- Perda esperada é PD vezes LGD vezes EAD. Em PD de 10%: 0,10 vezes 60% vezes R\$ 10.000, igual a R\$ 600.
- Resultado esperado é margem menos perda esperada: R\$ 1.200 menos R\$ 600, igual a R\$ 600.
- Equilíbrio: margem dividida por LGD vezes EAD, igual a 20%.

CUIDADOS E LIMITES

- A margem é considerada constante e já líquida dos custos definidos, apenas nesta simplificação. Não é receita recebida em todos os cenários do mundo real.
- Perda esperada não é lucro, e EAD não é o valor original do contrato sem a hipótese de igualdade.
- A versão alternativa, com margem condicional ao adimplemento, tem outro corte e não deve ser misturada a este gráfico.
- Resultados realizados usam y e são diferentes do valor esperado calculado com p.

TRANSIÇÃO

Antes de implantar, ainda precisamos saber se a relação continua válida no tempo e se conseguimos operar essa relação com controle.

48 · O que conseguimos monitorar agora? O que exige esperar?

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Pergunte se PD média crescente prova piora do modelo. Pode ser mudança da população.
- Pergunte se ausência de inadimplência recente prova segurança. Pode ser falta de maturação.
- Relacione à definição do alvo do slide 03 e termine com a necessidade de versionar modelo, dados, regra e explicações.

RESPOSTAS

- Imediatos: distribuição de renda e comprometimento, ausentes, taxa de aprovação e PD média.
- Com alvo maturado: inadimplência observada, calibração, discriminação e resultado.
- A data de observação define o que pode ser medido: uma coorte só entra nas métricas de desfecho 12 meses depois da contratação.

CUIDADOS E LIMITES

- PSI, se citado, é indicador de mudança de distribuição e depende de faixas e tamanho de amostra. Não use limiares universais como regra automática.
- Mudança de distribuição não demonstra por si só perda de desempenho.
- Os cenários são sintéticos e construídos para a aula. Não são previsão macroeconômica nem backtest real.
- Nem todo alerta pede retreino: a ação depende do diagnóstico.

TRANSIÇÃO

Temos desempenho, probabilidades, economia e condições de operação. Agora vamos tomar uma decisão de comitê.

49 · Defenda sua recomendação para o comitê

Experimento sintético; semente e versões no notebook

CONDUÇÃO EM AULA

- Divida a turma em três grupos ou peça decisões individuais.
- Cada grupo tem dois minutos para recomendar e um minuto para defender.
- Solicite uma razão que faria mudar de opinião.
- Reforce que uma evidência de teste não autoriza ajustar repetidamente o modelo no mesmo teste e chamar isso de avaliação independente.

CUIDADOS E LIMITES

- Os números são de base sintética e servem à aprendizagem, não a uma decisão real de concessão.
- Valores próximos não autorizam declarar superioridade conclusiva.
- O formulário fica apenas neste dispositivo e não envia nada.
- Nenhum custo monetário de implantação é atribuído aos modelos: eles não foram medidos.

TRANSIÇÃO

Independentemente da escolha, quais princípios devem acompanhar qualquer modelagem de crédito?

50 · Você consegue explicar, comparar e usar os três modelos?

Síntese do curso; PDs do experimento sintético, semente 20260920

CONDUÇÃO EM AULA

- Peça que um aluno resuma cada técnica em uma frase.
- Retome a decisão do slide 01 sem inventar quais respostas a turma deu. Se as escolhas locais foram salvas, identifique que são escolhas naquele dispositivo.
- Leia a tabela dos quatro clientes por linha, não por coluna: pergunte qual modelo decide diferente. Nenhum decide.
- Pare em Carla. No boosting ela fica a 0,44 ponto do corte. Pergunte o que uma diferença dessas exige antes de trocar de modelo.
- Pergunte o que agora exigiriam antes de aprovar uma mudança de modelo.

RESPOSTAS

- Odds vezes 2 não é PD vezes 2: odds e probabilidade são escalas diferentes.
- Sim, a mesma folha agrupa atributos distintos que satisfazem as mesmas regras.
- Não: o boosting logístico soma no escore F e aplica a transformação depois.

CUIDADOS E LIMITES

- Complexidade pode ser útil, e a qualidade da decisão depende do processo inteiro.
- Concordar na decisão para quatro clientes não é concordar em geral: a tabela do slide 49 mostra a diferença na carteira inteira.
- As PDs desta tabela são as calibradas do experimento. A PD de 11,66% de Bruno, dos slides 07 a 20, vem do logit manual e é outro universo.
- Referências, notebook e modo estudo ficam disponíveis nos recursos finais.
- Não existe um 51º slide de agradecimento: o fechamento é esta síntese.

TRANSIÇÃO

Fim da sequência principal.