

LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2

Entender as três técnicas

Regressão logística, árvore de decisão e gradient boosting aplicados à probabilidade de inadimplência, da previsão à decisão de crédito

GUIA DO ALUNO

ENTREGA DA AULA

Comparação fundamentada dos modelos e exercícios de interpretação

FORMATO

Encontro de 180 minutos, com 15 minutos de intervalo. Cinquenta slides interativos em cinco blocos, com quatro clientes fictícios acompanhados do começo ao fim.

O problema de crédito

slides 01 a 06

Regressão logística

slides 07 a 20

Árvore de decisão

slides 21 a 30

Gradient boosting

slides 31 a 42

Avaliação e decisão

slides 43 a 50

NESTE GUIA

Como usar este guia e caminho da aula	2
Os quatro clientes, o alvo, o dicionário das variáveis e a origem dos números	3
Mapa dos 50 slides, com a página de cada um	4
Bloco 1: O problema de crédito, slides 01 a 06	6
Bloco 2: Regressão logística, slides 07 a 20	15
Bloco 3: Árvore de decisão, slides 21 a 30	31
Bloco 4: Gradient boosting, slides 31 a 42	43
Bloco 5: Avaliação e decisão, slides 43 a 50	57
Síntese das três técnicas, os modelos no teste e os quatro clientes nos três modelos	66
Antes da próxima aula: lista de verificação e cuidados de estudo	69
Glossário	71

Como usar. Leia cada página ao lado do slide correspondente na plataforma. Os exercícios estão sem gabarito: resolva no papel e confira na tela, que corrige e explica cada alternativa.

Como usar este guia

Este guia acompanha os 50 slides interativos da Aula 2, na mesma ordem. Cada página mostra o slide como ele aparece na tela, explica como ler o que está nele e diz o que vale a pena mexer.

Abra a aula pela plataforma, em Aulas ou em Materiais, e leia o guia ao lado. O que você mexe nos slides (controles, exercícios, escolhas) fica só no seu navegador: sobrevive a recarregar a página, some ao fechar a aba e não aparece em outro aparelho. "Reiniciar exemplo" devolve um slide ao início; "Limpar minhas explorações", no índice, apaga tudo.

Durante a aula ao vivo você segue o professor por padrão. "Navegar por conta própria" libera as setas e o índice (tecla I, com filtro por número, título ou bloco); "Voltar ao slide do professor" não apaga o que você explorou.

Os exercícios dos slides 01, 04, 20, 30, 42, 49 e 50 estão reproduzidos aqui sem gabarito. Resolva no papel antes de conferir na tela: o slide corrige na hora e explica cada alternativa.

Todos os dados são sintéticos. Nenhum número descreve carteira real. As fórmulas aparecem na notação dos slides, para você reconhecer na hora o que está vendo.

O caminho da aula

BLOCO	SLIDES	PERGUNTA QUE O BLOCO RESPONDE
O problema de crédito	01 a 06	O que exatamente queremos prever, com que informação e para decidir o quê?
Regressão logística	07 a 20	Como uma soma de efeitos vira uma probabilidade entre 0% e 100%, e como se lê cada coeficiente?
Árvore de decisão	21 a 30	Como perguntas sucessivas separam grupos de risco, e o que sustenta a taxa de cada folha?
Gradient boosting	31 a 42	Como correções sucessivas, somadas no escore, constroem uma previsão melhor que a de uma árvore só?
Avaliação e decisão	43 a 50	Como comparar os três modelos com justiça e transformar probabilidades em política de crédito?

Os quatro clientes, o alvo e as variáveis

Ana, Bruno, Carla e Diego aparecem no slide 01, antes de qualquer modelo, e voltam no slide 50 com as três técnicas e a política aplicadas. As seis características de cada um são as mesmas do começo ao fim. Perfis fictícios, elegíveis, sem desfecho revelado.

Características no momento da proposta

CLIENTE	RENDA	COMPROMETIMENTO	RELACIONAMENTO	UTILIZAÇÃO	HISTÓRICO	CANAL
Ana	R\$ 7.000	22%	36 meses	30%	não	Agência
Bruno	R\$ 4.500	38%	8 meses	65%	sim	Digital
Carla	R\$ 10.000	48%	60 meses	85%	não	Digital
Diego	R\$ 3.500	55%	4 meses	90%	sim	Parceiro

O alvo

Evento: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação.

População: solicitantes elegíveis, sem inadimplência corrente na data da proposta. **Unidade:** contrato de crédito pessoal, um cliente por registro. **Horizonte:** 12 meses.

Dicionário das variáveis

VARIÁVEL	UNIDADE	DEFINIÇÃO	DISPONIBILIDADE
Renda	R\$ por mês	Renda verificada na proposta.	Conhecida até a decisão.
Comprometimento	%	Parcela mensal total, já incluindo a operação proposta, dividida pela renda verificada.	Calculável no momento da decisão.
Relacionamento	meses	Meses completos de relacionamento com a instituição.	Conhecido até a decisão.
Utilização	%	Uso dos limites já existentes.	Último dado disponível até a decisão.
Histórico	0 ou 1	Houve atraso de 15 a 89 dias nos 12 meses anteriores. Não é inadimplência corrente.	Histórico conhecido na decisão.
Canal	categoria	Agência, digital ou parceiro. Variável preditiva, sem leitura causal.	Registrado na proposta.

De onde vêm os números

ORIGEM	O QUE SUSTENTA
Logit manual de seis características	slides 07 a 20, com conta aberta e conferível a mão; coeficientes escolhidos para ensinar, não estimados em dados
Árvore didática de 1.000 contratos	slides 21 a 30; contagens e taxas das folhas conferem com a raiz
Miniatura de 10 registros	slides 31 a 36 e 42; taxa de aprendizagem igual a 1 para facilitar a leitura
Experimento sintético de 28.000 contratos	slides 05, 18, 27 a 29, 37 a 41 e 43 a 49; semente 20260920, versões e conferências no notebook
Economia declarada na tela	slide 47: margem de R\$ 1.200, EAD de R\$ 10.000 e LGD de 60%

Experimento sintético: 28.000 contratos, semente 20260920, numpy 2.4.6, scikit learn 1.9.1, python 3.11.15. Base sintética. Nenhum dado real de cliente. Os modelos são ajustados no treino, selecionados na validação, calibrados na partição de calibração e avaliados uma única vez no teste.

Mapa dos 50 slides

SLIDE	TÍTULO	BLOCO	PÁGINA
01	Você aprovaria estes quatro clientes?	O problema de crédito	7
02	O que sabemos no momento da proposta?	O problema de crédito	9
03	Probabilidade de quê, para quem e até quando?	O problema de crédito	10
04	Esse dado existia quando o crédito foi aprovado?	O problema de crédito	11
05	Aprender no passado, escolher sem olhar o teste	O problema de crédito	13
06	O mesmo cliente, três formas de aprender o risco	O problema de crédito	14
07	Cada informação altera o escore do cliente	Regressão logística	16
08	-2,025 não é uma probabilidade	Regressão logística	17
09	Um escore, uma probabilidade entre 0% e 100%	Regressão logística	18
10	10% de PD significa odds de 1 para 9	Regressão logística	19
11	Mais 10 pontos de comprometimento multiplicam as odds por 1,49	Regressão logística	20
12	Bruno: como chegamos à PD de 11,66%?	Regressão logística	21
13	O modelo aprende penalizando previsões incompatíveis com os dados	Regressão logística	22
14	Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor	Regressão logística	23
15	Canal digital não significa duas vezes agência	Regressão logística	24
16	O efeito pode se intensificar depois de um limite	Regressão logística	25
17	O comprometimento pesa igual para quem tem histórico de atraso?	Regressão logística	26
18	Coeficientes extremos podem estar aprendendo ruído	Regressão logística	27
19	Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade	Regressão logística	28
20	Bruno aumenta seu comprometimento de 38% para 48%. E agora?	Regressão logística	29
21	Houve atraso? Qual é o comprometimento?	Árvore de decisão	32
22	Nesta folha, 18 de 600 contratos ficaram inadimplentes	Árvore de decisão	33
23	Qual pergunta separa melhor os comportamentos observados?	Árvore de decisão	34
24	Histórico reduz o Gini de 0,180 para 0,160	Árvore de decisão	35
25	Duas folhas com PD de 10%. A evidência é igual?	Árvore de decisão	36
26	O mesmo aumento de comprometimento pode mudar de folha	Árvore de decisão	37
27	A árvore cresce. O resultado fora do treino acompanha?	Árvore de decisão	38
28	Três controles, três formas de conter o excesso de divisões	Árvore de decisão	39
29	Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?	Árvore de decisão	40
30	Carla recebe qual PD nesta árvore?	Árvore de decisão	41
31	E se uma árvore pequena ainda deixar estrutura nos erros?	Gradient boosting	44
32	A próxima árvore aprende a partir das previsões atuais	Gradient boosting	45

SLIDE	TÍTULO	BLOCO	PÁGINA
33	Dois eventos em dez contratos: começamos em 20%	Gradient boosting	46
34	A primeira correção reduz A e aumenta B	Gradient boosting	47
35	A primeira árvore mudou as previsões. Agora mudam os gradientes	Gradient boosting	48
36	Escore inicial mais árvore 1 mais árvore 2 é a nova PD	Gradient boosting	49
37	Learning rate e número de árvores precisam ser escolhidos juntos	Gradient boosting	50
38	Uma correção pode depender de uma característica ou da combinação de várias	Gradient boosting	51
39	Continuar melhorando o treino pode deixar de ajudar a validação	Gradient boosting	52
40	Mais flexibilidade exige mais disciplina de validação	Gradient boosting	53
41	O que o modelo usa em geral? O que pesou para Bruno?	Gradient boosting	54
42	Carla caiu no grupo B. Qual é a previsão?	Gradient boosting	55
43	Estamos comparando modelos ou comparando condições diferentes?	Avaliação e decisão	58
44	Quem aparece primeiro na fila de risco?	Avaliação e decisão	59
45	Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?	Avaliação e decisão	60
46	Até qual PD vamos aprovar?	Avaliação e decisão	61
47	Com estas hipóteses, o equilíbrio ocorre em PD de 20%	Avaliação e decisão	62
48	O que conseguimos monitorar agora? O que exige esperar?	Avaliação e decisão	63
49	Defenda sua recomendação para o comitê	Avaliação e decisão	64
50	Você consegue explicar, comparar e usar os três modelos?	Avaliação e decisão	66

BLOCO 1 DE 5 · SLIDES 01 A 06

1 O problema de crédito

O que exatamente queremos prever, com que informação e para decidir o quê?

O que você vai aprender

- Formular o alvo: evento, horizonte, população e unidade de análise.
- Separar a informação que existia na decisão da informação que só aparece depois.
- Dividir a base por calendário respeitando os 12 meses de maturação do alvo.
- Reconhecer que as três técnicas partem dos mesmos dados e do mesmo objetivo.

Ideias para levar

- Sem a mesma definição de inadimplência, duas PDs não são comparáveis.
- Vale a data em que a informação ficou disponível, não a data do fenômeno.
- O teste é avaliado uma única vez, com regras congeladas antes.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
01	Você aprovaria estes quatro clientes?	7
02	O que sabemos no momento da proposta?	9
03	Probabilidade de quê, para quem e até quando?	10
04	Esse dado existia quando o crédito foi aprovado?	11
05	Aprender no passado, escolher sem olhar o teste	13
06	O mesmo cliente, três formas de aprender o risco	14

Você aprovaria estes quatro clientes?

Crédito pessoal, horizonte de 12 meses

O PROBLEMA DE CRÉDITO

slide 01 de 50

Você aprovaria estes quatro clientes?

Crédito pessoal, horizonte de 12 meses

Ana
R\$ 7.000 por mês · comprometimento 22% ·
histórico não · utilização 30% · relacionamento
36 meses

Aprovar

Recusar

Preciso de mais informação

Bruno
R\$ 4.500 por mês · comprometimento 38% ·
histórico sim · utilização 65% · relacionamento 8
meses

Aprovar

Recusar

Preciso de mais informação

Carla
R\$ 10.000 por mês · comprometimento 48% ·
histórico não · utilização 85% · relacionamento
60 meses

Aprovar

Recusar

Preciso de mais informação

Diego
R\$ 3.500 por mês · comprometimento 55% ·
histórico sim · utilização 90% · relacionamento 4
meses

Aprovar

Recusar

Preciso de mais informação

Que informação faria você mudar de ideia?

Aprovar exige estimar risco e definir uma política.

Esquema conceitual; sem dados

COMO USAR
Escolha uma opção por cliente. A
seleção fica apenas neste
dispositivo e não vira estatística da
turma.
[Revelar mais informações](#)
O desafio da aula
[Reiniciar exemplo](#)

O desafio da aula
Estimar PD, comparar
modelos e transformar risco
em decisão.

Slide 01 como aparece na tela (estado revelado, com os controles e as etapas abertas). Quatro propostas de crédito pessoal com renda e comprometimento, cada uma com três opções de decisão.

A aula começa pelo problema, não pela técnica. Quatro propostas de crédito pessoal chegam ao mesmo tempo, cada uma com renda, comprometimento, histórico de atraso, utilização de limite e tempo de relacionamento. Ana tem a renda alta e o comprometimento mais baixo; Diego tem a renda mais baixa, comprometimento de 55% e atraso recente. Entre os dois, Bruno e Carla misturam sinais: Carla ganha R\$ 10.000 por mês, mas compromete 48% da renda e usa 85% dos limites. Nenhum deles tem desfecho conhecido. O que o slide pede é que você registre uma decisão por cliente e perceba que, sem uma estimativa de risco e sem uma regra de aprovação, a decisão vira opinião. É exatamente isso que os 49 slides seguintes constroem: estimar a PD com três técnicas, comparar as três e transformar risco em política.

NA TELA

Escolha Aprovar, Recusar ou Preciso de mais informação para cada cliente. A seleção fica apenas no seu dispositivo. "Revelar mais informações" mostra histórico, utilização e relacionamento; "O desafio da aula" resume o percurso.

Versão da aula 2b6298264377 · gerado em 22 de setembro de 2026 · dados sintéticos

7 de 71

EXERCÍCIO

Antes de qualquer modelo

Registre uma decisão por cliente e anote, em uma linha, a informação que faria você mudar de ideia.

1. Ana: R\$ 7.000 por mês, comprometimento 22%, sem histórico de atraso, utilização 30%, relacionamento 36 meses.
2. Bruno: R\$ 4.500 por mês, comprometimento 38%, com histórico de atraso, utilização 65%, relacionamento 8 meses.
3. Carla: R\$ 10.000 por mês, comprometimento 48%, sem histórico de atraso, utilização 85%, relacionamento 60 meses.
4. Diego: R\$ 3.500 por mês, comprometimento 55%, com histórico de atraso, utilização 90%, relacionamento 4 meses.

Aprovar exige estimar risco e definir uma política.

Esquema conceitual; sem dados

O que sabemos no momento da proposta?

Seis características por cliente, com unidade e momento de observação

O PROBLEMA DE CRÉDITO slide 02 de 50

O que sabemos no momento da proposta?

Seis características por cliente, com unidade e momento de observação

CLIENTE	Renda R\$ por mês	Comprometimento %	Relacionamento meses	Utilização %	Histórico 0 ou 1	Canal categoria
Ana	7.000	22	36	30	0	Agência
Bruno	4.500	38	8	65	1	Digital
Carla	10.000	48	60	85	0	Digital
Diego	3.500	55	4	90	1	Parceiro

Ana

Renda **R\$ 7.000**
Comprometimento **22%**
Relacionamento **36 meses**
Utilização **30%**
Histórico **não**
Canal **Agência**
Perfil fictício, elegível, sem desfecho revelado.

DICIONÁRIO

Selecione um cabeçalho para ver unidade, definição e momento de observação da variável.

[Comparar dois clientes](#) [Reiniciar exemplo](#)

Cada variável descreve uma dimensão do risco. Nenhuma decide sozinha.

Esquema conceitual; sem dados

Slide 02 como aparece na tela (estado revelado, com os controles e as etapas abertas). Tabela de quatro clientes por seis características, com ficha ampliada do cliente selecionado.

Tudo o que os modelos vão usar está nesta tabela: seis características por cliente, cada uma com unidade e momento de observação. Renda em reais por mês, verificada na proposta. Comprometimento em porcentagem da renda, já incluindo a parcela proposta. Relacionamento em meses completos. Utilização dos limites existentes, em porcentagem. Histórico como indicador 0 ou 1: houve atraso de 15 a 89 dias nos 12 meses anteriores, o que não é inadimplência corrente. Canal como categoria (agência, digital ou parceiro), variável preditiva sem leitura causal. Repare que nenhuma coluna decide sozinha: Carla tem a maior renda e também o segundo maior comprometimento. A ficha ampliada à direita mostra o cliente selecionado; o dicionário explica cada cabeçalho. Esses quatro perfis voltam em quase todos os slides, então vale memorizar os números de Bruno, o cliente que servirá de exemplo de cálculo.

NA TELA

Clique num nome para ampliar a ficha e num cabeçalho para ler unidade, definição e momento de observação. "Comparar dois clientes" coloca dois perfis lado a lado.

Cada variável descreve uma dimensão do risco. Nenhuma decide sozinha.

Esquema conceitual; sem dados

O PROBLEMA DE CRÉDITO · SLIDE 03 DE 50

Probabilidade de quê, para quem e até quando?

Atraso superior a 90 dias em qualquer momento dos 12 meses após a contratação

O PROBLEMA DE CRÉDITO slide 03 de 50

Probabilidade de quê, para quem e até quando?

Atraso superior a 90 dias em qualquer momento dos 12 meses após a contratação



Evento: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação.

População: solicitantes elegíveis, sem inadimplência corrente na proposta. Unidade: um contrato de crédito pessoal.

Data até a qual conhecemos os dados (mês desde a contratação)

 mês 12[Reiniciar exemplo](#)

Atingir exatamente 90 dias não satisfaz a definição. O evento exige mais de 90.

CONTRATO A**y = 1****CONTRATO B****y = 0****CONTRATO C****alvo incompleto**

Eixo horizontal: meses desde a contratação. Eixo vertical: atraso em dias.

Sem a mesma definição de inadimplência, duas PDs não são comparáveis.

Trajetórias ilustrativas de contratos fictícios; cálculo próprio

Slide 03 como aparece na tela (estado revelado, com os controles e as etapas abertas). Três trajetórias de atraso em dias ao longo de 12 meses, com linha de 90 dias e máscara do que ainda não foi observado.

Antes de estimar uma probabilidade é preciso dizer probabilidade de quê, para quem e até quando. A definição adotada na aula: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação, para solicitantes elegíveis sem inadimplência corrente, com um contrato de crédito pessoal como unidade. Os três contratos ilustram o que a definição faz. O contrato A cruza os 90 dias no mês 8 e recebe y igual a 1. O contrato B chega exatamente a 90 dias no mês 6 e volta a zero: como o evento exige mais de 90, ele termina a janela com y igual a 0. O contrato C foi contratado há 6 meses e a janela ainda não fechou: o alvo é desconhecido, e ele não pode entrar no treino. A conclusão vale para qualquer comparação de modelos ou de carteiras: com definições diferentes de inadimplência, duas PDs não são comparáveis.

NA TELA

Arraste o controle da data até a qual conhecemos os dados e veja a máscara avançar sobre os três contratos. Com menos de 12 meses, o contrato C fica sem alvo.

Sem a mesma definição de inadimplência, duas PDs não são comparáveis.

Trajetórias ilustrativas de contratos fictícios; cálculo próprio

Esse dado existia quando o crédito foi aprovado?

Classifique cada informação pela data em que ela ficou disponível

O PROBLEMA DE CRÉDITO slide 04 de 50

Esse dado existia quando o crédito foi aprovado?

Classifique cada informação pela data em que ela ficou disponível

Renda verificada: R\$ 4.500 por mês
disponibilidade: documento verificado 3 dias antes da proposta

Disponível na decisão

Informação do futuro

Histórico de atrasos: um atraso de 40 dias
disponibilidade: apurado nos 12 meses anteriores à proposta

Disponível na decisão

Informação do futuro

Utilização de limite: 65%
disponibilidade: último extrato fechado antes da proposta

Disponível na decisão

Informação do futuro

Comprometimento com a parcela proposta: 38%
disponibilidade: calculado na simulação da própria proposta

Disponível na decisão

Informação do futuro

Valor renegociado: R\$ 3.200
disponibilidade: registrado 3 meses depois da contratação

Disponível na decisão

Informação do futuro

Atraso máximo nos 12 meses seguintes: 95 dias
disponibilidade: apurado no fim da janela de 12 meses

Disponível na decisão

Informação do futuro

Consulta de bureau: score 480
disponibilidade: consultada 2 dias depois da inadimplência

Disponível na decisão

Informação do futuro

Uma variável excelente depois do evento pode ser inútil para decidir antes dele.

Registros didáticos de disponibilidade; cálculo próprio

A FRONTEIRA DA DECISÃO

Só entra no modelo o que já existia e já estava acessível no momento da proposta.

Conferir

[Reiniciar exemplo](#)

Nada é corrigido antes de conferir.

Slide 04 como aparece na tela (estado inicial, antes de conferir). Sete fichas de informação, cada uma com valor e data de disponibilidade, classificadas entre disponível na decisão e informação do futuro.

Este slide treina a pergunta mais importante da preparação de dados: essa informação existia e estava acessível no momento da proposta? Sete fichas trazem um valor e a data em que ele ficou disponível. Renda verificada três dias antes da proposta, histórico apurado nos 12 meses anteriores, utilização do último extrato fechado e comprometimento calculado na própria simulação estavam disponíveis na decisão. Valor renegociado três meses depois da contratação, atraso máximo apurado no fim da janela e consulta ao bureau feita dois dias depois da inadimplência são informação do futuro: descrevem o desfecho ou só existiram depois dele. A regra que resolve todos os casos: vale a data de disponibilidade da informação, não a data do fenômeno que ela descreve. Uma variável excelente para explicar o passado pode ser inútil, ou perigosa, para decidir antes do evento.

NA TELA

Classifique cada ficha como "Disponível na decisão" ou "Informação do futuro" e clique em Conferir. O placar mostra quantas ficaram certas.

Versão da aula 2b6298264377 · gerado em 22 de setembro de 2026 · dados sintéticos

11 de 71

EXERCÍCIO

Classifique as sete informações

Para cada ficha, marque se estava disponível na decisão ou se é informação do futuro. Justifique pela data de disponibilidade.

1. Renda verificada: R\$ 4.500 por mês (documento verificado 3 dias antes da proposta).
2. Histórico de atrasos: um atraso de 40 dias (apurado nos 12 meses anteriores à proposta).
3. Utilização de limite: 65% (último extrato fechado antes da proposta).
4. Comprometimento com a parcela proposta: 38% (calculado na simulação da própria proposta).
5. Valor renegociado: R\$ 3.200 (registrado 3 meses depois da contratação).
6. Atraso máximo nos 12 meses seguintes: 95 dias (apurado no fim da janela de 12 meses).
7. Consulta de bureau: score 480 (consultada 2 dias depois da inadimplência).

☐ Disponível na decisão☐ Informação do futuro

Uma variável excelente depois do evento pode ser inútil para decidir antes dele.

Registros didáticos de disponibilidade; cálculo próprio


Aprender no passado, escolher sem olhar o teste

Quatro partições, cada uma com 12 meses de maturação antes de o alvo existir

O PROBLEMA DE CRÉDITO slide 05 de 50

Aprender no passado, escolher sem olhar o teste

Quatro partições, cada uma com 12 meses de maturação antes de o alvo existir



MOMENTO DA DECISÃO

Pronto para ajustar

Pronto para calibrar

Pronto para testar

Erro comum

Com o alvo do teste completo, avaliamos uma única vez as regras já congeladas. O teste não escolhe nada.

[Reiniciar exemplo](#)

Barra sólida: contratações. Barra clara: os 12 meses até o alvo existir. Uma faixa apagada indica alvo ainda desconhecido na data da decisão.

Separar por calendário só funciona se respeitarmos quando cada resultado ficou disponível.

Experimento sintético; semente e versões no notebook

Slide 05 como aparece na tela (estado revelado, com os controles e as etapas abertas). Linha do tempo com quatro faixas de contratação, extensão clara de maturação de 12 meses e uma linha vertical de decisão.

O experimento sintético que sustenta a segunda metade da aula tem 28.000 contratos divididos por calendário em quatro partições. Treino: contratações de janeiro de 2018 a dezembro de 2019, 16.000 contratos, alvo completo em dezembro de 2020. Validação de ajuste: janeiro a junho de 2021, 4.000 contratos, alvo em junho de 2022. Calibração e política: agosto a dezembro de 2022, 3.000 contratos, alvo em dezembro de 2023. Teste final: fevereiro a julho de 2024, 5.000 contratos, alvo em julho de 2025. A barra clara depois de cada faixa são os 12 meses de maturação: só depois deles o desfecho existe. A linha vertical marca o momento da decisão; uma faixa apagada indica alvo ainda desconhecido nessa data. A separação por calendário reproduz a vida real, em que o modelo aprende no passado e é usado no futuro. E o teste tem uma regra: é avaliado uma única vez, com as escolhas já congeladas. O teste não escolhe nada.

NA TELA

Alterne entre "Pronto para ajustar", "Pronto para calibrar" e "Pronto para testar" para ver quais partições já têm alvo completo em cada momento. "Erro comum" mostra o que acontece quando o teste participa da escolha.

Separar por calendário só funciona se respeitarmos quando cada resultado ficou disponível.

Experimento sintético; semente e versões no notebook

O mesmo cliente, três formas de aprender o risco

A ficha de entrada é a mesma nos três mecanismos

O PROBLEMA DE CRÉDITO slide 06 de 50

O mesmo cliente, três formas de aprender o risco

A ficha de entrada é a mesma nos três mecanismos

Bruno

R\$ 4.500 por mês · comprometimento 38% · relacionamento 8 meses · utilização 65% · histórico sim

O que vamos verificar?

[Reiniciar exemplo](#)

Ordenar risco: o maior risco fica acima do menor?

Estimar probabilidades: 10% previsto vira cerca de 10% observado?

Apoiar a decisão: a política resultante melhora o resultado?

Regressão logística etapa 3 de 3

Combina efeitos em um escore

PD entre 0% e 100%

O escore vira probabilidade

[Etapas completas](#) [Reiniciar](#)

Árvore de decisão etapa 3 de 3

Separa clientes por perguntas

A taxa observada na folha

[Etapas completas](#) [Reiniciar](#)

Gradient boosting etapa 3 de 3

Acrescenta correções sucessivas ao escore

Só no fim o escore vira probabilidade

[Etapas completas](#) [Reiniciar](#)

Os dados e o objetivo são comuns. Muda a forma de construir a previsão.

Esquema conceitual; sem dados

Slide 06 como aparece na tela (estado revelado, com os controles e as etapas abertas). Três painéis com o mecanismo de cada técnica: soma ponderada com curva logística, percurso em árvore e contribuições sucessivas ao escore.

Bruno é o mesmo nos três painéis: R\$ 4.500 por mês, comprometimento 38%, relacionamento 8 meses, utilização 65%, histórico de atraso. O que muda é como cada técnica transforma essa ficha em probabilidade. A regressão logística combina as características num escore z , uma soma ponderada, e converte o escore em PD pela curva logística. A árvore faz perguntas sucessivas (houve atraso? o comprometimento passa de 40%) e atribui a taxa observada no grupo final. O gradient boosting parte de um escore inicial e acrescenta correções sucessivas, uma por árvore; só no fim o escore somado vira PD. Antes de comparar as técnicas, o slide fixa três perguntas que valem para todas: elas ordenam o risco? Estimam probabilidades na escala certa, de modo que 10% previsto vire cerca de 10% observado? Apoiam uma decisão que melhora o resultado? Guarde essas três perguntas: são os critérios do bloco final.

NA TELA

Avance as etapas de cada painel com "Próxima etapa" para ver o mecanismo se montar. "O que vamos verificar?" mostra as três perguntas comuns.

Os dados e o objetivo são comuns. Muda a forma de construir a previsão.

Esquema conceitual; sem dados

BLOCO 2 DE 5 · SLIDES 07 A 20

2 Regressão logística

Como uma soma de efeitos vira uma probabilidade entre 0% e 100%, e como se lê cada coeficiente?

O que você vai aprender

- Montar o escore z a partir do intercepto e das diferenças de cada característica para o perfil de referência.
- Converter o escore em probabilidade pela curva logística e transitar entre probabilidade, odds e log odds.
- Ler um coeficiente como multiplicador de odds, cuja tradução em PD depende do ponto de partida.
- Entender o que o ajuste minimiza, como categorias e não linearidades entram e por que se penaliza coeficientes.

Ideias para levar

- O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.
- Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.
- A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
07	Cada informação altera o escore do cliente	16
08	-2,025 não é uma probabilidade	17
09	Um escore, uma probabilidade entre 0% e 100%	18
10	10% de PD significa odds de 1 para 9	19
11	Mais 10 pontos de comprometimento multiplicam as odds por 1,49	20
12	Bruno: como chegamos à PD de 11,66%?	21
13	O modelo aprende penalizando previsões incompatíveis com os dados	22

SLIDE	TÍTULO	PÁGINA
14	Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor	23
15	Canal digital não significa duas vezes agência	24
16	O efeito pode se intensificar depois de um limite	25
17	O comprometimento pesa igual para quem tem histórico de atraso?	26
18	Coeficientes extremos podem estar aprendendo ruído	27
19	Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade	28
20	Bruno aumenta seu comprometimento de 38% para 48%. E agora?	29

REGRESSÃO LOGÍSTICA · SLIDE 07 DE 50


Cada informação altera o escore do cliente

Do perfil de referência às diferenças do cliente

REGRESSÃO LOGÍSTICA slide 07 de 50

Cada informação altera o escore do cliente

Do perfil de referência às diferenças do cliente

Cliente **Ana** **Bruno** Carla Diego

Perfil de referência: renda R\$ 5.000, comprometimento 30%, relacionamento 12 meses, utilização 40% e sem histórico de atraso. O intercepto vale para esse perfil.

CARACTERÍSTICA	CONTA coeficiente × (valor - referência)	CONTRIBUIÇÃO no escore z
Comprometimento (p.p.)	0,04 × (38 - 30)	+0,320
Histórico de atraso (indicador)	0,80 × (1 - 0)	+0,800
Relacionamento (meses)	-0,02 × (8 - 12)	+0,080
Utilização (p.p.)	0,01 × (65 - 40)	+0,250
Renda (R\$)	-0,00005 × (4500 - 5000)	+0,025
Intercepto (perfil de referência)	-3,50	

Recomeçar uma por vez

Mostrar todas

Reiniciar exemplo

z = -2,025

O sinal e o tamanho de cada contribuição dependem do coeficiente e da unidade da variável.

Exemplo didático de logit; cálculo próprio

Slide 07 como aparece na tela (estado revelado, com os controles e as etapas abertas). Waterfall das contribuições de cada característica ao escore, partindo do intercepto do perfil de referência.

A regressão logística começa com uma soma. Cada característica contribui com coeficiente vezes a diferença entre o valor do cliente e o valor do perfil de referência: renda R\$ 5.000, comprometimento 30%, relacionamento 12 meses, utilização 40% e sem histórico de atraso. O intercepto, menos 3,50, é o escore desse perfil. Para Bruno, comprometimento $0,04 \times (38 - 30) = +0,320$; histórico $0,80 \times (1 - 0) = +0,800$; relacionamento $-0,02 \times (8 - 12) = +0,080$, porque ter menos tempo que a referência aumenta o escore; utilização $0,01 \times (65 - 40) = +0,250$; renda $-0,00005 \times (4500 - 5000) = +0,025$. Somando ao intercepto, $z = -2,025$. O gráfico em cascata mostra cada parcela como um degrau. Dois detalhes importam para ler qualquer coeficiente: o sinal diz a direção, e o tamanho depende da unidade da variável (um ponto de comprometimento vale 0,04; um real de renda vale 0,00005). Comparar coeficientes crus entre variáveis de unidades diferentes não faz sentido.

$$z = \beta_0 + \sum_j \beta_j (x_j - \bar{x}_j)$$

Escore como intercepto mais a soma das contribuições, cada uma medida em relação ao perfil de referência.

NA TELA

Troque o cliente e veja as parcelas mudarem. "Recomeçar uma por vez" monta a cascata parcela a parcela.

O sinal e o tamanho de cada contribuição dependem do coeficiente e da unidade da variável.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 08 DE 50

-2,025 não é uma probabilidade


Uma previsão sem restrição pode sair do intervalo entre 0% e 100%

REGRESSÃO LOGÍSTICA slide 08 de 50

-2,025 não é uma probabilidade


Uma previsão sem restrição pode sair do intervalo entre 0% e 100%

OS ESCORES DOS QUATRO CLIENTES



PRECISAMOS DE UMA TRANSFORMAÇÃO


Em vez de restringir a reta, modelamos uma escala livre e a convertemos por uma função que nunca sai do intervalo. É a curva logística do próximo slide.



UMA RETA DIRETO NA PROBABILIDADE

exemplo do problema

$$p_{\text{reta}} = 0,10 + 0,03 (\text{comp} - 30)$$



Comprometimento

70 70%

previsão da reta: 130% · fora dos limites de probabilidade

Precisamos de uma transformação

Reiniciar exemplo

A PD precisa permanecer entre 0% e 100%, qualquer que seja o escore.

Exemplo didático de logit; cálculo próprio

Slide 08 como aparece na tela (estado revelado, com os controles e as etapas abertas). Reta numérica dos escores dos quatro clientes, régua de probabilidade sem correspondência e uma reta de probabilidade que sai dos limites.

O escore de Bruno é -2,025; o de Ana, -4,500; o de Carla, -3,540; o de Diego, -0,965. Nenhum deles é uma probabilidade: um escore pode ser qualquer número real, e uma reta ajustada direto na probabilidade não respeita os limites. O exemplo do painel direito mostra o problema: p igual a $0,10 + 0,03 \times (\text{comp} - 30)$ dá 130% para um comprometimento de 70% e valores negativos para comprometimentos baixos. A solução não é truncar a reta, e sim modelar uma escala livre (o escore) e converter esse escore por uma função que nunca sai do intervalo entre 0% e 100%. Essa função é a curva logística do próximo slide. A régua de probabilidade ainda sem correspondência, no meio do slide, é proposital: o escore e a probabilidade são escalas diferentes, e a ponte entre elas é o assunto seguinte.

NA TELA

Arraste o comprometimento e veja a reta sair dos limites. "Precisamos de uma transformação" mostra a curva que resolve o problema.

A PD precisa permanecer entre 0% e 100%, qualquer que seja o escore.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 09 DE 50


Um escore, uma probabilidade entre 0% e 100%

A curva logística converte qualquer número real em probabilidade

REGRESSÃO LOGÍSTICA slide 09 de 50

Um escore, uma probabilidade entre 0% e 100%

A curva logística converte qualquer número real em probabilidade



$$p = \frac{1}{1 + e^{-z}}$$

escore z **-2,025**PD **11,66%**

Leitura: aproximadamente 11,7 eventos em 100 exposições semelhantes, e não uma contagem garantida.

Escore do perfil de Bruno.

Escore z

-2,025 11,66%

Ana Bruno Carla Diego

Ampliar as PDs baixas (0% a 30%)

[Reiniciar exemplo](#)

A mesma variação de escore pode gerar mudanças muito diferentes de probabilidade.

Exemplo didático de logit; cálculo próprio

Slide 09 como aparece na tela (estado revelado, com os controles e as etapas abertas). Curva logística com ponto móvel, guias até os eixos e marcadores dos quatro clientes.

A curva logística converte qualquer escore em probabilidade: $p = 1 / (1 + e^{-z})$. Em z igual a 0 a probabilidade é 50%, a referência matemática da curva. Para z muito negativo a curva se aproxima de 0%; para z muito positivo, de 100%. Bruno, com z = -2,025, fica em 11,66%: aproximadamente 11,7 eventos em 100 exposições semelhantes, e não uma contagem garantida. Ana (-4,500) está em 1,10%, Carla (-3,540) em 2,82% e Diego (-0,965) em 27,59%. Observe o formato: a curva é quase plana nos extremos e íngreme no centro. Por isso a mesma variação de escore pode produzir mudanças muito diferentes de probabilidade, dependendo de onde o cliente está. Esse fato explica os slides 11 e 14.

$$p = \frac{1}{1 + e^{-z}}$$

Curva logística: converte o escore z em probabilidade entre 0% e 100%.

NA TELA

Arraste o escore e leia a PD; use "Ampliar as PDs baixas" para ver com detalhe a região entre 0% e 30%, onde os quatro clientes estão.

A mesma variação de escore pode gerar mudanças muito diferentes de probabilidade.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 10 DE 50

10% de PD significa odds de 1 para 9

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes

REGRESSÃO LOGÍSTICA slide 10 de 50

10% de PD significa odds de 1 para 9

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes

FREQUÊNCIA ESPERADA EM 100 EXPOSIÇÕES

10 eventos e 90 não eventos.
Representação ilustrativa, não 100 contratos com resultado garantido.

PROBABILIDADE

$10 / 100 = 10\%$
denominador: 100

ODDS

$10 / 90 = 0,1111$
denominador: 90

LOG ODDS

$\ln(0,1111) = -2,197$
É exatamente a escala em que o logit soma as contribuições: o escore z.

Probabilidade de inadimplência

odds 0,1111

Referências **10%** 20% 50% [Reiniciar exemplo](#)

CONVERSÕES NOS DOIS SENTIDOS

$$\text{odds} = \frac{p}{1-p}$$

$$p = \frac{\text{odds}}{1 + \text{odds}}$$

$$z = \ln\left(\frac{p}{1-p}\right)$$

$$p = \frac{1}{1 + e^{-z}}$$

Conferência de ida e volta: partindo de 10,00%, a volta por odds devolve 10,00% e a volta por log odds devolve 10,00%.

Nos limites 0% e 100% o log odds vai a infinito. Por isso a escala vai de 1% a 99%.

Odds comparam eventos e não eventos. Probabilidade compara eventos e total.

Exemplo didático de logit; cálculo próprio

Slide 10 como aparece na tela (estado revelado, com os controles e as etapas abertas). Grade de cem pontos com a quantidade esperada de eventos, frações de conversão e o logaritmo das odds.

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes. Com PD de 10%, esperamos 10 eventos e 90 não eventos em 100 exposições. A probabilidade compara eventos com o total: $10 / 100 = 10\%$. As odds comparam eventos com não eventos: $10 / 90 = 0,1111$, ou 1 para 9. O log odds é o logaritmo natural das odds: $\ln(0,1111) = -2,197$, e essa é exatamente a escala do escore z, onde o logit soma as contribuições. As quatro conversões do painel direito permitem ir e voltar: $\text{odds} = p / (1 - p)$, $p = \text{odds} / (1 + \text{odds})$, $z = \ln(p / (1 - p))$ e $p = 1 / (1 + e^{-z})$. Nos limites 0% e 100% o log odds vai a infinito, e é por isso que o controle vai de 1% a 99%. Domine essas conversões: o próximo slide mostra por que um coeficiente do logit é lido em odds, não em pontos de probabilidade.

$$\text{odds} = \frac{p}{1-p} \quad p = \frac{\text{odds}}{1 + \text{odds}}$$

Ida e volta entre probabilidade e odds.

$$z = \ln\left(\frac{p}{1-p}\right) \quad p = \frac{1}{1 + e^{-z}}$$

Ida e volta entre probabilidade e log odds, a escala do escore.

NA TELA

Arraste a probabilidade e acompanhe a grade de cem pontos, as odds e o log odds. Os botões 10%, 20% e 50% marcam referências úteis.

Odds comparam eventos e não eventos. Probabilidade compara eventos e total.

Exemplo didático de logit; cálculo próprio

Mais 10 pontos de comprometimento multiplicam as odds por 1,49


O mesmo multiplicador de odds gera mudanças diferentes de PD

REGRESSÃO LOGÍSTICA slide 11 de 50

Mais 10 pontos de comprometimento multiplicam as odds por 1,49

O mesmo multiplicador de odds gera mudanças diferentes de PD

$\Delta \text{comp} = +10 \text{ p.p.}$ $\Delta z = 0,04 \times 10 = 0,4000$ razão de chances = $e^{0,40} \approx 1,4918$



MUDANÇA APLICADA

+1 p.p. de comprometimento

+10 p.p. de comprometimento

Odds multiplicadas por 2

Exploração: variação de comprometimento

10 razão 1,4918

[Reiniciar exemplo](#)

PD INICIAL	ODDS ANTES	ODDS DEPOIS	PD DEPOIS	DIFERENÇA p.p.
2%	0,0204	0,0304	2,95%	+0,95 p.p.
10%	0,1111	0,1658	14,22%	+4,22 p.p.
40%	0,6667	0,9945	49,86%	+9,86 p.p.

Razão de chances de 1,49 não significa risco 49% maior. Odds e probabilidade são escalas diferentes.

Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.

Exemplo didático de logit; cálculo próprio

Slide 11 como aparece na tela (estado revelado, com os controles e as etapas abertas). Faixa de cálculo do multiplicador de odds e três pares de barras antes e depois para PDs iniciais de 2%, 10% e 40%.

Mais 10 pontos de comprometimento elevam o escore em $0,04 \times 10 = 0,40$, e isso multiplica as odds por $e^{0,40}$, aproximadamente 1,4918. O multiplicador é o mesmo para qualquer cliente; a mudança de PD não é. Partindo de 2%, as odds vão de 0,0204 para 0,0304 e a PD vai a 2,95%, mais 0,95 ponto. Partindo de 10%, as odds vão de 0,1111 para 0,1658 e a PD vai a 14,22%, mais 4,22 pontos. Partindo de 40%, as odds vão de 0,6667 para 0,9945 e a PD vai a 49,86%, mais 9,86 pontos. É a mesma conversão exata, cliente a cliente. Daí a regra de leitura: uma mudança na variável multiplica as odds, e a mudança de PD depende do ponto de partida. E o alerta do rodapé: razão de chances de 1,49 não significa risco 49% maior. Odds e probabilidade são escalas diferentes.

$$\Delta z = \beta \Delta x = 0,04 \times 10 = 0,40 \quad \frac{\text{odds}_{\text{depois}}}{\text{odds}_{\text{antes}}} = e^{\Delta z} = e^{0,40} \approx 1,4918$$

A razão de chances é o multiplicador das odds, não a variação da PD.

NA TELA

Compare "+1 p.p.", "+10 p.p." e "Odds multiplicadas por 2"; o controle de exploração aplica qualquer variação de comprometimento e recalcula a razão.

Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 12 DE 50

Bruno: como chegamos à PD de 11,66%?

Duas etapas auditáveis: somar o escore e aplicar a logística

REGRESSÃO LOGÍSTICA slide 12 de 50

Bruno: como chegamos à PD de 11,66%?

Duas etapas auditáveis: somar o escore e aplicar a logística

FICHA DO CLIENTE

perfil original

Ana Bruno Carla Diego

Renda em R\$ por mês

4500 R\$ 4.500

Comprometimento em %

38 38%

Relacionamento em meses

8 8 meses

Utilização em %

65 65%

Histórico de atraso de 15 a 89 dias

não sim

Canal: Digital. Informativo: não participa desta fórmula manual.

Restaurar Bruno

Reiniciar exemplo

ETAPA 1: SOMAR O ESCORE


PARCELA	CONTA	VALOR
Intercepto	perfil de referência	-3,500
Comprometimento	$0,04 \times (38 - 30)$	+0,320
Histórico de atraso	$0,80 \times (1 - 0)$	+0,800
Relacionamento	$-0,02 \times (8 - 12)$	+0,080
Utilização	$0,01 \times (65 - 40)$	+0,250
Renda	$-0,00005 \times (4500 - 5000)$	+0,025
Escore z	soma das parcelas	-2,025

ETAPA 2: APLICAR A LOGÍSTICA

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{2,025}}$$

11,66%

valor sem arredondamento: 0,1166029692

**O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.**

Exemplo didático de logit; cálculo próprio

Slide 12 como aparece na tela (estado revelado, com os controles e as etapas abertas). Ficha editável do cliente, decomposição do escore e medidor de PD com curva logística.

Este é o slide de referência para todo o bloco: a PD de Bruno em duas etapas auditáveis. Etapa 1, somar o escore: intercepto $-3,500$; comprometimento $0,04 \times (38 - 30) = +0,320$; histórico $0,80 \times (1 - 0) = +0,800$; relacionamento $-0,02 \times (8 - 12) = +0,080$; utilização $0,01 \times (65 - 40) = +0,250$; renda $-0,00005 \times (4500 - 5000) = +0,025$. Soma: $z = -2,025$. Etapa 2, aplicar a logística: $p = 1 / (1 + e^{\text{elevado a } 2,025}) = 11,66\%$, ou $0,1166029692$ sem arredondamento. O canal de Bruno é digital, mas ele não participa desta fórmula manual; o slide 15 mostra como uma categoria entraria. A ficha é editável de propósito: mude uma característica e veja a parcela correspondente, o escore e a PD se recalcularem. Faça isso com o comprometimento em 48% antes de chegar ao exercício do slide 20.

$$z = -3,50 + 0,04 (38 - 30) + 0,80 (1 - 0) - 0,02 (8 - 12) + 0,01 (65 - 40) - 0,00005 (4500 - 5000) = -2,025$$

Etapa 1: a soma das parcelas de Bruno.

$$p = \frac{1}{1 + e^{2,025}} = 11,66\%$$

Etapa 2: a logística aplicada ao escore.

NA TELA

Edite qualquer característica pelos controles ou troque de cliente. "Restaurar Bruno" volta ao perfil original.

O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 13 DE 50



O modelo aprende penalizando previsões incompatíveis com os dados

Perda logarítmica de uma observação, em função da probabilidade prevista

REGRESSÃO LOGÍSTICA slide 13 de 50

O modelo aprende penalizando previsões incompatíveis com os dados

Perda logarítmica de uma observação, em função da probabilidade prevista

OBSERVAÇÃO COM Y = 1 (HOUE EVENTO)**OBSERVAÇÃO COM Y = 0 (NÃO HOUE EVENTO)**

$$L = -[y \ln p + (1 - y) \ln(1 - p)]$$

observação **y = 1**
 previsão **10,0%**
 perda **2,3026**

Probabilidade prevista

 perda 2,3026

Desfecho observado

☐ y = 0 ☒ y = 1
[Esconder a amostra](#)[Reiniciar exemplo](#)

OBSERVAÇÃO	y	p prevista	L
nº 1	0	5%	0,0513
nº 2	0	10%	0,1054
nº 3	0	20%	0,2231
nº 4	0	40%	0,5108
nº 5	1	60%	0,5108
nº 6	1	80%	0,2231
Média			0,2708

O QUE O AJUSTE MINIMIZA

$$L(\beta) = \frac{1}{n} \sum_{i=1}^n -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

A média das perdas dos 6 contratos, e não a perda de uma observação. Os coeficientes são os que dão o menor valor dela.

A log loss pune previsões confiantes que contradizem o que ocorreu.

Exemplo didático de logit; cálculo próprio

Slide 13 como aparece na tela (estado revelado, com os controles e as etapas abertas). Duas curvas de perda individual em função da probabilidade prevista, uma para y igual a 1 e outra para y igual a 0.

Como o modelo escolhe os coeficientes? Penalizando previsões incompatíveis com o que ocorreu. A perda logarítmica de uma observação é $L = -[y \ln p + (1 - y) \ln(1 - p)]$. Se houve evento (y igual a 1) e o modelo previu 10%, a perda é $-\ln(0,10) = 2,3026$; se tivesse previsto 90%, seria 0,1054. Se não houve evento (y igual a 0), a perda cresce quando a previsão se aproxima de 100%. A tabela dos seis contratos mostra as perdas individuais: uma observação sem evento prevista em 5% custa 0,0513; uma com evento prevista em 60% custa 0,5108; a média das seis é 0,2708. O ajuste minimiza essa média sobre todos os contratos do treino, não a perda de uma observação. As curvas dizem o essencial: a log loss pune com força previsões confiantes que contradizem o desfecho, e é indiferente a acertos que já eram prováveis.

$$L = -[y \ln p + (1 - y) \ln(1 - p)]$$

Perda de uma observação com desfecho y e probabilidade prevista p.

$$L(\beta) = \frac{1}{n} \sum_{i=1}^n -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

O que o ajuste minimiza: a média das perdas do treino.

NA TELA

Arraste a probabilidade prevista e alterne y igual a 0 ou 1 para ver a perda de uma observação. "Mostrar a amostra" abre a tabela dos seis contratos.

A log loss pune previsões confiantes que contradizem o que ocorreu.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 14 DE 50


Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

O mesmo deslocamento horizontal produz alturas diferentes na sigmoide

REGRESSÃO LOGÍSTICA slide 14 de 50

Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

O mesmo deslocamento horizontal produz alturas diferentes na sigmoide



$$\Delta_{comp} = 10 \text{ p.p.} \Rightarrow \Delta z = 0,04 \times 10 = 0,400$$

$$p : 10,00\% \rightarrow 14,22\% \quad (4,22 \text{ p.p.})$$

PD inicial

2% 10% 40%

ou valor livre, de 1% a 60%

10 +4,22 p.p.

Mudança em comprometimento, em pontos

10 $\Delta z = 0,400$

Esconder a aproximação local

[Reiniciar exemplo](#)

PD INICIAL	VARIAÇÃO EXATA p.p.	APROXIMAÇÃO LOCAL p.p.	DIFERENÇA p.p.
2%	+0,955 p.p.	+0,784 p.p.	-0,171 p.p.
10%	+4,219 p.p.	+3,600 p.p.	-0,619 p.p.
40%	+9,863 p.p.	+9,600 p.p.	-0,263 p.p.

 $\frac{\partial p}{\partial_{comp}} = \beta p(1-p) = 0,04 p(1-p)$ em probabilidade por ponto percentual; vale para mudanças pequenas.
A resposta em probabilidade é mais intensa na região central da curva.

Exemplo didático de logit; cálculo próprio

Slide 14 como aparece na tela (estado revelado, com os controles e as etapas abertas). Sigmoide com três segmentos destacados, partindo de PDs de 2%, 10% e 40%, e comparação entre variação exata e aproximação pela tangente.

O mesmo deslocamento de 0,40 no escore produz alturas diferentes na sigmoide. A partir de 2%, a PD sobe 0,955 ponto; a partir de 10%, 4,219 pontos; a partir de 40%, 9,863 pontos. A tabela compara a variação exata com a aproximação pela derivada, $\beta p(1-p)$ por ponto percentual de comprometimento: 0,784, 3,600 e 9,600 pontos, respectivamente. A aproximação local é boa para mudanças pequenas e subestima a variação quando a curva se encurva ao longo do trecho; em 10% a diferença é de 0,619 ponto. A leitura para a prática: a resposta em probabilidade é mais intensa na região central da curva, perto de 50%, e mais suave nas caudas. Quando alguém pedir "o efeito de um ponto de comprometimento na PD", a resposta honesta é: depende do ponto de partida do cliente.

$$\frac{\partial p}{\partial_{comp}} = \beta p(1-p) = 0,04 p(1-p)$$

Efeito marginal em probabilidade por ponto percentual: vale para mudanças pequenas.

NA TELA

Escolha a PD inicial (2%, 10%, 40% ou valor livre de 1% a 60%) e a mudança em comprometimento; "Mostrar a aproximação local" desenha a tangente.

A resposta em probabilidade é mais intensa na região central da curva.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 15 DE 50

Canal digital não significa duas vezes agência

Categorias entram por comparação com uma referência

REGRESSÃO LOGÍSTICA slide 15 de 50

Canal digital não significa duas vezes agência


Categorias entram por comparação com uma referência

REFERÊNCIA ATUAL: AGÊNCIA

extensão pedagógica da fórmula

$$z = -3,50 + 0,30 \cdot 1[\text{digital}] + 0,60 \cdot 1[\text{parceiro}]$$

CANAL	INDICADOR DIGITAL	INDICADOR PARCEIRO	CONTRIBUIÇÃO no escore	ESCORE Z	PD
Agência	0	0	0,00	-3,50	2,93%
Digital	1	0	+0,30	-3,20	3,92%
Parceiro	0	1	+0,60	-2,90	5,22%

**O QUE 1, 2 E 3 IMPORIA**

Usar canal = 1, 2 e 3 em uma única variável imporia que a diferença entre agência e digital é igual à diferença entre digital e parceiro, e que a ordem econômica existe. Nada nos dados garante isso.

Canal do cliente

☒ Agência
 ☐ Digital
 ☐ Parceiro

☒ Referência: Agência
 ☐ Referência: Digital

☐ Referência: Parceiro
[Reiniciar exemplo](#)

Trocar a referência muda o intercepto e os coeficientes. As três PDs permanecem 2,93%, 3,92% e 5,22% em qualquer parametrização.

O número atribuído a uma categoria não deve inventar uma ordem econômica.

Extensão pedagógica da fórmula manual; cálculo próprio

Slide 15 como aparece na tela (estado revelado, com os controles e as etapas abertas). Três categorias de canal, tabela de indicadores e contribuição adicional ao escore, com troca da categoria de referência.

Categorias entram no logit por comparação com uma referência, nunca como números 1, 2 e 3. Com agência como referência, o canal entra por dois indicadores: $z = -3,50 + 0,30 \times 1[\text{digital}] + 0,60 \times 1[\text{parceiro}]$. Para o perfil de referência, isso dá escore -3,50 e PD 2,93% na agência, -3,20 e 3,92% no digital, -2,90 e 5,22% no parceiro. Trocar a referência muda o intercepto e os coeficientes, mas as três PDs permanecem 2,93%, 3,92% e 5,22% em qualquer parametrização: a previsão não depende de qual categoria você chamou de base. Usar canal = 1, 2 e 3 numa única variável imporia que a diferença entre agência e digital é igual à diferença entre digital e parceiro, e que existe uma ordem econômica entre eles. Nada nos dados garante isso. É uma extensão pedagógica da fórmula manual: no cálculo de Bruno, no slide 12, o canal não participa.

$$z = -3,50 + 0,30 \cdot 1[\text{digital}] + 0,60 \cdot 1[\text{parceiro}]$$

Indicadores em relação à referência agência; cada categoria recebe a sua contribuição.

NA TELA

Troque o canal do cliente e a categoria de referência e confira que os coeficientes mudam enquanto as PDs ficam iguais.

O número atribuído a uma categoria não deve inventar uma ordem econômica.

Extensão pedagógica da fórmula manual; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 16 DE 50



O efeito pode se intensificar depois de um limite

Linearidade é nos parâmetros, não na forma das variáveis

REGRESSÃO LOGÍSTICA slide 16 de 50

O efeito pode se intensificar depois de um limite

Linearidade é nos parâmetros, não na forma das variáveis



$$z = -3,50 + 0,04 (\text{comp} - 30) + 0,04 \max(\text{comp} - 40, 0)$$

Comprometimento

55 13,01%

[Voltar à forma linear](#)[Ver como entra na equação](#)[Reiniciar exemplo](#)**INCLINAÇÃO POR FAIXA**

FAIXA	INCLINAÇÃO NO ESCORE por ponto
comprometimento até 40%	0,04
comprometimento acima de 40%	0,08

No nó, as duas formas coincidem: contribuição 0,400 em ambos os casos. A função é contínua.

A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Cenário separado da fórmula manual; cálculo próprio

Slide 16 como aparece na tela (estado revelado, com os controles e as etapas abertas). Contribuição ao escore e PD resultante em função do comprometimento, com e sem mudança de inclinação em 40%.

Linearidade é nos parâmetros, não na forma das variáveis. O cenário separado deste slide acrescenta um nó em 40% de comprometimento: $z = -3,50 + 0,04 (\text{comp} - 30) + 0,04 \max(\text{comp} - 40, 0)$. Até 40% a inclinação no escore é 0,04 por ponto; acima, 0,08. No nó as duas formas coincidem, com contribuição 0,400, e a função é contínua. Em comprometimento de 55%, a forma flexível dá contribuição 1,600 e PD de 13,01% para o perfil de referência, contra a reta pontilhada da forma linear. O modelo continua sendo um logit: os coeficientes entram somando, e é isso que o ajuste estima. O que mudou foi a variável, transformada para permitir que o efeito se intensifique depois de um limite. Splines, logaritmos e faixas fazem o mesmo. A escolha dessas formas é do analista, e por isso precisa ser documentada e validada fora do tempo.

$$z = -3,50 + 0,04 (\text{comp} - 30) + 0,04 \max(\text{comp} - 40, 0)$$

Um nó em 40%: a inclinação passa de 0,04 para 0,08 por ponto, sem descontinuidade.

NA TELA

Arraste o comprometimento e alterne entre a forma linear e a forma com nó; "Ver como entra na equação" mostra o termo adicional.

A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Cenário separado da fórmula manual; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 17 DE 50



O comprometimento pesa igual para quem tem histórico de atraso?

Interação é diferença de inclinação na escala do escore

REGRESSÃO LOGÍSTICA slide 17 de 50

O comprometimento pesa igual para quem tem histórico de atraso?

Interação é diferença de inclinação na escala do escore



$$z = -3,50 + 0,80 \text{ hist} + (0,04 + \delta \text{ hist})(\text{comp} - 30)$$

sem interação **interação de 0,03**

Comprometimento

termo 0,300

Ver o termo cruzado

[Reiniciar exemplo](#)

EM COMPROMETIMENTO DE 40%

inclinações **0,04 e 0,07 por ponto**

diferença no escore **1,100**

diferença em PD **+7,61 p.p.**

Mesmo sem interação, a diferença em PD varia com o comprometimento: a sigmoide é não linear.

Com interação, o efeito do comprometimento no escore depende do histórico.

Cenário separado da fórmula manual; cálculo próprio

Slide 17 como aparece na tela (estado revelado, com os controles e as etapas abertas). Duas retas de escore por comprometimento, uma para cada valor de histórico, e as curvas de PD correspondentes.

Uma interação é uma diferença de inclinação na escala do escore. No cenário do slide, $z = -3,50 + 0,80 \text{ hist} + (0,04 + \delta \text{ hist})(\text{comp} - 30)$: para quem tem histórico de atraso, cada ponto de comprometimento vale $0,04 + \delta$. Com δ igual a $0,03$, em comprometimento de 40% as inclinações são $0,04$ e $0,07$ por ponto, os escores são $-3,10$ (sem histórico) e $-2,00$ (com histórico), diferença de $1,100$ no escore, e as PDs são $4,3\%$ e $11,9\%$, diferença de $7,61$ pontos. Um detalhe que engana: mesmo sem interação, a diferença em PD entre as duas curvas varia com o comprometimento, porque a sigmoide é não linear. A interação existe quando as retas do painel esquerdo, na escala do escore, têm inclinações diferentes. É lá que se enxerga o termo cruzado.

$$z = -3,50 + 0,80 \text{ hist} + (0,04 + \delta \text{ hist})(\text{comp} - 30)$$

Com δ diferente de zero, a inclinação do comprometimento depende do histórico.**NA TELA**

Alterne "sem interação" e "interação de 0,03", arraste o comprometimento e veja as duas escalas. "Ver o termo cruzado" destaca o produto $\text{hist} \times (\text{comp} - 30)$.

Com interação, o efeito do comprometimento no escore depende do histórico.

Cenário separado da fórmula manual; cálculo próprio


Coeficientes extremos podem estar aprendendo ruído

Trajетórias de coeficientes e perdas, na grade de penalização efetivamente treinada

REGRESSÃO LOGÍSTICA slide 18 de 50

Coeficientes extremos podem estar aprendendo ruído

Trajетórias de coeficientes e perdas, na grade de penalização efetivamente treinada



A melhor explicação do treino pode ser sensível demais para funcionar fora dele.

Experimento sintético; semente e versões no notebook

Slide 18 como aparece na tela (estado revelado, com os controles e as etapas abertas). Trajetórias de coeficientes padronizados em função da força da penalização e curvas de perda de treino e validação.

Coeficientes extremos podem estar aprendendo ruído. A regularização acrescenta à perda uma penalidade sobre o tamanho dos coeficientes, $1/(2C)$ vezes a soma dos quadrados: quanto menor C, maior a força e mais os coeficientes encolhem. As trajetórias do painel esquerdo, em coeficientes padronizados, mostram isso ao longo da grade efetivamente treinada. O painel direito compara a perda de treino com a de validação. Na amostra reduzida de 600 contratos, com a especificação flexível, a perda de treino continua caindo enquanto a de validação sobe: a melhor explicação do treino é sensível demais para funcionar fora dele. O mínimo de validação ocorre em $C = 0,0100$, força 100, com log loss de validação 0,35472, log loss de treino 0,32275 e AUC de validação 0,7170. O teste final não participa dessa escolha: a validação escolhe, o teste só confirma uma vez.

$$L_{\text{pen}} = L + \frac{1}{2C} \sum_j \beta_j^2$$

Perda penalizada: C menor significa força maior e coeficientes menores.

NA TELA

Arraste C apenas nos valores treinados e alterne "Amostra reduzida" e "Treino completo" para ver quando a penalização faz diferença.

A melhor explicação do treino pode ser sensível demais para funcionar fora dele.

Experimento sintético; semente e versões no notebook

REGRESSÃO LOGÍSTICA · SLIDE 19 DE 50


Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Adequação do logit em três situações práticas

REGRESSÃO LOGÍSTICA slide 19 de 50

Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Adequação do logit em três situações práticas



As faixas observadas caem sobre as duas curvas, e a distância entre elas é a mesma em toda a extensão. É o que uma soma de efeitos produz.

Curvas: o logit manual desta aula, no perfil de referência. Pontos: faixas ilustrativas escritas para a situação selecionada, não são dados observados.

FORÇAS

- função compacta e auditável
- interpretação condicionada à codificação
- previsão rápida e fácil de implantar
- regularização e transformações disponíveis

LIMITES

- a forma funcional é escolhida, não descoberta
- variáveis ausentes ou mal medidas continuam ausentes
- extrapolação fora da faixa observada é frágil
- correlação entre atributos dificulta a leitura de um coeficiente
- mudança de população desloca o nível da previsão

SITUAÇÃO**Sinal predominantemente aditivo****Interação relevante omitida****Amostra pequena ou instável****Critérios de escolha**

As características somam efeitos de forma estável e as faixas de risco crescem de forma regular.

PERGUNTA DE DIAGNÓSTICO

As curvas de risco por faixa são compatíveis com uma soma de efeitos na escala do escore?

Ação possível. Manter o logit como referência, documentar a especificação e verificar calibração fora do tempo.

[Reiniciar exemplo](#)**O logit oferece uma estrutura explícita, mas a qualidade depende da especificação e da validação.**

Síntese conceitual aplicada; sem dados

Slide 19 como aparece na tela (estado revelado, com os controles e as etapas abertas). Risco por faixa de comprometimento com as duas curvas do logit ao centro, três situações práticas de adequação e uma síntese de critérios de escolha.

O logit oferece uma estrutura explícita: função compacta e auditável, interpretação condicionada à codificação, previsão rápida e fácil de implantar, regularização e transformações disponíveis. Os limites vêm da mesma origem: a forma funcional é escolhida, não descoberta; variáveis ausentes ou mal medidas continuam ausentes; a extrapolação fora da faixa observada é frágil; correlação entre atributos dificulta a leitura de um coeficiente; mudança de população desloca o nível da previsão. Três situações práticas mostram como decidir. Sinal predominantemente aditivo: pergunte se as curvas de risco por faixa são compatíveis com uma soma de efeitos na escala do escore e, se forem, mantenha o logit como referência, documente a especificação e verifique calibração fora do tempo. Interação relevante omitida e amostra pequena ou instável têm perguntas e ações próprias. Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade.

NA TELA

Escolha cada situação para ler a pergunta de diagnóstico e a ação possível; "Critérios de escolha" resume o que decide entre manter o logit e testar outra técnica.

O logit oferece uma estrutura explícita, mas a qualidade depende da especificação e da validação.

Síntese conceitual aplicada; sem dados

Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exercício: acompanhar a escala do escore e a escala da probabilidade

REGRESSÃO LOGÍSTICA slide 20 de 50

Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exercício: acompanhar a escala do escore e a escala da probabilidade

Bruno

Renda

R\$ 4.500

Comprometimento

38%

Relacionamento

8 meses

Utilização

65%

Histórico

sim

Canal

Digital

Uma única alteração: comprometimento de 38% para 48%.

perfil original

REVISÃO RÁPIDA

[Rever a razão de chances \(slide 11\)](#)

[Rever a calculadora de PD \(slide 12\)](#)

A escolha feita aqui é preservada ao voltar.

ESCOLHA UMA ALTERNATIVA

A A PD sobe 10 pontos percentuais.

B O escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.

C A PD é multiplicada por e elevado a 0,40.

Conferir

Resolver passo a passo

Desafio opcional

[Reiniciar exercício](#)

1. VARIAÇÃO DA CARACTERÍSTICA

etapa ainda não revelada

2. VARIAÇÃO DO ESCORE

etapa ainda não revelada

3. EFEITO NAS ODDS

etapa ainda não revelada

4. NOVA PROBABILIDADE

etapa ainda não revelada

Entender o logit exige acompanhar a escala do escore e a escala da probabilidade.

Exemplo didático de logit; cálculo próprio

Slide 20 como aparece na tela (estado inicial, antes de conferir). Perfil de Bruno com uma única alteração destacada e três alternativas de interpretação.

O exercício fecha o bloco com o perfil de Bruno e uma única alteração: o comprometimento passa de 38% para 48%. As três alternativas testam a confusão mais comum da regressão logística. Resolva em quatro etapas, como a solução do slide: variação da característica, variação do escore (coeficiente vezes a variação), efeito nas odds (multiplicação por e elevado à variação do escore) e nova probabilidade (a volta pela logística). Use os números do slide 12 como ponto de partida: escore $-2,025$ e PD 11,66%. O desafio opcional é um cenário separado, independente do aumento de comprometimento: Bruno sem o histórico de atraso, mantendo tudo o mais igual. Escreva cada etapa antes de conferir na tela.

NA TELA

Escolha uma alternativa e clique em Conferir; "Resolver passo a passo" abre as quatro etapas uma a uma; "Desafio opcional" mostra o cenário sem histórico.

EXERCÍCIO**Bruno passa de 38% para 48% de comprometimento. O que muda na PD?**

Marque a alternativa correta e depois preencha as quatro etapas com os seus números.

- A. A PD sobe 10 pontos percentuais.
- B. O escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.
- C. A PD é multiplicada por e elevado a 0,40.

ETAPAS

1. Variação da característica: $\Delta_{\text{comp}} = \underline{\hspace{2cm}}$ pontos
2. Variação do escore: $\Delta z = 0,04 \times \underline{\hspace{2cm}} = \underline{\hspace{2cm}}$, de -2,025 para $\underline{\hspace{2cm}}$
3. Efeito nas odds: odds passam de $\underline{\hspace{2cm}}$ para $\underline{\hspace{2cm}}$, multiplicadas por $\underline{\hspace{2cm}}$
4. Nova probabilidade: $p = 1 / (1 + e \text{ elevado a } \underline{\hspace{2cm}}) = \underline{\hspace{2cm}}\%$, diferença de $\underline{\hspace{2cm}}$ p.p.

DESAFIO

Cenário separado: Bruno sem o histórico de atraso, com comprometimento em 38% e os demais valores originais. Qual é o novo escore e a nova PD? E o que esse cálculo diz, ou não diz, sobre o efeito causal de remover o atraso do cadastro?

Entender o logit exige acompanhar a escala do escore e a escala da probabilidade.

Exemplo didático de logit; cálculo próprio

BLOCO 3 DE 5 · SLIDES 21 A 30

3 Árvore de decisão

Como perguntas sucessivas separam grupos de risco, e o que sustenta a taxa de cada folha?

O que você vai aprender

- Percorrer uma árvore: raiz, nós, ramos e folhas, com a PD igual à frequência observada no grupo.
- Escolher uma divisão pelo ganho de impureza de Gini, ponderado pelo tamanho de cada lado.
- Ler a incerteza de uma folha pelo intervalo de Wilson e o efeito do tamanho mínimo por folha.
- Controlar a complexidade por profundidade, mínimo por folha e poda, e testar a estabilidade entre reamostragens.

Ideias para levar

- A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.
- Não basta uma folha pura: importa como toda a amostra fica depois da divisão.
- Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
21	Houve atraso? Qual é o comprometimento?	32
22	Nesta folha, 18 de 600 contratos ficaram inadimplentes	33
23	Qual pergunta separa melhor os comportamentos observados?	34
24	Histórico reduz o Gini de 0,180 para 0,160	35
25	Duas folhas com PD de 10%. A evidência é igual?	36

SLIDE	TÍTULO	PÁGINA
26	O mesmo aumento de comprometimento pode mudar de folha	37
27	A árvore cresce. O resultado fora do treino acompanha?	38
28	Três controles, três formas de conter o excesso de divisões	39
29	Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?	40
30	Carla recebe qual PD nesta árvore?	41


Houve atraso? Qual é o comprometimento?

Uma árvore organiza a previsão em perguntas sucessivas

ÁRVORE DE DECISÃO slide 21 de 50

Houve atraso? Qual é o comprometimento?

Uma árvore organiza a previsão em perguntas sucessivas



As perguntas e seus limites são aprendidos dos dados. Aqui usamos uma árvore pequena para enxergar o mecanismo. As folhas ainda não mostram PD: primeiro a estrutura.

Ana

Comprometimento **22%**

Histórico

não

Só estas duas entram nas perguntas desta árvore.

Cliente

Ana Bruno Carla Diego

Próximo passo

Reiniciar exemplo

PERCURSO

1. A raiz pergunta pelo histórico.
2. Resposta de Ana: hist = 0.
3. Segundo nó: comp ≤ 40%. Chega à folha.

Regra completa da folha: hist = 0 e comp ≤ 40%.

Raiz: primeira pergunta. Nó: qualquer pergunta. Ramo: resposta que leva adiante. Folha: grupo final, onde a previsão é atribuída.

A árvore encaminha clientes semelhantes para uma mesma estimativa de risco.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 21 como aparece na tela (estado revelado, com os controles e as etapas abertas). Árvore de profundidade dois: histórico na raiz e comprometimento em cada ramo, com o percurso de um cliente destacado.

Uma árvore organiza a previsão em perguntas sucessivas. A raiz pergunta se houve atraso de 15 a 89 dias; cada ramo leva a uma segunda pergunta, se o comprometimento passa de 40%; e cada resposta termina numa folha, o grupo de contratos que satisfaz as mesmas regras. Ana responde hist igual a 0 na raiz e comp de 22%, até 40%, no segundo nó: chega à folha cuja regra completa é hist igual a 0 e comp até 40%. Só essas duas características entram nas perguntas desta árvore; renda, utilização e relacionamento ficam de fora, o que já antecipa uma propriedade importante: dois clientes com rendas muito diferentes podem receber a mesma previsão. O vocabulário fica fixado aqui. Raiz é a primeira pergunta; nó é qualquer pergunta; ramo é a resposta que leva adiante; folha é o grupo final, onde a previsão é atribuída. As perguntas e seus limites são aprendidos dos dados; a árvore pequena serve para enxergar o mecanismo.

NA TELA

Escolha o cliente e avance com "Próximo passo" para percorrer a árvore pergunta a pergunta. O painel Percurso registra cada resposta.

A árvore encaminha clientes semelhantes para uma mesma estimativa de risco.

Árvore didática de 1.000 contratos; cálculo próprio


Nesta folha, 18 de 600 contratos ficaram inadimplentes

A PD da folha é a frequência observada no grupo

ÁRVORE DE DECISÃO slide 22 de 50

Nesta folha, 18 de 600 contratos ficaram inadimplentes

A PD da folha é a frequência observada no grupo



FOLHA	N	EVENTOS	PD
hist = 0 e comp ≤ 40%	600	18	3%
hist = 0 e comp > 40%	200	22	11%
hist = 1 e comp ≤ 40%	80	12	15%
hist = 1 e comp > 40%	120	48	40%
Soma das folhas	1.000	100	10%

FOLHA DE ANA

árvore didática

hist = 0 e comp ≤ 40%

$$\hat{p} = \frac{d}{n} = \frac{18}{600} = 3\%$$

3,0%

Barra vermelha: contratos com evento. Barra clara: contratos sem evento.

Cliente

Ana Bruno Carla Diego

Leitura simples, só a taxa

Reiniciar exemplo

CONFERÊNCIA

As quatro folhas somam 1.000 contratos e 100 eventos, exatamente os totais da raiz.

Mesma folha, mesma previsão: dois clientes com rendas diferentes recebem a mesma PD, porque a renda não participa das perguntas desta árvore.

A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 22 como aparece na tela (estado revelado, com os controles e as etapas abertas). Árvore de 1.000 contratos com contagens em cada nó e PD por folha, com o percurso do cliente selecionado.

A PD de uma folha é a frequência observada no grupo. Na árvore didática de 1.000 contratos com 100 eventos (taxa 10%), a raiz separa 800 contratos sem histórico (40 eventos, PD 5%) de 200 com histórico (60 eventos, PD 30%). Depois do comprometimento, as quatro folhas ficam assim: hist 0 e comp até 40%, 600 contratos e 18 eventos, PD 3%; hist 0 e comp acima de 40%, 200 e 22, PD 11%; hist 1 e comp até 40%, 80 e 12, PD 15%; hist 1 e comp acima de 40%, 120 e 48, PD 40%. A conferência vale a pena: as folhas somam 1.000 contratos e 100 eventos, exatamente os totais da raiz. Ana cai na primeira folha: $\hat{p} = 18 / 600 = 3\%$. Mesma folha, mesma previsão: dois clientes com rendas diferentes recebem a mesma PD, porque a renda não participa das perguntas. A previsão é uma frequência observada, sujeita à incerteza da contagem (slide 25) e à capacidade de generalizar (slide 27).

$$\hat{p} = \frac{d}{n} = \frac{18}{600} = 3\%$$

PD da folha de Ana: eventos divididos por contratos do grupo.

NA TELA

Troque o cliente para destacar o percurso e a folha; "Leitura simples, só a taxa" esconde as contagens e mostra apenas a PD.

A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.

Árvore didática de 1.000 contratos; cálculo próprio

Qual pergunta separa melhor os comportamentos observados?

Dois candidatos à primeira divisão, a partir da mesma raiz

ÁRVORE DE DECISÃO slide 23 de 50

Qual pergunta separa melhor os comportamentos observados?

Dois candidatos à primeira divisão, a partir da mesma raiz

Raiz1.000 contratos · 100 eventos · taxa 10%10,0%

Histórico de atraso

escolher este

hist = 0n = 800 · eventos 40 · taxa 5,00%

hist = 1n = 200 · eventos 60 · taxa 30,00%

Comprometimento até 40%

escolher este

comp ≤ 40%n = 680 · eventos 30 · taxa 4,41%

comp > 40%n = 320 · eventos 70 · taxa 21,88%

EXPLORAÇÃO

Comparar composição e peso

Ver regra de escolha

Reiniciar exemplo

Regra de escolha: a divisão escolhida é a de menor impureza ponderada, considerando ao mesmo tempo a mistura de classes em cada lado e o tamanho de cada lado. O cálculo completo com o índice de Gini vem no próximo slide.

Os dois candidatos partem exatamente da mesma raiz: 1.000 contratos e 100 eventos.

Uma boa divisão cria grupos mais homogêneos segundo a função objetivo.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 23 como aparece na tela (estado revelado, com os controles e as etapas abertas). Raiz de 1.000 contratos com 10% de eventos e dois candidatos de divisão, cada um com duas barras de composição.

Qual pergunta separa melhor os comportamentos observados? Dois candidatos partem exatamente da mesma raiz, 1.000 contratos e 100 eventos. Dividir pelo histórico produz 800 contratos com taxa de 5,00% e 200 com taxa de 30,00%. Dividir pelo comprometimento em 40% produz 680 contratos com taxa de 4,41% e 320 com taxa de 21,88%. As barras mostram a composição de cada lado: quanto mais um lado concentra eventos e o outro os evita, mais homogêneos ficam os grupos. A regra de escolha não olha só a folha mais pura: a divisão escolhida é a de menor impureza ponderada, considerando ao mesmo tempo a mistura de classes em cada lado e o tamanho de cada lado. O cálculo completo, com o índice de Gini, vem no próximo slide. Antes de avançar, tente prever qual candidato vence e por quê.

NA TELA

Use "escolher este" em cada candidato e "Comparar composição e peso"; "Ver regra de escolha" enuncia o critério.

Uma boa divisão cria grupos mais homogêneos segundo a função objetivo.

Árvore didática de 1.000 contratos; cálculo próprio

Versão da aula 2b6298264377 · gerado em 22 de setembro de 2026 · dados sintéticos

34 de 71

Histórico reduz o Gini de 0,180 para 0,160

Impureza da raiz, média ponderada dos filhos e ganho

ÁRVORE DE DECISÃO slide 24 de 50

Histórico reduz o Gini de 0,180 para 0,160

Impureza da raiz, média ponderada dos filhos e ganho

1. IMPUREZA DA RAIZ

$$p = \frac{100}{1.000} = 10\%$$

$$G(\text{raiz}) = 2p(1-p) = 0,180$$

2. IMPUREZA DE CADA FILHO

$$G_{\text{esq}} = 2p_{\text{esq}}(1-p_{\text{esq}}) = 0,0950 \quad \text{hist} = 0, \quad p_{\text{esq}} = 5,00\%$$

$$G_{\text{dir}} = 2p_{\text{dir}}(1-p_{\text{dir}}) = 0,4200 \quad \text{hist} = 1, \quad p_{\text{dir}} = 30,00\%$$

3. PONDERAÇÃO PELO TAMANHO

$$\bar{G} = \frac{n_{\text{esq}}}{n} G_{\text{esq}} + \frac{n_{\text{dir}}}{n} G_{\text{dir}}$$

$$= \frac{800}{1.000} \cdot 0,0950 + \frac{200}{1.000} \cdot 0,4200$$

$$= 0,160000$$

4. GANHO E COMPARAÇÃO


$$\Delta G = G(\text{raiz}) - \bar{G} = 0,180 - 0,160000 = 0,020000$$

candidato comprometimento até 40%: $\Delta G = 0,013272$

Próxima etapa

Trocar candidato

Reiniciar exemplo

IMPUREZA BINÁRIA $G = 2p(1-p)$ **Não basta uma folha pura: importa como toda a amostra fica depois da divisão.**

Árvore didática de 1.000 contratos; cálculo próprio

Slide 24 como aparece na tela (estado revelado, com os controles e as etapas abertas). Três etapas do cálculo do ganho de Gini e curva de impureza binária em função da taxa de eventos.

O ganho de Gini em quatro etapas. Impureza da raiz: $p = 100 / 1.000 = 10\%$ e $G(\text{raiz}) = 2p(1-p) = 0,180$. Impureza de cada filho da divisão pelo histórico: com p de 5,00% para hist igual a 0, $G = 0,0950$; com p de 30,00% para hist igual a 1, $G = 0,4200$. Ponderação pelo tamanho: $800/1.000 \times 0,0950 + 200/1.000 \times 0,4200 = 0,160000$. Ganho: $0,180 - 0,160000 = 0,020000$. O candidato comprometimento até 40% dá ganho de 0,013272, menor. O histórico vence. A curva de impureza binária ajuda a ler: G é zero num grupo puro, máximo de 0,5 quando a taxa é 50%, e o filho com 30% de eventos é o mais impuro dos três pontos marcados. Ainda assim a divisão compensa, porque o outro filho, com 800 contratos, ficou muito mais puro. Não basta uma folha pura: importa como toda a amostra fica depois da divisão.

$$G = 2p(1-p)$$

Impureza de Gini para dois desfechos.

$$\bar{G} = \frac{n_{\text{esq}}}{n} G_{\text{esq}} + \frac{n_{\text{dir}}}{n} G_{\text{dir}} \quad \Delta G = G(\text{raiz}) - \bar{G}$$

Impureza ponderada dos filhos e ganho da divisão.

NA TELA

Avance com "Próxima etapa" e use "Trocar candidato" para refazer as contas com o comprometimento.

Não basta uma folha pura: importa como toda a amostra fica depois da divisão.

Árvore didática de 1.000 contratos; cálculo próprio

ÁRVORE DE DECISÃO · SLIDE 25 DE 50


Duas folhas com PD de 10%. A evidência é igual?

Intervalo binomial descritivo de Wilson, nominal de 95%

ÁRVORE DE DECISÃO slide 25 de 50

Duas folhas com PD de 10%. A evidência é igual?

Intervalo binomial descritivo de Wilson, nominal de 95%

**LEITURA**

amplitude $\propto \sqrt{\hat{p}(1-\hat{p})/n}$ Mesma taxa, evidências diferentes: com 20 contratos a amplitude é 27,3 p.p.; com 1.000, 3,7 p.p..

Tamanho da folha pequena, mantendo a taxa em 10%
 2 em 20
Esconder a folha sem eventos[Reiniciar exemplo](#)**RESSALVA**

Intervalo binomial descritivo. Não incorpora a escolha adaptativa das folhas.

Uma folha com zero eventos não prova risco zero: o limite superior permanece positivo.

É por isso que a árvore recebe um tamanho mínimo de folha como parâmetro.

10% em 20 contratos não oferece a mesma precisão que 10% em 1.000.

Pares binomiais ilustrativos; cálculo próprio

Slide 25 como aparece na tela (estado revelado, com os controles e as etapas abertas). Duas linhas com ponto em 10% e intervalo de Wilson, uma com 2 eventos em 20 contratos e outra com 100 em 1.000.

Duas folhas com PD de 10% não trazem a mesma evidência. Com 2 eventos em 20 contratos, o intervalo de Wilson nominal de 95% vai de 2,8% a 30,1%, amplitude de 27,3 pontos. Com 100 eventos em 1.000 contratos, vai de 8,3% a 12,0%, amplitude de 3,7 pontos. A amplitude é proporcional à raiz de $\hat{p}(1-\hat{p})/n$: dividir a incerteza por dois exige quatro vezes mais contratos. A terceira linha mostra o caso traiçoeiro: uma folha com 0 eventos em 20 contratos não prova risco zero; o limite superior permanece positivo, 16,1%. É por isso que a árvore recebe um tamanho mínimo de folha como parâmetro. Ressalva do slide: o intervalo é binomial descritivo e não incorpora a escolha adaptativa das folhas, feita pelo próprio algoritmo olhando os dados.

$$\text{amplitude} \propto \sqrt{\hat{p}(1-\hat{p})/n}$$

Mesma taxa, evidências diferentes: a incerteza cai com a raiz do tamanho da folha.

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

Intervalo de Wilson, com z igual a 1,96 para 95% nominal.

NA TELA

Arraste o tamanho da folha pequena mantendo a taxa em 10% e veja o intervalo estreitar. "Esconder a folha sem eventos" simplifica a leitura.

10% em 20 contratos não oferece a mesma precisão que 10% em 1.000.

Pares binomiais ilustrativos; cálculo próprio



O mesmo aumento de comprometimento pode mudar de folha

As regras da árvore dividem o espaço em regiões de previsão constante

ÁRVORE DE DECISÃO slide 26 de 50

O mesmo aumento de comprometimento pode mudar de folha

As regras da árvore dividem o espaço em regiões de previsão constante



Cliente: **Ana** Bruno Carla Diego perfil original

Comprometimento: 38 PD 15,0%

histórico = 0 histórico = 1 Perfil original

[Comparar com o logit](#) [Reiniciar exemplo](#)

Regra atual: hist = 1 e comp ≤ 40%, PD 15%.
Em comprometimento exatamente igual a 40, o cliente segue pelo ramo até 40.

Os efeitos dependem do caminho. Dentro de uma folha, a previsão é constante.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 26 como aparece na tela (estado revelado, com os controles e as etapas abertas). Duas faixas de comprometimento, uma para cada valor de histórico, com as quatro regiões da árvore, os quatro clientes posicionados e a curva do logit sobreponível.

As regras da árvore dividem o espaço em regiões de previsão constante. O mapa mostra duas faixas de comprometimento, uma para cada valor de histórico, cortadas em 40%: sem histórico, PD de 3% até 40% e 11% acima; com histórico, 15% até 40% e 40% acima. Os quatro clientes estão posicionados: Ana em 22% sem histórico (3%), Carla em 48% sem histórico (11%), Bruno em 38% com histórico (15%) e Diego em 55% com histórico (40%). Dentro de uma região a previsão não muda: Bruno pode ir de 38% para 40% de comprometimento sem sair da folha de 15%; um ponto a mais e ele salta para 40%. É o oposto do logit, em que cada ponto de comprometimento move o escore continuamente. Em comprometimento exatamente igual a 40, o cliente segue pelo ramo até 40. Os efeitos dependem do caminho, e o mesmo aumento pode significar nada ou uma mudança de folha.

NA TELA


Arraste o comprometimento do cliente selecionado e alterne o histórico; a regra atual e a PD aparecem abaixo do mapa.

Os efeitos dependem do caminho. Dentro de uma folha, a previsão é constante.

Árvore didática de 1.000 contratos; cálculo próprio

A árvore cresce. O resultado fora do treino acompanha?

Profundidade, perda de treino e perda de validação no experimento sintético



Quando a árvore cresce, o resultado fora do treino acompanha? O experimento auxiliar de duas variáveis mostra as regiões aprendidas com profundidade 2 (4 folhas, validação 0,275), 4 (16 folhas, validação 0,262) e 8 (70 folhas, validação 0,401): a profundidade 8 recorta o mapa em retalhos que memorizam o treino. Na base principal, com mínimo de 20 contratos por folha, a perda de treino cai sempre que a profundidade aumenta, mas a perda de validação passa por um mínimo na profundidade 4 (16 folhas, mediana de 366 contratos por folha, treino 0,3434 e validação 0,3496) e depois sobe forte: 0,51 na profundidade 12 e 0,66 sem limite. Uma árvore que memoriza o treino produz probabilidades frágeis fora dele. A validação, não o treino, escolhe a profundidade.

NA TELA

Arraste a profundidade máxima apenas nos ajustes executados e acompanhe folhas, mediana por folha e as duas perdas.

Uma árvore que memoriza o treino pode produzir probabilidades frágeis fora dele.

Experimento sintético; semente e versões no notebook

Três controles, três formas de conter o excesso de divisões


Profundidade máxima, mínimo de contratos por folha e poda por complexidade

ÁRVORE DE DECISÃO slide 28 de 50

Três controles, três formas de conter o excesso de divisões

Profundidade máxima, mínimo de contratos por folha e poda por complexidade

MODELO SELECIONADO, RESUMIDO ATÉ O NÍVEL 2



Nomes abreviados nas caixas: comp é comprometimento, hist é histórico, util é utilização, rel é relacionamento. Ramos além do nível mostrado aparecem resumidos. A árvore selecionada tem 24 folhas.

Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

Profundidade máxima

Mínimo de contratos por folha

Poda por custo e complexidade


Limita quantas perguntas em sequência a árvore pode fazer. Aqui o mínimo por folha fica fixo em 300 contratos.

Cenário treinado

profundidade 2

4 folhas mediana de 1.916 contratos por folha

validação 0,3619



Como foi escolhido?

[Reiniciar exemplo](#)

Experimento sintético; semente e versões no notebook

Slide 28 como aparece na tela (estado revelado, com os controles e as etapas abertas). Árvore treinada resumida até o terceiro nível e três controles de complexidade com cenários efetivamente ajustados.

Três controles contêm o excesso de divisões. Profundidade máxima limita quantas perguntas em sequência a árvore pode fazer. Mínimo de contratos por folha impede grupos pequenos demais para sustentar uma taxa, como mostrou o slide 25. Poda por custo e complexidade remove divisões cujo ganho não compensa a penalidade escolhida. O modelo selecionado tem 24 folhas e aparece resumido até o nível 2: a raiz divide por hist até 0,5 (n de 16.000, PD 13,3%); à esquerda, comp até 43,5 (12.940 contratos, PD 9,4%); à direita, comp até 44,7 (3.060 contratos, PD 29,7%). Os cenários efetivamente ajustados, com mínimo por folha fixo em 300 contratos, dão log loss de validação 0,3619 na profundidade 2, 0,3526 na 3, 0,3510 na 4 e 0,3481 na 6. Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

NA TELA

Alterne os três controles e arraste o cenário treinado; "Como foi escolhido?" explica a seleção pela validação.

Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

Experimento sintético; semente e versões no notebook

ÁRVORE DE DECISÃO · SLIDE 29 DE 50

Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?

Vinte reamostragens do treino, com os mesmos hiperparâmetros


ÁRVORE DE DECISÃO slide 29 de 50

Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?

Vinte reamostragens do treino, com os mesmos hiperparâmetros

RÉPLICA A: Nº 1


8 folhas · AUC validação 0,7028



nomes abreviados nas caixas. raiz: comprometimento ≤ 43,35 · PD de Bruno: 14,85%

RÉPLICA B: Nº 3

7 folhas · AUC validação 0,7065




nomes abreviados nas caixas. raiz: histórico ≤ 0,50 · PD de Bruno: 27,59%

A raiz mudou de comprometimento para histórico apenas por reamostragem do treino.

Entre as 20 réplicas, a raiz foi comprometimento em 10 delas e histórico em 10 delas.

PD NAS 20 RÉPLICAS



Réplica A **1** 2 3 4 5 6 7 8

Réplica B 9 10 11 12 13 14 15 16

Ana Bruno Carla Diego

[Reiniciar exemplo](#)

Mesma complexidade nas 20 réplicas: profundidade 3 e mínimo de 300 contratos por folha.

Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Experimento sintético; semente e versões no notebook

Slide 29 como aparece na tela (estado revelado, com os controles e as etapas abertas). Duas árvores de réplicas diferentes lado a lado e a dispersão das PDs dos quatro clientes nas vinte réplicas.

Se mudarmos um pouco a amostra, a árvore continua contando a mesma história? Vinte reamostragens do treino, com os mesmos hiperparâmetros (profundidade 3 e mínimo de 300 contratos por folha), dão árvores diferentes. A réplica 1 abre pelo comprometimento até 43,4 (8 folhas, AUC de validação 0,7028) e dá PD de 14,85% para Bruno; a réplica 3 abre pelo histórico (7 folhas, AUC 0,7065) e dá 27,59%. Entre as 20 réplicas, a raiz foi comprometimento em 10 e histórico em 10. A dispersão das PDs mostra o tamanho da instabilidade: Ana entre 3,6% e 7,3%, Bruno entre 14,1% e 29,1%, Carla entre 13,3% e 19,9%, Diego entre 58,4% e 67,2%. Uma regra fácil de ler pode ser sensível à amostra que a produziu, e é esse o preço da legibilidade: antes de apresentar uma árvore como "a regra", verifique se ela sobrevive a reamostragens.

NA TELA

Escolha as réplicas A e B e o cliente; o gráfico marca as duas réplicas na nuvem das vinte PDs.

Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Experimento sintético; semente e versões no notebook


Carla recebe qual PD nesta árvore?

Exercício: percorrer, calcular e questionar

ÁRVORE DE DECISÃO slide 30 de 50

Carla recebe qual PD nesta árvore?

Exercício: percorrer, calcular e questionar



Carla

R\$ 10.000 por mês · comprometimento 48% · relacionamento 60 meses · utilização 85% · histórico não · canal digital

QUANDO A ÁRVORE É UMA BOA ESCOLHA

- o efeito de uma variável depende do valor de outra, e a interação não precisa ser escrita à mão
- a relação não é monótona, e transformar a variável seria um chute
- a regra precisa virar política operacional, legível linha a linha
- não escolha pela leitura do diagrama: uma observação pode trocar a variável de um nó
- não leia a taxa da folha sem o tamanho da folha
- não compare com outra família pela perda de treino

À esquerda, o que a árvore entrega e a soma não entrega. À direita, o preço, e é o mesmo preço em qualquer família: só evidência fora da amostra decide.

Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

Árvore didática de 1.000 contratos; cálculo próprio

1. INDIQUE O CAMINHO

histórico = 0, depois comprometimento acima de 40%

histórico = 0, depois comprometimento até 40%

histórico = 1, depois comprometimento acima de 40%

2. CALCULE A PD DA FOLHA

em porcentagem

3. SE A RENDA DE CARLA DOBRASSE, MANTENDO FIXAS AS ENTRADAS USADAS NA ÁRVORE

A PD permanece a mesma

A PD cai pela metade

Não é possível avaliar a função

Conferir

Desafio final

Reiniciar exercício

Slide 30 como aparece na tela (estado inicial, antes de conferir). Árvore didática com a taxa da folha de Carla oculta, três tarefas de percurso e cálculo, e o painel de quando a árvore é uma boa escolha.

O exercício percorre a árvore didática com Carla: R\$ 10.000 por mês, comprometimento 48%, relacionamento 60 meses, utilização 85%, sem histórico, canal digital. A taxa da folha de Carla está oculta, e você precisa reconstruir essa taxa a partir das contagens do slide 22. Três tarefas: indicar o caminho, calcular a PD da folha em porcentagem e responder o que acontece se a renda de Carla dobrar mantendo fixas as entradas usadas pela árvore. A terceira pergunta é a mais importante: ela testa se você entendeu que a previsão só depende das características que entram nas perguntas. Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

NA TELA

Marque o caminho, digite a PD e escolha a resposta da terceira pergunta; Conferir corrige as três. "Desafio final" abre uma pergunta extra.

EXERCÍCIO

Carla recebe qual PD nesta árvore?

Use a árvore de 1.000 contratos do slide 22 (contagens por folha) e o perfil de Carla.

1. Indique o caminho: histórico igual a 0 e depois comprometimento acima de 40%; histórico igual a 0 e depois comprometimento até 40%; ou histórico igual a 1 e depois comprometimento acima de 40%.
2. Calcule a PD da folha, em porcentagem, a partir de eventos e contratos da folha: _____ / _____ = _____%.
3. Se a renda de Carla dobrasse, mantendo fixas as entradas usadas na árvore: a PD permanece a mesma, a PD cai pela metade, ou não é possível avaliar a função?

Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

Árvore didática de 1.000 contratos; cálculo próprio

BLOCO 4 DE 5 · SLIDES 31 A 42

4

Gradient boosting

Como correções sucessivas, somadas no escore, constroem uma previsão melhor que a de uma árvore só?

O que você vai aprender

- Ver o que sobra nos resíduos de uma árvore rasa e por que vale acrescentar correções.
- Seguir o ciclo em quatro passos: prever, calcular o gradiente, ajustar uma árvore aos resíduos e atualizar o escore.
- Refazer a miniatura de 10 registros: escore inicial, duas árvores e conversão única em PD.
- Escolher taxa de aprendizagem, número de árvores e profundidade pela validação, com parada definida antes.

Ideias para levar

- Cada árvore responde ao que ainda precisa melhorar na previsão atual.
- A soma acontece no escore F. A logística é aplicada uma única vez, no fim.
- Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
31	E se uma árvore pequena ainda deixar estrutura nos erros?	44
32	A próxima árvore aprende a partir das previsões atuais	45
33	Dois eventos em dez contratos: começamos em 20%	46
34	A primeira correção reduz A e aumenta B	47
35	A primeira árvore mudou as previsões. Agora mudam os gradientes	48
36	Escore inicial mais árvore 1 mais árvore 2 é a nova PD	49

SLIDE	TÍTULO	PÁGINA
37	Learning rate e número de árvores precisam ser escolhidos juntos	50
38	Uma correção pode depender de uma característica ou da combinação de várias	51
39	Continuar melhorando o treino pode deixar de ajudar a validação	52
40	Mais flexibilidade exige mais disciplina de validação	53
41	O que o modelo usa em geral? O que pesou para Bruno?	54
42	Carla caiu no grupo B. Qual é a previsão?	55

E se uma árvore pequena ainda deixar estrutura nos erros?

Resíduos agregados por região, no experimento auxiliar de duas variáveis

GRADIENT BOOSTING slide 31 de 50

E se uma árvore pequena ainda deixar estrutura nos erros?

Resíduos agregados por região, no experimento auxiliar de duas variáveis

PREVISÃO DE UMA ÁRVORE DE PROFUNDIDADE 2

MÉDIA DE Y – P POR REGIÃO

Vermelho: a previsão ficou baixa demais. Verde: ficou alta demais.

O QUE SOBRA DEPOIS DA ÁRVORE RASA

regiões com resíduo positivo	13 de 36
média dessas regiões	0,0567
média das demais	-0,0325
validação da árvore rasa	0,2752

Onde a previsão ficou baixa?

E onde ficou alta?

Acrescentar uma correção

Reiniciar exemplo

Os resíduos mostrados são do conjunto usado no ajuste desta árvore auxiliar, com duas variáveis. Nenhum resultado do teste participa.

Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos.

Experimento auxiliar de duas variáveis; cálculo próprio

Slide 31 como aparece na tela (estado revelado, com os controles e as etapas abertas). Mapa de previsão de uma árvore rasa e média do resíduo observado menos previsto por região.

E se uma árvore pequena ainda deixar estrutura nos erros? No experimento auxiliar de duas variáveis, uma árvore de profundidade 2 prevê a PD em quatro regiões, e o mapa da média de $y - p$ por região mostra o que sobra: vermelho onde a previsão ficou baixa demais (resíduo positivo, até 0,18 no canto de comprometimento e utilização altos) e verde onde ficou alta demais (até -0,13). Das 36 regiões, 13 têm resíduo positivo, com média 0,0567; as demais têm média -0,0325; a validação da árvore rasa é 0,2752. Os resíduos não são ruído aleatório: têm padrão espacial, concentrado nos cantos. Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos, com uma nova árvore ajustada ao que sobrou. Os resíduos mostrados são do conjunto usado no ajuste desta árvore auxiliar; nenhum resultado do teste participa.

NA TELA

"Onde a previsão ficou baixa?" e "E onde ficou alta?" destacam cada sinal; "Acrescentar uma correção" mostra a próxima árvore atuando.

Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos.

Experimento auxiliar de duas variáveis; cálculo próprio

GRADIENT BOOSTING · SLIDE 32 DE 50

A próxima árvore aprende a partir das previsões atuais

Um ciclo de atualização em quatro passos

GRADIENT BOOSTING slide 32 de 50

A próxima árvore aprende a partir das previsões atuais

Um ciclo de atualização em quatro passos

novo escore = escore atual + taxa de aprendizagem × contribuição da árvore

$$F_m = F_{m-1} + \eta h_m$$

1. PREVER COM O QUE JÁ EXISTE

$$p = \sigma(F) = \frac{1}{1 + e^{-F}} = \frac{1}{1 + e^{-1,3863}} = 20,0000\%$$

A previsão atual do grupo vem do escore acumulado até aqui, na mesma logística do slide 09.

2. CALCULAR A DIREÇÃO DE MELHORIA

$$r = -\frac{\partial L}{\partial F} = y - p = 0 - 0,2000 = -0,2000$$

O resíduo não é escolha de conveniência: para a perda logística do slide 13, o gradiente negativo em relação ao escore é exatamente y menos p . Por isso a técnica se chama gradient boosting.

3. AJUSTAR UMA ÁRVORE PEQUENA AOS R

$$h_1(\text{folha B}) = \bar{r}_B = 0,200000$$


A árvore devolve um número por folha, positivo ou negativo. Não é um voto.

4. ATUALIZAR O ESCORE

$$F_1 = F_0 + \eta h_1 = -1,3863 + 1 \times 0,200000 = -1,1863$$

Só depois de somar todas as contribuições aplicamos a função logística.

A RÉGUA DO ESCORE ACUMULADO



PD aparece apenas depois da transformação logística: 20,00% passa a 23,39%

Próximo passo

Comparar mecanismos

Reiniciar exemplo

Miniatura didática de 10 registros, com taxa de aprendizagem igual a 1 apenas para facilitar a leitura. O registro usado no passo 2 tem $y = 0$ e pertence ao grupo B.

Cada árvore responde ao que ainda precisa melhorar na previsão atual.

Miniatura didática de 10 registros; cálculo próprio

Slide 32 como aparece na tela (estado revelado, com os controles e as etapas abertas). Ciclo em quatro passos: prever, calcular a direção de melhoria, ajustar a correção e atualizar o escore, com a régua do escore acumulado.

O ciclo do gradient boosting tem quatro passos, mostrados com a miniatura de 10 registros e taxa de aprendizagem igual a 1. Passo 1, prever com o que já existe: $p = \sigma(F)$, com F inicial de $-1,3863$, dá 20,0000%. Passo 2, calcular a direção de melhoria: para a perda logística, o gradiente negativo em relação ao escore é exatamente $y - p$; para um registro do grupo B sem evento, $0 - 0,2000 = -0,2000$. É daí que vem o nome gradient boosting: o resíduo não é escolha de conveniência. Passo 3, ajustar uma árvore pequena aos resíduos: a folha B recebe a média dos seus r , 0,200000. A árvore devolve um número por folha, positivo ou negativo, não um voto. Passo 4, atualizar o escore: $F_1 = F_0 + \eta h_1 = -1,3863 + 1 \times 0,200000 = -1,1863$. A régua mostra o escore acumulado; a PD aparece só depois da transformação logística: 20,00% passa a 23,39%.

$$F_m = F_{m-1} + \eta h_m$$

Novo escore igual ao escore atual mais taxa de aprendizagem vezes a contribuição da árvore.

$$r = -\frac{\partial L}{\partial F} = y - p$$

Para a perda logística, o gradiente negativo em relação ao escore é a diferença entre observado e previsto.

NA TELA

Avance com "Próximo passo" e use "Comparar mecanismos" para contrastar com o logit e com a árvore única.

Cada árvore responde ao que ainda precisa melhorar na previsão atual.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 33 DE 50

Dois eventos em dez contratos: começamos em 20%

O melhor preditor constante da perda logarítmica no treino

GRADIENT BOOSTING slide 33 de 50

Dois eventos em dez contratos: começamos em 20%

O melhor preditor constante da perda logarítmica no treino

previsão inicial 20,00% $F_0 = \ln\left(\frac{0,20}{0,80}\right) = -1,3863$ perda média 0,5004

miniatura didática, distinta da base de comparação

GRUPO A


comprometimento 30% · 0 eventos em 5

REGISTRO	y	p ₀	r = y - p ₀
nº 1	0	20,00%	
nº 2	0	20,00%	
nº 3	0	20,00%	
nº 4	0	20,00%	
nº 5	0	20,00%	

GRUPO B

comprometimento 50% · 2 eventos em 5

REGISTRO	y	p ₀	r = y - p ₀
nº 6	0	20,00%	
nº 7	0	20,00%	
nº 8	0	20,00%	
nº 9	1	20,00%	
nº 10	1	20,00%	

PERDA MÉDIA EM FUNÇÃO DA PREVISÃO CONSTANTE**Previsão constante**
 20 perda 0,5004

Usar melhor constante

Mostrar os resíduos

[Reiniciar exemplo](#)

A curva é calculada diretamente com os dez rótulos, sem treinar biblioteca alguma. O mínimo ocorre na média empírica de y, igual a 20%.

Antes de usar características, a taxa observada fornece o ponto de partida do exemplo.

Miniatura didática de 10 registros; cálculo próprio

Slide 33 como aparece na tela (estado revelado, com os controles e as etapas abertas). Dez registros divididos em dois grupos, previsão inicial constante e curva da perda média em função dessa constante.

Antes de usar características, o boosting precisa de um ponto de partida. Na miniatura, dez registros em dois grupos de comprometimento: grupo A, 30%, sem eventos em 5; grupo B, 50%, 2 eventos em 5. A taxa observada é 2 em 10, 20%, e o escore inicial correspondente é $F_0 = \ln(0,20 / 0,80) = -1,3863$. A curva da perda média em função de uma previsão constante confirma a escolha: o mínimo, 0,5004, ocorre exatamente em 20%, a média empírica de y. A curva é calculada diretamente com os dez rótulos, sem treinar biblioteca alguma; arraste a constante e veja a perda subir para os dois lados. É a versão mais simples do que o slide 13 mostrou: o melhor preditor constante da perda logarítmica no treino é a taxa observada. Nesta miniatura, taxa de aprendizagem 1 e apenas dois passos, para as contas caberem numa folha.

$$F_0 = \ln\left(\frac{0,20}{0,80}\right) = -1,3863$$

Escore inicial: log odds da taxa observada nos dez registros.

NA TELA

Arraste a previsão constante e observe a perda; "Usar melhor constante" volta a 20%; "Mostrar os resíduos" preenche a coluna r.

Antes de usar características, a taxa observada fornece o ponto de partida do exemplo.

Miniatura didática de 10 registros; cálculo próprio

A primeira correção reduz A e aumenta B

Resíduos, média por folha e atualização do escore

GRADIENT BOOSTING slide 34 de 50

A primeira correção reduz A e aumenta B

Resíduos, média por folha e atualização do escore

OS DEZ REGISTROS

REGISTRO	GRUPO	y	p _{atual}	r = y - p	h(folha)	F _{novo}	p _{novo}
nº 1	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 2	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 3	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 4	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 5	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%
nº 6	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 7	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 8	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%
nº 9	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%
nº 10	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%

destacar um registro:

nº 6 (y = 0) nº 9 (y = 1)

primeira ordem didática

A ÁRVORE AJUSTADA AOS RESÍDUOS



POR GRUPO

	A	B
escore inicial	-1,386294	-1,386294
contribuição da árvore	-0,200000	+0,200000
escore novo	-1,586294	-1,186294
PD	16,9906%	23,3922%

Etapas completas

[Reiniciar exemplo](#)

etapa 4 de 4

A árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha.

Miniatura didática de 10 registros; cálculo próprio

Slide 34 como aparece na tela (estado revelado, com os controles e as etapas abertas). Dez registros com a coluna de resíduo, um stump que divide o comprometimento em 40 e as folhas com a média dos resíduos.

A primeira correção reduz A e aumenta B. Com a previsão inicial de 20,00% para todos, os resíduos são -0,2000 para os oito registros sem evento e 0,8000 para os dois com evento. A árvore de um nó corta o comprometimento em 40% e calcula a média dos resíduos por folha: folha A, cinco registros, $h = -0,200000$; folha B, cinco registros, $h = 0,200000$ (três de -0,2 e dois de 0,8). A média geral dos resíduos é 0,0000, como esperado quando a constante inicial é a taxa observada. A atualização, com taxa 1, dá escore -1,586294 e PD 16,9906% no grupo A, e escore -1,186294 e PD 23,3922% no grupo B. Repare que os dois registros com evento e os três sem evento do grupo B recebem a mesma correção: a árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha.

$$h_1(\text{folha}) = \bar{r}_{\text{folha}} \quad F_1 = F_0 + \eta h_1$$

Cada folha recebe a média dos resíduos; o escore de cada registro é atualizado pela folha em que caiu.

NA TELA

Avance as quatro etapas e destaque o registro nº 6 (sem evento) ou nº 9 (com evento) para seguir a linha na tabela.

A árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha.

Miniatura didática de 10 registros; cálculo próprio

A primeira árvore mudou as previsões. Agora mudam os gradientes

A segunda correção é recalculada depois da primeira


GRADIENT BOOSTING slide 35 de 50

A primeira árvore mudou as previsões. Agora mudam os gradientes

A segunda correção é recalculada depois da primeira


OS MESMOS DEZ REGISTROS

Antes da primeira correção									
REGISTRO	GRUPO	Y	P0	R0	P1	R1	F2	P2	
nº 1	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%	
nº 2	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%	
nº 3	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%	
nº 4	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%	
nº 5	A	0	20,00%	-0,2000	16,9906%	-0,169906	-1,756200	14,7267%	
nº 6	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%	
nº 7	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%	
nº 8	B	0	20,00%	-0,2000	23,3922%	-0,233922	-1,020217	26,4985%	
nº 9	B	1	20,00%	0,8000	23,3922%	0,766078	-1,020217	26,4985%	
nº 10	B	1	20,00%	0,8000	23,3922%	0,766078	-1,020217	26,4985%	



No grupo B, o resíduo de quem teve evento caiu de 0,8 para 0,766078 e o de quem não teve ficou mais negativo, de -0,2 para -0,233922.

A SEGUNDA ÁRVORE

[Ajustar segunda árvore](#)[Atualizar](#)

Reiniciar exemplo

A exposição principal para em duas iterações. A correção média do grupo B continua positiva, mas caiu de 0,200000 para 0,166078.

A próxima correção é recalculada depois da anterior. Ela não repete mecanicamente o mesmo passo.

Miniatura didática de 10 registros; cálculo próprio

Slide 35 como aparece na tela (estado revelado, com os controles e as etapas abertas). Tabela com as previsões e resíduos antes e depois da primeira correção, segunda árvore com novas médias e trajetória de PD por iteração.

A primeira árvore mudou as previsões, e por isso mudam os gradientes. No grupo B, quem teve evento passou a resíduo 0,766078 (era 0,8) e quem não teve passou a -0,233922 (era -0,2). A segunda árvore usa o mesmo corte em 40%, mas as novas médias: h2 = -0,169906 na folha A e 0,166078 na folha B. Depois da segunda atualização, o grupo A chega ao escore -1,756200 e PD 14,7267%; o grupo B, ao escore -1,020217 e PD 26,4985%. A trajetória por iteração deixa claro o movimento: 20% para 16,99% e 14,73% no grupo A; 20% para 23,39% e 26,50% no grupo B. A correção média do grupo B continua positiva, mas caiu de 0,200000 para 0,166078: a próxima correção é recalculada depois da anterior, e não repete mecanicamente o mesmo passo. A exposição principal para em duas iterações.

NA TELA

"Ajustar segunda árvore" recalcula as médias dos novos resíduos; "Atualizar" aplica a correção e estende a trajetória.

A próxima correção é recalculada depois da anterior. Ela não repete mecanicamente o mesmo passo.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 36 DE 50


Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Somamos contribuições no escore e só então calculamos a probabilidade


GRADIENT BOOSTING slide 36 de 50

Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Somamos contribuições no escore e só então calculamos a probabilidade


 $F = -1,020217$ $p = \sigma(F) = 26,4985\%$ grupo A chegaria a -1,756200 e PD 14,7267%
SOLICITANTE NOVO
 sem desfecho conhecido
 Comprometimento do solicitante
 50 grupo B, como Diego
Taxa de aprendizagem η $\eta = 1$ $\eta = 0,40$
 Nenhum campo de desfecho aparece nesta ficha. O y foi usado apenas no treinamento. Trocar η não reescala o resultado: as mesmas duas árvores mudam de valor porque os resíduos da segunda são recalculados sobre o escore já atualizado pela primeira.

árvore 1 +0,200000
 comprometimento 50% é maior que 40, portanto folha do grupo B

árvore 2 +0,166078
 comprometimento 50% é maior que 40, portanto folha do grupo B
CONVERSÃO DO ESCORE SOMADO

Ver somente o escore Converter em PD

Como foi treinado? Reiniciar exemplo

Para prever, o cliente percorre as árvores já aprendidas. Não precisamos conhecer seu desfecho. Miniatura didática de 10 registros; cálculo próprio

Slide 36 como aparece na tela (estado revelado, com os controles e as etapas abertas). Waterfall do escore inicial e das duas contribuições, com a conversão logística ao lado e a ficha de um solicitante novo.

Para prever um solicitante novo, sem desfecho conhecido, o cliente percorre as árvores já aprendidas e as contribuições são somadas no escore. Com comprometimento de 50%, ele cai na folha do grupo B nas duas árvores: $F = -1,386294 + 0,200000 + 0,166078 = -1,020217$, e só então $p = \sigma(F) = 26,4985\%$. Se caísse no grupo A, chegaria a -1,756200 e PD 14,7267%. A cascata mostra o escore inicial e as duas contribuições; o painel de conversão aplica a logística uma única vez, no fim. Dois pontos para levar: nenhum campo de desfecho aparece na ficha do solicitante, porque o y foi usado apenas no treinamento; e as árvores não somam probabilidades, somam contribuições no escore. Esse é o erro que o exercício do slide 42 vai testar.

$$F = F_0 + h_1 + h_2 = -1,386294 + 0,200000 + 0,166078 = -1,020217 \quad p = \sigma(F) = 26,4985\%$$

Soma no escore e conversão única em probabilidade.

NA TELA

Arraste o comprometimento do solicitante entre os grupos; "Converter em PD" aplica a logística; "Como foi treinado?" volta aos slides 33 a 35.

Para prever, o cliente percorre as árvores já aprendidas. Não precisamos conhecer seu desfecho.

Miniatura didática de 10 registros; cálculo próprio


Learning rate e número de árvores precisam ser escolhidos juntos

Trajetórias de perda treinadas com cada taxa, no experimento sintético

GRADIENT BOOSTING slide 37 de 50

Learning rate e número de árvores precisam ser escolhidos juntos

Trajetórias de perda treinadas com cada taxa, no experimento sintético



PD com 105 árvores: Ana 5,00% Bruno 23,35% Carla 17,60% Diego 61,05%
Trajetórias calculadas a cada cinco iterações e registradas no notebook.

Mudar o passo altera previsões, gradientes e, portanto, o que as próximas árvores aprendem.

Experimento sintético; semente e versões no notebook

Slide 37 como aparece na tela (estado revelado, com os controles e as etapas abertas). Perda de treino e de validação por iteração para três taxas de aprendizagem, com o ponto selecionado e a PD de um cliente.

Taxa de aprendizagem e número de árvores precisam ser escolhidos juntos. As curvas mostram a log loss de validação por iteração para três taxas efetivamente treinadas no experimento sintético: com η igual a 0,30 a perda cai rápido e depois sobe, sinal de sobreajuste; com 0,03 ela cai devagar e ainda não convergiu em 300 árvores; com 0,10, a taxa selecionada, o mínimo de validação ocorre em 106 árvores, com log loss 0,34460. A linha tracejada é a perda de treino da taxa selecionada, que continua caindo: o treino nunca avisa quando parar. Com 105 árvores, as PDs dos quatro clientes são Ana 5,00%, Bruno 23,35%, Carla 17,60% e Diego 61,05%. Por que não basta multiplicar no final? Porque mudar o passo altera as previsões, logo os gradientes e, portanto, o que as próximas árvores aprendem. Trajetórias calculadas a cada cinco iterações e registradas no notebook.

$$F_m = F_{m-1} + \eta h_m$$

A taxa η escala cada contribuição: taxa menor exige mais árvores.

NA TELA

Altere a taxa treinada e arraste o número de árvores apenas nas iterações calculadas; o painel mostra a melhor iteração de cada taxa.

Mudar o passo altera previsões, gradientes e, portanto, o que as próximas árvores aprendem.

Experimento sintético; semente e versões no notebook

Uma correção pode depender de uma característica ou da combinação de várias

Profundidade de cada árvore no experimento auxiliar de duas variáveis

GRADIENT BOOSTING slide 38 de 50

Uma correção pode depender de uma característica ou da combinação de várias

Profundidade de cada árvore no experimento auxiliar de duas variáveis

MESMA ESCALA E MESMO DOMÍNIO NOS TRÊS PAINÉIS

experimento auxiliar de duas variáveis

PROFUNDIDADE 1

utilização

comprometimento

PD no ponto: 46,66% · validação 0,2549

PROFUNDIDADE 2

utilização

comprometimento

PD no ponto: 58,88% · validação 0,2535

PROFUNDIDADE 3

utilização

comprometimento

PD no ponto: 47,53% · validação 0,2606

escala de PD prevista 0% 60%

A regra do canto alto e alto: se comprometimento acima de 40% e utilização acima de 50%, o risco sobe mais do que a soma dos dois efeitos isolados. Taxa 0,1 e 150 árvores nos três painéis; muda apenas a profundidade.

Cliente sintético: comprometimento 65%, utilização 80%, PD 46,66% na profundidade 1.

Alto e alto Alto e baixo Baixo e alto

Baixo e baixo

Comprometimento 65 65%

Utilização 80 80%

profundidade 1 profundidade 2

profundidade 3

Reiniciar exemplo

Muitas regras simples somadas não são sempre equivalentes a regras que combinam condições.

Experimento auxiliar de duas variáveis; cálculo próprio

Slide 38 como aparece na tela (estado revelado, com os controles e as etapas abertas). Superfícies de PD prevista para boosting com profundidade 1, 2 e 3, na mesma escala e no mesmo domínio.

Uma correção pode depender de uma característica ou da combinação de várias. No experimento auxiliar de duas variáveis, com taxa 0,1 e 150 árvores nos três painéis, muda apenas a profundidade de cada árvore. Profundidade 1 (um corte por árvore) só consegue somar efeitos de comprometimento e de utilização: a superfície é formada por faixas. Profundidade 2 combina as duas condições e captura a regra do canto alto e alto: se comprometimento acima de 40% e utilização acima de 50%, o risco sobe mais do que a soma dos dois efeitos isolados. Para o cliente sintético com comprometimento 65% e utilização 80%, a PD é 46,66% na profundidade 1 (validação 0,2549), 58,88% na profundidade 2 (validação 0,2535) e 47,53% na profundidade 3 (validação 0,2606). A validação prefere a profundidade 2: muitas regras simples somadas não são sempre equivalentes a regras que combinam condições, e mais profundidade não é sempre melhor.

NA TELA

Escolha um dos quatro cantos ou arraste comprometimento e utilização; alterne a profundidade e compare a PD no ponto.

Muitas regras simples somadas não são sempre equivalentes a regras que combinam condições.

Experimento auxiliar de duas variáveis; cálculo próprio

Versão da aula 2b6298264377 · gerado em 22 de setembro de 2026 · dados sintéticos

51 de 71


Continuar melhorando o treino pode deixar de ajudar a validação

Regra de parada com tolerância e paciência, definida antes de olhar o teste

GRADIENT BOOSTING slide 39 de 50

Continuar melhorando o treino pode deixar de ajudar a validação

Regra de parada com tolerância e paciência, definida antes de olhar o teste



REGRA DEFINIDA ANTES DE TREINAR

máximo de 300 iterações · tolerância 0,000100
· paciência 20 · escolha na validação fora do tempo

[Avançar treinamento](#)[Ir para a melhor iteração](#)[Reiniciar exemplo](#)

300 de 300 iterações reveladas · melhor validação até aqui 0,34467 · paciência 203 de 20

Curvas calculadas no notebook, reveladas em lotes de 20 iterações.

MELHOR ITERAÇÃO E ITERAÇÃO DE PARADA

Melhor iteração na validação: 106, com log loss 0,34460. A paciência encerraria em 89, depois do mínimo. O modelo servido é o da melhor iteração.

A curva do teste não aparece em nenhum seletor.

A melhor iteração é escolhida usando uma amostra destinada a essa escolha.

Experimento sintético; semente e versões no notebook

Slide 39 como aparece na tela (estado revelado, com os controles e as etapas abertas). Log loss de treino e de validação por iteração, com a melhor iteração e a iteração de parada marcadas.

Continuar melhorando o treino pode deixar de ajudar a validação. A regra de parada foi definida antes de treinar: máximo de 300 iterações, tolerância 0,000100, paciência 20, escolha na validação fora do tempo. Reveladas as 300 iterações, a melhor validação é 0,34460 na iteração 106, e a paciência teria encerrado o treino em 89, antes do mínimo, porque ali a validação passou 20 iterações sem melhorar além da tolerância. O modelo servido é o da melhor iteração observada. Dois cuidados que o slide deixa explícitos: a curva do teste não aparece em nenhum seletor, e a paciência é uma regra prática que pode parar cedo demais; por isso ela é declarada com antecedência, para não virar uma escolha feita olhando o resultado. A melhor iteração é escolhida usando uma amostra destinada a essa escolha.

NA TELA

"Avançar treinamento" revela as curvas em lotes de 20 iterações; "Ir para a melhor iteração" marca 106 e a parada em 89.

A melhor iteração é escolhida usando uma amostra destinada a essa escolha.

Experimento sintético; semente e versões no notebook

Mais flexibilidade exige mais disciplina de validação

Quatro situações, a pergunta de diagnóstico e a evidência que a responde

GRADIENT BOOSTING

slide 40 de 50

Mais flexibilidade exige mais disciplina de validação

Quatro situações, a pergunta de diagnóstico e a evidência que a responde

SINAL APROXIMADAMENTE ADITIVO

As características contribuem de forma estável e quase somável na escala do escore.
cuidado: Complexidade sem ganho é custo de manutenção sem retorno.

INTERAÇÕES RELEVANTES

O risco depende de combinações de condições, como comprometimento alto junto de utilização alta.
cuidado: Encontrar interação no treino é fácil. Reproduzir a interação fora do tempo é o teste.

O QUE VERIFICAR EM SINAL APROXIMADAMENTE ADITIVO

O boosting ganha da especificação linear bem construída, fora do tempo?
Qual evidência aceitar. Aceitar apenas ganho que persiste na validação fora do tempo contra um logit com transformações e interações plausíveis. Se o ganho não persiste, o logit basta.

POUCOS EVENTOS

Volume pequeno de inadimplências, faixas finas e estimativas instáveis.
cuidado: Flexibilidade com poucos eventos costuma ajustar ruído.

MUDANÇA DE POPULAÇÃO

A composição dos solicitantes muda ao longo do tempo.
cuidado: Nenhum algoritmo corrige sozinho mudança de população.

SENSIBILIDADE JÁ CALCULADA

MODELO	AUC VALIDAÇÃO	LOG LOSS VALIDAÇÃO
Logit regularizado	0,7379	0,34299
Logit flexível	0,7385	0,34395
Gradient boosting	0,7366	0,34460

Neste experimento os três ficam próximos na validação. Isso é o resultado observado aqui, não uma generalização de mercado.

Reiniciar exemplo

GANHOS POSSÍVEIS

- relações não lineares sem especificação manual
- interações capturadas pela profundidade das árvores
- boa adaptação a dados tabulares com muitas colunas

CUSTOS

- ajuste de hiperparâmetros e orçamento de busca
- explicação menos direta que um coeficiente
- risco de sobreajuste quando a validação é frouxa
- manutenção, versionamento e verificação de calibração

Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.

Síntese conceitual, com um resultado calculado como exemplo

Slide 40 como aparece na tela (estado revelado, com os controles e as etapas abertas). Quatro situações de adequação do boosting, cada uma com pergunta de diagnóstico e evidência aceitável.

Mais flexibilidade exige mais disciplina de validação. Quatro situações, cada uma com pergunta de diagnóstico e evidência aceitável. Sinal aproximadamente aditivo: o boosting ganha do logit bem construído fora do tempo? Aceite apenas ganho que persiste na validação fora do tempo contra um logit com transformações e interações plausíveis; se o ganho não persiste, o logit basta. Interações relevantes: encontrar interação no treino é fácil; reproduzir a interação fora do tempo é o teste. Poucos eventos: flexibilidade com poucos eventos costuma ajustar ruído. Mudança de população: nenhum algoritmo corrige sozinho. A sensibilidade já calculada, na validação e não no teste, mostra os três próximos: logit regularizado AUC 0,7379 e log loss 0,34299; logit flexível 0,7385 e 0,34395; gradient boosting 0,7366 e 0,34460. É o resultado observado neste experimento, não uma generalização de mercado.

NA TELA

Escolha cada situação para ler a pergunta e a evidência; a tabela de sensibilidade fica visível em todas.

Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.

Síntese conceitual, com um resultado calculado como exemplo

O que o modelo usa em geral? O que pesou para Bruno?

Importância global por permutação e contribuição local no escore


GRADIENT BOOSTING slide 41 de 50

O que o modelo usa em geral? O que pesou para Bruno?

Importância global por permutação e contribuição local no escore

GLOBAL: IMPORTÂNCIA NA CARTEIRA


validação, jan a jun de 2021



AUC de referência na validação: 0,7366. A barra mostra quanto a AUC cai quando os valores da variável são embaralhados.

LOCAL: O ESCORE DE BRUNO

contribuições em escore
referência -2,056



Conferência: referência mais a soma das contribuições é -1,189179, e o escore do modelo é -1,189179. Diferença menor que 10 elevado a menos 9.

DO ESCORE À PD

escore do boosting -1,1892
PD do modelo 23,34%
PD depois da calibração 25,78%

Cliente

Ana Bruno Carla Diego

Destacar uma variável (nome abreviado)

comp hist util rel renda

canal

[Reiniciar exemplo](#)

COMO LER

O painel global mede desempenho: quanto a AUC cai ao embaralhar a variável. O local mede escore: quanto a característica desloca a previsão daquele cliente. Alterar a variável não garante essa redução: explicação não identifica causa.

Uma variável importante na carteira não precisa ser o principal fator da previsão de todo cliente.

Experimento sintético; semente e versões no notebook

Slide 41 como aparece na tela (estado revelado, com os controles e as etapas abertas). Importância global por queda de AUC ao permutar cada variável e decomposição local do escore de um cliente.

O que o modelo usa em geral e o que pesou para Bruno são perguntas diferentes. A importância global por permutação mede a queda da AUC de validação (referência 0,7366) quando os valores de uma variável são embaralhados: comprometimento 0,0618, histórico 0,0419, utilização 0,0177, relacionamento 0,0058, renda 0,0032 e canal 0,0030. A contribuição local decompõe o escore de Bruno em relação à referência -2,056: comprometimento -0,024, histórico +0,651, utilização +0,155, relacionamento +0,121, renda -0,004, canal -0,031, totalizando -1,189. A conferência fecha: referência mais contribuições dá -1,189179, igual ao escore do modelo, diferença menor que 10 elevado a menos 9. Do escore à PD: 23,34% no modelo e 25,78% depois da calibração. Para Bruno, o histórico pesa mais que o comprometimento, o inverso do ranking global. E explicação não identifica causa: alterar a variável não garante a redução prevista.

$$F(\text{Bruno}) = \text{referência} + \sum_j c_j = -2,056 + 0,867 = -1,189$$

As contribuições locais somam exatamente o escore do modelo.

NA TELA

Troque o cliente e destaque uma variável pelo nome abreviado para ler as duas medidas lado a lado.

Uma variável importante na carteira não precisa ser o principal fator da previsão de todo cliente.

Experimento sintético; semente e versões no notebook

Carla caiu no grupo B. Qual é a previsão?

Exercício: somar em escore e converter uma única vez

GRADIENT BOOSTING slide 42 de 50

Carla caiu no grupo B. Qual é a previsão?

Exercício: somar em escore e converter uma única vez

O QUE JÁ SABEMOS

cliente	Carla, comp 48% · grupo B
escore inicial F0	-1,386294
folha da árvore 1	+0,200000
folha da árvore 2	+0,166078
taxa de aprendizagem	1
PD final	oculta

PERGUNTA DE INTERPRETAÇÃO

Uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real?

A resposta aparece ao conferir a alternativa.

ESCOLHA O MÉTODO CORRETO

A Somar como pontos percentuais: 20% mais 20% mais 16,6078%.

B Somar ao escore e aplicar a função logística uma única vez.

C Tirar a média das duas folhas.

Conferir

Ver resolução

Desafio de consolidação

Reiniciar exercício

A resolução aparece em duas etapas: primeiro a soma no escore, depois a conversão.

Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

Miniatura didática de 10 registros; cálculo próprio

Slide 42 como aparece na tela (estado inicial, antes de conferir). Escore inicial e duas folhas do grupo B, com os atributos de Carla e três métodos possíveis de combinação.

O exercício de consolidação do boosting. O que já sabemos: escore inicial F0 de -1,386294, folha da árvore 1 de +0,200000, folha da árvore 2 de +0,166078, taxa de aprendizagem 1. O novo cliente caiu no grupo B nas duas árvores. Três métodos possíveis de combinação, e só um está certo. Antes de conferir, escreva a conta completa e converta o escore em PD uma única vez. A pergunta de interpretação vale tanto quanto a conta: uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real? A contribuição explica a função preditiva aprendida com registros históricos; ela não identifica o efeito de uma intervenção sobre o cadastro. Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

NA TELA

Escolha o método e clique em Conferir; "Desafio de consolidação" abre uma variação com outro grupo.

EXERCÍCIO**O novo cliente caiu no grupo B. Qual é a previsão?**

Escore inicial -1,386294; folha da árvore 1 +0,200000; folha da árvore 2 +0,166078; taxa de aprendizagem 1. Marque o método correto e calcule a PD.

- A. Somar como pontos percentuais: 20% mais 20% mais 16,6078%.
- B. Somar ao escore e aplicar a função logística uma única vez.
- C. Tirar a média das duas folhas.

ETAPAS

1. Escore final: _____ + _____ + _____ = _____

2. PD final: $1 / (1 + e \text{ elevado a } \text{_____}) = \text{_____} \%$

DESAFIO

Uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real? Responda em duas linhas.

Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

Miniatura didática de 10 registros; cálculo próprio

BLOCO 5 DE 5 · SLIDES 43 A 50

5 Avaliação e decisão

Como comparar os três modelos com justiça e transformar probabilidades em política de crédito?

O que você vai aprender

- Fixar o protocolo antes de qualquer métrica: mesmo alvo, mesma informação, teste congelado.
- Separar discriminação (AUC e KS) de calibração (previsto contra observado, faixa a faixa).
- Ligar o corte de aprovação à economia da operação e ao que se observa na carteira depois.
- Defender uma recomendação que combine desempenho, economia, estabilidade e capacidade de execução.

Ideias para levar

- Um modelo pode ordenar bem mesmo com probabilidades na escala errada.
- A política é uma decisão adicional ao modelo.
- Parte da qualidade do modelo só será conhecida depois da maturação do alvo.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
43	Estamos comparando modelos ou comparando condições diferentes?	58
44	Quem aparece primeiro na fila de risco?	59
45	Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?	60
46	Até qual PD vamos aprovar?	61

SLIDE	TÍTULO	PÁGINA
47	Com estas hipóteses, o equilíbrio ocorre em PD de 20%	62
48	O que conseguimos monitorar agora? O que exige esperar?	63
49	Defenda sua recomendação para o comitê	64
50	Você consegue explicar, comparar e usar os três modelos?	66

Estamos comparando modelos ou comparando condições diferentes?

O protocolo precede qualquer métrica

AVALIAÇÃO E DECISÃO slide 43 de 50

Estamos comparando modelos ou comparando condições diferentes?

O protocolo precede qualquer métrica

CONDIÇÃO	LOGIT REGULARIZADO	ÁRVORE CONTROLADA	GRADIENT BOOSTING
Amostra e alvo mesmas coortes, mesmo evento e mesmo horizonte de 12 meses		comum	
Informação disponível as seis características, com a mesma regra de disponibilidade		comum	
Pré processamento tratamento próprio é permitido, sem vantagem de informação	padronização, mais a imputação comum	imputação pela mediana do treino e indicadores de ausência	
Escolha de complexidade sempre pela perda na validação fora do tempo	grade de penalização L2	profundidade, mínimo por folha e poda	taxa, profundidade e número de árvores
Avaliação final uma única passagem, com regras definidas antes		teste congelado	

OS QUATRO PERÍODOS, COM A MATURAÇÃO DE 12 MESES

treino

validação

calibração e política

teste

2018 2020 2022 2024 2026

treino 16.000 · validação 4.000 · calibração e política 3.000 · teste 5.000 contratos

DETECTAR COMPARAÇÃO INJUSTA

Boosting com variável do futuro

Logit sem tratamento

Configuração escolhida pelo teste

Esconder metadados

Reiniciar exemplo

METADADOS DAS PARTIÇÕES

treino jan/2018 a dez/2019 · n = 16.000 · 2.124 eventos · alvo completo em dez/2020

validação jan/2021 a jun/2021 · n = 4.000 · 522 eventos · alvo completo em jun/2022

calibração e política ago/2022 a dez/2022 · n = 3.000 · 464 eventos · alvo completo em dez/2023

teste fev/2024 a jul/2024 · n = 5.000 · 712 eventos · alvo completo em jul/2025

semente 20.260.920 · numpy 2.4.6 · sklearn 1.9.1 · python 3.11.15

sha256 do arquivo de resultados: 819746e8a01e72c2e9974080...

Mesmo alvo, mesma informação e teste preservado são condições da comparação.

Experimento sintético; semente e versões no notebook

Slide 43 como aparece na tela (estado revelado, com os controles e as etapas abertas). Tabela do protocolo com o que é comum aos três modelos e o que é próprio de cada um, mais a tira dos quatro períodos.

Estamos comparando modelos ou comparando condições diferentes? O protocolo precede qualquer métrica. Comum aos três modelos: mesmas coortes, mesmo evento e mesmo horizonte de 12 meses; as seis características com a mesma regra de disponibilidade; avaliação final numa única passagem, com regras definidas antes, no teste congelado. Próprio de cada um: o pré processamento (padronização mais a imputação comum no logit; imputação pela mediana do treino e indicadores de ausência nos três) e a escolha de complexidade, sempre pela perda na validação fora do tempo: grade de penalização L2 no logit; profundidade, mínimo por folha e poda na árvore; taxa, profundidade e número de árvores no boosting. As partições: treino 16.000 contratos e 2.124 eventos; validação 4.000 e 522; calibração e política 3.000 e 464; teste 5.000 e 712. Semente 20260920, com versões de numpy, scikit learn e python registradas. Mesmo alvo, mesma informação e teste preservado são condições da comparação.

NA TELA

Os três botões mostram comparações injustas típicas: boosting com variável do futuro, logit sem tratamento e configuração escolhida pelo teste. "Ver protocolo executado" abre os metadados.

Mesmo alvo, mesma informação e teste preservado são condições da comparação.

Experimento sintético; semente e versões no notebook

Versão da aula 2b6298264377 · gerado em 22 de setembro de 2026 · dados sintéticos

58 de 71

Quem aparece primeiro na fila de risco?

AUC contada por pares e curvas do experimento sintético

AVALIAÇÃO E DECISÃO slide 44 de 50

Quem aparece primeiro na fila de risco?

AUC contada por pares e curvas do experimento sintético

Microexemplo de pares



Curvas do experimento

modelo Logit

Árvore

Boosting

teste, 5.000 contratos de fev a jul de 2024



AUC 0,7444 KS 0,3769 n = 5.000 contratos, 712 eventos

Mudar o corte não altera a AUC. A taxa de falsos positivos do eixo não é a inadimplência da carteira aprovada.

Um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada.

Microexemplo de ranking e experimento sintético, em abas identificadas

Slide 44 como aparece na tela (estado revelado, com os controles e as etapas abertas). Seis registros ordenados por escore com comparação de pares, e curvas ROC e acumuladas do KS.

Quem aparece primeiro na fila de risco? A AUC é a probabilidade de um inadimplente receber escore maior que um adimplente escolhido ao acaso, e o microexemplo de seis registros a conta par a par. Nas curvas do experimento, no teste de 5.000 contratos e 712 eventos, o boosting tem AUC 0,7444 e KS 0,3769: a curva ROC acima da diagonal e a maior distância entre as acumuladas de inadimplentes e adimplentes. Dois avisos do rodapé: mudar o corte não altera a AUC, porque ela resume todos os cortes de uma vez; e a taxa de falsos positivos do eixo não é a inadimplência da carteira aprovada, que depende do corte e é medida no slide 46. A conclusão que o próximo slide vai explorar: um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada.

$$AUC = P(s_{\text{inadimplente}} > s_{\text{adimplente}}) \quad KS = \max_c |F_1(c) - F_0(c)|$$

AUC como probabilidade de ordenação correta de um par; KS como maior distância entre as acumuladas.

NA TELA

Na aba "Microexemplo de pares", selecione um inadimplente e compare com os adimplentes; na aba "Curvas do experimento", troque o modelo.

Um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada.

Microexemplo de ranking e experimento sintético, em abas identificadas

AVALIAÇÃO E DECISÃO · SLIDE 45 DE 50


Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?

Média prevista contra frequência observada, faixa a faixa

AVALIAÇÃO E DECISÃO slide 45 de 50

Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?

Média prevista contra frequência observada, faixa a faixa



FAIXA	N EVENTOS	PREVISTA	OBSERVADA	WILSON
1	500	13	3,71%	2,60%
2	501	25	5,40%	4,99%
3	504	31	6,70%	6,15%
4	495	50	7,98%	10,10%
5	500	42	9,46%	8,40%
6	500	50	11,17%	10,00%
7	503	59	13,16%	11,73%
8	497	105	16,24%	21,13%
9	500	114	22,89%	22,80%
10	500	223	46,40%	44,60%

PREVISÕES ORIGINAIS

AUC **0,744367**
Brier **0,10676**
log loss **0,35694**
PD média prevista **14,31%**
taxa observada **14,24%**

Modelo

Logit **Árvore** **Boosting**

Versão das previsões

Originais

Odds vezes 2 (perturbação)

Calibradas (Platt)

[Reiniciar exemplo](#)

odds $\times 2 \iff z + \ln 2$: deslocamento constante no log odds não troca ninguém de lugar na fila, então a AUC permanece 0,744367. Brier e log loss mudam.

Calibrar é verificar a escala das probabilidades, não apenas a ordem dos clientes.

Experimento sintético; semente e versões no notebook

Slide 45 como aparece na tela (estado revelado, com os controles e as etapas abertas). Diagrama de calibração com dez faixas por quantis, intervalos de Wilson e histograma das probabilidades previstas.

Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes? O diagrama de calibração compara, faixa a faixa por quantis das previsões no teste, a PD média prevista com a frequência observada, com intervalos de Wilson. Para o boosting, na faixa 6 a PD prevista é 11,17% e a observada 10,00% (7,7% a 12,9%); na faixa 8, prevista 16,24% e observada 21,13% (17,8% a 24,9%), a maior discrepância; na faixa 10, 46,40% contra 44,60%. No conjunto, PD média prevista 14,31% e taxa observada 14,24%, com AUC 0,744367, Brier 0,10676 e log loss 0,35694. A perturbação "odds vezes 2" é a demonstração central: multiplicar as odds equivale a somar $\ln 2$ ao log odds, um deslocamento constante que não troca ninguém de lugar na fila, então a AUC permanece 0,744367, mas Brier e log loss pioram. Calibrar é verificar a escala das probabilidades, não apenas a ordem dos clientes.

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad \text{odds} \times 2 \iff z + \ln 2$$

Brier mede qualidade probabilística; o deslocamento constante em z preserva a ordem e muda a escala.

NA TELA

Troque o modelo e a versão das previsões (originais, odds vezes 2, calibradas por Platt) e acompanhe AUC, Brier e log loss.

Calibrar é verificar a escala das probabilidades, não apenas a ordem dos clientes.

Experimento sintético; semente e versões no notebook


Até qual PD vamos aprovar?

O corte define quem entra na carteira e o que se observa depois

AVALIAÇÃO E DECISÃO slide 46 de 50

Até qual PD vamos aprovar?

O corte define quem entra na carteira e o que se observa depois



NO CORTE DE 20,0%

partição de política	
aprovados	2.372 de 3.000
taxa de aprovação	79,1%
eventos entre aprovados	236
inadimplência entre aprovados	9,95%
PD média dos aprovados	9,86%

Corte de aprovação

aprovação 79,1%

[Logit](#) [Árvore](#) [Boosting](#)

[Partição de política](#) [Teste, modo final](#)

[Corte congelado 20%](#)

[Mesmo volume de aprovação](#)

[Reiniciar exemplo](#)

A política é definida nesta partição, antes de qualquer olhar ao teste.

A mesma previsão pode sustentar políticas diferentes. A política é uma decisão adicional ao modelo.

Experimento sintético; semente e versões no notebook

Slide 46 como aparece na tela (estado revelado, com os controles e as etapas abertas). Histograma das PDs com a linha de corte, taxa de aprovação e inadimplência observada entre aprovados.

Até qual PD vamos aprovar? O corte define quem entra na carteira e o que se observa depois. Com o boosting calibrado e corte de 20,0% na partição de política, são aprovados 2.372 de 3.000 contratos, taxa de aprovação de 79,1%; entre os aprovados há 236 eventos, inadimplência de 9,95%, com PD média de 9,86%. As duas curvas abaixo do histograma mostram o compromisso: subir o corte aprova mais e eleva a inadimplência entre aprovados; baixar o corte faz o oposto. A política é definida nesta partição, antes de qualquer olhar ao teste; "Teste, modo final" aplica o corte congelado uma única vez. A mesma previsão pode sustentar políticas diferentes, e a política é uma decisão adicional ao modelo: o slide seguinte mostra de onde vem o número 20%.

$$\text{taxa de aprovação} = \frac{\#\{\hat{p} \leq c\}}{n} \quad \text{inadimplência entre aprovados} = \frac{\sum_{\hat{p} \leq c} y}{\#\{\hat{p} \leq c\}}$$

As duas curvas do slide, em função do corte c .

NA TELA

Arraste o corte de aprovação, troque o modelo e a partição; "Corte congelado 20%" e "Mesmo volume de aprovação" fixam duas comparações justas.

A mesma previsão pode sustentar políticas diferentes. A política é uma decisão adicional ao modelo.

Experimento sintético; semente e versões no notebook

AVALIAÇÃO E DECISÃO · SLIDE 47 DE 50


Com estas hipóteses, o equilíbrio ocorre em PD de 20%

Aproximação didática por operação, horizonte de 12 meses

AVALIAÇÃO E DECISÃO slide 47 de 50

Com estas hipóteses, o equilíbrio ocorre em PD de 20%

Aproximação didática por operação, horizonte de 12 meses

**HIPÓTESES**

aproximação didática, 12 meses

$$\mathbb{E}[\text{resultado}] = m - p \text{ LGD EAD} \quad p^* = \frac{m}{\text{LGD EAD}} = 20\%$$


margem antes da perda **R\$ 1.200**EAD **R\$ 10.000**LGD **60%**perda esperada **R\$ 600**resultado esperado **R\$ 600****PD do contrato**

10,0 R\$ 600

Mudar hipóteses

Versão com margem condicional

Reiniciar exemplo

MARGEM MENOS PERDA ESPERADA**Um bom ranking só gera valor quando probabilidades e política se conectam à economia da operação.**

Economia didática declarada na tela; cálculo próprio

Slide 47 como aparece na tela (estado revelado, com os controles e as etapas abertas). Resultado esperado por operação em função da PD, com o ponto de equilíbrio marcado e a decomposição em margem menos perda esperada.

Com estas hipóteses, o equilíbrio ocorre em PD de 20%. A aproximação didática por operação, no horizonte de 12 meses: resultado esperado igual à margem antes da perda, R\$ 1.200, menos a perda esperada, PD vezes LGD de 60% vezes EAD de R\$ 10.000. Em PD de 10%, a perda esperada é R\$ 600 e o resultado R\$ 600. O resultado zero quando p iguala m dividido por LGD vezes EAD: $1.200 / (0,6 \times 10.000) = 20\%$. Acima disso, cada operação destrói valor em média; abaixo, cria. Esse é o corte de equilíbrio usado no slide 46 e na comparação do slide 49. A versão com margem condicional muda a formulação (margem só no adimplemento, custo por operação) e produz outro corte, que pertence só a ela. Um bom ranking só gera valor quando probabilidades e política se conectam à economia da operação.

$$\mathbb{E}[\text{resultado}] = m - p \text{ LGD EAD} \quad p^* = \frac{m}{\text{LGD EAD}} = \frac{1.200}{0,6 \times 10.000} = 20\%$$

Resultado esperado por operação e PD de equilíbrio.

NA TELA

Arraste a PD do contrato; "Mudar hipóteses" altera margem, LGD e EAD e move o ponto de equilíbrio.

Um bom ranking só gera valor quando probabilidades e política se conectam à economia da operação.

Economia didática declarada na tela; cálculo próprio


O que conseguimos monitorar agora? O que exige esperar?

Indicadores imediatos e indicadores que dependem da maturação do alvo

AVALIAÇÃO E DECISÃO slide 48 de 50

O que conseguimos monitorar agora? O que exige esperar?

Indicadores imediatos e indicadores que dependem da maturação do alvo



Data de observação

41 coortes com alvo completo nesta data.

CENÁRIOS SINTÉTICOS

Mudança na composição dos solicitantes

Mais ausência em uma variável

Relação entre características e risco alterada

Os dois primeiros indicadores de cada cenário aparecem no dia seguinte à contratação. Inadimplência, calibração e discriminação só existem depois dos 12 meses de maturação.

[Reiniciar exemplo](#)

INDICADORES IMEDIATOS

comprometimento médio da coorte mais recente **35,5%**
utilização média **45,8%**
ausência de utilização **4,6%**
taxa de aprovação no corte congelado **77,2%**
PD média prevista **16,57%**

INDICADORES COM ALVO MATURADO

inadimplência da coorte mais recente já maturada **14,63%**
coorte correspondente **jul/2024**
coortes já maturadas **41 de 41**

Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

Experimento sintético; semente e versões no notebook

Slide 48 como aparece na tela (estado revelado, com os controles e as etapas abertas). Coortes mensais com indicadores imediatos e, para as coortes já maturadas, inadimplência observada.

O que conseguimos monitorar agora e o que exige esperar? Indicadores imediatos existem no dia seguinte à contratação: comprometimento médio da coorte mais recente 35,5%, utilização média 45,8%, ausência de utilização 4,6%, taxa de aprovação no corte congelado 77,2%, PD média prevista 16,57%. Indicadores com alvo maturado só existem 12 meses depois: na data de observação de julho de 2025, a coorte mais recente já maturada é a de julho de 2024, com inadimplência de 14,63%, e 41 de 41 coortes têm alvo completo. As linhas comparam PD média prevista e inadimplência observada por coorte de contratação. Os cenários sintéticos mostram como cada tipo de mudança aparece: composição dos solicitantes, mais ausência numa variável e relação entre características e risco alterada. Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

NA TELA

Arraste a data de observação e veja quantas coortes já maturaram; escolha um cenário sintético para ver os indicadores reagirem.

Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

Experimento sintético; semente e versões no notebook

Defenda sua recomendação para o comitê

Desempenho, economia, estabilidade e capacidade de execução na mesma mesa

AVALIAÇÃO E DECISÃO slide 49 de 50

Defenda sua recomendação para o comitê

Desempenho, economia, estabilidade e capacidade de execução na mesma mesa

TESTE DE FEV A JUL DE 2024, 5.000 CONTRATOS E 712 EVENTOS

base sintética

EVIDÊNCIA NO TESTE	LOGIT	ÁRVORE	BOOSTING
AUC	0,7446	0,7392	0,7444
Brier, qualidade probabilística	0,10670	0,10823	0,10707
Taxa de aprovação	74,8%	77,7%	79,4%
Inadimplência entre aprovados	8,50%	9,32%	9,22%
Resultado por aprovado	R\$ 690	R\$ 641	R\$ 647
Resultado total da carteira	R\$ 2.578.800	R\$ 2.487.600	R\$ 2.565.600

Política congelada antes do teste: aprovar quando a PD calibrada não passa de 20%, que é o ponto de equilíbrio econômico do slide 47.

Modelo candidato **Logit** **Árvore** **Boosting** Política

Corte de equilíbrio

Corte da partição de política

Restrição

Nenhuma

Simplicidade

Explicação individual

Ver argumentos possíveis

Reiniciar exemplo

Sem restrição adicional declarada.

REQUISITOS DA OPERAÇÃO

- equipe enxuta, sem time dedicado a manutenção de modelos
- explicação da recusa exigida pelo canal e pela área de conduta
- acompanhamento mensal, com alvo maturando 12 meses depois

SUA JUSTIFICATIVA

Por que este modelo e esta política?

Qual é o principal risco desta escolha?

Como monitorar depois da implantação?

O texto fica apenas neste dispositivo.

Uma recomendação precisa combinar desempenho, economia, estabilidade e capacidade de execução.

Experimento sintético; semente e versões no notebook

Slide 49 como aparece na tela (estado inicial, antes de conferir). Tabela comparativa dos três modelos no teste, com política congelada, e um formulário de justificativa local.

Defenda sua recomendação para o comitê. No teste de fevereiro a julho de 2024, 5.000 contratos e 712 eventos, com a política congelada de aprovar PD calibrada até 20%: logit AUC 0,7446, Brier 0,10670, aprovação 74,8%, inadimplência entre aprovados 8,50%, resultado por aprovado R\$ 690 e total R\$ 2.578.800; árvore AUC 0,7392, Brier 0,10823, aprovação 77,7%, inadimplência 9,32%, R\$ 641 e R\$ 2.487.600; boosting AUC 0,7444, Brier 0,10707, aprovação 79,4%, inadimplência 9,22%, R\$ 647 e R\$ 2.565.600. A maior AUC é do logit, mas a diferença para o menor é de 0,0054, pequena diante da variabilidade de uma única amostra. Aprovação e inadimplência mudam junto com o modelo: comparar apenas AUC esconde a diferença de volume. Manter o logit como referência e avaliar outro método como desafiante é uma recomendação defensável, se a evidência sustentar. Nenhum resultado autoriza reajustar o modelo neste mesmo teste e chamar a nova medida de avaliação independente.

NA TELA

Escolha modelo candidato, política e restrição; "Ver argumentos possíveis" lista o que a evidência sustenta. Escreva a sua justificativa nos três campos.

EXERCÍCIO**Prepare a recomendação para o comitê**

Escolha um modelo e uma política e responda em até três linhas cada pergunta, citando os números da tabela do teste.

1. Por que este modelo e esta política?
2. Qual é o principal risco desta escolha?
3. Como monitorar depois da implantação?

Uma recomendação precisa combinar desempenho, economia, estabilidade e capacidade de execução.

Experimento sintético; semente e versões no notebook

Você consegue explicar, comparar e usar os três modelos?

Definir, estimar, validar e decidir são etapas conectadas

AVALIAÇÃO E DECISÃO slide 50 de 50

Você consegue explicar, comparar e usar os três modelos?

Definir, estimar, validar e decidir são etapas conectadas

TÉCNICA	COMO CONSTRÓI A PD	PRINCIPAL CUIDADO	EVIDÊNCIA NECESSÁRIA
Regressão logística	soma funções das características em um escore e converte pela logística	especificação, unidade das variáveis e leitura dos coeficientes	validação da forma funcional e calibração fora do tempo
Árvore de decisão	aprende regras sucessivas e usa a frequência observada na folha	complexidade, tamanho de folha e instabilidade entre amostras	desempenho fora do tempo e estabilidade entre reamostragens
Gradient boosting	acrescenta contribuições sucessivas ao escore e converte no fim	trajetória de ajuste, complexidade de cada árvore e explicação	curva de validação, parada definida antes e verificação de calibração

Para os três: informação disponível na decisão, validação temporal, calibração das probabilidades e conexão com a decisão econômica.

OS MESMOS QUATRO CLIENTES DO COMEÇO

CLIENTE	LOGIT PD calibrada	ÁRVORE PD calibrada	BOOSTING PD calibrada	NO CORTE DE 20%
Ana	3,06%	5,62%	5,49%	aprovado nos três
Bruno	35,09%	24,00%	25,78%	recusado nos três
Carla	14,21%	17,80%	19,56%	aprovado nos três
Diego	68,51%	60,61%	64,91%	recusado nos três

O que muda e o que não muda: as três técnicas discordam na PD, e a maior diferença é de 11,1 pontos, em Bruno. Mesmo assim, no corte de 20% os três modelos tomam a mesma decisão para os quatro. Carla é a que chega mais perto de virar: 19,56% no boosting, a 0,44 ponto do corte.

TRÊS PERGUNTAS DE RECUPERAÇÃO [Reiniciar](#)

Odds multiplicadas por 2 significam PD multiplicada por 2?

[Responder](#)

A mesma folha pode conter clientes diferentes?

[Responder](#)

As árvores do boosting somam probabilidades?

[Responder](#)

APLICAR NO MEU TRABALHO [Copiar roteiro](#)

1. Alvo: qual evento, em qual horizonte e para qual população elegível.
2. Dados: o que existia e estava acessível na data da decisão.
3. Referência: um modelo simples bem especificado, que os demais precisam superar.
4. Protocolo: partições por data, maturação do alvo e regras congeladas antes do teste.
5. Comparação: mesmo conjunto de informação, mesma métrica e incerteza declarada.
6. Decisão: corte, economia da operação e plano de monitoramento com responsável.

Leve os seis passos para a sua carteira. A conclusão da aula está na linha de fechamento, abaixo.

A técnica importa. A evidência que sustenta seu uso importa tanto quanto.

Síntese do curso; PDs do experimento sintético, semente 20260920

Slide 50 como aparece na tela (estado inicial, antes de conferir). Tabela de síntese dos três modelos, a comparação das três PDs para os quatro clientes do slide 01, três perguntas de recuperação e o roteiro de aplicação no trabalho.

A síntese das três técnicas em três colunas: como cada uma constrói a PD, o principal cuidado e a evidência necessária. A regressão logística soma funções das características num escore e converte pela logística; cuidado com especificação, unidade das variáveis e leitura dos coeficientes; exige validação da forma funcional e calibração fora do tempo. A árvore aprende regras sucessivas e usa a frequência da folha; cuidado com complexidade, tamanho de folha e instabilidade entre amostras; exige desempenho fora do tempo e estabilidade entre reamostragens. O boosting acrescenta contribuições sucessivas ao escore e converte no fim; cuidado com a trajetória de ajuste, a complexidade de cada árvore e a explicação; exige curva de validação, parada definida antes e verificação de calibração. Para os três: informação disponível na decisão, validação temporal, calibração e conexão com a decisão econômica. Os quatro clientes do começo voltam, e as três perguntas de recuperação testam as confusões mais comuns da aula.

NA TELA

Abra cada pergunta de recuperação só depois de responder; "Copiar roteiro" leva os seis passos para o seu trabalho.

EXERCÍCIO**Três perguntas de recuperação**

Responda por escrito antes de abrir as respostas no slide. Cada uma remete a um slide da aula.

1. Odds multiplicadas por 2 significam PD multiplicada por 2? (rever o slide 11)
2. A mesma folha pode conter clientes diferentes? (rever o slide 22)
3. As árvores do boosting somam probabilidades? (rever o slide 36)

DESAFIO

Para Ana, Bruno, Carla e Diego: qual modelo, qual política e por quê? Use as PDs dos slides 12, 22, 26 e 37 e o corte de 20% do slide 47.

A técnica importa. A evidência que sustenta seu uso importa tanto quanto.

Síntese do curso; PDs do experimento sintético, semente 20260920

Síntese das três técnicas

TÉCNICA	COMO CONSTRÓI A PD	PRINCIPAL CUIDADO	EVIDÊNCIA NECESSÁRIA
Regressão logística	soma funções das características em um escore e converte pela logística	especificação, unidade das variáveis e leitura dos coeficientes	validação da forma funcional e calibração fora do tempo
Árvore de decisão	aprende regras sucessivas e usa a frequência observada na folha	complexidade, tamanho de folha e instabilidade entre amostras	desempenho fora do tempo e estabilidade entre reamostragens
Gradient boosting	acrescenta contribuições sucessivas ao escore e converte no fim	trajetória de ajuste, complexidade de cada árvore e explicação	curva de validação, parada definida antes e verificação de calibração

Para os três: informação disponível na decisão, validação temporal, calibração das probabilidades e conexão com a decisão econômica.

Os três modelos no teste, com a mesma política

EVIDÊNCIA NO TESTE	LOGIT REGULARIZADO	ÁRVORE CONTROLADA	GRADIENT BOOSTING
AUC no teste	0,7446	0,7392	0,7444
Brier, previsões calibradas	0,10670	0,10823	0,10707
Taxa de aprovação	74,8%	77,7%	79,4%
Inadimplência entre aprovados	8,50%	9,32%	9,22%
Resultado por aprovado	R\$ 690	R\$ 641	R\$ 647
Resultado total da carteira	R\$ 2.578.800	R\$ 2.487.600	R\$ 2.565.600

Teste de fevereiro a julho de 2024, 5.000 contratos e 712 eventos. Política congelada antes do teste: aprovar quando a PD calibrada não passa de 20%, o ponto de equilíbrio econômico do slide 47. Fonte: experimento sintético, semente 20260920, mesma tabela do slide 49.

Os quatro clientes nos três modelos

CLIENTE	LOGIT	ÁRVORE	BOOSTING	NO CORTE DE 20%
Ana	3,06%	5,62%	5,49%	aprovado nos três
Bruno	35,09%	24,00%	25,78%	recusado nos três
Carla	14,21%	17,80%	19,56%	aprovado nos três
Diego	68,51%	60,61%	64,91%	recusado nos três

PDs calibradas dos modelos do experimento sintético, as mesmas que a política usa. As PDs sem calibração aparecem nos slides 37 e 41; a PD do logit manual de Bruno (11,66%) é de outro universo, o exemplo didático dos slides 07 a 20.

Roteiro para aplicar no trabalho

- 1. Alvo:** qual evento, em qual horizonte e para qual população elegível.
- 2. Dados:** o que existia e estava acessível na data da decisão.
- 3. Referência:** um modelo simples bem especificado, que os demais precisam superar.
- 4. Protocolo:** partições por data, maturação do alvo e regras congeladas antes do teste.
- 5. Comparação:** mesmo conjunto de informação, mesma métrica e incerteza declarada.
- 6. Decisão:** corte, economia da operação e plano de monitoramento com responsável.

Antes da próxima aula, você deve conseguir

- ☐ Enunciar o alvo da aula com evento, horizonte, população e unidade, e explicar por que duas PDs com definições diferentes não se comparam.
- ☐ Classificar uma informação como disponível na decisão ou informação do futuro pela data de disponibilidade.
- ☐ Calcular a PD de Bruno em duas etapas, a partir dos coeficientes e do perfil de referência, e refazer a conta para um comprometimento de 48%.
- ☐ Converter probabilidade em odds e em log odds, nos dois sentidos, e explicar por que uma razão de chances de 1,49 não é risco 49% maior.
- ☐ Percorrer a árvore didática com qualquer um dos quatro clientes e calcular a PD da folha a partir das contagens.
- ☐ Calcular o ganho de Gini de uma divisão e dizer por que o histórico venceu o comprometimento na raiz.
- ☐ Refazer as duas iterações da miniatura de boosting e converter o escore final em PD uma única vez.
- ☐ Explicar por que taxa de aprendizagem, número de árvores e parada precisam ser escolhidos juntos e na validação.
- ☐ Distinguir discriminação de calibração e dizer o que muda quando as odds são multiplicadas por 2.
- ☐ Derivar o ponto de equilíbrio de 20% a partir das hipóteses econômicas e defender um corte para o comitê.

Cuidados de estudo

BLOCO	ERRO FREQUENTE	COMO SE CORRIGE
O problema de crédito	Usar uma variável registrada depois da contratação, como valor renegociado ou consulta ao bureau posterior ao evento.	Perguntar sempre a data de disponibilidade da informação, não a data do fenômeno.
O problema de crédito	Escolher hiperparâmetros olhando o teste.	O teste é avaliado uma única vez, com regras congeladas antes. Escolhas usam a validação.
Regressão logística	Ler o coeficiente como variação da PD.	O coeficiente multiplica as odds. A variação da PD depende do ponto de partida e passa pela logística.
Regressão logística	Tratar odds dobradas como PD dobrada.	Odds de 0,1111 dobradas dão 0,2222, o que corresponde a PD de 18,18%, não de 20%.
Regressão logística	Codificar canal como 1, 2 e 3 numa única variável.	Categorias entram por indicadores em relação a uma referência. Números inventam uma ordem que os dados não garantem.
Regressão logística	Confundir linearidade nos parâmetros com linearidade nas variáveis.	Nós, transformações e interações mantêm o modelo linear nos parâmetros e mudam a forma do efeito.
Árvore de decisão	Confiar na taxa de uma folha pequena como se fosse precisa.	10% em 20 contratos tem intervalo de 2,8% a 30,1%; em 1.000 contratos, 8,3% a 12,0%.
Árvore de decisão	Escolher a divisão pela folha mais pura.	A regra é a menor impureza ponderada pelo tamanho de cada lado, medida em toda a amostra.
Árvore de decisão	Esperar que a renda mude a PD de Carla na árvore didática.	A renda não participa das perguntas dessa árvore. Dentro da folha a previsão é constante.
Gradient boosting	Somar as folhas do boosting em pontos percentuais.	As contribuições somam no escore F. A logística é aplicada uma única vez, no fim.
Gradient boosting	Repetir a mesma correção em cada iteração.	Depois de cada árvore os gradientes são recalculados. A segunda correção do grupo B cai de 0,200000 para 0,166078.
Gradient boosting	Ler contribuição positiva do histórico como efeito causal.	A contribuição explica a função aprendida com registros históricos, não o efeito de mudar o cadastro.

BLOCO	ERRO FREQUENTE	COMO SE CORRIGE
Avaliação e decisão	Comparar AUCs de modelos que usaram informação diferente.	Mesmo alvo, mesma informação e teste preservado são condições da comparação.
Avaliação e decisão	Tomar AUC boa como prova de probabilidades corretas.	Multiplicar as odds por 2 não altera a AUC e piora Brier e log loss. Calibração é verificação à parte.
Avaliação e decisão	Ler a taxa de falsos positivos da ROC como inadimplência da carteira aprovada.	A inadimplência entre aprovados depende do corte e é medida na partição de política, faixa a faixa.
Avaliação e decisão	Julgar a qualidade do modelo no dia seguinte à implantação.	Composição, ausência e aprovação aparecem no dia seguinte. Inadimplência, calibração e discriminação só depois de 12 meses.

Glossário

PD

Probabilidade de inadimplência: chance estimada de o evento definido ocorrer no horizonte definido. Deve ser lida como frequência esperada em exposições semelhantes, não como destino de um cliente.

Evento e horizonte

Nesta aula, atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação. Atingir exatamente 90 dias não conta.

Escore z

Soma do intercepto com as contribuições de cada característica, na escala do log odds. Pode ser qualquer número real.

Odds

Razão entre a probabilidade do evento e a do não evento: p dividido por $(1 - p)$. PD de 10% corresponde a odds de 1 para 9, ou 0,1111.

Log odds

Logaritmo natural das odds. É a escala em que o logit soma as contribuições.

Curva logística (sigmoide)

Função que converte qualquer escore em probabilidade entre 0% e 100%: p igual a 1 dividido por $(1 + e^{\text{elevado a menos } z})$.

Razão de chances

Multiplicador das odds quando uma característica muda: e elevado ao coeficiente vezes a variação. Não é a variação da PD.

Log loss (perda logarítmica)

Perda de uma observação: menos o logaritmo da probabilidade atribuída ao que de fato ocorreu. O ajuste minimiza a média das perdas.

Regularização

Penalidade sobre o tamanho dos coeficientes, controlada por C . Força maior (C menor) encolhe coeficientes e reduz a sensibilidade ao ruído do treino.

Raiz, nó, ramo e folha

Raiz é a primeira pergunta; nó é qualquer pergunta; ramo é a resposta que leva adiante; folha é o grupo final, onde a previsão é atribuída.

Impureza de Gini

G igual a $2p(1 - p)$ para dois desfechos: zero quando o grupo é puro, máximo de 0,5 quando a taxa é 50%. A divisão escolhida é a de menor impureza ponderada.

Intervalo de Wilson

Intervalo binomial descritivo para a taxa de uma folha. Mesma taxa com menos contratos produz intervalo mais largo.

Poda por complexidade

Remoção de divisões cujo ganho não compensa o custo de complexidade, escolhido pela validação.

Resíduo (gradiente negativo)

Para a perda logística, y menos p : diferença entre o observado e a probabilidade atual. É o que a próxima árvore do boosting aprende.

Taxa de aprendizagem (η)

Fração da contribuição de cada árvore que entra no escore. Taxa menor exige mais árvores e costuma generalizar melhor.

Parada com paciência

Regra que interrompe o treino quando a validação não melhora além de uma tolerância por certo número de iterações. Definida antes de olhar o teste.

Importância por permutação

Queda da AUC quando os valores de uma variável são embaralhados. Mede uso global, não efeito causal.

Contribuição local

Quanto cada característica desloca o escore de um cliente em relação à referência. Explica a função aprendida, não identifica causa.

AUC

Probabilidade de um inadimplente receber escore maior que um adimplente escolhido ao acaso. Mede ordenação, não escala.

KS

Maior distância entre as distribuições acumuladas dos escores de inadimplentes e adimplentes.

Calibração

Compatibilidade entre PD prevista e frequência observada, faixa a faixa. Brier e log loss medem qualidade probabilística; a AUC não a captura.

Corte de aprovação

PD máxima aceita na política. Define taxa de aprovação e inadimplência entre aprovados, e é decidido na partição de política, antes do teste.

Ponto de equilíbrio

PD em que o resultado esperado por operação é zero: margem dividida por LGD vezes EAD. Com as hipóteses da aula, 20%.

Maturação do alvo

Os 12 meses que precisam passar depois da contratação para o desfecho existir. Indicadores de qualidade só aparecem depois dela.