

LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2

Entender as três técnicas

Regressão logística, árvore de decisão e gradient boosting aplicados à probabilidade de inadimplência, da previsão à decisão de crédito

GUIA DO PROFESSOR

ENTREGA DA AULA

Comparação fundamentada dos modelos e exercícios de interpretação

FORMATO

Encontro de 180 minutos, com 15 minutos de intervalo. Cinquenta slides interativos em cinco blocos, com quatro clientes fictícios acompanhados do começo ao fim.

O problema de crédito

slides 01 a 06

Regressão logística

slides 07 a 20

Árvore de decisão

slides 21 a 30

Gradient boosting

slides 31 a 42

Avaliação e decisão

slides 43 a 50

NESTE GUIA

Como usar este guia, ritmo proposto e caminho da aula	2
Os quatro clientes, o alvo, o dicionário das variáveis e a origem dos números	3
Mapa dos 50 slides, com a página de cada um	5
Bloco 1: O problema de crédito, slides 01 a 06	7
Bloco 2: Regressão logística, slides 07 a 20	14
Bloco 3: Árvore de decisão, slides 21 a 30	30
Bloco 4: Gradient boosting, slides 31 a 42	42
Bloco 5: Avaliação e decisão, slides 43 a 50	56
Síntese das três técnicas, os modelos no teste e os quatro clientes nos três modelos	65
Sinais para observar na turma e lista de verificação de saída	66
Glossário	68

Edição do professor. Contém respostas dos exercícios, notas de condução e cuidados reservados. Não distribuir aos alunos: eles recebem o guia do aluno, sem gabarito.

Versão da aula 64c08fbe6569 · material gerado em 21 de setembro de 2026

Todos os dados são sintéticos. Nenhum número descreve carteira real.

Como usar este guia

Este guia reúne, na ordem dos 50 slides, o que o painel da aula mostra no bloco "Roteiro do slide no ar": condução, respostas esperadas, cuidados e limites, aprofundamentos e a transição para o slide seguinte. Serve para preparar a aula e para conduzir sem depender da tela.

Na plataforma, inicie a aula pelo cartão da turma e, no painel, use "Conduzir pelos slides" e "Projetar os slides". A janela projetada não mostra notas, impressão nem modo estudo: a turma vê só o slide. As notas ficam no painel e neste guia.

Sem a plataforma, abra o arquivo completo da aula: a tecla P ou o botão Professor mostram as notas ao lado do slide. O aluno recebe uma versão compilada sem as notas, tanto na tela ao vivo quanto em Materiais.

Cada slide vem capturado no estado revelado (solução aberta, etapas completas), que é o estado que a impressão do baralho também usa. Os exercícios trazem o gabarito em "Respostas esperadas". O guia do aluno reproduz os mesmos exercícios sem gabarito.

O ritmo por bloco na tabela abaixo é uma proposta para os 165 minutos úteis do encontro, calculada a partir da duração definida no desenho do curso (180 minutos com 15 de intervalo). Não foi validada em sala: ajuste à turma.

Ritmo proposto por bloco

BLOCO	SLIDES	MINUTOS
O problema de crédito	01 a 06	25
Regressão logística	07 a 20	45
Árvore de decisão	21 a 30	35
Gradient boosting	31 a 42	35
Avaliação e decisão	43 a 50	25
Total útil	50 slides	165

Proposta calculada sobre os 165 minutos úteis definidos no desenho do curso (180 minutos com 15 de intervalo). Não validada em sala. Os blocos de logit e de boosting concentram as contas feitas a mão e os exercícios; se houver folga, reserve a eles.

O caminho da aula

BLOCO	SLIDES	PERGUNTA QUE O BLOCO RESPONDE
O problema de crédito	01 a 06	O que exatamente queremos prever, com que informação e para decidir o quê?
Regressão logística	07 a 20	Como uma soma de efeitos vira uma probabilidade entre 0% e 100%, e como se lê cada coeficiente?
Árvore de decisão	21 a 30	Como perguntas sucessivas separam grupos de risco, e o que sustenta a taxa de cada folha?
Gradient boosting	31 a 42	Como correções sucessivas, somadas no escore, constroem uma previsão melhor que a de uma árvore só?
Avaliação e decisão	43 a 50	Como comparar os três modelos com justiça e transformar probabilidades em política de crédito?

Os quatro clientes, o alvo e as variáveis

Ana, Bruno, Carla e Diego aparecem no slide 01, antes de qualquer modelo, e voltam no slide 50 com as três técnicas e a política aplicadas. As seis características de cada um são as mesmas do começo ao fim. Perfis fictícios, elegíveis, sem desfecho revelado.

Características no momento da proposta

CLIENTE	RENDA	COMPROMETIMENTO	RELACIONAMENTO	UTILIZAÇÃO	HISTÓRICO	CANAL
Ana	R\$ 7.000	22%	36 meses	30%	não	Agência
Bruno	R\$ 4.500	38%	8 meses	65%	sim	Digital
Carla	R\$ 10.000	48%	60 meses	85%	não	Digital
Diego	R\$ 3.500	55%	4 meses	90%	sim	Parceiro

O alvo

Evento: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação.

População: solicitantes elegíveis, sem inadimplência corrente na data da proposta. **Unidade:** contrato de crédito pessoal, um cliente por registro. **Horizonte:** 12 meses.

Dicionário das variáveis

VARIÁVEL	UNIDADE	DEFINIÇÃO	DISPONIBILIDADE
Renda	R\$ por mês	Renda verificada na proposta.	Conhecida até a decisão.
Comprometimento	%	Parcela mensal total, já incluindo a operação proposta, dividida pela renda verificada.	Calculável no momento da decisão.
Relacionamento	meses	Meses completos de relacionamento com a instituição.	Conhecido até a decisão.
Utilização	%	Uso dos limites já existentes.	Último dado disponível até a decisão.
Histórico	0 ou 1	Houve atraso de 15 a 89 dias nos 12 meses anteriores. Não é inadimplência corrente.	Histórico conhecido na decisão.
Canal	categoria	Agência, digital ou parceiro. Variável preditiva, sem leitura causal.	Registrado na proposta.

De onde vêm os números

ORIGEM	O QUE SUSTENTA
Logit manual de seis características	slides 07 a 20, com conta aberta e conferível a mão; coeficientes escolhidos para ensinar, não estimados em dados
Árvore didática de 1.000 contratos	slides 21 a 30; contagens e taxas das folhas conferem com a raiz
Miniatura de 10 registros	slides 31 a 36 e 42; taxa de aprendizagem igual a 1 para facilitar a leitura

ORIGEM	O QUE SUSTENTA
Experimento sintético de 28.000 contratos	slides 05, 18, 27 a 29, 37 a 41 e 43 a 49; semente 20260920, versões e conferências no notebook
Economia declarada na tela	slide 47: margem de R\$ 1.200, EAD de R\$ 10.000 e LGD de 60%

Experimento sintético: 28.000 contratos, semente 20260920, numpy 2.4.6, scikit learn 1.9.1, python 3.11.15. Base sintética. Nenhum dado real de cliente. Os modelos são ajustados no treino, selecionados na validação, calibrados na partição de calibração e avaliados uma única vez no teste.

Mapa dos 50 slides

SLIDE	TÍTULO	BLOCO	PÁGINA
01	Você aprovaria estes quatro clientes?	O problema de crédito	8
02	O que sabemos no momento da proposta?	O problema de crédito	9
03	Probabilidade de quê, para quem e até quando?	O problema de crédito	10
04	Esse dado existia quando o crédito foi aprovado?	O problema de crédito	11
05	Aprender no passado, escolher sem olhar o teste	O problema de crédito	12
06	O mesmo cliente, três formas de aprender o risco	O problema de crédito	13
07	Cada informação altera o escore do cliente	Regressão logística	15
08	-2,025 não é uma probabilidade	Regressão logística	16
09	Um escore, uma probabilidade entre 0% e 100%	Regressão logística	17
10	10% de PD significa odds de 1 para 9	Regressão logística	18
11	Mais 10 pontos de comprometimento multiplicam as odds por 1,49	Regressão logística	19
12	Bruno: como chegamos à PD de 11,66%?	Regressão logística	20
13	O modelo aprende penalizando previsões incompatíveis com os dados	Regressão logística	21
14	Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor	Regressão logística	22
15	Canal digital não significa duas vezes agência	Regressão logística	23
16	O efeito pode se intensificar depois de um limite	Regressão logística	24
17	O comprometimento pesa igual para quem tem histórico de atraso?	Regressão logística	25
18	Coeficientes extremos podem estar aprendendo ruído	Regressão logística	26
19	Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade	Regressão logística	27
20	Bruno aumenta seu comprometimento de 38% para 48%. E agora?	Regressão logística	28
21	Houve atraso? Qual é o comprometimento?	Árvore de decisão	31
22	Nesta folha, 18 de 600 contratos ficaram inadimplentes	Árvore de decisão	32
23	Qual pergunta separa melhor os comportamentos observados?	Árvore de decisão	33
24	Histórico reduz o Gini de 0,180 para 0,160	Árvore de decisão	34
25	Duas folhas com PD de 10%. A evidência é igual?	Árvore de decisão	35
26	O mesmo aumento de comprometimento pode mudar de folha	Árvore de decisão	36
27	A árvore cresce. O resultado fora do treino acompanha?	Árvore de decisão	37
28	Três controles, três formas de conter o excesso de divisões	Árvore de decisão	38
29	Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?	Árvore de decisão	39
30	Carla recebe qual PD nesta árvore?	Árvore de decisão	40

SLIDE	TÍTULO	BLOCO	PÁGINA
31	E se uma árvore pequena ainda deixar estrutura nos erros?	Gradient boosting	43
32	A próxima árvore aprende a partir das previsões atuais	Gradient boosting	44
33	Dois eventos em dez contratos: começamos em 20%	Gradient boosting	45
34	A primeira correção reduz A e aumenta B	Gradient boosting	46
35	A primeira árvore mudou as previsões. Agora mudam os gradientes	Gradient boosting	47
36	Escore inicial mais árvore 1 mais árvore 2 é a nova PD	Gradient boosting	48
37	Learning rate e número de árvores precisam ser escolhidos juntos	Gradient boosting	49
38	Uma correção pode depender de uma característica ou da combinação de várias	Gradient boosting	50
39	Continuar melhorando o treino pode deixar de ajudar a validação	Gradient boosting	51
40	Mais flexibilidade exige mais disciplina de validação	Gradient boosting	52
41	O que o modelo usa em geral? O que pesou para Bruno?	Gradient boosting	53
42	O novo cliente caiu no grupo B. Qual é a previsão?	Gradient boosting	54
43	Estamos comparando modelos ou comparando condições diferentes?	Avaliação e decisão	57
44	Quem aparece primeiro na fila de risco?	Avaliação e decisão	58
45	Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?	Avaliação e decisão	59
46	Até qual PD vamos aprovar?	Avaliação e decisão	60
47	Com estas hipóteses, o equilíbrio ocorre em PD de 20%	Avaliação e decisão	61
48	O que conseguimos monitorar agora? O que exige esperar?	Avaliação e decisão	62
49	Defenda sua recomendação para o comitê	Avaliação e decisão	63
50	Você consegue explicar, comparar e usar os três modelos?	Avaliação e decisão	64

BLOCO 1 DE 5 · SLIDES 01 A 06

1 O problema de crédito

O que exatamente queremos prever, com que informação e para decidir o quê?

O que você vai aprender

- Formular o alvo: evento, horizonte, população e unidade de análise.
- Separar a informação que existia na decisão da informação que só aparece depois.
- Dividir a base por calendário respeitando os 12 meses de maturação do alvo.
- Reconhecer que as três técnicas partem dos mesmos dados e do mesmo objetivo.

Ideias para levar

- Sem a mesma definição de inadimplência, duas PDs não são comparáveis.
- Vale a data em que a informação ficou disponível, não a data do fenômeno.
- O teste é avaliado uma única vez, com regras congeladas antes.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
01	Você aprovaria estes quatro clientes?	8
02	O que sabemos no momento da proposta?	9
03	Probabilidade de quê, para quem e até quando?	10
04	Esse dado existia quando o crédito foi aprovado?	11
05	Aprender no passado, escolher sem olhar o teste	12
06	O mesmo cliente, três formas de aprender o risco	13

O PROBLEMA DE CRÉDITO - SLIDE 01 DE 50

Você aprovaria estes quatro clientes?

Crédito pessoal, horizonte de 12 meses

O PROBLEMA DE CRÉDITO slide 01 de 50
Você aprovaria estes quatro clientes?
Crédito pessoal, horizonte de 12 meses

Ana R\$ 7.000 por mês - comprometimento 22% - histórico não - utilização 30% - relacionamento 36 meses	Aprovar Recusar Preciso de mais informação
Bruno R\$ 4.500 por mês - comprometimento 38% - histórico sim - utilização 65% - relacionamento 8 meses	Aprovar Recusar Preciso de mais informação
Carla R\$ 10.000 por mês - comprometimento 48% - histórico não - utilização 85% - relacionamento 60 meses	Aprovar Recusar Preciso de mais informação
Diego R\$ 3.500 por mês - comprometimento 55% - histórico sim - utilização 90% - relacionamento 4 meses	Aprovar Recusar Preciso de mais informação

Que informação faria você mudar de ideia?

Aprovar exige estimar risco e definir uma política.

Esquema conceitual; sem dados

Slide 01 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Quatro propostas de crédito pessoal com renda e comprometimento, cada uma com três opções de decisão. Escolha Aprovar, Recusar ou Preciso de mais informação para cada cliente. A seleção fica apenas no seu dispositivo. "Revelar mais informações" mostra histórico, utilização e relacionamento; "O desafio da aula" resume o percurso.

TRANSIÇÃO PARA O SLIDE 02

Antes de escolher uma técnica, precisamos conhecer os mesmos clientes e definir exatamente o que vamos prever.

CONDUÇÃO

- Peça 20 segundos de avaliação silenciosa e registre uma opinião por perfil.
- Pergunte por que Carla, com a maior renda da mesa, ainda poderia exigir investigação.
- Se alguém pedir taxa, prazo e custos, reconheça que faltam elementos da política econômica. A conta aparece no slide 47.

CUIDADOS E LIMITES

- A seleção representa apenas a escolha neste dispositivo. Não existe contagem de turma nem resultado coletivo.
- Nenhuma proposta tem desfecho conhecido. Não atribua valor moral à renda nem ao nome do cliente.
- Um cliente de maior risco ainda pode ser economicamente aceitável sob certas condições. Cobrar mais não resolve qualquer risco.

EXERCÍCIO

Antes de qualquer modelo

Registre uma decisão por cliente e anote, em uma linha, a informação que faria você mudar de ideia.

- Ana: R\$ 7.000 por mês, comprometimento 22%, sem histórico de atraso, utilização 30%, relacionamento 36 meses.
- Bruno: R\$ 4.500 por mês, comprometimento 38%, com histórico de atraso, utilização 65%, relacionamento 8 meses.
- Carla: R\$ 10.000 por mês, comprometimento 48%, sem histórico de atraso, utilização 85%, relacionamento 60 meses.
- Diego: R\$ 3.500 por mês, comprometimento 55%, com histórico de atraso, utilização 90%, relacionamento 4 meses.

Aprovar

Recusar

Preciso de mais informação

Aprovar exige estimar risco e definir uma política.

Esquema conceitual; sem dados

O PROBLEMA DE CRÉDITO · SLIDE 02 DE 50

O que sabemos no momento da proposta?

Seis características por cliente, com unidade e momento de observação

O PROBLEMA DE CRÉDITO slide 02 de 50

O que sabemos no momento da proposta?

Seis características por cliente, com unidade e momento de observação

CLIENTE	Renda R\$ por mês	Comprometimento %	Relacionamento meses	Utilização %	Histórico 0 ou 1	Canal categoria
Ana	7.000	22	36	30	0	Agência
Bruno	4.500	38	8	65	1	Digital
Carla	10.000	48	60	85	0	Digital
Diego	3.500	55	4	90	1	Parceiro

Ana
Renda **R\$ 7.000**
Comprometimento **22%**
Relacionamento **36 meses**
Utilização **30%**
Histórico **não**
Canal **Agência**
Perfil fictício, elegível, sem desfecho revelado.

DICIONÁRIO
Selecione um cabeçalho para ver unidade, definição e momento de observação da variável.

Comparar dois clientes Reiniciar exemplo

Cada variável descreve uma dimensão do risco. Nenhuma decide sozinha.

Esquema conceitual; sem dados

Slide 02 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Tabela de quatro clientes por seis características, com ficha ampliada do cliente selecionado. Clique num nome para ampliar a ficha e num cabeçalho para ler unidade, definição e momento de observação. "Comparar dois clientes" coloca dois perfis lado a lado.

TRANSIÇÃO PARA O SLIDE 03

Conhecer os atributos não basta: o que significa exatamente risco nesta aula?

CONDUÇÃO

- Compare primeiro a renda de Carla e a de Bruno. Depois revele comprometimento e utilização.
- Contraste relacionamento e histórico por último.
- Pergunte: qual combinação parece mais informativa que uma variável isolada? Aceite hipóteses diferentes.

CUIDADOS E LIMITES

- Canal não é efeito causal nem evidência de qualidade moral. Uma variável útil para previsão pode refletir seleção.
- Comprometimento é a parcela total mensal já incluindo a nova operação, dividida pela renda verificada.
- Histórico registra atraso de 15 a 89 dias no passado. Não é inadimplência corrente.
- As unidades serão preservadas em toda a aula, especialmente percentual contra fração.

Cada variável descreve uma dimensão do risco. Nenhuma decide sozinha.

Esquema conceitual; sem dados

Probabilidade de quê, para quem e até quando?

Atraso superior a 90 dias em qualquer momento dos 12 meses após a contratação

O PROBLEMA DE CRÉDITO slide 03 de 50

Probabilidade de quê, para quem e até quando?

Atraso superior a 90 dias em qualquer momento dos 12 meses após a contratação

Evento: atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação.

População: solicitantes elegíveis, sem inadimplência corrente na proposta. Unidade: um contrato de crédito pessoal.

Data até a qual conhecemos os dados (mês desde a contratação)

12 mês 12

Reiniciar exemplo

Atingir exatamente 90 dias não satisfaz a definição. O evento exige mais de 90.

CONTRATO A $y = 1$

evento identificado no mês 8, $y = 1$

CONTRATO B $y = 0$

janela completa sem evento, $y = 0$

CONTRATO C alvo incompleto

ainda não observado

janela incompleta, alvo ainda desconhecido

Contratado há 6 meses: a janela de 12 meses ainda não terminou.

Eixo horizontal: meses desde a contratação. Eixo vertical: atraso em dias.

Sem a mesma definição de inadimplência, duas PDs não são comparáveis.

Trajetoórias ilustrativas de contratos fictícios; cálculo próprio

Slide 03 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Três trajetórias de atraso em dias ao longo de 12 meses, com linha de 90 dias e máscara do que ainda não foi observado. Arraste o controle da data até a qual conhecemos os dados e veja a máscara avançar sobre os três contratos. Com menos de 12 meses, o contrato C fica sem alvo.

TRANSIÇÃO PARA O SLIDE 04

Agora sabemos o que prever. Precisamos garantir que os dados usados para prever existiam antes do resultado.

CONDUÇÃO

- Peça a classificação do contrato C antes de mostrar o status.
- Separe explicitamente ainda não aconteceu de não acontecerá dentro da janela.
- Leve o controle até o mês 12 e consolide os três elementos: população elegível, evento e horizonte.

RESPOSTAS ESPERADAS

- A atinge 95 dias no mês 8, portanto $y = 1$.
- B fecha os 12 meses com máximo de 88 dias, portanto $y = 0$.
- C tem apenas 6 meses observados e nenhum evento: alvo incompleto, nunca $y = 0$.
- Chegar exatamente a 90 dias não satisfaz superior a 90 dias. No mês 7 o contrato A ainda não tem evento.

CUIDADOS E LIMITES

- Esta é uma definição operacional didática. Não é transcrição de norma bancária.
- Mudar o limite de atraso ou o horizonte muda o alvo previsto, e portanto muda o modelo.

Sem a mesma definição de inadimplência, duas PDs não são comparáveis.

Trajetoórias ilustrativas de contratos fictícios; cálculo próprio

Versão da aula 64c08f6e6569 - gerado em 21 de setembro de 2026 - dados sintéticos

10 de 69

O PROBLEMA DE CRÉDITO · SLIDE 04 DE 50

Esse dado existia quando o crédito foi aprovado?

Classifique cada informação pela data em que ela ficou disponível

O PROBLEMA DE CRÉDITO slide 04 de 50

Esse dado existia quando o crédito foi aprovado?

Classifique cada informação pela data em que ela ficou disponível

Renda verificada: R\$ 4.500 por mês disponibilidade: documento verificado 3 dias antes da proposta	Disponível na decisão	Informação do futuro	sem classificação
Histórico de atrasos: um atraso de 40 dias disponibilidade: apurado nos 12 meses anteriores à proposta	Disponível na decisão	Informação do futuro	sem classificação
Utilização de limite: 65% disponibilidade: último extrato fechado antes da proposta	Disponível na decisão	Informação do futuro	sem classificação
Comprometimento com a parcela proposta: 38% disponibilidade: calculado na simulação da própria proposta	Disponível na decisão	Informação do futuro	sem classificação
Valor renegociado: R\$ 3.200 disponibilidade: registrado 3 meses depois da contratação	Disponível na decisão	Informação do futuro	sem classificação
Atraso máximo nos 12 meses seguintes: 95 dias disponibilidade: apurado no fim da janela de 12 meses	Disponível na decisão	Informação do futuro	sem classificação
Consulta de bureau: score 480 disponibilidade: consultada 2 dias depois da inadimplência	Disponível na decisão	Informação do futuro	sem classificação

Uma variável excelente depois do evento pode ser inútil para decidir antes dele.

Registros didáticos de disponibilidade; cálculo próprio

Slide 04 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Sete fichas de informação, cada uma com valor e data de disponibilidade, classificadas entre disponível na decisão e informação do futuro. Classifique cada ficha como "Disponível na decisão" ou "Informação do futuro" e clique em Conferir. O placar mostra quantas ficaram certas.

TRANSIÇÃO PARA O SLIDE 05

Além de separar passado e futuro dentro de cada proposta, precisamos separar as amostras usadas para aprender e avaliar.

CONDUÇÃO

- Classifique primeiro as três fáceis: renda verificada, histórico anterior e utilização conhecida.
- Use o atraso máximo dos 12 meses seguintes para estabelecer a regra.
- Termine com a consulta tardia de bureau: a informação pode descrever algo anterior, mas o acesso e a versão precisam existir na decisão.

RESPOSTAS ESPERADAS

- Renda verificada, histórico anterior, utilização conhecida na data e comprometimento com a parcela proposta estão disponíveis na decisão.
- Valor renegociado três meses depois, atraso máximo dos 12 meses seguintes e consulta de bureau posterior à inadimplência são informação do futuro.
- O comprometimento com a parcela proposta é permitido porque a parcela é conhecida na simulação, e não depende de observar o desfecho.

CUIDADOS E LIMITES

- Data de referência e data de disponibilidade são coisas diferentes.
- Limpeza, imputação, seleção de variáveis e normalização também vazam informação se aprenderem com o teste.

EXERCÍCIO

Classifique as sete informações

Para cada ficha, marque se estava disponível na decisão ou se é informação do futuro. Justifique pela data de disponibilidade.

1. Renda verificada: R\$ 4.500 por mês (documento verificado 3 dias antes da proposta).
2. Histórico de atrasos: um atraso de 40 dias (apurado nos 12 meses anteriores à proposta).
3. Utilização de limite: 65% (último extrato fechado antes da proposta).
4. Comprometimento com a parcela proposta: 38% (calculado na simulação da própria proposta).
5. Valor renegociado: R\$ 3.200 (registrado 3 meses depois da contratação).
6. Atraso máximo nos 12 meses seguintes: 95 dias (apurado no fim da janela de 12 meses).
7. Consulta de bureau: score 480 (consultada 2 dias depois da inadimplência).

Disponível na decisão

Informação do futuro

Uma variável excelente depois do evento pode ser inútil para decidir antes dele.

Registros didáticos de disponibilidade; cálculo próprio

Aprender no passado, escolher sem olhar o teste

Quatro partições, cada uma com 12 meses de maturação antes de o alvo existir

O PROBLEMA DE CRÉDITO slide 05 de 50

Aprender no passado, escolher sem olhar o teste
Quatro partições, cada uma com 12 meses de maturação antes de o alvo existir

MOMENTO DA DECISÃO

Com o alvo do teste completo, avaliamos uma única vez as regras já congeladas. O teste não escolhe nada.

[Reiniciar exemplo](#)

Barra sólida: contratações. Barra clara: os 12 meses até o alvo existir. Uma faixa apagada indica alvo ainda desconhecido na data da decisão.

Separar por calendário só funciona se respeitarmos quando cada resultado ficou disponível.

Experimento sintético; semente e versões no notebook

Slide 05 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Linha do tempo com quatro faixas de contratação, extensão clara de maturação de 12 meses e uma linha vertical de decisão. Alterne entre "Pronto para ajustar", "Pronto para calibrar" e "Pronto para testar" para ver quais partições já têm alvo completo em cada momento. "Erro comum" mostra o que acontece quando o teste participa da escolha.

TRANSIÇÃO PARA O SLIDE 06

Agora temos regras de comparação. Como cada técnica transforma os mesmos dados em uma PD?

CONDUÇÃO

- Peça que o aluno aponte a diferença entre o fim das contratações e o fim da observação.
- Pergunte: podemos escolher o corte depois de ver os resultados finais? Revele que o teste avalia escolhas congeladas.
- Datas completas ficam aqui nas notas; a projeção mostra apenas os anos.

RESPOSTAS ESPERADAS

- Treino: contratações de jan/2018 a dez/2019, alvo completo em dez/2020.
- Validação de ajuste: jan a jun/2021, alvo completo em jun/2022.
- Calibração e política: ago a dez/2022, alvo completo em dez/2023.
- Teste final: fev a jul/2024, alvo completo em jul/2025.

CUIDADOS E LIMITES

- Os espaços entre cortes tornam a maturação visível. Não são uma recomendação universal de desenho operacional.
- Divisão aleatória não é sempre inválida. Ela apenas não testa a generalização temporal buscada aqui.
- O modelo base é congelado antes da calibração, e a política antes do teste.

Separar por calendário só funciona se respeitarmos quando cada resultado ficou disponível.

Experimento sintético; semente e versões no notebook

O PROBLEMA DE CRÉDITO · SLIDE 06 DE 50

O mesmo cliente, três formas de aprender o risco

A ficha de entrada é a mesma nos três mecanismos

O PROBLEMA DE CRÉDITO slide 06 de 30

O mesmo cliente, três formas de aprender o risco

A ficha de entrada é a mesma nos três mecanismos

Bruno

R\$ 4.500 por mês · comprometimento 38% · relacionamento 8 meses · utilização 65% · histórico sim

O que vamos verificar?

[Reiniciar exemplo](#)

Ordenar risco: o maior risco fica acima do menor?

Estimar probabilidades: 10% previsto vira cerca de 10% observado?

Apoiar a decisão: a política resultante melhora o resultado?

Regressão logística etapa 3 de 3

Combina efeitos em um escore

PD entre 0% e 100%

O escore vira probabilidade

Etapas completas [Reiniciar](#)

Árvore de decisão etapa 3 de 3

Separar clientes por perguntas

A taxa observada na folha

Etapas completas [Reiniciar](#)

Gradient boosting etapa 3 de 3

Acréscima correções sucessivas ao escore

Só no fim o escore vira probabilidade

Etapas completas [Reiniciar](#)

Os dados e o objetivo são comuns. Muda a forma de construir a previsão.

Esquema conceitual; sem dados

NA TELA

Três painéis com o mecanismo de cada técnica: soma ponderada com curva logística, percurso em árvore e contribuições sucessivas ao escore. Avance as etapas de cada painel com "Próxima etapa" para ver o mecanismo se montar. "O que vamos verificar?" mostra as três perguntas comuns.

TRANSIÇÃO PARA O SLIDE 07

Vamos começar pela ideia mais familiar:
combinar características em um escore e
converter esse escore em probabilidade.

CONDUÇÃO

- Passe rapidamente pelos três mecanismos, sem fórmulas.
- Pergunte qual parece mais fácil de explicar e se isso basta para escolher.
- Termine selecionando logit, que abre o próximo bloco.

CUIDADOS E LIMITES

- A árvore não é um conjunto de regras definidas pelo gestor: a estrutura é aprendida dos dados, embora o gestor imponha limites.
- Boosting não é votação majoritária nem soma de probabilidades.
- O logit não é incapaz de representar não linearidades.
- Nenhum painel traz PD de modelo: aqui só existe o mecanismo.

Os dados e o objetivo são comuns. Muda a forma de construir a previsão.

Esquema conceitual; sem dados

BLOCO 2 DE 5 · SLIDES 07 A 20

2

Regressão logística

Como uma soma de efeitos vira uma probabilidade entre 0% e 100%, e como se lê cada coeficiente?

O que você vai aprender

- Montar o escore z a partir do intercepto e das diferenças de cada característica para o perfil de referência.
- Converter o escore em probabilidade pela curva logística e transitar entre probabilidade, odds e log odds.
- Ler um coeficiente como multiplicador de odds, cuja tradução em PD depende do ponto de partida.
- Entender o que o ajuste minimiza, como categorias e não linearidades entram e por que se penaliza coeficientes.

Ideias para levar

- O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.
- Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.
- A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
07	Cada informação altera o escore do cliente	15
08	-2,025 não é uma probabilidade	16
09	Um escore, uma probabilidade entre 0% e 100%	17
10	10% de PD significa odds de 1 para 9	18
11	Mais 10 pontos de comprometimento multiplicam as odds por 1,49	19
12	Bruno: como chegamos à PD de 11,66%?	20
13	O modelo aprende penalizando previsões incompatíveis com os dados	21

SLIDE	TÍTULO	PÁGINA
14	Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor	22
15	Canal digital não significa duas vezes agência	23
16	O efeito pode se intensificar depois de um limite	24
17	O comprometimento pesa igual para quem tem histórico de atraso?	25
18	Coefficientes extremos podem estar aprendendo ruído	26
19	Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade	27
20	Bruno aumenta seu comprometimento de 38% para 48%. E agora?	28

REGRESSÃO LOGÍSTICA · SLIDE 07 DE 50

Cada informação altera o escore do cliente

Do perfil de referência às diferenças do cliente

REGRESSÃO LOGÍSTICA slide 07 de 50

Cada informação altera o escore do cliente

Do perfil de referência às diferenças do cliente

$$z = \beta_0 + \sum_j \beta_j (x_j - \bar{x}_j)$$

cada barra abaixo é uma parcela da soma: $\beta_j (x_j - \bar{x}_j)$

Intercepto $-3,50$

Característica	Conta: coeficiente x (valor - referência)	Contribuição no escore z
Comprometimento (p.p.)	$0,04 \times (38 - 30)$	+0,320
Histórico de atraso (indicador)	$0,80 \times (1 - 0)$	+0,800
Relacionamento (meses)	$-0,02 \times (8 - 12)$	+0,080
Utilização (p.p.)	$0,01 \times (65 - 40)$	+0,250
Renda (R\$)	$-0,00005 \times (4500 - 5000)$	+0,025
Intercepto (perfil de referência)		-3,50

Recomeçar uma por vez Mostrar todas

Reiniciar exemplo $z = -2,025$

O sinal e o tamanho de cada contribuição dependem do coeficiente e da unidade da variável. Exemplo didático de logit; cálculo próprio

Slide 07 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Waterfall das contribuições de cada característica ao escore, partindo do intercepto do perfil de referência. Troque o cliente e veja as parcelas mudarem. "Recomeçar uma por vez" monta a cascata parcela a parcela.

TRANSIÇÃO PARA O SLIDE 08

O escore pode ser qualquer número. Como converter esse escore em algo entre zero e um?

CONDUÇÃO

- Comece no perfil de referência: renda R\$ 5.000, comprometimento 30%, relacionamento 12 meses, utilização 40% e sem histórico de atraso.
- Acrescente comprometimento e histórico. Pergunte qual teve maior contribuição neste cliente.
- Mostre que um coeficiente pequeno pode gerar efeito relevante quando a variável muda muito.
- Revele z e pergunte se esse número já é uma probabilidade.

CUIDADOS E LIMITES

- A contribuição exibida é relativa à codificação de referência escolhida. Não é decomposição causal nem medida universal de importância.
- Coeficiente e contribuição observada são coisas diferentes: a contribuição multiplica o coeficiente pelo desvio da variável.
- Centrar as variáveis facilita a interpretação do intercepto e não muda a classe de funções.

APROFUNDAR

- Material original, capítulo 4, página 13: o intercepto é âncora de nível, não coeficiente comum. Naquele exemplo, utilização zero e atraso zero não existem na carteira, então o intercepto não tem leitura como PD de um cliente real.
- Trocar o intercepto desloca a PD de todas as propostas e preserva a ordem de risco. É por isso que recalibrar um modelo cuja ordenação continua boa equivale a reestimar o nível, sem alterar a AUC. O mesmo fato aparece no slide 45.

O sinal e o tamanho de cada contribuição dependem do coeficiente e da unidade da variável.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA - SLIDE 08 DE 50

-2,025 não é uma probabilidade


Uma previsão sem restrição pode sair do intervalo entre 0% e 100%

REGRESSÃO LOGÍSTICA slide 08 de 50

-2,025 não é uma probabilidade

Uma previsão sem restrição pode sair do intervalo entre 0% e 100%

OS ESCORES DOS QUATRO CLIENTES



PRECISAMOS DE UMA TRANSFORMAÇÃO


Em vez de restringir a reta, modelamos uma escala livre e a convertemos por uma função que nunca sai do intervalo. É a curva logística do próximo slide.



UMA RETA DIRETO NA PROBABILIDADE

exemplo do problema

$P_{\text{reta}} = 0,10 + 0,03 (\text{comp} - 30)$



acima de 100%: fora dos limites

abaixo de 0%: fora dos limites

Comprometimento

previsão da reta: 130% - fora dos limites de probabilidade

Precisamos de uma transformação

Reiniciar exemplo

A PD precisa permanecer entre 0% e 100%, qualquer que seja o escore.

Exemplo didático de logit; cálculo próprio

Slide 08 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Reta numérica dos escores dos quatro clientes, régua de probabilidade sem correspondência e uma reta de probabilidade que sai dos limites. Arraste o comprometimento e veja a reta sair dos limites. "Precisamos de uma transformação" mostra a curva que resolve o problema.

TRANSIÇÃO PARA O SLIDE 09

A função logística faz exatamente essa conversão, preservando a ordem dos escores.

CONDUÇÃO

- Peça que o aluno calcule a reta simplificada em comprometimento de 20%.
- Revele o resultado negativo, leve o controle até 70% e mostre o excesso acima de 100%.
- Volte a Bruno e lembre que o escore dele não foi definido como probabilidade.

CUIDADOS E LIMITES

- A reta usada aqui existe para mostrar o problema. Não é modelo estimado.
- Não conclua que todo modelo linear de probabilidade é inútil. A mensagem é a dificuldade de garantir limites.
- Truncar em 0 e 1 altera a função de forma improvisada e não substitui um modelo probabilístico.

A PD precisa permanecer entre 0% e 100%, qualquer que seja o escore.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 09 DE 50

Um escore, uma probabilidade entre 0% e 100%

A curva logística converte qualquer número real em probabilidade

REGRESSÃO LOGÍSTICA slide 09 de 50

Um escore, uma probabilidade entre 0% e 100%

A curva logística converte qualquer número real em probabilidade

$$p = \frac{1}{1 + e^{-z}}$$

escore z **-2,025**
PD **11,66%**

Leitura: aproximadamente 11,7 eventos em 100 exposições semelhantes, e não uma contagem garantida.
Escore do perfil de Bruno.

Escore z: 11,66%

Ana Bruno Carla Diego

Ampliar as PDs baixas (0% a 30%)

[Reiniciar exemplo](#)

A mesma variação de escore pode gerar mudanças muito diferentes de probabilidade.

Exemplo didático de logit; cálculo próprio

Slide 09 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Curva logística com ponto móvel, guias até os eixos e marcadores dos quatro clientes. Arraste o escore e leia a PD; use "Ampliar as PDs baixas" para ver com detalhe a região entre 0% e 30%, onde os quatro clientes estão.

TRANSIÇÃO PARA O SLIDE 10

Para interpretar os coeficientes, precisamos entender a escala em que a soma foi feita: o logaritmo das odds.

CONDUÇÃO

- Comece em Bruno. Vá até $z = 0$ e pergunte o valor esperado antes de revelar.
- Compare o efeito de somar 1 ao escore em $z = -5$ e em $z = 0$.
- Termine em Ana e Bruno para mostrar que a função preserva a ordem dos escores.

CUIDADOS E LIMITES

- A sigmoide é estritamente crescente: a ordem de z e a ordem de p são a mesma.
- Um escore finito nunca produz exatamente 0 ou 1. A formatação pode arredondar para 0,00%, o que não significa impossibilidade.
- O ponto de 50% é referência matemática, não corte de aprovação.

APROFUNDAR

- Material original, capítulo 4, página 6: probabilidade, odds, log odds e escore de bureau são quatro réguas da mesma ordem. Lá, PD de 5% corresponde a odds 0,053, log odds -2,944 e escore didático 865.
- Qualquer transformação monótona preserva a ordenação e, portanto, a AUC. O que muda é a régua de comunicação e de cálculo.

A mesma variação de escore pode gerar mudanças muito diferentes de probabilidade.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 10 DE 50

10% de PD significa odds de 1 para 9

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes

REGRESSÃO LOGÍSTICA

slide 10 de 50

10% de PD significa odds de 1 para 9

Probabilidade, odds e log odds descrevem o mesmo risco em escalas diferentes

FREQUÊNCIA ESPERADA EM 100 EXPOSIÇÕES

10 eventos e 90 não eventos.
Representação ilustrativa, não 100 contratos com resultado garantido.

PROBABILIDADE

10 / 100 = 10%

denominador: 100

ODDS

10 / 90 = 0,1111

denominador: 90

LOG ODDS

$\ln(0,1111) = -2,197$

É exatamente a escala em que o logit soma as contribuições: o escore z.

Probabilidade de Inadimplência

10 odds 0,1111

Referências **10%** **20%** **50%** [Reiniciar exemplo](#)

CONVERSÕES NOS DOIS SENTIDOS

$$\text{odds} = \frac{p}{1-p}$$

$$p = \frac{\text{odds}}{1+\text{odds}}$$

$$z = \ln\left(\frac{p}{1-p}\right)$$

$$p = \frac{1}{1+e^{-z}}$$

Conferência de ida e volta: partindo de 10,00% a volta por odds devolve 10,00% e a volta por log odds devolve 10,00%.

Nos limites 0% e 100% o log odds vai a infinito. Por isso a escala vai de 1% a 99%.

Odds comparam eventos e não eventos. Probabilidade compara eventos e total.

Exemplo didático de logit; cálculo próprio

Slide 10 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Grade de cem pontos com a quantidade esperada de eventos, frações de conversão e o logaritmo das odds. Arraste a probabilidade e acompanhe a grade de cem pontos, as odds e o log odds. Os botões 10%, 20% e 50% marcam referências úteis.

TRANSIÇÃO PARA O SLIDE 11

Agora conseguimos interpretar o que acontece quando um coeficiente aumenta o log odds.

CONDUÇÃO

- Pergunte 10 dividido por quê antes de revelar as odds.
- Mostre que trocar o denominador muda o conceito: 10 em 100 contra 10 para 90.
- Vá a 50% e depois a 20%. Termine lembrando que o escore z do logit é o log odds.

RESPOSTAS ESPERADAS

- $p = 50\%$: odds 1 e log odds 0.
- $p = 20\%$: odds 0,25 e log odds aproximadamente $-1,386$.
- $p = 10\%$: odds $1/9$ aproximadamente 0,1111 e log odds aproximadamente $-2,197$.

CUIDADOS E LIMITES

- Odds não são outra porcentagem de risco. Podem passar de 1 e não se limitam a 100%.
- Uma razão escrita 1 para 9 é diferente do número decimal 0,1111 apenas na forma de escrever.
- Em p igual a 0 ou 1 o log odds vai a infinito. Por isso a entrada principal vai de 1% a 99%.

Odds comparam eventos e não eventos. Probabilidade compara eventos e total.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 11 DE 50

Mais 10 pontos de comprometimento multiplicam as odds por 1,49

O mesmo multiplicador de odds gera mudanças diferentes de PD

REGRESSÃO LOGÍSTICA slide 11 de 50

Mais 10 pontos de comprometimento multiplicam as odds por 1,49

O mesmo multiplicador de odds gera mudanças diferentes de PD

$\Delta comp = +10 \text{ p.p.}$ $\Delta z = 0,04 \times 10 = 0,4000$ razão de chances = $e^{0,40} \approx 1,4918$

PD INICIAL	ANTES	DEPOIS	PD DIFERENÇA p.p.
2%	0,0204	0,0304	+0,95 p.p.
10%	0,1111	0,1658	+4,22 p.p.
40%	0,6667	0,9945	+4,86 p.p.

Razão de chances de 1,49 não significa risco 49% maior. Odds e probabilidade são escalas diferentes.

Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida. Exemplo didático de logit; cálculo próprio

Slide 11 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Faixa de cálculo do multiplicador de odds e três pares de barras antes e depois para PDs iniciais de 2%, 10% e 40%. Compare "+1 p.p.", "+10 p.p." e "Odds multiplicadas por 2"; o controle de exploração aplica qualquer variação de comprometimento e recalcula a razão.

TRANSIÇÃO PARA O SLIDE 12

Vamos aplicar essa interpretação a um cliente completo e conferir todas as etapas da conta.

CONDUÇÃO

- Peça que os alunos antecipem a PD quando as odds dobrem, começando pelo cenário de 10%.
- Revele primeiro 10%, depois 2% e 40%.
- Explique que a leitura vale mantidas as outras variáveis do modelo.

RESPOSTAS ESPERADAS

- Com odds multiplicadas por 2: 2% vira aproximadamente 3,92%; 10% vira 18,18%; 40% vira 57,14%.
- Com mais 10 pontos de comprometimento, o multiplicador é elevado a 0,40, aproximadamente 1,4918.

CUIDADOS E LIMITES

- Razão de chances de 1,49 não significa que o risco aumenta 49%.
- Para uma mudança finita use a conversão exata, não o efeito marginal local.
- A leitura é associativa e condicionada às demais variáveis. Não é efeito causal.
- Os três riscos iniciais são cenários didáticos. Não são os quatro clientes.

APROFUNDAR

- Material original, capítulo 4, página 11: naquele exemplo, utilização a cada 10 pontos tem razão de chances 2,1071 e atraso a cada 10 dias tem 4,0370. A leitura está correta como multiplicação das chances e não autoriza leitura causal.
- Página 14 do mesmo capítulo: trocar a unidade muda o coeficiente e não muda o modelo. A utilização vale 0,74530 por dezena de pontos, 0,07453 por ponto e 7,45300 por fração do limite, com PD prevista idêntica nos três casos.
- Disso decorre que comparar 1,3955 com 0,7453 para dizer qual variável pesa mais não significa nada: as unidades são diferentes. A comparação legítima usa um movimento realista de cada variável, como um desvio padrão, que é o que o slide 18 faz com coeficientes padronizados.

Uma mudança na variável multiplica as odds. A mudança de PD depende do ponto de partida.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 12 DE 50

Bruno: como chegamos à PD de 11,66%?

Duas etapas auditáveis: somar o escore e aplicar a logística

REGRESSÃO LOGÍSTICA slide 12 de 50

Bruno: como chegamos à PD de 11,66%?

Duas etapas auditáveis: somar o escore e aplicar a logística

FICHA DO CLIENTE

perfil original

Ana Bruno Carla Diego

Renda em R\$ por mês 4500 R\$ 4.500

Comprometimento em % 38 38%

Relacionamento em meses 8 8 meses

Utilização em % 65 65%

Histórico de atraso de 15 a 89 dias não sim

Canal: Digital. Informativo: não participa desta fórmula manual.

Restaurar Bruno

Reiniciar exemplo

ETAPA 1: SOMAR O ESCORE


PARCELA	CONTA	VALOR
Intercepto	perfil de referência	-3,500
Comprometimento	$0,04 \times (38 - 30)$	+0,320
Histórico de atraso	$0,80 \times (1 - 0)$	+0,800
Relacionamento	$-0,02 \times (8 - 12)$	+0,080
Utilização	$0,01 \times (65 - 40)$	+0,250
Renda	$-0,00005 \times (4500 - 5000)$	+0,025
Escore z	soma das parcelas	-2,025

ETAPA 2: APLICAR A LOGÍSTICA

$$p = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{2,025}}$$

11,66%

valor sem arredondamento: 0,1166029692



O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.

Exemplo didático de logit; cálculo próprio

Slide 12 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Ficha editável do cliente, decomposição do escore e medidor de PD com curva logística. Edite qualquer característica pelos controles ou troque de cliente. "Restaurar Bruno" volta ao perfil original.

TRANSIÇÃO PARA O SLIDE 13

Esses coeficientes foram escolhidos para tornar a conta transparente. Como um modelo aprende coeficientes a partir dos dados?

CONDUÇÃO

- Reconstrua a conta passo a passo antes de mexer nos controles.
- Peça uma alteração que reduza a PD e outra que a aumente.
- Questione se a alteração seria factível: reduzir comprometimento sem mudar parcela ou renda é uma simulação abstrata.

RESPOSTAS ESPERADAS

- Ana 1,10%, Bruno 11,66%, Carla 2,82% e Diego 27,59%, com a fórmula manual.
- O recurso descreve a sensibilidade do modelo, não a garantia de uma ação causal disponível ao cliente.

CUIDADOS E LIMITES

- Canal aparece na ficha e não participa desta fórmula manual.
- Esta PD é do exemplo didático. Não é previsão de modelo treinado.

O cálculo tem duas etapas auditáveis: somar o escore e aplicar a logística.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 13 DE 50

O modelo aprende penalizando previsões incompatíveis com os dados

Perda logarítmica de uma observação, em função da probabilidade prevista

REGRESSÃO LOGÍSTICA slide 13 de 50

O modelo aprende penalizando previsões incompatíveis com os dados

Perda logarítmica de uma observação, em função da probabilidade prevista

OBSERVAÇÃO COM Y = 1 (HOUEVE EVENTO)

OBSERVAÇÃO COM Y = 0 (NÃO HOUEVE EVENTO)

$$L = -[y \ln p + (1 - y) \ln(1 - p)]$$

observação **y = 1**
 previsão **10,0%**
 perda **2,3026**

Probabilidade prevista
 perda 2,3026

Desfecho observado
y = 0 **y = 1**

[Esconder a amostra](#)
[Reiniciar exemplo](#)

OBSERVAÇÃO	y	p prevista	L
nº 1	0	5%	0,0513
nº 2	0	10%	0,1054
nº 3	0	20%	0,2231
nº 4	0	40%	0,5108
nº 5	1	60%	0,5108
nº 6	1	80%	0,2231
Média			0,2708

O QUE O AJUSTE MINIMIZA

$$L(\beta) = \frac{1}{n} \sum_{i=1}^n -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

A média das perdas dos 6 contratos, e não a perda de uma observação. Os coeficientes são os que dão o menor valor dela.

A log loss pune previsões confiantes que contradizem o que ocorreu.

Exemplo didático de logit; cálculo próprio

Slide 13 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Duas curvas de perda individual em função da probabilidade prevista, uma para y igual a 1 e outra para y igual a 0. Arraste a probabilidade prevista e alterne y igual a 0 ou 1 para ver a perda de uma observação. "Mostrar a amostra" abre a tabela dos seis contratos.

TRANSIÇÃO PARA O SLIDE 14

Mesmo com um coeficiente fixo, o efeito observado na PD muda ao longo da curva logística.

CONDUÇÃO

- Escolha y = 1 com p = 10% e depois aumente p até 90%.
- Troque y para 0 mantendo p = 90% e pergunte por que a penalização aumenta.
- Mostre que uma observação não define sozinha os coeficientes: a perda total agrega todos os casos.

RESPOSTAS ESPERADAS

- Para y = 1: p = 0,10 gera perda aproximadamente 2,3026; p = 0,90 gera aproximadamente 0,1054.
- Para y = 0 a relação se inverte: p = 0,90 gera aproximadamente 2,3026.
- Minimizar a log loss equivale a maximizar a verossimilhança do modelo logístico.

CUIDADOS E LIMITES

- Classificar corretamente a partir de um corte não basta para medir a qualidade da probabilidade.
- A perda depende do grau de confiança, não apenas do lado do corte.
- A função objetivo do treino não garante o melhor desempenho futuro.
- Em p igual a 0 ou 1 a perda vai a infinito. As curvas são desenhadas entre 0,1% e 99,9%.

APROFUNDAR

- Material original, capítulo 4, páginas 15 a 17: a perda de cada observação determina os coeficientes, e a descida de gradiente percorre os parâmetros uma iteração por vez até a convergência.
- Nesta aula a descida aparece no bloco de boosting, slides 32 a 35, com a mesma mecânica de resíduo, passo e atualização do escore.
- Página 18 do original: navegador, Python com a mesma regra e sklearn chegam ao mesmo resultado, com diferença máxima de 0,000327 no intercepto. A conferência equivalente aqui está nos metadados do slide 43 e no notebook.

A log loss pune previsões confiantes que contradizem o que ocorreu.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 14 DE 50

Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

O mesmo deslocamento horizontal produz alturas diferentes na sigmoide

REGRESSÃO LOGÍSTICA slide 14 de 50

Aumentar o escore em 0,40 não aumenta toda PD pelo mesmo valor

O mesmo deslocamento horizontal produz alturas diferentes na sigmoide

$\Delta_{comp} = 10 \text{ p.p.} \Rightarrow \Delta z = 0,04 \times 10 = 0,400$
 $p: 10,00\% \rightarrow 14,22\% \text{ (4,22 p.p.)}$

PD inicial: 2%, 10%, 40%
ou valor livre, de 1% a 60%
Mudança em comprometimento, em pontos: 10 $\Delta z = 0,400$

Esconder a aproximação local
[Reiniciar exemplo](#)

PD INICIAL	VARIACÃO EXATA p.p.	APROXIMAÇÃO LOCAL p.p.	DIFERENÇA p.p.
2%	+0,955 p.p.	+0,784 p.p.	-0,171 p.p.
10%	+4,219 p.p.	+3,600 p.p.	-0,619 p.p.
40%	+9,863 p.p.	+9,600 p.p.	-0,263 p.p.

$\frac{\partial p}{\partial z} = \beta p(1-p) = 0,04p(1-p)$ em probabilidade por ponto percentual; vale para mudanças pequenas.

A resposta em probabilidade é mais intensa na região central da curva.

Exemplo didático de logit; cálculo próprio

Slide 14 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Sigmoide com três segmentos destacados, partindo de PDs de 2%, 10% e 40%, e comparação entre variação exata e aproximação pela tangente. Escolha a PD inicial (2%, 10%, 40% ou valor livre de 1% a 60%) e a mudança em comprometimento; "Mostrar a aproximação local" desenha a tangente.

TRANSIÇÃO PARA O SLIDE 15

Até aqui usamos variáveis numéricas e um indicador. Como incluir uma característica com várias categorias?

CONDUÇÃO

- Comece pelos três segmentos, todos com a mesma largura horizontal, e peça que comparem as alturas.
- Revele os valores e só então a derivada.
- Reduza a mudança para 1 ponto e mostre a aproximação local ficando mais próxima.

RESPOSTAS ESPERADAS

- O efeito máximo da derivada da logística ocorre em p igual a 0,5. Isso é matemática, não recomendação de operar perto de 50% de PD.
- A derivada é aproximação para mudanças pequenas. Para 10 pontos de comprometimento, use a conversão exata.

CUIDADOS E LIMITES

- A variação de z continua sendo o coeficiente vezes a variação da variável.
- Valores em pontos percentuais não podem ser lidos em unidade de odds.
- Em variação zero, os dois métodos dão exatamente zero.

A resposta em probabilidade é mais intensa na região central da curva.

Exemplo didático de logit; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 15 DE 50

Canal digital não significa duas vezes agência

Categorias entram por comparação com uma referência

REGRESSÃO LOGÍSTICA slide 15 de 50

Canal digital não significa duas vezes agência

Categorias entram por comparação com uma referência

REFERÊNCIA ATUAL: AGÊNCIA extensão pedagógica da fórmula
 $z = -3,50 + 0,30 \cdot I[\text{digital}] + 0,60 \cdot I[\text{parceiro}]$

CANAL	INDICADOR DIGITAL	INDICADOR PARCEIRO	CONTRIBUIÇÃO no escore	ESCORE Z	PD
Agência	0	0	0,00	-3,50	2,93%
Digital	1	0	+0,30	-3,20	3,92%
Parceiro	0	1	+0,60	-2,90	5,22%

O QUE 1, 2 E 3 IMPORIA
Usar canal = 1, 2 e 3 em uma única variável imporia que a diferença entre agência e digital é igual à diferença entre digital e parceiro, e que a ordem econômica existe. Nada nos dados garante isso.

O número atribuído a uma categoria não deve inventar uma ordem econômica.

Extensão pedagógica da fórmula manual; cálculo próprio

Slide 15 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

Canal do cliente
Agência Digital Parceiro
Referência: Agência Referência: Digital
Referência: Parceiro
Reiniciar exemplo

Trocar a referência muda o intercepto e os coeficientes. As três PDs permanecem 2,93%, 3,92% e 5,22% em qualquer parametrização.

NA TELA

Três categorias de canal, tabela de indicadores e contribuição adicional ao escore, com troca da categoria de referência. Troque o canal do cliente e a categoria de referência e confira que os coeficientes mudam enquanto as PDs ficam iguais.

TRANSIÇÃO PARA O SLIDE 16

A codificação determina a forma que o modelo enxerga a informação. Podemos também flexibilizar a forma das variáveis numéricas.

CONDUÇÃO

- Pergunte o que ficaria implícito ao usar canal igual a 1, 2 e 3 diretamente.
- Mostre a tabela de indicadores e só então troque a referência.
- Use o momento para separar interpretação de coeficientes e previsão do modelo.

RESPOSTAS ESPERADAS

- Com agência como referência: digital soma 0,30 e parceiro soma 0,60 ao escore.
- Com digital como referência: intercepto passa a -3,20, agência recebe -0,30 e parceiro +0,30. As PDs por categoria não mudam.
- Categoria omitida não é categoria ausente: ela está no intercepto.

CUIDADOS E LIMITES

- Este é um exemplo separado, que não altera a fórmula canônica dos slides 07 a 14 nem as PDs dos quatro clientes.
- Uma categoria nova em produção exige tratamento definido na codificação. Não invente coeficiente.
- Canal pode refletir seleção, não causalidade.
- Manter todas as indicadoras junto com o intercepto cria redundância na parametrização.

O número atribuído a uma categoria não deve inventar uma ordem econômica.

Extensão pedagógica da fórmula manual; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 16 DE 50


O efeito pode se intensificar depois de um limite

Linearidade é nos parâmetros, não na forma das variáveis

REGRESSÃO LOGÍSTICA slide 16 de 50

O efeito pode se intensificar depois de um limite

Linearidade é nos parâmetros, não na forma das variáveis



$z = -3,50 + 0,04(\text{comp} - 30) + 0,04 \max(\text{comp} - 40, 0)$

Comprometimento 13,01%

[Voltar à forma linear](#)

[Ver como entra na equação](#)

[Reiniciar exemplo](#)

INCLINAÇÃO POR FAIXA	
FAIXA	INCLINAÇÃO NO ESCORE por ponto
comprometimento até 40%	0,04
comprometimento acima de 40%	0,08

No nó, as duas formas coincidem: contribuição 0,400 em ambos os casos. A função é contínua.

A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Cenário separado da fórmula manual; cálculo próprio

Slide 16 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Contribuição ao escore e PD resultante em função do comprometimento, com e sem mudança de inclinação em 40%. Arraste o comprometimento e alterne entre a forma linear e a forma com nó; "Ver como entra na equação" mostra o termo adicional.

TRANSIÇÃO PARA O SLIDE 17

Além de mudar a forma de um efeito, podemos permitir que ele dependa de outra característica.

CONDUÇÃO

- Mostre primeiro a relação na escala do escore.
- Ative a transformação e peça que identifiquem onde a inclinação muda.
- Acompanhe a tradução para PD e pergunte como decidir se a flexibilidade ajudou: a resposta cita validação, não a beleza da curva.

RESPOSTAS ESPERADAS

- Antes de 40% a inclinação é 0,04 por ponto. Depois de 40% passa a 0,08 por ponto.
- A função é contínua no nó: em comprometimento de 40% as duas formas coincidem.

CUIDADOS E LIMITES

- Escolher o nó olhando o teste vaza informação.
- Flexibilidade custa parâmetros e exige controle de complexidade.
- Este é um exemplo linear por partes, não uma spline cúbica.
- Árvores não são necessárias para representar toda não linearidade.

APROFUNDAR

- Material original, capítulo 4, página 21: faixas devolvem flexibilidade sem trocar de família, ao custo de um coeficiente por faixa em vez de um por variável.
- As regras declaradas lá continuam válidas: volume mínimo por faixa, monotonicidade quando existe hipótese econômica de direção, estabilidade das fronteiras nas safras seguintes e fronteiras definidas antes de olhar o alvo.
- O WoE é esse mesmo tratamento com um valor específico por faixa, o logaritmo da razão entre a distribuição dos adimplentes e a dos inadimplentes. A mudança de inclinação deste slide é a alternativa contínua, com um parâmetro adicional apenas.

A linearidade é nos parâmetros. A forma das variáveis pode ser flexível.

Cenário separado da fórmula manual; cálculo próprio

REGRESSÃO LOGÍSTICA · SLIDE 17 DE 50

O comprometimento pesa igual para quem tem histórico de atraso?

Interação é diferença de inclinação na escala do escore

REGRESSÃO LOGÍSTICA slide 17 de 50

O comprometimento pesa igual para quem tem histórico de atraso?

Interação é diferença de inclinação na escala do escore

$$z = -3,50 + 0,80 \text{ hist} + (0,04 + \delta \text{ hist}) (\text{comp} - 30)$$

sem interação interação de 0,03

Comprometimento: 40 termo 0,300

Ver o termo cruzado

Reiniciar exemplo

EM COMPROMETIMENTO DE 40%
 inclinações no escore: 0,04 e 0,07 por ponto
 diferença no escore: 1,100
 diferença em PD: +7,61 p.p.
 Mesmo sem interação, a diferença em PD varia com o comprometimento: a sigmoide é não linear.

Com interação, o efeito do comprometimento no escore depende do histórico.

Cenário separado da fórmula manual; cálculo próprio

Slide 17 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Duas retas de escore por comprometimento, uma para cada valor de histórico, e as curvas de PD correspondentes. Alterne "sem interação" e "interação de 0,03", arraste o comprometimento e veja as duas escalas. "Ver o termo cruzado" destaca o produto $\text{hist} \times (\text{comp} - 30)$.

TRANSIÇÃO PARA O SLIDE 18

Cada transformação ou interação acrescenta flexibilidade. Como evitar que isso capture particularidades da amostra?

CONDUÇÃO

- Comece pelo escore, com as duas retas paralelas.
- Pergunte o que muda quando o termo cruzado é ativado. Só então observe a PD.
- Peça que o aluno separe efeito do histórico no escore de diferença de probabilidade.

RESPOSTAS ESPERADAS

- Sem interação: inclinação 0,04 nos dois grupos, retas paralelas no escore.
- Com interação de 0,03: inclinação 0,04 para histórico zero e 0,07 para histórico um.
- Mesmo sem termo cruzado, a diferença de PD entre os grupos varia com o comprometimento, porque a sigmoide é não linear.

CUIDADOS E LIMITES

- Os coeficientes principais são condicionais ao valor de referência das demais variáveis.
- Com interação, o coeficiente do histórico não é efeito constante em qualquer comprometimento.
- A leitura é associativa e pode não representar uma intervenção viável.
- Ausência de termo cruzado não implica diferença constante de PD.

Com interação, o efeito do comprometimento no escore depende do histórico.

Cenário separado da fórmula manual; cálculo próprio

Coeficientes extremos podem estar aprendendo ruído

Trajetórias de coeficientes e perdas, na grade de penalização efetivamente treinada

REGRESSÃO LOGÍSTICA slide 18 de 50

Coeficientes extremos podem estar aprendendo ruído

Trajétórias de coeficientes e perdas, na grade de penalização efetivamente treinada

TRAJETÓRIAS DOS COEFICIENTES

PERDA DE TREINO E DE VALIDAÇÃO

AMOSTRA REDUZIDA DO TREINO (600 CONTRATOS)

$$L_{pen} = L + \frac{1}{2C} \sum \beta_j^2$$

C e força	0,0100 · 100
log loss treino	0,32275
log loss validação	0,35472
AUC validação	0,7170

Penalização, apenas nos valores treinados

C = 0,0100

Amostra reduzida

Treino completo

Reiniciar exemplo

Com 600 contratos e a especificação flexível, a perda de treino continua caindo enquanto a de validação sobe. O mínimo de validação ocorre em C = 0,0100, com log loss 0,35472. O teste final não participa desta escolha.

A melhor explicação do treino pode ser sensível demais para funcionar fora dele.

Experimento sintético; semente e versões no notebook

Slide 18 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Trajétórias de coeficientes padronizados em função da força da penalização e curvas de perda de treino e validação. Arraste C apenas nos valores treinados e alterne "Amostra reduzida" e "Treino completo" para ver quando a penalização faz diferença.

TRANSIÇÃO PARA O SLIDE 19

Podemos tornar o logit mais flexível e controlar sua complexidade. Em quais situações essa combinação é especialmente útil?

CONDUÇÃO

- Comece com penalização fraca, observe as magnitudes e a validação.
- Aumente a penalização e discuta o que melhora e o que piora.
- Compare os dois cenários: na amostra completa o efeito é pequeno; na amostra reduzida ele aparece com clareza.

CUIDADOS E LIMITES

- Regularização reduz variância em muitas situações. Não garante estabilidade em qualquer conjunto nem resolve mudança de população.
- Coeficientes padronizados não são os números da fórmula manual dos slides 07 a 14.
- A escolha da penalização faz parte do treinamento, e usa validação, nunca o teste.
- Com variáveis correlacionadas, nem todo coeficiente diminui de magnitude de forma monótona.
- A força da penalização mostrada é 1 dividido por C. C menor significa penalização maior.

A melhor explicação do treino pode ser sensível demais para funcionar fora dele.

Experimento sintético; semente e versões no notebook

Versão da aula 64c08f6e6569 · gerado em 21 de setembro de 2026 · dados sintéticos

26 de 69

REGRESSÃO LOGÍSTICA · SLIDE 19 DE 50


Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Adequação do logit em três situações práticas

REGRESSÃO LOGÍSTICA slide 19 de 50

Explicar a estrutura é vantagem; especificar a estrutura é responsabilidade

Adequação do logit em três situações práticas



FORÇAS

- função compacta e auditável
- interpretação condicionada à codificação
- previsão rápida e fácil de implantar
- regularização e transformações disponíveis

LIMITES

- a forma funcional é escolhida, não descoberta
- variáveis ausentes ou mal medidas continuam ausentes
- extrapolação fora da faixa observada é frágil
- correlação entre atributos dificulta a leitura de um coeficiente
- mudança de população desloca o nível da previsão

SITUAÇÃO

Sinal predominantemente aditivo

Interação relevante omitida

Amostra pequena ou instável

Crítérios de escolha

As características somam efeitos de forma estável e as faixas de risco crescem de forma regular.

PERGUNTA DE DIAGNÓSTICO

As curvas de risco por faixa são compatíveis com uma soma de efeitos na escala do escore?

Ação possível. Manter o logit como referência, documentar a especificação e verificar calibração fora do tempo.

[Reiniciar exemplo](#)

O logit oferece uma estrutura explícita, mas a qualidade depende da especificação e da validação. Síntese conceitual aplicada; sem dados

Slide 19 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Mecanismo do logit ao centro, com três situações práticas de adequação e uma síntese de critérios de escolha. Escolha cada situação para ler a pergunta de diagnóstico e a ação possível; "Critérios de escolha" resume o que decide entre manter o logit e testar outra técnica.

TRANSIÇÃO PARA O SLIDE 20

Antes de mudar de técnica, vamos verificar se conseguimos usar o que aprendemos em uma decisão de interpretação.

CONDUÇÃO

- Peça uma razão para manter o logit mesmo se outro algoritmo tiver AUC um pouco maior.
- Aceite manutenção, clareza de especificação e estabilidade, sempre condicionadas a evidência.
- Depois peça uma situação em que insistir em um logit mal especificado seria prejudicial.

CUIDADOS E LIMITES

- Interpretável depende da quantidade de termos, transformações, interações e do público. Um logit com centenas de variáveis não é automaticamente fácil de explicar.
- Coeficiente não é causa.
- O desempenho de uma formulação simples não é o limite de toda a classe.
- Produzir uma probabilidade não garante que ela esteja calibrada.

APROFUNDAR

- Material original, capítulo 4, página 20: a linearidade em log odds é o limite da família. Um padrão não monótono na utilização não é representável sem transformar a variável.
- Página 19: a fronteira de decisão do logit é uma reta no plano das variáveis, porque o escore é uma soma. Mudar o corte desloca a reta paralelamente e mudar um coeficiente gira a reta. Compare com as regiões retangulares da árvore no slide 26.
- Página 22: a síntese do capítulo original é soma, curva e limite. Os três aparecem aqui nos slides 07, 09 e neste.

O logit oferece uma estrutura explícita, mas a qualidade depende da especificação e da validação.

Síntese conceitual aplicada; sem dados

REGRESSÃO LOGÍSTICA · SLIDE 20 DE 50

Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exercício: acompanhar a escala do escore e a escala da probabilidade

REGRESSÃO LOGÍSTICA slide 20 de 50

Bruno aumenta seu comprometimento de 38% para 48%. E agora?

Exercício: acompanhar a escala do escore e a escala da probabilidade

Bruno **perfil original**

Renda **R\$ 4.500**

Comprometimento **38%**

Relacionamento **8 meses**

Utilização **65%**

Histórico **sim**

Canal **Digital**

Uma única alteração: comprometimento de 38% para 48%.

REVISÃO RÁPIDA

Rever a razão de chances (slide 11)

Rever a calculadora de PD (slide 12)

A escolha feita aqui é preservada ao voltar.

ESCOLHA UMA ALTERNATIVA

A A PD sobe 10 pontos percentuais.

B O escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.

C A PD é multiplicada por e elevado a 0,40.

Conferir

Correta. A variação do escore é $0,04 \times 10 = 0,40$. As odds são multiplicadas por 1,4918 e a PD passa de 11,66% para 16,45%.

Próxima etapa da solução **Desafio opcional**

[Reiniciar exercício](#)

1. VARIAÇÃO DA CARACTERÍSTICA
comprometimento passa de 38% para 48%, ou seja $\Delta \text{comp} = +10$ pontos

2. VARIAÇÃO DO ESCORE
 $\Delta z = 0,04 \times 10 = 0,400$, de $-2,025$ para $-1,625$

3. EFEITO NAS ODDS
odds passam de 0,1320 para 0,1969, multiplicadas por 1,4918

4. NOVA PROBABILIDADE
 $p = 1 / (1 + e^{-1,625}) = 16,4516\%$, diferença de $+4,79$ p.p.

Entender o logit exige acompanhar a escala do escore e a escala da probabilidade. Exemplo didático de logit; cálculo próprio

Slide 20 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Perfil de Bruno com uma única alteração destacada e três alternativas de interpretação. Escolha uma alternativa e clique em Conferir; "Resolver passo a passo" abre as quatro etapas uma a uma; "Desafio opcional" mostra o cenário sem histórico.

TRANSIÇÃO PARA O SLIDE 21

Agora imagine que o modelo não some características, mas faça perguntas sucessivas: houve atraso? O comprometimento é alto? Essa é a lógica de uma árvore.

CONDUÇÃO

- Dê um minuto em duplas. Peça a explicação de quem escolheu cada alternativa, sem expor pessoas.
- Use a solução para revisar a diferença entre coeficiente e alteração de PD.
- Pergunte oralmente: o que podemos afirmar sobre o efeito causal de reduzir o comprometimento?

RESPOSTAS ESPERADAS

- A alternativa correta é a segunda: o escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.
- Escore original $-2,025$ e PD 11,66%. Novo escore $-1,625$ e PD aproximadamente 16,45%. Diferença aproximada de 4,79 pontos.
- Sobre causalidade: o cálculo descreve o modelo mantendo as demais entradas fixas. Não identifica efeito causal.
- Desafio opcional: sem o histórico de atraso, o escore de Bruno cai 0,80 e a PD passa de 11,66% para aproximadamente 5,66%.

CUIDADOS E LIMITES

- O que dobra são as odds, não a probabilidade. Converter odds em PD exige a volta pela logística.
- Os coeficientes deste exemplo foram escolhidos para ensinar, não estimados em dados. A ordem de grandeza é plausível; os valores não são um modelo.
- Uma PD de Bruno não diz o que acontecerá com Bruno. Diz a frequência esperada em exposições semelhantes.

EXERCÍCIO**Bruno passa de 38% para 48% de comprometimento. O que muda na PD?**

Marque a alternativa correta e depois preencha as quatro etapas com os seus números.

- A. A PD sobe 10 pontos percentuais.
- B. O escore sobe 0,40 e as odds são multiplicadas por e elevado a 0,40.
- C. A PD é multiplicada por e elevado a 0,40.

ETAPAS

1. Variação da característica: $\Delta_{\text{comp}} = \underline{\hspace{2cm}}$ pontos
2. Variação do escore: $\Delta z = 0,04 \times \underline{\hspace{2cm}} = \underline{\hspace{2cm}}$, de -2,025 para $\underline{\hspace{2cm}}$
3. Efeito nas odds: odds passam de $\underline{\hspace{2cm}}$ para $\underline{\hspace{2cm}}$, multiplicadas por $\underline{\hspace{2cm}}$
4. Nova probabilidade: $p = 1 / (1 + e \text{ elevado a } \underline{\hspace{2cm}}) = \underline{\hspace{2cm}}\%$, diferença de $\underline{\hspace{2cm}}$ p.p.

DESAFIO

Cenário separado: Bruno sem o histórico de atraso, com comprometimento em 38% e os demais valores originais. Qual é o novo escore e a nova PD? E o que esse cálculo diz, ou não diz, sobre o efeito causal de remover o atraso do cadastro?

Entender o logit exige acompanhar a escala do escore e a escala da probabilidade.

Exemplo didático de logit; cálculo próprio

BLOCO 3 DE 5 · SLIDES 21 A 30

3 Árvore de decisão

Como perguntas sucessivas separam grupos de risco, e o que sustenta a taxa de cada folha?

O que você vai aprender

- Percorrer uma árvore: raiz, nós, ramos e folhas, com a PD igual à frequência observada no grupo.
- Escolher uma divisão pelo ganho de impureza de Gini, ponderado pelo tamanho de cada lado.
- Ler a incerteza de uma folha pelo intervalo de Wilson e o efeito do tamanho mínimo por folha.
- Controlar a complexidade por profundidade, mínimo por folha e poda, e testar a estabilidade entre reamostragens.

Ideias para levar

- A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.
- Não basta uma folha pura: importa como toda a amostra fica depois da divisão.
- Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
21	Houve atraso? Qual é o comprometimento?	31
22	Nesta folha, 18 de 600 contratos ficaram inadimplentes	32
23	Qual pergunta separa melhor os comportamentos observados?	33
24	Histórico reduz o Gini de 0,180 para 0,160	34
25	Duas folhas com PD de 10%. A evidência é igual?	35

SLIDE	TÍTULO	PÁGINA
26	O mesmo aumento de comprometimento pode mudar de folha	36
27	A árvore cresce. O resultado fora do treino acompanha?	37
28	Três controles, três formas de conter o excesso de divisões	38
29	Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?	39
30	Carla recebe qual PD nesta árvore?	40

ÁRVORE DE DECISÃO · SLIDE 21 DE 50

Houve atraso? Qual é o comprometimento?

Uma árvore organiza a previsão em perguntas sucessivas

ÁRVORE DE DECISÃO slide 21 de 50
Houve atraso? Qual é o comprometimento?
Uma árvore organiza a previsão em perguntas sucessivas

As perguntas e seus limites são aprendidos dos dados. Aqui usamos uma árvore pequena para enxergar o mecanismo. As folhas ainda não mostram PD: primeiro a estrutura.

A árvore encaminha clientes semelhantes para uma mesma estimativa de risco.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 21 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

Ana
Comprometimento **22%**
Histórico **não**
Só estas duas entram nas perguntas desta árvore.

Cliente
Ana Bruno Carla Diego
Próximo passo
[Reiniciar exemplo](#)

PERCURSO
1. A raiz pergunta pelo histórico.
2. Resposta de Ana: hist = 0.
3. Segundo nó: comp ≤ 40%. Chega à folha.
Regra completa da folha: hist = 0 e comp ≤ 40%.

Raiz: primeira pergunta. Nó: qualquer pergunta.
Ramo: resposta que leva adiante. Folha: grupo final, onde a previsão é atribuída.

NA TELA

Árvore de profundidade dois: histórico na raiz e comprometimento em cada ramo, com o percurso de um cliente destacado. Escolha o cliente e avance com "Próximo passo" para percorrer a árvore pergunta a pergunta. O painel Percurso registra cada resposta.

TRANSIÇÃO PARA O SLIDE 22

Depois de encaminhar o cliente, precisamos atribuir uma PD ao grupo ao qual ele pertence.

CONDUÇÃO

- Pergunte qual informação a árvore consultará primeiro.
- Leve Ana à esquerda e então à folha de comprometimento até 40%.
- Mostre Diego no outro ramo para criar contraste. Só depois nomeie nó, ramo e folha.
- Não explique Gini neste slide.

RESPOSTAS ESPERADAS

- Ana: histórico 0 e comprometimento 22%, portanto ramo esquerdo e folha de comprometimento até 40%.
- Bruno: histórico 1 e comprometimento 38%, portanto ramo direito e folha de comprometimento até 40%.
- Carla: histórico 0 e comprometimento 48%, folha de comprometimento acima de 40%.
- Diego: histórico 1 e comprometimento 55%, folha de comprometimento acima de 40%.
- Comprometimento exatamente igual a 40 vai para o ramo até 40.

CUIDADOS E LIMITES

- O percurso é determinístico, mas a previsão ao final é probabilística. Duas pessoas diferentes podem cair na mesma folha.
- As perguntas e os limites são aprendidos dos dados. O limite de 40% é regra deste exemplo, não norma de crédito.
- Esta árvore pequena serve para enxergar o mecanismo. Não é o resultado do experimento maior.

A árvore encaminha clientes semelhantes para uma mesma estimativa de risco.

Árvore didática de 1.000 contratos; cálculo próprio

Nesta folha, 18 de 600 contratos ficaram inadimplentes

A PD da folha é a frequência observada no grupo

ÁRVORE DE DECISÃO slide 22 de 50

Nesta folha, 18 de 600 contratos ficaram inadimplentes

A PD da folha é a frequência observada no grupo

Houve atraso de 15 a 89 dias?
n = 1.000 · eventos 100
PD 10%

hist = 0

Comprometimento acima de 40%?
n = 800 · eventos 40
PD 5%

comp ≤ 40%

folha
n = 600 · eventos 18
PD 3%

comp > 40%

folha
n = 200 · eventos 22
PD 11%

hist = 1

Comprometimento acima de 40%?
n = 200 · eventos 60
PD 30%

comp ≤ 40%

folha
n = 80 · eventos 12
PD 15%

comp > 40%

folha
n = 120 · eventos 48
PD 40%

FOLHA DE ANA

hist = 0 e comp ≤ 40%

$$\hat{p} = \frac{d}{n} = \frac{18}{600} = 3\%$$

3,0%

Barra vermelha: contratos com evento. Barra clara: contratos sem evento.

Cliente

Ana Bruno Carla Diego

Leitura simples, só a taxa

Reiniciar exemplo

FOLHA

hist = 0 e comp ≤ 40%

hist = 0 e comp > 40%

hist = 1 e comp ≤ 40%

hist = 1 e comp > 40%

Soma das folhas

N

600

200

80

120

1.000

EVENTOS

18

22

12

48

100

PD

3%

11%

15%

40%

10%

CONFERÊNCIA

As quatro folhas somam 1.000 contratos e 100 eventos, exatamente os totais da raiz.

Mesma folha, mesma previsão: dois clientes com rendas diferentes recebem a mesma PD, porque a renda não participa das perguntas desta árvore.

A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 22 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Árvore de 1.000 contratos com contagens em cada nó e PD por folha, com o percurso do cliente selecionado. Troque o cliente para destacar o percurso e a folha; "Leitura simples, só a taxa" esconde as contagens e mostra apenas a PD.

TRANSIÇÃO PARA O SLIDE 23

Por que a primeira pergunta foi sobre histórico, e não sobre renda ou comprometimento?

CONDUÇÃO

- Construa a conta de Ana em voz alta e peça a de Bruno.
- Pergunte se clientes da mesma folha terão a mesma previsão mesmo com rendas diferentes: sim, nesta árvore, porque a renda não entra nas perguntas.

RESPOSTAS ESPERADAS

- Ana 18/600 = 3%. Bruno 12/80 = 15%. Carla 22/200 = 11%. Diego 48/120 = 40%.
- As folhas somam 1.000 contratos e 100 eventos, iguais à raiz.

CUIDADOS E LIMITES

- A taxa aparente da folha não comprova calibração futura.
- Este exemplo é sem pesos. Com ajuste ponderado, a fórmula da folha refletiria os pesos.
- Estas PDs são da árvore didática. Não são previsões do experimento estimado, e não devem ser comparadas com as PDs manuais do logit como se uma fosse mais correta.

A previsão é a frequência observada no grupo, sujeita à incerteza e à generalização.

Árvore didática de 1.000 contratos; cálculo próprio

Qual pergunta separa melhor os comportamentos observados?

Dois candidatos à primeira divisão, a partir da mesma raiz

ÁRVORE DE DECISÃO slide 23 de 50

Qual pergunta separa melhor os comportamentos observados?

Dois candidatos à primeira divisão, a partir da mesma raiz

Raiz 1.000 contratos · 100 eventos · taxa 10% **10,0%**

Histórico de atraso **escolher este**

hist = 0 n = 800 · eventos 40 · taxa 5,00%

hist = 1 n = 200 · eventos 60 · taxa 30,00%

Comprometimento até 40% **escolher este**

comp ≤ 40% n = 680 · eventos 30 · taxa 4,41%

comp > 40% n = 320 · eventos 70 · taxa 21,88%

EXPLORAÇÃO

Comparar composição e peso

Ver regra de escolha

Reiniciar exemplo

Regra de escolha: a divisão escolhida é a de menor impureza ponderada, considerando ao mesmo tempo a mistura de classes em cada lado e o tamanho de cada lado. O cálculo completo com o índice de Gini vem no próximo slide.

Os dois candidatos partem exatamente da mesma raiz: 1.000 contratos e 100 eventos.

Árvore didática de 1.000 contratos; cálculo próprio

Uma boa divisão cria grupos mais homogêneos segundo a função objetivo.

Slide 23 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Raiz de 1.000 contratos com 10% de eventos e dois candidatos de divisão, cada um com duas barras de composição. Use "escolher este" em cada candidato e "Comparar composição e peso"; "Ver regra de escolha" enuncia o critério.

TRANSIÇÃO PARA O SLIDE 24

Vamos colocar essa comparação em números com o índice de Gini.

CONDUÇÃO

- Peça que o aluno escolha visualmente e explique por quê.
- Se ele usar apenas a diferença entre taxas, pergunte o que aconteceria com uma folha de duas observações.
- Mostre o papel do tamanho do grupo antes de revelar a regra de escolha.

RESPOSTAS ESPERADAS

- Histórico separa em 800 contratos com 5% e 200 contratos com 30%.
- Comprometimento separa em 680 contratos com aproximadamente 4,41% e 320 contratos com 21,88%.
- A regra de escolha é a menor impureza ponderada, calculada no próximo slide.

CUIDADOS E LIMITES

- Esta é a melhor divisão entre os candidatos comparados, não entre todas as variáveis possíveis.
- A busca é gulosa e local: a melhor divisão imediata não garante a árvore globalmente ótima.
- Com dados agregados não é possível varrer limiares intermediários sem inventar contagens.

Uma boa divisão cria grupos mais homogêneos segundo a função objetivo.

Árvore didática de 1.000 contratos; cálculo próprio

ÁRVORE DE DECISÃO · SLIDE 24 DE 50

Histórico reduz o Gini de 0,180 para 0,160

Impureza da raiz, média ponderada dos filhos e ganho

ÁRVORE DE DECISÃO slide 24 de 50

Histórico reduz o Gini de 0,180 para 0,160

Impureza da raiz, média ponderada dos filhos e ganho

1. IMPUREZA DA RAIZ

$$p = \frac{100}{1.000} = 10\%$$
$$G(\text{raiz}) = 2p(1-p) = 0,180$$

2. IMPUREZA DE CADA FILHO

$$G_{\text{eq}} = 2p_{\text{eq}}(1-p_{\text{eq}}) = 0,0950 \quad \text{hist} = 0, \quad p_{\text{eq}} = 5,00\%$$
$$G_{\text{dr}} = 2p_{\text{dr}}(1-p_{\text{dr}}) = 0,4200 \quad \text{hist} = 1, \quad p_{\text{dr}} = 30,00\%$$

3. PONDERAÇÃO PELO TAMANHO

$$\hat{G} = \frac{n_{\text{eq}}}{n} G_{\text{eq}} + \frac{n_{\text{dr}}}{n} G_{\text{dr}}$$
$$= \frac{800}{1.000} \cdot 0,0950 + \frac{200}{1.000} \cdot 0,4200$$
$$= 0,160000$$

4. GANHO E COMPARAÇÃO

$$\Delta G = G(\text{raiz}) - \hat{G} = 0,180 - 0,160000 = 0,020000$$

candidato comprometimento até 40%; $\Delta G = 0,013272$

Próxima etapa Trocar candidato

Reiniciar exemplo

IMPUREZA BINÁRIA $G = 2p(1-p)$

Histórico de atraso
Comprometimento até 40%

0,0200
0,0133
ganho de impureza

Não basta uma folha pura: importa como toda a amostra fica depois da divisão.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 24 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Três etapas do cálculo do ganho de Gini e curva de impureza binária em função da taxa de eventos. Avance com "Próxima etapa" e use "Trocar candidato" para refazer as contas com o comprometimento.

TRANSIÇÃO PARA O SLIDE 25

Ao dividir mais, as folhas parecem mais precisas. Mas quanto podemos confiar em uma taxa calculada com poucas observações?

CONDUÇÃO

- Peça a conta do Gini da raiz antes de revelar.
- Antes de ponderar, pergunte por que não usar a média simples. Mostre a diferença entre 800 e 200 registros.
- Termine explicitando que o algoritmo compara vários candidatos, repete o procedimento em cada nó e precisa de uma regra para parar.

RESPOSTAS ESPERADAS

- Raiz com 10% de eventos: Gini igual a 0,180.
- Por histórico: 0,8 vezes 0,095 mais 0,2 vezes 0,420 resulta em 0,160, com ganho de 0,020.
- Por comprometimento: impureza ponderada 0,166728 e ganho 0,013272.
- Impureza zero em grupo puro; máximo de 0,5 quando a taxa é 50%.

CUIDADOS E LIMITES

- Gini é critério de impureza no treino. Não é AUC, KS nem lucro.
- Outras perdas podem orientar árvores. Não misture entropia e Gini no mesmo cálculo.
- Ganho de impureza não é efeito causal do histórico.

Não basta uma folha pura: importa como toda a amostra fica depois da divisão.

Árvore didática de 1.000 contratos; cálculo próprio

Duas folhas com PD de 10%. A evidência é igual?

Intervalo binomial descritivo de Wilson, nominal de 95%

ÁRVORE DE DECISÃO slide 25 de 50

Duas folhas com PD de 10%. A evidência é igual?

Intervalo binomial descritivo de Wilson, nominal de 95%

2 em 20

folha pequena - taxa 10,0%

2,8% a 30,1%

100 em 1.000

folha grande - taxa 10,0%

8,3% a 12,0%

0 em 20

folha sem eventos - taxa 0,0%

0,0% a 16,1%

0%10%20%30%40%

taxa de eventos na folha

LEITURA

amplitude $\propto \sqrt{\hat{p}(1-\hat{p})/n}$ Mesma taxa, evidências diferentes: com 20 contratos a amplitude é 27,3 p.p.; com 1.000, 3,7 p.p..

Tamanho da folha pequena, mantendo a taxa em 10%

2 em 20

Esconder a folha sem eventos

Reiniciar exemplo

RESSALVA

Intervalo binomial descritivo. Não incorpora a escolha adaptativa das folhas.

Uma folha com zero eventos não prova risco zero: o limite superior permanece positivo.

É por isso que a árvore recebe um tamanho mínimo de folha como parâmetro.

FOLHA	EVENTOS	N	TAXA	INTERVALO DE WILSON
folha pequena	2	20	10,0%	2,8% a 30,1%
folha grande	100	1.000	10,0%	8,3% a 12,0%
folha sem eventos	0	20	0,0%	0,0% a 16,1%

10% em 20 contratos não oferece a mesma precisão que 10% em 1.000.

Pares binomiais ilustrativos; cálculo próprio

Slide 25 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Duas linhas com ponto em 10% e intervalo de Wilson, uma com 2 eventos em 20 contratos e outra com 100 em 1.000. Arraste o tamanho da folha pequena mantendo a taxa em 10% e veja o intervalo estreitar. "Esconder a folha sem eventos" simplifica a leitura.

TRANSIÇÃO PARA O SLIDE 26

Folhas maiores estabilizam estimativas, mas a árvore também precisa capturar diferenças relevantes entre clientes.

CONDUÇÃO

- Pergunte qual folha transmitiria mais confiança e por quê.
- Aumente o tamanho da folha e peça que o aluno narre o que mudou.
- Mostre o caso de zero eventos e pergunte se o gestor poderia tratar o risco como impossível.

RESPOSTAS ESPERADAS

- 2 em 20: intervalo aproximado de 2,8% a 30,1%.
- 100 em 1.000: intervalo aproximado de 8,3% a 12,0%.
- 0 em 20: o limite superior continua positivo, aproximadamente 16,1%. Zero evento não prova risco zero.

CUIDADOS E LIMITES

- O intervalo descreve a dimensão binomial. Não incorpora a escolha adaptativa das folhas, a seleção da população nem a mudança temporal.
- Não é correto dizer que a PD individual tem 95% de chance de cair nesse intervalo.
- A incerteza real da árvore inclui a busca pelos cortes, e é maior que a mostrada aqui.

APROFUNDAR

- Fórmula do intervalo de Wilson, com z igual a 1,96 para 95% nominal: o centro é $(\hat{p} + z^2/2n)$ dividido por $(1 + z^2/n)$, e a meia amplitude é z vezes a raiz de $[\hat{p}(1-\hat{p})/n + z^2/4n^2]$, dividida pelo mesmo denominador.
- Wilson é preferível ao intervalo normal simples justamente no caso deste slide: taxa baixa e folha pequena, onde o intervalo normal produz limite inferior negativo.

10% em 20 contratos não oferece a mesma precisão que 10% em 1.000.

Pares binomiais ilustrativos; cálculo próprio

Versão da aula 64c08f8be6569 - gerado em 21 de setembro de 2026 - dados sintéticos

35 de 69

O mesmo aumento de comprometimento pode mudar de folha

As regras da árvore dividem o espaço em regiões de previsão constante

ÁRVORE DE DECISÃO slide 26 de 50

O mesmo aumento de comprometimento pode mudar de folha

As regras da árvore dividem o espaço em regiões de previsão constante

Os efeitos dependem do caminho. Dentro de uma folha, a previsão é constante.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 26 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Duas faixas de comprometimento, uma para cada valor de histórico, com as quatro regiões da árvore e os quatro clientes posicionados. Arraste o comprometimento do cliente selecionado e alterne o histórico; a regra atual e a PD aparecem abaixo do mapa.

TRANSIÇÃO PARA O SLIDE 27

Se continuarmos dividindo o espaço, podemos criar regiões cada vez menores. Quando isso começa a prejudicar?

CONDUÇÃO

- Mova Bruno de 38 para 41 e compare com Ana ao redor do mesmo limite.
- A mudança é de 15% para 40% no ramo com histórico, e de 3% para 11% no ramo sem histórico.
- Pergunte se uma mudança pequena de risco verdadeiro deveria produzir esse salto: a descontinuidade é da aproximação do modelo.

CUIDADOS E LIMITES

- Árvores capturam interações porque a pergunta de um ramo depende das decisões anteriores. Isso não dispensa validação.
- Uma folha define uma região constante. Ensembles produzem funções mais detalhadas.
- O limite de 40% é deste exemplo. Não é política de crédito.
- Histórico é categórico: as duas faixas são categorias, não um eixo contínuo.

Os efeitos dependem do caminho. Dentro de uma folha, a previsão é constante.

Árvore didática de 1.000 contratos; cálculo próprio

A árvore cresce. O resultado fora do treino acompanha?

Profundidade, perda de treino e perda de validação no experimento sintético

ÁRVORE DE DECISÃO slide 27 de 50

A árvore cresce. O resultado fora do treino acompanha?

Profundidade, perda de treino e perda de validação no experimento sintético

EXPERIMENTO AUXILIAR DE DUAS VARIÁVEIS: AS REGIÕES APRENDIDAS

experimento auxiliar, não o modelo completo

PROFUNDIDADE 2

utilização

comprometimento

4 folhas - validação

0,275

PROFUNDIDADE 4

utilização

comprometimento

16 folhas - validação

0,262

PROFUNDIDADE 8

utilização

comprometimento

70 folhas - validação

0,401

escala de PD prevista 0% 50%

Uma árvore que memoriza o treino pode produzir probabilidades frágeis fora dele.

Experimento sintético; semente e versões no notebook

BASE PRINCIPAL: PERDA POR PROFUNDIDADE, COM MÍNIMO DE 20 CONTRATOS POR FOLHA

log loss

melhor na validação

validação

treino

profundidade máxima

16 folhas mediana de 366 contratos por folha

treino 0,3434 · validação 0,3496 Reiniciar exemplo

Slide 27 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Mapas de regiões de um experimento auxiliar de duas variáveis para profundidades 2, 4 e 8, e curvas de perda de treino e validação por profundidade. Arraste a profundidade máxima apenas nos ajustes executados e acompanhe folhas, mediana por folha e as duas perdas.

TRANSIÇÃO PARA O SLIDE 28

Podemos controlar o crescimento de mais de uma maneira. Cada parâmetro restringe uma parte diferente da árvore.

CONDUÇÃO

- Comece raso, aumente a complexidade e peça que comparem treino e validação.
- Mostre a mediana de contratos por folha como pista de fragilidade, não como prova isolada.
- A seleção usa a validação fora do tempo, nunca o teste final.

CUIDADOS E LIMITES

- Os mapas vêm de um experimento auxiliar com apenas duas variáveis. Não são projeção exata do modelo completo.
- A perda mostrada usa log loss com proteção numérica de 10 elevado a menos 6, porque árvores produzem probabilidades iguais a 0 ou 1 em folhas puras. O Brier está disponível na tabela.
- Desempenho de uma única amostra varia. Diferenças pequenas podem não ser robustas.
- Nem toda árvore profunda é ruim: a profundidade interage com tamanho de folha e poda.

Uma árvore que memoriza o treino pode produzir probabilidades frágeis fora dele.

Experimento sintético; semente e versões no notebook

ÁRVORE DE DECISÃO · SLIDE 28 DE 50

Três controles, três formas de conter o excesso de divisões

Profundidade máxima, mínimo de contratos por folha e poda por complexidade

ÁRVORE DE DECISÃO slide 28 de 50

Três controles, três formas de conter o excesso de divisões

Profundidade máxima, mínimo de contratos por folha e poda por complexidade



Nome abreviado nas caixas: comp é comprometimento, hist é histórico, util é utilização, nel é relacionamento. Ramos além do nível mostrado aparecem resumidos. A árvore selecionada tem 24 folhas.

Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

Slide 28 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Árvore treinada resumida até o terceiro nível e três controles de complexidade com cenários efetivamente ajustados. Alterne os três controles e arraste o cenário treinado; "Como foi escolhido?" explica a seleção pela validação.

TRANSIÇÃO PARA O SLIDE 29

Mesmo árvores de tamanho parecido podem mudar bastante quando mudamos a amostra usada para aprender.

CONDUÇÃO

- Mostre primeiro a profundidade, depois uma folha pequena que ainda existe mesmo em árvore rasa.
- Use essa folha para motivar o mínimo de contratos por folha.
- Por fim, explique que a poda considera retirar partes de uma árvore já crescida.

RESPOSTAS ESPERADAS

- O parâmetro de folha é mínimo de observações, não mínimo de inadimplentes.
- O alfa da poda não tem unidade universal de nós removidos: ele é o preço por folha no critério de custo e complexidade.
- A seleção usa a perda de validação fora do tempo.

CUIDADOS E LIMITES

- Cada configuração corresponde a uma árvore realmente treinada, não a uma ocultação visual de nós.
- Aumentar o mínimo por folha não melhora calibração automaticamente.
- O critério final continua sendo desempenho fora da amostra de ajuste.

Controlar complexidade é escolher quais detalhes dos dados vale a pena manter.

Experimento sintético; semente e versões no notebook

ÁRVORE DE DECISÃO · SLIDE 29 DE 50

Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?

Vinte reamostragens do treino, com os mesmos hiperparâmetros

ÁRVORE DE DECISÃO slide 29 de 50

Se mudarmos um pouco a amostra, a árvore continua contando a mesma história?

Vinte reamostragens do treino, com os mesmos hiperparâmetros

RÉPLICA A: Nº 1
8 folhas · AUC validação 0,7028

comp $\leq 43,4$
n = 16.000
PD 13,2%

sim não

resumido
n = 13.445
PD 9,6%

resumido
n = 2.555
PD 32,2%

nomes abreviados nas caixas. raiz:
comprometimento $\leq 43,35$ · PD de Bruno: 14,83%

RÉPLICA B: Nº 3
7 folhas · AUC validação 0,7065

hist $\leq 0,5$
n = 16.000
PD 13,5%

sim não

resumido
n = 12.970
PD 9,7%

resumido
n = 3.030
PD 30,0%

nomes abreviados nas caixas. raiz: histórico
 $\leq 0,50$ · PD de Bruno: 27,59%

PD NAS 20 RÉPLICAS

Ana 3,6% a 7,3%

Bruno 14,1% a 29,1%

Carla 13,3% a 19,8%

Diego 58,4% a 67,2%

0% 20% 40% 60%

PD prevista na réplica

Réplica A 1 2 3 4 5 6 7 8

Réplica B 9 10 11 12 13 14 15 16

Ana Bruno Carla Diego

Reiniciar exemplo

Mesma complexidade nas 20 réplicas: profundidade 3 e mínimo de 300 contratos por folha.

A raiz mudou de comprometimento para histórico apenas por reamostragem do treino.
Entre as 20 réplicas, a raiz foi comprometimento em 10 delas e histórico em 10 delas.

Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Experimento sintético; semente e versões no notebook

NA TELA

Duas árvores de réplicas diferentes lado a lado e a dispersão das PDs dos quatro clientes nas vinte réplicas. Escolha as réplicas A e B e o cliente; o gráfico marca as duas réplicas na nuvem das vinte PDs.

TRANSIÇÃO PARA O SLIDE 30

Antes de combinar várias árvores, vamos verificar se sabemos interpretar uma única árvore e suas limitações.

CONDUÇÃO

- Pergunte qual das duas árvores é a verdadeira e use a pergunta para discutir estimativa e variabilidade.
- Compare estrutura e previsão: uma raiz diferente não significa mudança enorme de PD, e previsões podem variar mesmo com raízes iguais.

CUIDADOS E LIMITES

- O bootstrap ilustra sensibilidade ao treinamento. Não é intervalo preditivo calibrado do risco verdadeiro de um cliente.
- Não reamostramos o teste para treinar.
- As réplicas exibidas foram escolhidas por critério declarado: a primeira réplica de cada variável de raiz observada, e não a mais dramática.
- Este slide não é uma aula de random forest. Apenas situa por que ensembles exploram múltiplas funções.

Uma regra fácil de ler pode ser sensível à amostra que a produziu.

Experimento sintético; semente e versões no notebook

ÁRVORE DE DECISÃO · SLIDE 30 DE 50

Carla recebe qual PD nesta árvore?

Exercício: percorrer, calcular e questionar

ÁRVORE DE DECISÃO slide 30 de 50

Carla recebe qual PD nesta árvore?

Exercício: percorrer, calcular e questionar

1. INDIQUE O CAMINHO

histórico = 0, depois comprometimento acima de 40%

histórico = 0, depois comprometimento até 40%

histórico = 1, depois comprometimento acima de 40%

Caminho correto: Carla tem histórico 0 e comprometimento 48%, acima de 40%.

2. CALCULE A PD DA FOLHA

11 em porcentagem

Correto: 22 dividido por 200 resulta em 11%.

3. SE A RENDA DE CARLA DOBRASSE, MANTENDO FIXAS AS ENTRADAS USADAS NA ÁRVORE

A PD permanece a mesma A PD cai pela metade

Não é possível avaliar a função

Conferir Desafio final Reiniciar exercício

Carla

R\$ 10.000 por mês · comprometimento 48% · relacionamento 60 meses · utilização 85% · histórico não · canal digital

Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

Árvore didática de 1.000 contratos; cálculo próprio

Slide 30 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Árvore didática com a taxa da folha de Carla oculta e três tarefas: caminho, cálculo da PD e efeito de dobrar a renda. Marque o caminho, digite a PD e escolha a resposta da terceira pergunta; Conferir corrige as três. "Desafio final" abre uma pergunta extra.

TRANSIÇÃO PARA O SLIDE 31

Uma única árvore é clara, mas pode ser limitada ou instável. Podemos construir uma previsão melhor acrescentando várias árvores pequenas em sequência?

CONDUÇÃO

- Reserve dois minutos em duplas.
- Não revele a resposta ao primeiro clique em um ramo errado: explique a regra e permita corrigir.
- Conclua com a importância de tamanho de folha, validação e estabilidade. Este é um bom ponto para a pausa da aula.

RESPOSTAS ESPERADAS

- Carla tem histórico 0 e comprometimento 48%, acima de 40%. Chega à folha de 22 eventos em 200 contratos, ou seja 11%.
- Dobrar a renda isoladamente, com o comprometimento mantido fixo, não altera esta árvore, porque a renda não é usada nas perguntas.
- Numa mudança econômica real o comprometimento poderia variar. A simulação é sobre a função do modelo.
- Desafio final: Bruno de 38% para 41% passa de 15% para 40%. Isso não prova um salto real de risco exatamente nesse limite: é uma descontinuidade da aproximação aprendida.

CUIDADOS E LIMITES

- A taxa de uma folha é estimativa com incerteza, e folhas pequenas têm intervalo largo. Ler a taxa sem o tamanho da folha é o erro mais comum aqui.
- A regra da árvore é associação aprendida na amostra, não relação causal: mudar a variável no cliente não move a PD dele pelo caminho da árvore.
- Esta árvore vem da miniatura de 1.000 contratos, separada da base do experimento. Não compare o desempenho dela com o dos modelos treinados.

EXERCÍCIO**Carla recebe qual PD nesta árvore?**

Use a árvore de 1.000 contratos do slide 22 (contagens por folha) e o perfil de Carla.

1. Indique o caminho: histórico igual a 0 e depois comprometimento acima de 40%; histórico igual a 0 e depois comprometimento até 40%; ou histórico igual a 1 e depois comprometimento acima de 40%.
2. Calcule a PD da folha, em porcentagem, a partir de eventos e contratos da folha: _____ / _____ = _____%.
3. Se a renda de Carla dobrasse, mantendo fixas as entradas usadas na árvore: a PD permanece a mesma, a PD cai pela metade, ou não é possível avaliar a função?

Uma regra legível ajuda a explicar o cálculo, mas não dispensa evidência de qualidade.

Árvore didática de 1.000 contratos; cálculo próprio

BLOCO 4 DE 5 · SLIDES 31 A 42

4 Gradient boosting

Como correções sucessivas, somadas no escore, constroem uma previsão melhor que a de uma árvore só?

O que você vai aprender

- Ver o que sobra nos resíduos de uma árvore rasa e por que vale acrescentar correções.
- Seguir o ciclo em quatro passos: prever, calcular o gradiente, ajustar uma árvore aos resíduos e atualizar o escore.
- Refazer a miniatura de 10 registros: escore inicial, duas árvores e conversão única em PD.
- Escolher taxa de aprendizagem, número de árvores e profundidade pela validação, com parada definida antes.

Ideias para levar

- Cada árvore responde ao que ainda precisa melhorar na previsão atual.
- A soma acontece no escore F. A logística é aplicada uma única vez, no fim.
- Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
31	E se uma árvore pequena ainda deixar estrutura nos erros?	43
32	A próxima árvore aprende a partir das previsões atuais	44
33	Dois eventos em dez contratos: começamos em 20%	45
34	A primeira correção reduz A e aumenta B	46
35	A primeira árvore mudou as previsões. Agora mudam os gradientes	47
36	Escore inicial mais árvore 1 mais árvore 2 é a nova PD	48

SLIDE	TÍTULO	PÁGINA
37	Learning rate e número de árvores precisam ser escolhidos juntos	49
38	Uma correção pode depender de uma característica ou da combinação de várias	50
39	Continuar melhorando o treino pode deixar de ajudar a validação	51
40	Mais flexibilidade exige mais disciplina de validação	52
41	O que o modelo usa em geral? O que pesou para Bruno?	53
42	O novo cliente caiu no grupo B. Qual é a previsão?	54

GRADIENT BOOSTING · SLIDE 31 DE 50


E se uma árvore pequena ainda deixar estrutura nos erros?

Resíduos agregados por região, no experimento auxiliar de duas variáveis

GRADIENT BOOSTING slide 31 de 50

E se uma árvore pequena ainda deixar estrutura nos erros?

Resíduos agregados por região, no experimento auxiliar de duas variáveis




PREVISÃO DE UMA ÁRVORE DE PROFUNDIDADE 2

utilização

comprometimento

PD prevista 0% 50%



MÉDIA DE Y - P POR REGIÃO

utilização

comprometimento

Vermelho: a previsão ficou baixa demais. Verde: ficou alta demais.

O QUE SOBRA DEPOIS DA ÁRVORE RASA

regiões com resíduo positivo **13 de 36**

média dessas regiões **0,0567**

média das demais **-0,0325**

validação da árvore rasa **0,2752**

Onde a previsão ficou baixa?

E onde ficou alta?

Acrescentar uma correção

Reiniciar exemplo

Os resíduos mostrados são do conjunto usado no ajuste desta árvore auxiliar, com duas variáveis. Nenhum resultado do teste participa.

Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos.

Experimento auxiliar de duas variáveis; cálculo próprio

Slide 31 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Mapa de previsão de uma árvore rasa e média do resíduo observado menos previsto por região. "Onde a previsão ficou baixa?" e "E onde ficou alta?" destacam cada sinal; "Acrescentar uma correção" mostra a próxima árvore atuando.

TRANSIÇÃO PARA O SLIDE 32

Vamos entender a regra de construção: partir de um escore simples, calcular a direção de melhoria e acrescentar uma árvore.

CONDUÇÃO

- Retome o slide 27: aumentar uma única árvore não é a única opção.
- Mostre que há grupos em que a previsão ficou sistematicamente baixa ou alta.
- Pergunte como uma próxima função poderia atuar nesses grupos. Termine apresentando a palavra sequencial.

CUIDADOS E LIMITES

- Um resíduo individual não é padrão. A leitura só faz sentido na média por região.
- Subajuste e variabilidade não se resolvem com boosting em todos os casos: combinar árvores também acrescenta complexidade e pode sobreajustar.
- Os resíduos aqui vêm do conjunto usado no ajuste, nunca do teste.
- O título é uma hipótese a ilustrar com dados, não um diagnóstico automático.

Em vez de exigir tudo de uma árvore, podemos construir a previsão por acréscimos.

Experimento auxiliar de duas variáveis; cálculo próprio

GRADIENT BOOSTING · SLIDE 32 DE 50

A próxima árvore aprende a partir das previsões atuais

Um ciclo de atualização em quatro passos

GRADIENT BOOSTING slide 32 de 50

A próxima árvore aprende a partir das previsões atuais
Um ciclo de atualização em quatro passos

novο score = score atual + taxa de aprendizagem × contribuição da árvore
 $F_m = F_{m-1} + \eta h_m$

1. PREVER COM O QUE JÁ EXISTE
 $p = \sigma(F) = \frac{1}{1 + e^{-F}} = \frac{1}{1 + e^{-1,3863}} = 20,0000\%$
A previsão atual do grupo vem do score acumulado até aqui, na mesma logística do slide 09.

2. CALCULAR A DIREÇÃO DE MELHORIA
 $r = -\frac{\partial L}{\partial F} = y - p = 0 - 0,2000 = -0,2000$
O resíduo não é escolha de conveniência: para a perda logística do slide 13, o gradiente negativo em relação ao score é exatamente y menos p. Por isso a técnica se chama gradient boosting.

3. AJUSTAR UMA ÁRVORE PEQUENA AOS R
 $h_1(\text{folha B}) = F_B = 0,200000$
A árvore devolve um número por folha, positivo ou negativo. Não é um voto.

4. ATUALIZAR O SCORE
 $F_1 = F_0 + \eta h_1 = -1,3863 + 1 \times 0,200000 = -1,1863$
Só depois de somar todas as contribuições aplicamos a função logística.

A RÉGUA DO SCORE ACUMULADO

depois da árvore 1
-1,1863
Início
-1,3863
-1,8 -1,5 -1,2 -0,9 -0,6
score F do grupo B

PD aparece apenas depois da transformação logística: 20,00% passa a 23,39%

Próximo passo

[Comparar mecanismos](#)

[Reiniciar exemplo](#)

Miniautura didática de 10 registros, com taxa de aprendizagem igual a 1 apenas para facilitar a leitura. O registro usado no passo 2 tem y = 0 e pertence ao grupo B.

Cada árvore responde ao que ainda precisa melhorar na previsão atual.

Slide 32 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Ciclo em quatro passos: prever, calcular a direção, ajustar a correção e atualizar o score, com a régua do score acumulado. Avance com "Próximo passo" e use "Comparar mecanismos" para contrastar com o logit e com a árvore única.

TRANSIÇÃO PARA O SLIDE 33

Antes de corrigir qualquer coisa, precisamos de uma previsão inicial. Qual seria a melhor se tratássemos todos igualmente?

CONDUÇÃO

- Pergunte se cada árvore produz uma nova PD a ser somada.
- Revele que o objeto somado é F, um score na escala de log odds neste caso.
- Reconecte ao slide 09: só ao final aplicamos a função logística.

RESPOSTAS ESPERADAS

- Novo score é igual ao score atual mais a taxa de aprendizagem vezes a contribuição da árvore.
- A árvore de regressão devolve números positivos ou negativos, não um voto entre adimplente e inadimplente.
- Em combinação independente, os modelos são ajustados sem esse encadeamento e depois agregados.

CUIDADOS E LIMITES

- O algoritmo pode otimizar perdas diferentes. Aqui o alvo é binário e a perda é logística.
- O gradiente depende da função de perda escolhida.
- Esta é uma apresentação de primeira ordem, didaticamente válida. Implementações podem usar atualizações diferentes nas folhas.

Cada árvore responde ao que ainda precisa melhorar na previsão atual.

Miniautura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 33 DE 50

Dois eventos em dez contratos: começamos em 20%

O melhor preditor constante da perda logarítmica no treino

GRADIENT BOOSTING · slide 33 de 50

Dois eventos em dez contratos: começamos em 20%

O melhor preditor constante da perda logarítmica no treino

previsão inicial 20,00% $F_0 = \ln\left(\frac{0,20}{0,80}\right) = -1,3863$ perda média 0,5004

miniatura didática, distinta da base de comparação

GRUPO A				
comprometimento 30% · 0 eventos em 5				
REGISTRO	y	p ₀	r = y - p ₀	
nº 1	0	20,00%		
nº 2	0	20,00%		
nº 3	0	20,00%		
nº 4	0	20,00%		
nº 5	0	20,00%		

GRUPO B				
comprometimento 50% · 2 eventos em 5				
REGISTRO	y	p ₀	r = y - p ₀	
nº 6	0	20,00%		
nº 7	0	20,00%		
nº 8	0	20,00%		
nº 9	1	20,00%		
nº 10	1	20,00%		

PERDA MÉDIA EM FUNÇÃO DA PREVISÃO CONSTANTE

perda média dos 10 registros

previsão constante

20 perda 0,5004

Usar melhor constante Mostrar os resíduos

Reiniciar exemplo

A curva é calculada diretamente com os dez rótulos, sem treinar biblioteca alguma. O mínimo ocorre na média empírica de y, igual a 20%.

Antes de usar características, a taxa observada fornece o ponto de partida do exemplo. Miniatura didática de 10 registros; cálculo próprio

Slide 33 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Dez registros divididos em dois grupos, previsão inicial constante e curva da perda média em função dessa constante. Arraste a previsão constante e observe a perda; "Usar melhor constante" volta a 20%; "Mostrar os resíduos" preenche a coluna r.

TRANSIÇÃO PARA O SLIDE 34

Agora compare o que aconteceu com o que previmos: essa diferença indica a direção da primeira correção.

CONDUÇÃO

- Pergunte qual PD seria razoável antes de olhar qualquer característica.
- Compare 10%, 20% e 40% na perda média.
- Revele que a média empírica minimiza a perda do modelo constante não ponderado, e conecte F0 à conversão do slide 10.
- Só então mostre os grupos A e B, anunciando que eles permitirão melhorar a previsão uniforme.

RESPOSTAS ESPERADAS

- Média de y igual a 0,2, que é o mínimo da curva de perda.
- $F_0 = \ln(0,20 / 0,80) = -1,3863$, com logaritmo natural.

CUIDADOS E LIMITES

- O ponto inicial depende da perda, dos pesos e da implementação. Este exemplo é sem pesos e binário.
- A taxa de 20% descreve esta miniatura. Não descreve o mercado de crédito nem a base principal.
- Os desfechos aqui são atributos de treinamento conhecidos, não informação sobre um cliente novo.
- Ao avançar para a miniatura canônica, a previsão inicial volta a 20%.

Antes de usar características, a taxa observada fornece o ponto de partida do exemplo.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 34 DE 50

A primeira correção reduz A e aumenta B

Resíduos, média por folha e atualização do escore

GRADIENT BOOSTING slide 34 de 50

A primeira correção reduz A e aumenta B

Resíduos, média por folha e atualização do escore

OS DEZ REGISTROS									
REGISTRO	GRUPO	y	Parcial	$r = y - p$	$M(\text{folha})$	P_{sim}	$P_{\text{não}}$	primeira ordem didática	
nº 1	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%		
nº 2	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%		
nº 3	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%		
nº 4	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%		
nº 5	A	0	20,00%	-0,2000	-0,200000	-1,586294	16,9906%		
nº 6	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%		
nº 7	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%		
nº 8	B	0	20,00%	-0,2000	0,200000	-1,186294	23,3922%		
nº 9	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%		
nº 10	B	1	20,00%	0,8000	0,200000	-1,186294	23,3922%		

destacar um registro: **nº 6 (y = 0)** **nº 9 (y = 1)**

A ÁRVORE AJUSTADA AOS RESÍDUOS



POR GRUPO	A	B
escore inicial	-1,386294	-1,386294
contribuição da árvore	-0,200000	+0,200000
escore novo	-1,586294	-1,186294
PD	16,9906%	23,3922%

Etapas completas [Reiniciar exemplo](#)
etapa 4 de 4

A árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha. Miniatura didática de 10 registros; cálculo próprio

Slide 34 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Dez registros com a coluna de resíduo, um stump que divide o comprometimento em 40 e as folhas com a média dos resíduos. Avance as quatro etapas e destaque o registro nº 6 (sem evento) ou nº 9 (com evento) para seguir a linha na tabela.

TRANSIÇÃO PARA O SLIDE 35

Depois da atualização, os resíduos mudaram. Por isso a segunda árvore precisa olhar novamente para as previsões.

CONDUÇÃO

- Peça o resíduo de um evento e o de um não evento.
- Calcule a média do grupo B em voz alta.
- Pergunte por que três adimplentes do grupo B receberam aumento. Resposta: o modelo captura o risco do grupo, não reproduz cada rótulo.

RESPOSTAS ESPERADAS

- Em A, cinco resíduos de -0,2 e média -0,2.
- Em B, três resíduos de -0,2 e dois de +0,8, média +0,2.
- Com taxa de aprendizagem 1: F do grupo A vai a -1,586294 e PD a 16,9906%. F do grupo B vai a -1,186294 e PD a 23,3922%.

CUIDADOS E LIMITES

- y menos p é o gradiente negativo da perda logística em relação ao escore nesta parametrização.
- Isso não significa que toda biblioteca use exatamente a média como valor final da folha.
- As contribuições estão em unidades de escore, não em pontos percentuais de PD.
- Primeira ordem didática: a folha recebe a média do gradiente negativo, sem passo de Newton.

A árvore aprende um padrão nos gradientes e aplica a mesma correção a quem cai na mesma folha.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 35 DE 50


A primeira árvore mudou as previsões. Agora mudam os gradientes

A segunda correção é recalculada depois da primeira

GRADIENT BOOSTING slide 35 de 50

A primeira árvore mudou as previsões. Agora mudam os gradientes

A segunda correção é recalculada depois da primeira



NA TELA

Tabela com as previsões e resíduos antes e depois da primeira correção, segunda árvore com novas médias e trajetória de PD por iteração. "Ajustar segunda árvore" recalcula as médias dos novos resíduos; "Atualizar" aplica a correção e estende a trajetória.

TRANSIÇÃO PARA O SLIDE 36

Somamos duas contribuições. Vamos olhar essa soma como uma função que também pode prever um cliente novo.

CONDUÇÃO

- Antes de revelar a média do grupo B, pergunte se ela continuará em mais 0,2.
- Faça a turma perceber que o resíduo de um y = 1 diminuiu e o de um y = 0 ficou mais negativo.
- Mostre que a correção média positiva persiste, mas mudou de tamanho.

RESPOSTAS ESPERADAS

- No grupo A, $r1 = -0,1699058933$ e a média da folha é o mesmo valor.
- No grupo B, três resíduos de $-0,2339223413$ e dois de $+0,7660776587$, média $+0,1660776587$.
- Com taxa 1: F do grupo A vai a $-1,7562002544$ e PD a $14,7267\%$. F do grupo B vai a $-1,0202167024$ e PD a $26,4985\%$.

CUIDADOS E LIMITES

- Os resíduos da segunda rodada usam p1, nunca p0.
- A nova árvore poderia usar outro corte em dados mais ricos. Aqui o corte permanece por construção da miniatura, que só tem dois valores de comprometimento.
- Nem toda correção diminui, e as previsões individuais não caminham necessariamente de forma monótona. Isso acontece aqui pela simplicidade dos grupos.
- O objetivo é reduzir a perda agregada, não acertar cada rótulo.

A próxima correção é recalculada depois da anterior. Ela não repete mecanicamente o mesmo passo.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 36 DE 50

Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Somamos contribuições no escore e só então calculamos a probabilidade

GRADIENT BOOSTING slide 36 de 50

Escore inicial mais árvore 1 mais árvore 2 é a nova PD

Somamos contribuições no escore e só então calculamos a probabilidade

escore inicial $-1,386294$

árvore 1, folha do grupo B $+0,200$

árvore 2, folha do grupo B $+0,166$

escore final $-1,020$

escore F

$F = -1,020217$ $p = \sigma(F) = 26,4985\%$

grupo A chegaria a $-1,756200$ e PD $14,7267\%$

Para prever, o cliente percorre as árvores já aprendidas. Não precisamos conhecer seu desfecho. Miniatura didática de 10 registros; cálculo próprio

Slide 36 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Waterfall do escore inicial e das duas contribuições, com a conversão logística ao lado e a ficha de um solicitante novo. Arraste o comprometimento do solicitante entre os grupos; "Converter em PD" aplica a logística; "Como foi treinado?" volta aos slides 33 a 35.

TRANSIÇÃO PARA O SLIDE 37

Se cada passo for menor, precisaremos de mais etapas. Como escolher o tamanho dos passos e o número de árvores?

CONDUÇÃO

- Apresente o solicitante novo e pergunte onde está o y dele.
- Mostre que y só foi usado no treinamento das duas árvores.
- Faça o percurso nas duas árvores, some e converta. Compare com o waterfall do logit: ambos somam em uma escala de escore, com funções diferentes.

RESPOSTAS ESPERADAS

- Grupo B: $-1,386294$ mais $0,200000$ mais $0,166078$ é igual a $-1,020217$, e a PD é $26,4985\%$.
- Grupo A: $-1,386294$ menos $0,200000$ menos $0,169906$ é igual a $-1,756200$, e a PD é $14,7267\%$.

CUIDADOS E LIMITES

- Não some as PDs de cada árvore nem chame as contribuições de probabilidades.
- Um conjunto real tem muitas árvores e padrões mais ricos. A miniatura de duas árvores só torna o mecanismo visível.
- Esta não é uma explicação por variável: é a decomposição exata da soma das árvores.
- Com taxa de aprendizagem diferente de 1, o que se soma é a taxa multiplicada pela contribuição.

Para prever, o cliente percorre as árvores já aprendidas. Não precisamos conhecer seu desfecho.

Miniatura didática de 10 registros; cálculo próprio

GRADIENT BOOSTING · SLIDE 37 DE 50

Learning rate e número de árvores precisam ser escolhidos juntos

Trajetórias de perda treinadas com cada taxa, no experimento sintético

GRADIENT BOOSTING slide 37 de 50

Learning rate e número de árvores precisam ser escolhidos juntos

Trajetórias de perda treinadas com cada taxa, no experimento sintético

$F_m = F_{m-1} + \eta h_m$

taxa de aprendizagem	0,10
árvores usadas	106
log loss de validação	0,34460
melhor iteração desta taxa	106 com 0,34460

Taxa de aprendizagem treinada
 $\eta = 0,03$ $\eta = 0,10$ $\eta = 0,30$

Número de árvores, apenas em iterações calculadas
 106 árvores · 0,34460

Por que não basta multiplicar no final?
 Reiniciar exemplo

PD com 105 árvores: Ana 5,00% Bruno 23,35% Carla 17,60% Diego 61,05%
 Trajetórias calculadas a cada cinco iterações e registradas no notebook.

Mudar o passo altera previsões, gradientes e, portanto, o que as próximas árvores aprendem.

Experimento sintético; semente e versões no notebook

Slide 37 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Perda de treino e de validação por iteração para três taxas de aprendizagem, com o ponto selecionado e a PD de um cliente. Alterne a taxa treinada e arraste o número de árvores apenas nas iterações calculadas; o painel mostra a melhor iteração de cada taxa.

TRANSIÇÃO PARA O SLIDE 38

Além de quantos passos dar e do tamanho de cada passo, importa o que cada árvore consegue representar.

CONDUÇÃO

- Compare as taxas no mesmo número de árvores e depois permita mais árvores para a taxa menor.
- Pergunte se taxa menor é sempre melhor. Não: há custo computacional, subajuste com poucas árvores e comportamento que depende dos dados.

RESPOSTAS ESPERADAS

- Cada curva vem de um treinamento próprio com sua taxa. Não é a reescala de um conjunto fixo de árvores.
- Multiplicar as contribuições no fim não reproduz outro treinamento, porque os resíduos dependem do escore atualizado a cada passo.

CUIDADOS E LIMITES

- O produto entre taxa e número de árvores não determina sozinho o modelo final: a trajetória muda.
- A taxa se relaciona com regularização, mas não substitui validação temporal.
- O teste final continua fora de qualquer escolha.

Mudar o passo altera previsões, gradientes e, portanto, o que as próximas árvores aprendem.

Experimento sintético; semente e versões no notebook

Uma correção pode depender de uma característica ou da combinação de várias

Profundidade de cada árvore no experimento auxiliar de duas variáveis

GRADIENT BOOSTING slide 38 de 50

Uma correção pode depender de uma característica ou da combinação de várias

Profundidade de cada árvore no experimento auxiliar de duas variáveis

MESMA ESCALA E MESMO DOMÍNIO NOS TRÊS PAINÉIS

experimento auxiliar de duas variáveis

PROFUNDIDADE 1

utilização

comprometimento

PD no ponto: 46,66%
validação 0,2549

PROFUNDIDADE 2

utilização

comprometimento

PD no ponto: 50,86%
validação 0,2535

PROFUNDIDADE 3

utilização

comprometimento

PD no ponto: 47,53%
validação 0,2606

Cliente sintético: comprometimento 65%, utilização 80%, PD 46,66% na profundidade 1.

Alto e alto Alto e baixo Baixo e alto Baixo e baixo

Comprometimento 65 65%

Utilização 80 80%

profundidade 1 profundidade 2 profundidade 3

Reiniciar exemplo

escala de PD prevista 0% 60%

A regra do canto alto e alto: se comprometimento acima de 40% e utilização acima de 50%, o risco sobe mais do que a soma dos dois efeitos isolados. Taxa 0,1 e 150 árvores nos três painéis; muda apenas a profundidade.

Muitas regras simples somadas não são sempre equivalentes a regras que combinam condições.

Experimento auxiliar de duas variáveis; cálculo próprio

Slide 38 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Superfícies de PD prevista para boosting com profundidade 1, 2 e 3, na mesma escala e no mesmo domínio. Escolha um dos quatro cantos ou arraste comprometimento e utilização; alterne a profundidade e compare a PD no ponto.

TRANSIÇÃO PARA O SLIDE 39

Temos vários controles de complexidade. O acompanhamento da validação ajuda a decidir quando interromper a construção.

CONDUÇÃO

- Mostre a combinação de comprometimento alto com utilização alta e pergunte que regra a descreve.
- Compare a representação por uma única condição e por duas condições.
- Revele que árvores mais profundas capturam estruturas mais complexas, e que cada passo também pode ajustar mais ruído.

CUIDADOS E LIMITES

- Profundidade máxima não é contagem universal e exata da ordem de interações. Profundidade 2 permite caminhos com duas condições, e implementações e repetição de variável importam.
- A soma de stumps é aditiva no escore F. A transformação logística pode induzir não aditividade na escala da probabilidade. Não diga que stumps não produzem interação na PD.
- Este experimento auxiliar não fala sobre o desempenho na base de crédito principal.

Muitas regras simples somadas não são sempre equivalentes a regras que combinam condições.

Experimento auxiliar de duas variáveis; cálculo próprio

GRADIENT BOOSTING · SLIDE 39 DE 50


Continuar melhorando o treino pode deixar de ajudar a validação

Regra de parada com tolerância e paciência, definida antes de olhar o teste

GRADIENT BOOSTING · slide 39 de 50

Continuar melhorando o treino pode deixar de ajudar a validação

Regra de parada com tolerância e paciência, definida antes de olhar o teste



REGRAS DEFINIDAS ANTES DE TREINAR
máximo de 300 iterações · tolerância 0,000100
· paciência 20 · escolha na validação fora do tempo

Avançar treinamento
Ir para a melhor iteração
Reiniciar exemplo

300 de 300 iterações reveladas · melhor validação até aqui 0,34467 · paciência 203 de 20
Curvas calculadas no notebook, reveladas em lotes de 20 iterações.

MELHOR ITERAÇÃO E ITERAÇÃO DE PARADA
Melhor iteração na validação: 106, com log loss 0,34460. A paciência encerraria em 89, depois do mínimo. O modelo servido é o da melhor iteração.
A curva do teste não aparece em nenhum seletor.

A melhor iteração é escolhida usando uma amostra destinada a essa escolha.

Experimento sintético; semente e versões no notebook

Slide 39 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Log loss de treino e de validação por iteração, com a melhor iteração e a iteração de parada marcadas. "Avançar treinamento" revela as curvas em lotes de 20 iterações; "Ir para a melhor iteração" marca 106 e a parada em 89.

TRANSIÇÃO PARA O SLIDE 40

Com esses controles, podemos avaliar em que condições a flexibilidade do boosting oferece ganhos e quais custos ela traz.

CONDUÇÃO

- Peça que a turma sugira onde parar antes de revelar toda a curva.
- Compare o palpite com a regra: tolerância e paciência evitam reagir a variações pequenas.
- Mostre que o mínimo aparente pode ser ruidoso.

CUIDADOS E LIMITES

- Melhor iteração e iteração de parada são coisas diferentes. A parada acontece depois da paciência, não no mínimo.
- A validação usada é fora do tempo, definida no protocolo. Não é um corte aleatório interno da biblioteca.
- Escolher o número de árvores é seleção de hiperparâmetro, e usa a mesma amostra de validação.
- Um eventual reajuste com mais dados precisa respeitar a disponibilidade temporal e ser definido antes de calibrar e testar.

A melhor iteração é escolhida usando uma amostra destinada a essa escolha.

Experimento sintético; semente e versões no notebook

Mais flexibilidade exige mais disciplina de validação

Quatro situações, a pergunta de diagnóstico e a evidência que a responde

GRADIENT BOOSTING · slide 40 de 50

Mais flexibilidade exige mais disciplina de validação

Quatro situações, a pergunta de diagnóstico e a evidência que a responde

SINAL APROXIMADAMENTE ADITIVO

As características contribuem de forma estável e quase somável na escala do escore.

cuidado: Complexidade sem ganho é custo de manutenção sem retorno.

INTERAÇÕES RELEVANTES

O risco depende de combinações de condições, como comprometimento alto junto de utilização alta.

cuidado: Encontrar interação no treino é fácil. Reproduzir a interação fora do tempo é o teste.

O QUE VERIFICAR EM SINAL APROXIMADAMENTE ADITIVO

O boosting ganha da especificação linear bem construída, fora do tempo?

Qual evidência aceitar. Aceitar apenas ganho que persiste na validação fora do tempo contra um logit com transformações e interações plausíveis. Se o ganho não persiste, o logit basta.

POUCOS EVENTOS

Volume pequeno de inadimplências, faixas finas e estimativas instáveis.

cuidado: Flexibilidade com poucos eventos costuma ajustar ruído.

MUDANÇA DE POPULAÇÃO

A composição dos solicitantes muda ao longo do tempo.

cuidado: Nenhum algoritmo corrige sozinho mudança de população.

SENSIBILIDADE JÁ CALCULADA

validação, não o teste	AUC VALIDAÇÃO	LOG LOSS VALIDAÇÃO
Logit	0,7379	0,34299
Logit regularizado	0,7385	0,34395
Gradient boosting	0,7366	0,34460

Neste experimento os três ficam próximos na validação. Isso é o resultado observado aqui, não uma generalização de mercado.

Reiniciar exemplo

GANHOS POSSÍVEIS

- relações não lineares sem especificação manual
- interações capturadas pela profundidade das árvores
- boa adaptação a dados tabulares com muitas colunas

CUSTOS

- ajuste de hiperparâmetros e orçamento de busca
- explicação menos direta que um coeficiente
- risco de sobreajuste quando a validação é frouxa
- manutenção, versionamento e verificação de calibração

Capturar padrões complexos é uma capacidade. Demonstrar que eles persistem é uma obrigação.

Síntese conceitual, com um resultado calculado como exemplo

Slide 40 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Quatro situações de adequação do boosting, cada uma com pergunta de diagnóstico e evidência aceitável. Escolha cada situação para ler a pergunta e a evidência; a tabela de sensibilidade fica visível em todas.

TRANSIÇÃO PARA O SLIDE 41

Se o modelo usa muitas árvores, como explicar o que ele aprendeu e por que atribuiu determinada PD a um cliente?

CONDUÇÃO

- Peça que a turma escolha uma situação em que começaria pelo logit e outra em que investigaria boosting.
- Discuta hipóteses e as evidências necessárias em cada caso.
- Não revele ainda a tabela final da comparação principal.

CUIDADOS E LIMITES

- Implementações como XGBoost, LightGBM e CatBoost existem e diferem entre si. Aqui não há catálogo de funcionalidades nem recomendação comercial.
- Suporte a dados ausentes e categóricos depende da implementação. Não é propriedade universal do método.
- A frase funciona bem em dados tabulares não substitui um experimento adequado no problema.
- Nenhuma nota subjetiva é atribuída aos algoritmos.

Capturar padrões complexos é uma capacidade.
Demonstrar que eles persistem é uma obrigação.

Síntese conceitual, com um resultado calculado como exemplo

GRADIENT BOOSTING · SLIDE 41 DE 50

O que o modelo usa em geral? O que pesou para Bruno?

Importância global por permutação e contribuição local no escore

GRADIENT BOOSTING slide 41 de 50

O que o modelo usa em geral? O que pesou para Bruno?

Importância global por permutação e contribuição local no escore

GLOBAL: IMPORTÂNCIA NA CARTEIRA

validação, jan a jun de 2021

comprometimento	0,0618
histórico	0,0419
utilização	0,0177
relacionamento	0,0058
renda	0,0032
canal	0,0030

AUC de referência na validação: 0,7366. A barra mostra quanto a AUC cai quando os valores da variável são embaralhados.

LOCAL: O ESCORE DE BRUNO

contribuições em escore

referência -2,056

comprometimento	-0,024
histórico	+0,651
utilização	+0,155
relacionamento	+0,121
renda	-0,004
canal	-0,031

escore de Bruno -1,189

escore do boosting

Conferência: referência mais a soma das contribuições é -1,189179, e o escore do modelo é -1,189179. Diferença menor que 10 elevado a menos 9.

DO ESCORE À PD

escore do boosting	-1,1892
PD do modelo	23,34%
PD depois da calibração	25,78%

Cliente

Ana Bruno Carla Diego

Destacar uma variável (nome abreviado)

comp hist util rel renda

canal

Reiniciar exemplo

COMO LER

O painel global mede desempenho: quanto a AUC cai ao embaralhar a variável. O local mede escore: quanto a característica desloca a previsão daquele cliente. Alterar a variável não garante essa redução: explicação não identifica causa.

Uma variável importante na carteira não precisa ser o principal fator da previsão de todo cliente.

Experimento sintético; semente e versões no notebook

Slide 41 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Importância global por queda de AUC ao permutar cada variável e decomposição local do escore de um cliente. Troque o cliente e destaque uma variável pelo nome abreviado para ler as duas medidas lado a lado.

TRANSIÇÃO PARA O SLIDE 42

Vamos verificar se conseguimos separar a construção da previsão de sua interpretação.

CONDUÇÃO

- Peça a variável mais relevante na carteira e a que mais eleva a previsão de Bruno. Mostre que podem ser diferentes.
- Compare Bruno e Carla mantendo as escalas.
- Termine com a pergunta: se alterarmos essa variável, garantimos essa redução de risco? Resposta: explicação de previsão não identifica efeito causal.

RESPOSTAS ESPERADAS

- As duas leituras respondem a perguntas diferentes: uma descreve a carteira, a outra descreve uma previsão.
- A soma da referência com as contribuições reproduz o escore do cliente, o que é conferido numericamente.

CUIDADOS E LIMITES

- Importância por permutação tem unidade própria, aqui queda de AUC na validação. Não é a mesma escala das contribuições locais, que estão em escore.
- Variáveis correlacionadas afetam atribuição e importância.
- Importância por redução de impureza tem limitações distintas das da permutação.
- As contribuições locais são valores de Shapley com expectativa intervencional sobre uma amostra de referência, calculados no notebook, e não um mecanismo econômico.

Uma variável importante na carteira não precisa ser o principal fator da previsão de todo cliente.

Experimento sintético; semente e versões no notebook

GRADIENT BOOSTING · SLIDE 42 DE 50

O novo cliente caiu no grupo B. Qual é a previsão?

Exercício: somar em escore e converter uma única vez

GRADIENT BOOSTING slide 42 de 50

O novo cliente caiu no grupo B. Qual é a previsão?

Exercício: somar em escore e converter uma única vez

O QUE JÁ SABEMOS

escore inicial F0	-1,386294
folha da árvore 1	+0,200000
folha da árvore 2	+0,166078
taxa de aprendizagem	1
PD final	26,4985%

PERGUNTA DE INTERPRETAÇÃO

Uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real?

Não. A contribuição explica a função preditiva aprendida com registros históricos. Ela não identifica o efeito de uma intervenção sobre o cadastro.

ESCOLHA O MÉTODO CORRETO

A Somar como pontos percentuais: 20% mais 20% mais 16,6078%.

B Somar ao escore e aplicar a função logística uma única vez.

C Tirar a média das duas folhas.

Conferir

Correta. Escore final -1,386294 mais 0,200000 mais 0,166078 é igual a -1,020217. Aplicando a logística, PD de 26,4985%.

Resolvido **Desafio de consolidação**

Reiniciar exercício

folha da árvore 1 +0,200

folha da árvore 2 +0,166

escore inicial

escore final

escore F

26,50%

26,4985%

sigmoid(-1,020217)

escore z

Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

Miniatura didática de 10 registros; cálculo próprio

Slide 42 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Escore inicial e duas folhas do grupo B, com três métodos possíveis de combinação. Escolha o método e clique em Conferir; "Desafio de consolidação" abre uma variação com outro grupo.

TRANSIÇÃO PARA O SLIDE 43

Sabemos como as três técnicas funcionam. Agora precisamos comparar as três em condições iguais e verificar o que cada métrica responde.

CONDUÇÃO

- Dê um minuto individual e outro em duplas.
- Peça que verbalizem onde o desfecho y foi usado e onde deixou de ser necessário.
- Conclua o bloco conectando logit e boosting pela saída probabilística, com funções de escore diferentes.

RESPOSTAS ESPERADAS

- Soma em escore: -1,386294 mais 0,200000 mais 0,166078 é igual a -1,020217. A PD é 26,4985%.
- Somar percentuais daria 20% mais 20% mais 16,6078%, o que não é a operação do modelo.
- A média das duas folhas ignoraria o escore inicial e a natureza aditiva da construção.
- Sobre causalidade: uma contribuição positiva do histórico não prova que remover o atraso do cadastro reduziria o risco real.
- Reduzir a taxa de aprendizagem exige recalcular as rodadas e os resíduos, não dividir a PD.

CUIDADOS E LIMITES

- A soma das árvores acontece na escala de log odds. Somar contribuições em probabilidade dá resultado errado.
- A miniatura tem 10 registros e serve para ver o mecanismo. Não é modelo ajustado nem sustenta comparação de desempenho.
- Reconstruir a previsão de um cliente novo não valida o modelo: validação exige amostra fora do tempo, no bloco seguinte.

EXERCÍCIO**O novo cliente caiu no grupo B. Qual é a previsão?**

Score inicial $-1,386294$; folha da árvore 1 $+0,200000$; folha da árvore 2 $+0,166078$; taxa de aprendizagem 1. Marque o método correto e calcule a PD.

- A. Somar como pontos percentuais: 20% mais 20% mais 16,6078%.
- B. Somar ao score e aplicar a função logística uma única vez.
- C. Tirar a média das duas folhas.

ETAPAS

1. Score final: _____ + _____ + _____ = _____

2. PD final: $1 / (1 + e^{\text{elevado a } \text{_____}}) = \text{_____}\%$

DESAFIO

Uma contribuição positiva do histórico prova que remover o atraso do cadastro reduziria o risco real? Responda em duas linhas.

Com as árvores treinadas, os atributos determinam o percurso e a soma determina a PD.

Miniatura didática de 10 registros; cálculo próprio

BLOCO 5 DE 5 · SLIDES 43 A 50

5

Avaliação e decisão

Como comparar os três modelos com justiça e transformar probabilidades em política de crédito?

O que você vai aprender

- Fixar o protocolo antes de qualquer métrica: mesmo alvo, mesma informação, teste congelado.
- Separar discriminação (AUC e KS) de calibração (previsto contra observado, faixa a faixa).
- Ligar o corte de aprovação à economia da operação e ao que se observa na carteira depois.
- Defender uma recomendação que combine desempenho, economia, estabilidade e capacidade de execução.

Ideias para levar

- Um modelo pode ordenar bem mesmo com probabilidades na escala errada.
- A política é uma decisão adicional ao modelo.
- Parte da qualidade do modelo só será conhecida depois da maturação do alvo.

Os slides deste bloco

SLIDE	TÍTULO	PÁGINA
43	Estamos comparando modelos ou comparando condições diferentes?	57
44	Quem aparece primeiro na fila de risco?	58
45	Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?	59
46	Até qual PD vamos aprovar?	60

SLIDE	TÍTULO	PÁGINA
47	Com estas hipóteses, o equilíbrio ocorre em PD de 20%	61
48	O que conseguimos monitorar agora? O que exige esperar?	62
49	Defenda sua recomendação para o comitê	63
50	Você consegue explicar, comparar e usar os três modelos?	64

Estamos comparando modelos ou comparando condições diferentes?

O protocolo precede qualquer métrica

AVALIAÇÃO E DECISÃO slide 43 de 50

Estamos comparando modelos ou comparando condições diferentes?

O protocolo precede qualquer métrica

CONDIÇÃO	LOGIT REGULARIZADO	ÁRVORE CONTROLADA	GRADIENT BOOSTING
Amostra e alvo mesmas coortes, mesmo evento e mesmo horizonte de 12 meses	comum	comum	comum
Informação disponível as seis características, com a mesma regra de disponibilidade	comum	comum	comum
Pré processamento tratamento próprio é permitido, sem vantagem de informação	padronização, mais a imputação comum	imputação pela mediana do treino e indicadores de ausência	
Escolha de complexidade sempre pela perda na validação fora do tempo	grade de penalização L2	profundidade, mínimo por folha e poda	taxa, profundidade e número de árvores
Avaliação final uma única passagem, com regras definidas antes	teste congelado	teste congelado	teste congelado

OS QUATRO PERÍODOS, COM A MATURAÇÃO DE 12 MESES

2018 treino 16.000 · validação 4.000 · calibração e política 3.000 · teste 5.000 contratos

Mesmo alvo, mesma informação e teste preservado são condições da comparação.

Experimento sintético; semente e versões no notebook

NA TELA

Tabela do protocolo com o que é comum aos três modelos e o que é próprio de cada um, mais a tira dos quatro períodos. Os três botões mostram comparações injustas típicas: boosting com variável do futuro, logit sem tratamento e configuração escolhida pelo teste.

"Ver protocolo executado" abre os metadados.

TRANSIÇÃO PARA O SLIDE 44

A primeira pergunta é se o modelo ordena corretamente os clientes de maior e menor risco.

CONDUÇÃO

- Recupere o slide 05 em miniatura na tira inferior.
- Pergunte por que usar todos os registros em todos os modelos ainda não garante justiça.
- Revele processamento e seleção, e só depois habilite a abertura dos resultados.

RESPOSTAS ESPERADAS

- Boosting com variável futura: a comparação mede vazamento, não algoritmo. Correção: remover a variável e refazer o treinamento.
- Logit sem tratamento enquanto outros receberam engenharia: baseline artificialmente fraco. Correção: dar ao logit transformações e interações plausíveis, como a sensibilidade deste experimento.
- Configuração escolhida pela métrica do teste: o teste deixa de ser independente. Correção: escolher na validação e usar o teste uma única vez.

CUIDADOS E LIMITES

- Modelos especificados antes do teste podem ser comparados nele. Ajustes motivados por esse teste exigem nova avaliação independente.
- A exploração em aula não deve produzir um campeão otimizado depois de ver o resultado.
- Calibradores e cortes pertencem às partições definidas para isso.

Mesmo alvo, mesma informação e teste preservado são condições da comparação.

Experimento sintético; semente e versões no notebook

Quem aparece primeiro na fila de risco?



AUC contada por pares e curvas do experimento sintético

AVALIAÇÃO E DECISÃO slide 44 de 50

Quem aparece primeiro na fila de risco?

AUC contada por pares e curvas do experimento sintético

Microexemplo de pares Curvas do experimento modelo Logit Árvore Boosting teste, 5.000 contratos de fev a jul de 2024



AUC 0,7444 KS 0,3769 n = 5.000 contratos, 712 eventos

Mudar o corte não altera a AUC. A taxa de falsos positivos do eixo não é a inadimplência da carteira aprovada.

Um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada. Microexemplo de ranking e experimento sintético, em abas identificadas

Slide 44 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Seis registros ordenados por escore com comparação de pares, e curvas ROC e acumuladas do KS. Na aba "Microexemplo de pares", selecione um inadimplente e compare com os adimplentes; na aba "Curvas do experimento", troque o modelo.

TRANSIÇÃO PARA O SLIDE 45

Mesmo que o ranking esteja certo, precisamos perguntar se uma previsão de 10% corresponde a cerca de 10% de eventos.

CONDUÇÃO

- Comece pelo par, não pela integral.
- Pergunte se o escore 0,8 significa 80% de PD calibrada. Neste exemplo não há essa evidência.
- Revele as curvas como resumo da ordenação e diferencie taxa de falsos positivos de inadimplência entre aprovados.

RESPOSTAS ESPERADAS

- São 9 pares, 7 corretamente ordenados: AUC igual a 7 dividido por 9, aproximadamente 0,7778.
- Empates contam meio par.
- Mudar o corte não muda a AUC: ela percorre todos os cortes.

CUIDADOS E LIMITES

- Orientação declarada: escore maior significa maior risco.
- AUC por pares não é acurácia, taxa de acerto de aprovados nem rentabilidade.
- KS e AUC resumem aspectos diferentes: um não determina o outro.
- Diferenças pequenas entre modelos podem exigir avaliação de incerteza.


Um modelo pode ordenar bem mesmo que suas probabilidades estejam na escala errada.

Microexemplo de ranking e experimento sintético, em abas identificadas

AVALIAÇÃO E DECISÃO · SLIDE 45 DE 50

Entre os clientes com PD próxima de 10%, quantos ficaram inadimplentes?

Média prevista contra frequência observada, faixa a faixa



NA TELA

Diagrama de calibração com dez faixas por quantis, intervalos de Wilson e histograma das probabilidades previstas. Troque o modelo e a versão das previsões (originais, odds vezes 2, calibradas por Platt) e acompanhe AUC, Brier e log loss.

TRANSIÇÃO PARA O SLIDE 46

Uma PD só vira ação quando definimos uma política. Vamos observar como um corte altera a carteira aprovada.

CONDUÇÃO

- Leia um ponto completo: probabilidade média, proporção observada, n e eventos.
- Aplique a perturbação das odds e pergunte o que deve acontecer com a AUC antes de revelar.
- Discuta por que PD em escala errada distorce perda esperada e política de corte.

RESPOSTAS ESPERADAS

- A transformação multiplica as odds por dois e preserva a ordem, portanto a AUC permanece idêntica.
- A calibração e as perdas mudam, e a direção depende de como o modelo já estava calibrado.

CUIDADOS E LIMITES

- Wilson por faixa é descrição binomial aproximada e não incorpora toda a seleção e modelagem.
- Brier e log loss avaliam qualidade probabilística, mas não são medidas exclusivas de calibração.
- Número de faixas, calibrador e versão não devem ser escolhidos pelo teste final.
- O calibrador de Platt foi ajustado na partição de calibração e aplicado ao teste sem reajuste.

APROFUNDAR

- O calibrador de Platt foi ajustado na partição de calibração e aplicado ao teste sem reajuste. O efeito observado na tela é o desse procedimento, não de um recalibrador ajustado no próprio teste.
- Platt é uma logística sobre o escore: $p_{\text{calibrada}} = \sigma(a \cdot z + b)$. Como a transformação é monotônica em z quando a é positivo, ela não altera a ordem nem a AUC, e é exatamente por isso que serve para corrigir nível sem estragar ordenação.

Calibrar é verificar a escala das probabilidades, não apenas a ordem dos clientes.

Experimento sintético; semente e versões no notebook

AVALIAÇÃO E DECISÃO · SLIDE 46 DE 50

Até qual PD vamos aprovar?

O corte define quem entra na carteira e o que se observa depois

AVALIAÇÃO E DECISÃO slide 46 de 50

Até qual PD vamos aprovar?

O corte define quem entra na carteira e o que se observa depois



NO CORTE DE 20,0%

partição de política	
aprovados	2.372 de 3.000
taxa de aprovação	79,1%
eventos entre aprovados	236
inadimplência entre aprovados	9,95%
PD média dos aprovados	9,86%

Corte de aprovação

20,0 aprovação 79,1%

Logit Árvore Boosting

Partição de política Teste, modo final

Corte congelado 20%

Mesmo volume de aprovação

Reiniciar exemplo

A política é definida nesta partição, antes de qualquer olhar ao teste.

Experimento sintético; semente e versões no notebook

A mesma previsão pode sustentar políticas diferentes. A política é uma decisão adicional ao modelo.

Slide 46 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Histograma das PDs com a linha de corte, taxa de aprovação e inadimplência observada entre aprovados. Arraste o corte de aprovação, troque o modelo e a partição; "Corte congelado 20%" e "Mesmo volume de aprovação" fixam duas comparações justas.

TRANSIÇÃO PARA O SLIDE 47

Para escolher um corte, precisamos colocar receitas e perdas na mesma conta.

CONDUÇÃO

- Reduza o corte e observe volume e composição.
- Pergunte se menor inadimplência implica melhor resultado. Não: pode haver perda de receita.
- Compare dois modelos no mesmo corte e depois no mesmo volume, e explique que são perguntas diferentes.

RESPOSTAS ESPERADAS

- Taxa de aprovação é o número de aprovados dividido pelo total avaliado.
- Inadimplência entre aprovados é a soma de eventos entre aprovados dividida pelo número de aprovados. Contratos recusados não entram no denominador.
- Média das PDs aprovadas e taxa observada são coisas diferentes: a primeira é previsão, a segunda é desfecho.

CUIDADOS E LIMITES

- A avaliação usa contratos com desfecho conhecido da população sintética, o que permite simular recusa. Em dados reais de apenas concedidos, inferir o desempenho dos rejeitados exige hipóteses adicionais.
- Limite de crédito, preço e prazo permanecem fixos aqui, para isolar a decisão de aprovação.
- Empates na PD, comuns na árvore, seguem a regra de aprovar todos no limite. Nenhum desempate usa y.
- Se ninguém for aprovado, a inadimplência entre aprovados fica indefinida.


A mesma previsão pode sustentar políticas diferentes. A política é uma decisão adicional ao modelo.

Experimento sintético; semente e versões no notebook

AVALIAÇÃO E DECISÃO - SLIDE 47 DE 50

Com estas hipóteses, o equilíbrio ocorre em PD de 20%

Aproximação didática por operação, horizonte de 12 meses



NA TELA

Resultado esperado por operação em função da PD, com o ponto de equilíbrio marcado e a decomposição em margem menos perda esperada. Arraste a PD do contrato; "Mudar hipóteses" altera margem, LGD e EAD e move o ponto de equilíbrio.

TRANSIÇÃO PARA O SLIDE 48

Antes de implantar, ainda precisamos saber se a relação continua válida no tempo e se conseguimos operar essa relação com controle.

CONDUÇÃO

- Construa a perda esperada, depois o resultado, depois o equilíbrio.
- Pergunte o efeito de aumentar a fração perdida mantendo a PD.
- Mostre que o mesmo cliente pode ser aceitável sob uma estrutura econômica e inviável sob outra, sem defender simplesmente aumento de taxa.

RESPOSTAS ESPERADAS

- Perda esperada é PD vezes LGD vezes EAD. Em PD de 10%: 0,10 vezes 60% vezes R\$ 10.000, igual a R\$ 600.
- Resultado esperado é margem menos perda esperada: R\$ 1.200 menos R\$ 600, igual a R\$ 600.
- Equilíbrio: margem dividida por LGD vezes EAD, igual a 20%.

CUIDADOS E LIMITES

- A margem é considerada constante e já líquida dos custos definidos, apenas nesta simplificação. Não é receita recebida em todos os cenários do mundo real.
- Perda esperada não é lucro, e EAD não é o valor original do contrato sem a hipótese de igualdade.
- A versão alternativa, com margem condicional ao adimplemento, tem outro corte e não deve ser misturada a este gráfico.
- Resultados realizados usam y e são diferentes do valor esperado calculado com p.

Um bom ranking só gera valor quando probabilidades e política se conectam à economia da operação.

Economia didática declarada na tela; cálculo próprio

O que conseguimos monitorar agora? O que exige esperar?

Indicadores imediatos e indicadores que dependem da maturação do alvo

AValiação e Decisão · slide 48 de 50

O que conseguimos monitorar agora? O que exige esperar?

Indicadores imediatos e indicadores que dependem da maturação do alvo

PD média prevista

inadimplência observada

INDICADORES IMEDIATOS

comprometimento médio da coorte mais recente 35,5%

utilização média 45,8%

ausência de utilização 4,8%

taxa de aprovação no corte congelado 77,2%

PD média prevista 16,57%

INDICADORES COM ALVO MATURADO

inadimplência da coorte mais recente 14,63%

já maturada

coorte correspondente jul/2024

coortes já maturadas 41 de 41

Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

Experimento sintético; semente e versões no notebook

Slide 48 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Coortes mensais com indicadores imediatos e, para as coortes já maturadas, inadimplência observada. Arraste a data de observação e veja quantas coortes já maturaram; escolha um cenário sintético para ver os indicadores reagirem.

TRANSIÇÃO PARA O SLIDE 49

Temos desempenho, probabilidades, economia e condições de operação. Agora vamos tomar uma decisão de comitê.

CONDUÇÃO

- Pergunte se PD média crescente prova piora do modelo. Pode ser mudança da população.
- Pergunte se ausência de inadimplência recente prova segurança. Pode ser falta de maturação.
- Relacione à definição do alvo do slide 03 e termine com a necessidade de versionar modelo, dados, regra e explicações.

RESPOSTAS ESPERADAS

- Imediatos: distribuição de renda e comprometimento, ausentes, taxa de aprovação e PD média.
- Com alvo maturado: inadimplência observada, calibração, discriminação e resultado.
- A data de observação define o que pode ser medido: uma coorte só entra nas métricas de desfecho 12 meses depois da contratação.

CUIDADOS E LIMITES

- PSI, se citado, é indicador de mudança de distribuição e depende de faixas e tamanho de amostra. Não use limiares universais como regra automática.
- Mudança de distribuição não demonstra por si só perda de desempenho.
- Os cenários são sintéticos e construídos para a aula. Não são previsão macroeconômica nem backtest real.
- Nem todo alerta pede retreino: a ação depende do diagnóstico.

Podemos observar a carteira entrando hoje, mas parte da qualidade do modelo só será conhecida depois.

Experimento sintético; semente e versões no notebook

Defenda sua recomendação para o comitê

Desempenho, economia, estabilidade e capacidade de execução na mesma mesa

AVAliação e Decisão

slide 49 de 50

Defenda sua recomendação para o comitê

Desempenho, economia, estabilidade e capacidade de execução na mesma mesa

TESTE DE FEV A JUL DE 2024, 5.000 CONTRATOS E 712 EVENTOS	LOGIT	ÁRVORE	base sintética
EVIDÊNCIA NO TESTE			BOOSTING
AUC	0,7446	0,7392	0,7444
Brier, qualidade probabilística	0,10670	0,10823	0,10707
Taxa de aprovação	74,8%	77,7%	79,4%
Inadimplência entre aprovados	8,50%	9,32%	9,22%
Resultado por aprovado	R\$ 690	R\$ 641	R\$ 647
Resultado total da carteira	R\$ 2.578.800	R\$ 2.487.600	R\$ 2.565.600

Política congelada antes do teste: aprovar quando a PD calibrada não passa de 20%, que é o ponto de equilíbrio econômico do slide 47.

Modelo candidato

Logit

Árvore

Boosting

Política

Corte de equilíbrio

Corte da partição de política

Restrição

Nenhuma

Simplicidade

Explicação individual

Esconder argumentos

Reiniciar exemplo

Sem restrição adicional declarada.

ARGUMENTOS QUE A EVIDÊNCIA SUSTENTA

- A maior AUC no teste é de Logit, com 0,7446. A diferença para o menor é de 0,0054, pequena diante da variabilidade de uma única amostra.
- O maior resultado total sob a política escolhida é de Logit, com R\$ 2.578.800 em 3.739 aprovados.
- Aprovação e inadimplência entre aprovados mudam junto com o modelo: comparar apenas AUC esconde a diferença de volume.
- Manter o logit como referência operacional e avaliar outro método como desafiante é uma recomendação defensável, se a evidência sustentar.
- Nenhum resultado aqui autoriza reajustar o modelo neste mesmo teste e chamar a nova medida de avaliação independente.

SUA JUSTIFICATIVA

Por que este modelo e esta política?

Qual é o principal risco desta escolha?

Como monitorar depois da implantação?

O texto fica apenas neste dispositivo.

Uma recomendação precisa combinar desempenho, economia, estabilidade e capacidade de execução.

Experimento sintético; semente e versões no notebook

Slide 49 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Tabela comparativa dos três modelos no teste, com política congelada, e um formulário de justificativa local. Escolha modelo candidato, política e restrição; "Ver argumentos possíveis" lista o que a evidência sustenta. Escreva a sua justificativa nos três campos.

TRANSIÇÃO PARA O SLIDE 50

Independentemente da escolha, quais princípios devem acompanhar qualquer modelagem de crédito?

CONDUÇÃO

- Divida a turma em três grupos ou peça decisões individuais.
- Cada grupo tem dois minutos para recomendar e um minuto para defender.
- Solicite uma razão que faria mudar de opinião.
- Reforce que uma evidência de teste não autoriza ajustar repetidamente o modelo no mesmo teste e chamar isso de avaliação independente.

CUIDADOS E LIMITES

- Os números são de base sintética e servem à aprendizagem, não a uma decisão real de concessão.
- Valores próximos não autorizam declarar superioridade conclusiva.
- O formulário fica apenas neste dispositivo e não envia nada.
- Nenhum custo monetário de implantação é atribuído aos modelos: eles não foram medidos.

EXERCÍCIO

Prepare a recomendação para o comitê

Escolha um modelo e uma política e responda em até três linhas cada pergunta, citando os números da tabela do teste.

- Por que este modelo e esta política?
- Qual é o principal risco desta escolha?
- Como monitorar depois da implantação?

Uma recomendação precisa combinar desempenho, economia, estabilidade e capacidade de execução.

Experimento sintético; semente e versões no notebook

AVALIAÇÃO E DECISÃO · SLIDE 50 DE 50

Você consegue explicar, comparar e usar os três modelos?

Definir, estimar, validar e decidir são etapas conectadas

AVALIAÇÃO E DECISÃO slide 50 de 50

Você consegue explicar, comparar e usar os três modelos?

Definir, estimar, validar e decidir são etapas conectadas

TÉCNICA	COMO CONSTRÓI A PD	PRINCIPAL CUIDADO	EVIDÊNCIA NECESSÁRIA	TREZ PERGUNTAS DE RECUPERAÇÃO
Regressão logística	soma funções das características em um escore e converte pela logística	especificação, unidade das variáveis e leitura dos coeficientes	validação da forma funcional e calibração fora do tempo	Odds multiplicadas por 2 significam PD multiplicada por 2? Não. Odds e probabilidade são escalas diferentes: com odds dobradas, 10% vira 18,18% e 40% vira 57,14%. Rever no slide 11 Esconder
Árvore de decisão	aprende regras sucessivas e usa a frequência observada na folha	complexidade, tamanho de folha e instabilidade entre amostras	desempenho fora do tempo e estabilidade entre reamostragens	A mesma folha pode conter clientes diferentes? Sim. A folha agrupa todos os contratos que satisfazem as mesmas regras, e atribui a mesma previsão a todos eles. Rever no slide 22 Esconder
Gradient boosting	acrescenta contribuições sucessivas ao escore e converte no fim	trajetória de ajuste, complexidade de cada árvore e explicação	curva de validação, parada definida antes e verificação de calibração	As árvores do boosting somam probabilidades? Não. A soma acontece no escore F, e a transformação logística é aplicada uma única vez no final. Rever no slide 36 Esconder
Para os três: informação disponível na decisão, validação temporal, calibração das probabilidades e conexão com a decisão econômica.				APLICAR NO MEU TRABALHO Copiar roteiro
OS MESMOS QUATRO CLIENTES DO COMEÇO qual modelo, qual política e por quê?				1. Alvo: qual evento, em qual horizonte e para qual população elegível. 2. Dados: o que existia e estava acessível na data da decisão. 3. Referência: um modelo simples bem especificado, que os demais precisam superar. 4. Protocolo: partição por data, maturação do alvo e regras congeladas antes do teste. 5. Comparação: mesmo conjunto de informação, mesma métrica e incerteza declarada. 6. Decisão: corte, economia da operação e plano de monitoramento com responsabilidade. Leve os seis passos para a sua carteira. A conclusão da aula está na linha de fechamento, abaixo.

A técnica importa. A evidência que sustenta seu uso importa tanto quanto.

Síntese do curso

Slide 50 como aparece na projeção, no estado revelado, com os controles e as etapas abertas.

NA TELA

Tabela de síntese dos três modelos, três perguntas de recuperação e o roteiro de aplicação no trabalho. Abra cada pergunta de recuperação só depois de responder; "Copiar roteiro" leva os seis passos para o seu trabalho.

TRANSIÇÃO PARA O SLIDE SEGUINTE

Fim da sequência principal.

CONDUÇÃO

- Peça que um aluno resuma cada técnica em uma frase.
- Retome a decisão do slide 01 sem inventar quais respostas a turma deu. Se as escolhas locais foram salvas, identifique que são escolhas naquele dispositivo.
- Pergunte o que agora exigiriam antes de aprovar uma mudança de modelo.

RESPOSTAS ESPERADAS

- Odds vezes 2 não é PD vezes 2: odds e probabilidade são escalas diferentes.
- Sim, a mesma folha agrupa atributos distintos que satisfazem as mesmas regras.
- Não: o boosting logístico soma no escore F e aplica a transformação depois.

CUIDADOS E LIMITES

- Complexidade pode ser útil, e a qualidade da decisão depende do processo inteiro.
- Referências, notebook e modo estudo ficam disponíveis nos recursos finais.
- Não existe um 51º slide de agradecimento: o fechamento é esta síntese.

EXERCÍCIO

Três perguntas de recuperação

Responda por escrito antes de abrir as respostas no slide. Cada uma remete a um slide da aula.

- Odds multiplicadas por 2 significam PD multiplicada por 2? (rever o slide 11)
- A mesma folha pode conter clientes diferentes? (rever o slide 22)
- As árvores do boosting somam probabilidades? (rever o slide 36)

DESAFIO

Para Ana, Bruno, Carla e Diego: qual modelo, qual política e por quê? Use as PDs dos slides 12, 22, 26 e 37 e o corte de 20% do slide 47.

A técnica importa. A evidência que sustenta seu uso importa tanto quanto.

Síntese do curso

Síntese das três técnicas

TÉCNICA	COMO CONSTRÓI A PD	PRINCIPAL CUIDADO	EVIDÊNCIA NECESSÁRIA
Regressão logística	soma funções das características em um escore e converte pela logística	especificação, unidade das variáveis e leitura dos coeficientes	validação da forma funcional e calibração fora do tempo
Árvore de decisão	aprende regras sucessivas e usa a frequência observada na folha	complexidade, tamanho de folha e instabilidade entre amostras	desempenho fora do tempo e estabilidade entre reamostragens
Gradient boosting	acrescenta contribuições sucessivas ao escore e converte no fim	trajetória de ajuste, complexidade de cada árvore e explicação	curva de validação, parada definida antes e verificação de calibração

Para os três: informação disponível na decisão, validação temporal, calibração das probabilidades e conexão com a decisão econômica.

Os três modelos no teste, com a mesma política

EVIDÊNCIA NO TESTE	LOGIT REGULARIZADO	ÁRVORE CONTROLADA	GRADIENT BOOSTING
AUC no teste	0,7446	0,7392	0,7444
Brier, previsões calibradas	0,10670	0,10823	0,10707
Taxa de aprovação	74,8%	77,7%	79,4%
Inadimplência entre aprovados	8,50%	9,32%	9,22%
Resultado por aprovado	R\$ 690	R\$ 641	R\$ 647
Resultado total da carteira	R\$ 2.578.800	R\$ 2.487.600	R\$ 2.565.600

Teste de fevereiro a julho de 2024, 5.000 contratos e 712 eventos. Política congelada antes do teste: aprovar quando a PD calibrada não passa de 20%, o ponto de equilíbrio econômico do slide 47. Fonte: experimento sintético, semente 20260920, mesma tabela do slide 49.

Os quatro clientes nos três modelos

CLIENTE	LOGIT	ÁRVORE	BOOSTING	NO CORTE DE 20%
Ana	3,06%	5,62%	5,49%	aprovado nos três
Bruno	35,09%	24,00%	25,78%	recusado nos três
Carla	14,21%	17,80%	19,56%	aprovado nos três
Diego	68,51%	60,61%	64,91%	recusado nos três

PDs calibradas dos modelos do experimento sintético, as mesmas que a política usa. As PDs sem calibração aparecem nos slides 37 e 41; a PD do logit manual de Bruno (11,66%) é de outro universo, o exemplo didático dos slides 07 a 20.

Roteiro para aplicar no trabalho

- 1. Alvo:** qual evento, em qual horizonte e para qual população elegível.
- 2. Dados:** o que existia e estava acessível na data da decisão.
- 3. Referência:** um modelo simples bem especificado, que os demais precisam superar.
- 4. Protocolo:** partições por data, maturação do alvo e regras congeladas antes do teste.
- 5. Comparação:** mesmo conjunto de informação, mesma métrica e incerteza declarada.
- 6. Decisão:** corte, economia da operação e plano de monitoramento com responsável.

Sinais para observar na turma

Confusões que os exercícios e as perguntas de recuperação expõem, com a correção que os próprios slides oferecem.

BLOCO	SINAL NA TURMA	COMO INTERVIR
O problema de crédito	Usar uma variável registrada depois da contratação, como valor renegociado ou consulta ao bureau posterior ao evento.	Perguntar sempre a data de disponibilidade da informação, não a data do fenômeno.
O problema de crédito	Escolher hiperparâmetros olhando o teste.	O teste é avaliado uma única vez, com regras congeladas antes. Escolhas usam a validação.
Regressão logística	Ler o coeficiente como variação da PD.	O coeficiente multiplica as odds. A variação da PD depende do ponto de partida e passa pela logística.
Regressão logística	Tratar odds dobradas como PD dobrada.	Odds de 0,1111 dobradas dão 0,2222, o que corresponde a PD de 18,18%, não de 20%.
Regressão logística	Codificar canal como 1, 2 e 3 numa única variável.	Categorias entram por indicadores em relação a uma referência. Números inventam uma ordem que os dados não garantem.
Regressão logística	Confundir linearidade nos parâmetros com linearidade nas variáveis.	Nós, transformações e interações mantêm o modelo linear nos parâmetros e mudam a forma do efeito.
Árvore de decisão	Confiar na taxa de uma folha pequena como se fosse precisa.	10% em 20 contratos tem intervalo de 2,8% a 30,1%; em 1.000 contratos, 8,3% a 12,0%.
Árvore de decisão	Escolher a divisão pela folha mais pura.	A regra é a menor impureza ponderada pelo tamanho de cada lado, medida em toda a amostra.
Árvore de decisão	Esperar que a renda mude a PD de Carla na árvore didática.	A renda não participa das perguntas dessa árvore. Dentro da folha a previsão é constante.
Gradient boosting	Somar as folhas do boosting em pontos percentuais.	As contribuições somam no escore F. A logística é aplicada uma única vez, no fim.
Gradient boosting	Repetir a mesma correção em cada iteração.	Depois de cada árvore os gradientes são recalculados. A segunda correção do grupo B cai de 0,200000 para 0,166078.
Gradient boosting	Ler contribuição positiva do histórico como efeito causal.	A contribuição explica a função aprendida com registros históricos, não o efeito de mudar o cadastro.
Avaliação e decisão	Comparar AUCs de modelos que usaram informação diferente.	Mesmo alvo, mesma informação e teste preservado são condições da comparação.
Avaliação e decisão	Tomar AUC boa como prova de probabilidades corretas.	Multiplicar as odds por 2 não altera a AUC e piora Brier e log loss. Calibração é verificação à parte.
Avaliação e decisão	Ler a taxa de falsos positivos da ROC como inadimplência da carteira aprovada.	A inadimplência entre aprovados depende do corte e é medida na partição de política, faixa a faixa.
Avaliação e decisão	Julgar a qualidade do modelo no dia seguinte à implantação.	Composição, ausência e aprovação aparecem no dia seguinte. Inadimplência, calibração e discriminação só depois de 12 meses.

Lista de verificação de saída do aluno

O que o guia do aluno pede que ele consiga fazer ao fim da aula.

- ☐ Enunciar o alvo da aula com evento, horizonte, população e unidade, e explicar por que duas PDs com definições diferentes não se comparam.
- ☐ Classificar uma informação como disponível na decisão ou informação do futuro pela data de disponibilidade.
- ☐ Calcular a PD de Bruno em duas etapas, a partir dos coeficientes e do perfil de referência, e refazer a conta para um comprometimento de 48%.
- ☐ Converter probabilidade em odds e em log odds, nos dois sentidos, e explicar por que uma razão de chances de 1,49 não é risco 49% maior.
- ☐ Percorrer a árvore didática com qualquer um dos quatro clientes e calcular a PD da folha a partir das contagens.
- ☐ Calcular o ganho de Gini de uma divisão e dizer por que o histórico venceu o comprometimento na raiz.
- ☐ Refazer as duas iterações da miniatura de boosting e converter o escore final em PD uma única vez.
- ☐ Explicar por que taxa de aprendizagem, número de árvores e parada precisam ser escolhidos juntos e na validação.
- ☐ Distinguir discriminação de calibração e dizer o que muda quando as odds são multiplicadas por 2.
- ☐ Derivar o ponto de equilíbrio de 20% a partir das hipóteses econômicas e defender um corte para o comitê.

Glossário

PD

Probabilidade de inadimplência: chance estimada de o evento definido ocorrer no horizonte definido. Deve ser lida como frequência esperada em exposições semelhantes, não como destino de um cliente.

Evento e horizonte

Nesta aula, atraso superior a 90 dias em qualquer momento dos 12 meses seguintes à contratação. Atingir exatamente 90 dias não conta.

Escore z

Soma do intercepto com as contribuições de cada característica, na escala do log odds. Pode ser qualquer número real.

Odds

Razão entre a probabilidade do evento e a do não evento: p dividido por $(1 - p)$. PD de 10% corresponde a odds de 1 para 9, ou 0,1111.

Log odds

Logaritmo natural das odds. É a escala em que o logit soma as contribuições.

Curva logística (sigmoide)

Função que converte qualquer escore em probabilidade entre 0% e 100%: p igual a 1 dividido por $(1 + e^{-z})$.

Razão de chances

Multiplicador das odds quando uma característica muda: e elevado ao coeficiente vezes a variação. Não é a variação da PD.

Log loss (perda logarítmica)

Perda de uma observação: menos o logaritmo da probabilidade atribuída ao que de fato ocorreu. O ajuste minimiza a média das perdas.

Regularização

Penalidade sobre o tamanho dos coeficientes, controlada por C . Força maior (C menor) encolhe coeficientes e reduz a sensibilidade ao ruído do treino.

Raiz, nó, ramo e folha

Raiz é a primeira pergunta; nó é qualquer pergunta; ramo é a resposta que leva adiante; folha é o grupo final, onde a previsão é atribuída.

Impureza de Gini

G igual a $2p(1 - p)$ para dois desfechos: zero quando o grupo é puro, máximo de 0,5 quando a taxa é 50%. A divisão escolhida é a de menor impureza ponderada.

Intervalo de Wilson

Intervalo binomial descritivo para a taxa de uma folha. Mesma taxa com menos contratos produz intervalo mais largo.

Poda por complexidade

Remoção de divisões cujo ganho não compensa o custo de complexidade, escolhido pela validação.

Resíduo (gradiente negativo)

Para a perda logística, y menos p : diferença entre o observado e a probabilidade atual. É o que a próxima árvore do boosting aprende.

Taxa de aprendizagem (η)

Fração da contribuição de cada árvore que entra no escore. Taxa menor exige mais árvores e costuma generalizar melhor.

Parada com paciência

Regra que interrompe o treino quando a validação não melhora além de uma tolerância por certo número de iterações. Definida antes de olhar o teste.

Importância por permutação

Queda da AUC quando os valores de uma variável são embaralhados. Mede uso global, não efeito causal.

Contribuição local

Quanto cada característica desloca o escore de um cliente em relação à referência. Explica a função aprendida, não identifica causa.

AUC

Probabilidade de um inadimplente receber escore maior que um adimplente escolhido ao acaso. Mede ordenação, não escala.

KS

Maior distância entre as distribuições acumuladas dos escores de inadimplentes e adimplentes.

Calibração

Compatibilidade entre PD prevista e frequência observada, faixa a faixa. Brier e log loss medem qualidade probabilística; a AUC não a captura.

Corte de aprovação

PD máxima aceita na política. Define taxa de aprovação e inadimplência entre aprovados, e é decidido na partição de política, antes do teste.

Ponto de equilíbrio

PD em que o resultado esperado por operação é zero: margem dividida por LGD vezes EAD. Com as hipóteses da aula, 20%.

Maturação do alvo

Os 12 meses que precisam passar depois da contratação para o desfecho existir. Indicadores de qualidade só aparecem depois dela.