

LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2 · VERSÃO DO ALUNO

05

CAPÍTULO 5 DE 11 · INFOGRÁFICO DE ABERTURA

Árvores de decisão

Como perguntas sucessivas dividem a população em grupos de risco?

1 · PERGUNTAS SUCESSIVAS CRIAM REGIÕES DE RISCO (BASE DIDÁTICA DE 16 PROPOSTAS)

1. Raiz

16 propostas, 8 defaults: metade a metade, Gini 0,500, impureza máxima. É o ponto de partida.

2. Corte vencedor

Utilização ≤ 57,5%: redução de Gini de 0,281, a maior entre todos os candidatos. Lado sim: 8 casos, 1 default. Lado não: 8 casos, 7 defaults.

3. Recursão

Cada lado recomeça a busca só com os casos que chegaram até ele. No lado esquerdo, utilização ≤ 27,5% dá ganho local de 0,094.

4. Folha

A previsão é a frequência da folha: 1 default em 2 propostas é PD de 50%, com intervalo de 95% de 9,5% a 90,5%.

2 · TRÊS NÚMEROS QUE A ÁRVORE COMPARA

0,500

Gini da raiz
Impureza máxima: o grupo está meio a meio.
Zero quando todos têm o mesmo desfecho.

0,281

redução do melhor corte
Ganho ponderado pelo tamanho dos dois filhos; o maior ganho permitido vence.

12,5% e 87,5%

taxas após a raiz
Uma única divisão já separa dois grupos com risco muito diferente.

Ganho = Gini(pai) – média ponderada dos Gini(filhos)

Na raiz desta base: 0,500 – 0,21875 = 0,281.

3 · ONDE A ÁRVORE ERRA, E COMO SE CONTROLA

Folhas pequenas, intervalos largos

Intervalo de 95% da taxa de cada folha:

2 casos, 1 default	50%: de 9,5% a 90,5%
6 casos, 0 default	0%: de 0% a 39,0%
6 casos, 6 defaults	100%: de 61,0% a 100%

Os intervalos se sobrepõem: a árvore não sustenta a decisão

Poda: um preço por folha (α = 0,030)

Custo = impureza + α × folhas:

Só a raiz	0,530
Profund. 1	0,279
Profund. 2	0,245

Crescer primeiro, cortar depois: a árvore de profundidade 2 vence a este preço.

Os freios e a instabilidade

- Profundidade máxima limita quantas perguntas se pode fazer.
- Mínimo de casos por folha limita quão pequeno um grupo pode ficar.
- Quando dois cortes têm ganhos próximos, retirar uma observação pode trocar a raiz: a árvore parece outro modelo.

TRÊS IDEIAS PARA LEVAR

Corte

O que vence a disputa por um nó? O corte que mais reduz a impureza, ponderado pelo tamanho dos filhos.

Folha

O que a folha prevê? A frequência observada nela, com o intervalo que o tamanho permite.

Controle

O que segura o sobreajuste? Profundidade, mínimo por folha e poda com preço por folha.

Prof. Genaro Dueire Lins · FGV · Edição 2026 · material derivado da plataforma decisaoedecredito.com · os números do material são reconstruções didáticas ou exemplos sintéticos, salvo indicação de fonte.

05

CAPÍTULO 5 DE 11 · AULA 2: ENTENDER AS TRÊS TÉCNICAS

Árvores de decisão

Como perguntas sucessivas dividem a população em grupos de risco?

O QUE VOCÊ APRENDE

Nó, regra, ramo, folha, profundidade, critério de impureza, escolha da divisão por busca, previsão na folha, incerteza da folha, complexidade e poda.

A ATIVIDADE

Calcular o ganho de dois cortes candidatos e escolher a divisão da raiz.

POR QUE IMPORTA

Como separar clientes em grupos com comportamentos diferentes usando perguntas simples?


ANTES DE COMEÇAR

Capítulo 2, em especial variabilidade e generalização.

Onde isto é usado depois. É o bloco de construção do capítulo 6.

A ideia central

Uma árvore faz perguntas sucessivas sobre as variáveis e divide a população em grupos cada vez mais homogêneos em relação ao evento. Em cada nó ela testa todos os cortes possíveis e escolhe o que mais reduz a impureza (Gini ou entropia) dos filhos; a previsão de uma folha é a taxa de default observada nela. A árvore captura interações e limiares sem que ninguém os declare, e é fácil de explicar caso a caso (basta seguir o caminho). O preço é a variância: folhas pequenas têm taxas instáveis (o intervalo de Wilson mostra quanto), e árvores profundas decoram a amostra. Profundidade, folha mínima e poda são os freios; a validação temporal diz se estão bem calibrados.



À esquerda, a busca pelo corte que mais reduz a impureza. À direita, a incerteza da taxa de uma folha com 20% de default conforme o número de casos: com 20 casos o intervalo vai de 8% a 42%.

COMO USAR ESTE MATERIAL

- Cada página traz a captura da plataforma e o texto **Como ler esta página**: o que o visual mostra, como ler e o que levar. Na plataforma os visuais são interativos; mova os controles descritos no texto.
- As 6 páginas essenciais são as vistas em aula; as complementares aprofundam no seu estudo. **Para discutir em aula** é a pergunta que o professor vai fazer.
- Responda às questões antes de abrir a plataforma: lá, cada resposta recebe o diagnóstico. O fecho lista o que você deve conseguir explicar.

O FIO DA AULA 2: ENTENDER AS TRÊS TÉCNICAS

As mesmas 16 propostas atravessam os três capítulos, cada uma com utilização, atraso e desfecho observado. Cada capítulo parte do caso que o anterior deixou em aberto, e a aula termina com as três PDs lado a lado.

Capítulo	A pergunta	Como termina
Capítulo 4 Regressão logística	Como características viram probabilidade?	Nenhuma reta separa a #15, que pagou, da #2, que deu default. O capítulo 5 troca a soma por perguntas sucessivas, nas mesmas 16 propostas.
Capítulo 5 Árvores de decisão VOCÊ ESTÁ AQUI	Como perguntas sucessivas dividem a população em grupos de risco?	A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.
Capítulo 6 Gradient boosting com árvores	Como uma sequência de árvores melhora uma previsão?	Aula 3, capítulo 7: como escolher entre modelos fora da amostra.

Mapa do capítulo

#	Página	O que ela entrega	min
1	Árvores de decisão	Ler uma previsão como o caminho da raiz até uma folha.	4
2	Perguntas em sequência fazem o que a soma não faz	O efeito de uma variável passa a depender das outras, sem termo de interação.	8
3	Anatomia da árvore	Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa.	8
4	Impureza: o quanto o grupo está misturado	Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.	8
5	Impureza na raiz	O Gini de um grupo, contado à mão.	9
6	Avaliar um corte candidato	O ganho é a impureza que o corte remove, ponderada pelo tamanho de cada lado.	10
7	A disputa pela raiz	Vence o corte de maior ganho, não o que parece melhor no desenho.	10
8	A raiz escolhida, e o que ela já resolve	Um corte já separa a base em 12,5% e 87,5% de default.	8
9	Recursão: a busca recomeça em cada lado	Cada nó resolve o seu problema só com os casos que chegaram até ele.	9
10	Uma proposta dentro da árvore	A folha dá uma taxa; o tamanho da folha diz quanto ela vale.	9
11	Percorrer a árvore	O caminho da raiz à folha é a explicação completa da decisão.	9
12	A previsão da folha é a frequência da folha	É o valor que minimiza a log loss no grupo, como no capítulo 2.	9
13	Quanto cada folha afirma	Folhas pequenas produzem intervalos largos demais para decidir.	10

#	Página	O que ela entrega	min
14	Os dois freios da árvore	Profundidade limita as perguntas; o mínimo por folha limita o tamanho do grupo.	10
15	Poda: crescer e depois cortar	Cada folha tem um preço; a poda pesa impureza contra número de folhas.	9
16	Instabilidade: uma proposta pode trocar a estrutura	Com ganhos empatados, tirar um caso muda a variável escolhida.	8
17	Gini ou entropia: a conclusão não muda	Trocar a medida de impureza raramente muda a árvore.	8
18	Logística e árvore nos mesmos casos	Uma fronteira suave contra regiões em degraus, proposta a proposta.	10
19	Síntese: regras locais e controle de variância	Partição por busca gulosa, previsão por frequência e complexidade sob controle.	9

Páginas em cinza são complementares: aprofundam no estudo e não entram no tempo de aula (6 essenciais, 49 min).

5.1 Árvores de decisão

essencial, vista em aula · 4 min

Ler uma previsão como o caminho da raiz até uma folha.

05

O DESAFIO DESTE CAPÍTULO

Uma sequência de perguntas pode criar regiões de risco.

Cortes sucessivos formam grupos homogêneos; cada folha entrega a sua taxa.

Corte


- 1 Cada pergunta compete por redução de impureza.

Caminho

Uma proposta percorre regras até uma folha.

Freio

- 3 Profundidade, folha mínima e poda controlam variância.



A raiz pergunta: utilização até 57,5%? É o corte que mais separa quem pagou de quem deu default.

Página 5.1, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A abertura tem duas metades. À esquerda, o desafio do capítulo, uma sequência de perguntas pode criar regiões de risco, e as três etapas: corte, caminho e freio. À direita, a árvore das 16 propostas, com duas perguntas e quatro folhas. Clique em cada etapa e veja a parte da árvore que ela acende. Corte: a regra da raiz, utilização até 57,5%, o corte que mais separa quem pagou de quem deu default.

Caminho: a #15, com 90% de utilização e sem atraso, responde não e não e cai numa folha de duas propostas, com PD de 50%. Freio: cada nível a mais faz folhas menores e menos confiáveis, e por isso a profundidade precisa de limite. A árvore responde à limitação que fechou o capítulo 4, a soma que não captura interação, e é o bloco de construção do capítulo 6. Guarde a pergunta do capítulo: como perguntas sucessivas dividem a população em grupos de risco?

PARA DISCUTIR EM AULA

Quem já usou árvore em produção? Para quê?


A SEGUIR Começamos pela limitação que motivou a mudança de família.

5.2

Perguntas em sequência fazem o que a soma não faz

complementar, de estudo · 8 min

O efeito de uma variável passa a depender das outras, sem termo de interação.



Página 5.2, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

As mesmas dezesseis propostas em dois planos, na mesma escala. À esquerda, a logística do capítulo 4: uma reta de PD 50%, o mesmo efeito de cada variável em todo o plano. Do lado errado ficam quatro propostas, com anel dourado: a #2 e a #10, que deram default abaixo da reta, e a #5 e a #15, que pagaram acima dela. Deslocar a reta troca quem erra, e o mínimo são três erros. À direita, a árvore do capítulo: três cortes em utilização criam quatro regiões, cada uma com a sua taxa. Duas são puras, 0% e 100%; as outras duas ficam em 50%, e nelas estão a #2 e a #15, com uma vizinha cada. Embaixo, o balanço. A árvore ganha interação sem escrever o termo, efeito que sobe e desce sem transformar a variável e regra legível, que vira política. Perde suavidade, porque a PD salta na fronteira, e estabilidade, porque uma proposta a menos pode mudar um corte. Pergunte-se quantos cortes a mais isolariam a #15 e o que sobraria na folha.

PARA PENSAR NO ESTUDO

Quantos cortes a mais a árvore precisaria para isolar a #15?

A SEGUIR Para construir a árvore, primeiro os nomes das partes.

5.3 Anatomia da árvore

essencial, vista em aula · 8 min

Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa.

ANATOMIA DA ÁRVORE · 16 PROPOSTAS · DUAS DIVISÕES · O DIAGRAMA USADO EM TODO O CAPÍTULO

Cinco palavras, e cada uma tem lugar no desenho. A profundidade conta divisões, não nós.

Nó

Regra

Ramo

Folha

Profundidade

Nó: um grupo de propostas. A raiz é o nó que contém todas as 16.

A árvore de profundidade 2 cada caixa traz quantas propostas chegaram ali, quantas deram default e a taxa




AS CINCO PALAVRAS

NÓ	um grupo de propostas. A raiz é o nó que contém todas as 16.
REGRA	a pergunta que divide o nó. Sempre da forma variável menor ou igual a valor.
RAMO	cada uma das duas saídas da regra. Sempre duas, nesta construção.
FOLHA	nó que não é mais dividido. É onde a previsão é produzida.
PROFUNDIDADE	número de regras entre a raiz e a folha. Esta árvore tem profundidade 2.

QUANTAS FOLHAS UMA PROFUNDIDADE PERMITE

profundidade máxima d3 → até 8 folhas



Profundidade d permite até 2 elevado a d folhas: 3 dá 8; 10 dá 1.024. Por isso a profundidade é o principal freio.

DUAS PROPRIEDADES QUE DECORREM DA FORMA

Toda proposta cai em exatamente uma folha: sem sobreposição e sem buraco. E o caminho até a folha explica a previsão inteira, linha a linha.

Página 5.3, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · PROFUNDIDADE CONTA O QUÊ

Nesta árvore uma proposta atravessa três caixas da raiz até a folha. Qual é a profundidade da árvore?

a. 3, porque são três caixas no caminho

b. 2, porque profundidade conta as regras aplicadas, e a folha não faz pergunta

c. 4, porque a árvore tem quatro folhas

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

Prof. Genaro Dueire Lins · FGV · 2026

7 de 28

COMO LER ESTA PÁGINA

A árvore de duas divisões que serve a todo o capítulo, com cada elemento aceso ao toque dos cinco botões: nó, regra, ramo, folha, profundidade. A raiz pergunta se a utilização é menor ou igual a 57,5%. À esquerda, a pergunta seguinte é 27,5%, e as folhas têm 2 propostas com 1 default (50%) e 6 com 0 (0%). À direita, 87,5%, com folhas de 6 propostas e 6 defaults (100%) e 2 com 1 (50%). São 7 nós, 3 regras, 6 ramos e 4 folhas, que somam 16 propostas e 8 defaults, sem sobreposição e sem buraco. Profundidade conta regras entre a raiz e a folha: esta árvore tem profundidade 2. O controle de profundidade máxima d , de 1 a 10, mostra quantas folhas ela permite: 2 elevado a d , então 8 em profundidade 3 e 1.024 em profundidade 10. Duas propriedades decorrem da forma: toda proposta cai em exatamente uma folha, e o caminho até ela é a explicação completa da previsão.

O QUE ESTÁ NA TELA

Clique em cada termo e veja a parte correspondente acesa.

PARA DISCUTIR EM AULA

Qual é a profundidade desta árvore, e quantas caixas um caso atravessa da raiz até a folha?

A SEGUIR Falta o critério que escolhe a regra de cada nó.

5.4 Impureza: o quanto o grupo está misturado

essencial, vista em aula · 8 min

Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.



Página 5.4, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · O QUE O GINI MEDE**

Um grupo tem 10% de defaults e outro tem 90%. Como os dois se comparam em Gini?

- O grupo de 10% tem Gini muito menor, porque o risco dele é menor
- Os dois têm exatamente o mesmo Gini, 0,18, porque a medida é simétrica e mede mistura, não nível de risco
- O grupo de 90% tem Gini 0,90, porque a impureza acompanha a proporção de defaults

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Duas medidas de mistura, fórmulas no alto: $Gini(p) = 2p(1 - p)$ e a entropia $H(p) = -p \log_2 p - (1 - p) \log_2(1 - p)$, em bits, onde p é a proporção de defaults no grupo. À esquerda, as curvas zeram em 0% e em 100% e chegam ao máximo em 50%, Gini 0,5 e entropia 1 bit, como na raiz desta base. Em 10% e em 90%, Gini 0,18 e entropia 0,469: as medidas são simétricas. Ao centro, o quadrado ensina a ler o Gini: sorteie uma proposta e dê a ela um rótulo sorteado na mesma proporção; as células em vinho são os erros e, somadas, dão $2p(1 - p)$, o próprio Gini. A linha pontilhada é a taxa de erro do nó, $\min(p, 1 - p)$, o erro de prever a maioria. Em 10%, ela vale 10%, contra 18% do Gini. Reta por partes, ela pode não acusar uma divisão que purifica: no 2º nível desta base, o Gini ponderado cai de 0,21875 para 0,12500 e os erros seguem 2 em 16. Baixa impureza significa homogeneidade, não risco baixo.

O QUE ESTÁ NA TELA

Mova a proporção de defaults e compare Gini, entropia e taxa de erro do nó.

PARA DISCUTIR EM AULA

Um grupo com 90% de defaults é puro?

A SEGUIR Com a medida definida, dá para pontuar um corte.

5.5

Impureza na raiz

complementar, de estudo · 9 min

O GINI DA RAIZ, CALCULADO À MÃO · A REFERÊNCIA CONTRA A QUAL TODO GANHO SERÁ MEDIDO

Uma conta de duas linhas sobre as dezesseis propostas. Ela é a referência do capítulo inteiro.

raiz

folha pura

folha mista

A raiz: as 16 propostas: 8 defaults em 16 propostas, $p = 0,5000$, $Gini = 2 \times 0,500 \times 0,500 = 0,50000$. Metade default, metade não default: máxima mistura.

O grupo D marca default, ✓ marca quem pagou

D

D

D

D

D

D

D

D

✓

✓

✓

✓

✓

✓

✓

✓

8 D e 8 ✓ · $p = 8 \div 16 = 0,5000$

$Gini = 2 \times p \times (1 - p) = 0,50000$

PROPOSTAS NO GRUPO	16
DEFAULTS	8
PROPORÇÃO P	$8 \div 16 = 0,5000$
GINI = $2 \times P \times (1 - P)$	$2 \times 0,500 \times 0,500 = 0,50000$

$Gini(t) = 2 \times p(t) \times (1 - p(t))$

0,5 é o máximo com alvo binário: a base foi montada meio a meio de propósito. Com 10% de default, o Gini da raiz seria 0,1800.

#	UTIL.	ATRASSO	DEFAULT?
1	20%	25 d	não
2	25%	20 d	sim
3	30%	5 d	não
4	35%	10 d	não
5	40%	20 d	não
6	45%	0 d	não
7	50%	0 d	não
8	55%	5 d	não
9	60%	20 d	sim
10	65%	0 d	sim
11	70%	5 d	sim
12	75%	40 d	sim
13	80%	5 d	sim
14	85%	30 d	sim
15	90%	0 d	não
16	95%	20 d	sim

Confira: conte os sim na última coluna.

O QUE SIGNIFICA REDUZIR A IMPUREZA

Um corte reduz a impureza quando os dois grupos ficam menos misturados que o original. O ganho mede essa redução, pesando cada grupo pelo tamanho.

Página 5.5, como aparece na plataforma, onde é interativa.

Prof. Genaro Dueire Lins · FGV · 2026

9 de 28

COMO LER ESTA PÁGINA

Três botões: raiz, folha pura e folha mista. Na raiz, as 16 propostas em caixas, D para default e ✓ para quem pagou: 8 D e 8 ✓, $p = 8 \div 16 = 0,5$, $Gini = 2 \times 0,5 \times 0,5 = 0,50000$, a mistura máxima. A folha pura, utilização entre 27,5% e 57,5%, tem 0 defaults em 6 e Gini zero: uma divisão ali não teria o que reduzir. A folha mista, utilização acima de 87,5%, tem 1 default em 2 e Gini 0,5 de novo, mas com peso 2 em 16. A tabela da direita lista as dezesseis propostas com utilização, atraso e desfecho; confira contando os sim na última coluna. Reduzir a impureza é produzir dois grupos mais homogêneos que o original; o ganho é a diferença entre a impureza antes e a média ponderada das impurezas depois, ponderada pelo tamanho. Esta base foi construída meio a meio de propósito; em carteira real com 10% de default, o Gini da raiz seria 0,18.

O QUE ESTÁ NA TELA

Compare a raiz, uma folha pura e uma folha mista.

PARA PENSAR NO ESTUDO

O Gini da raiz depende de quais variáveis existem?

A SEGUIR Agora, um corte candidato avaliado com essa referência.

5.6 Avaliar um corte candidato

complementar, de estudo · 10 min

O ganho é a impureza que o corte remove, ponderada pelo tamanho de cada lado.

AVALIAR UM CORTE CANDIDATO · 16 PROPOSTAS · GINI ANTES 0,50000

Um corte vale pela redução da impureza que produz, ponderada pelo tamanho dos dois grupos.

Utilização do limite


Maior atraso em 6 meses

Utilização do limite $\leq 62,5\%$: esquerda com 9 propostas e 2 defaults (Gini 0,34568), direita com 7 e 6 (Gini 0,24490); média ponderada 0,30159 e ganho 0,19841.

Ponto de corte

62,5% · candidato 9 de 15

As 16 propostas sobre a régua de utilização do limite o corte é o ponto médio entre dois valores vizinhos



LADO ESQUERDO: UTILIZAÇÃO DO LIMITE $\leq 62,5\%$

9 propostas · 2 defaults · proporção 22,2% · Gini 0,34568

#1, #2, #3, #4, #5, #6, #7, #8, #9

LADO DIREITO: UTILIZAÇÃO DO LIMITE $> 62,5\%$

7 propostas · 6 defaults · proporção 85,7% · Gini 0,24490

#10, #11, #12, #13, #14, #15, #16

A CONTA DO GANHO

GINI ANTES	0,50000
MÉDIA PONDERADA DEPOIS	$9 \div 16 \times 0,3457 + 7 \div 16 \times 0,2449 = 0,30159$
GANHO	0,19841

Ganho positivo, mas existe corte melhor. A próxima página varre todos.

$$\text{ganho} = \text{Gini}(\text{antes}) - [n_{\text{esq}} \div n \times \text{Gini}(\text{esq}) + n_{\text{dir}} \div n \times \text{Gini}(\text{dir})]$$

antes		0,5000
esquerda		0,3457
direita		0,2449
depois, ponderada		0,3016

Os candidatos são os pontos médios entre valores vizinhos: qualquer valor entre dois vizinhos dá a mesma divisão.

Página 5.6, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · GANHO DE UMA DIVISÃO**

Um corte deixa uma única proposta de um lado, com Gini zero, e quinze do outro, com sete defaults. Esse corte tem ganho alto?

- Sim, porque um dos lados ficou completamente puro
- Não, porque a média das impurezas é ponderada pelo tamanho e o lado puro pesa apenas um de dezesseis
- Não é possível avaliar sem conhecer o Gini da raiz

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Escolha a variável, utilização do limite ou maior atraso em 6 meses, e mova o ponto de corte: o controle percorre apenas os pontos médios entre valores consecutivos observados, porque qualquer valor entre dois vizinhos produz a mesma divisão. No exemplo, utilização $\leq 62,5\%$. Lado esquerdo: 9 propostas, 2 defaults, proporção 22,2%, Gini 0,34568 (#1 a #9). Lado direito: 7 propostas, 6 defaults, 85,7%, Gini 0,24490 (#10 a #16). A conta do ganho: Gini antes 0,50000; média ponderada depois, $9 \div 16 \times 0,3457 + 7 \div 16 \times 0,2449 = 0,30159$; ganho 0,19841. Positivo, mas existe corte melhor: utilização $\leq 57,5\%$, com 0,28125. As barras comparam antes, esquerda, direita e depois ponderada. Antes de responder à questão, mova o corte para o primeiro candidato, que deixa uma só proposta de um lado, e observe o que a ponderação pelo tamanho faz com um lado perfeitamente puro.

O QUE ESTÁ NA TELA

Escolha a variável e mova o corte: as contas aparecem na hora.

PARA PENSAR NO ESTUDO

Existe corte com ganho negativo?


A SEGUIR Testar um por um é o que o algoritmo faz, e depressa.

5.7

A disputa pela raiz

essencial, vista em aula · 10 min

Vence o corte de maior ganho, não o que parece melhor no desenho.



Página 5.7, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · AS DUAS MARGENS DA RAIZ

Na raiz, utilização <= 57,5% vence com ganho 0,28125. O corte vizinho, utilização <= 52,5%, fica em 0,19841, e o melhor corte de atraso fica em 0,07143. O que essas duas margens dizem?

a. Que a escolha da variável é estável e a do ponto de corte não: a margem sobre o atraso é de quase quatro vezes, e sobre o corte vizinho é de 1,4 vez

b. Que a árvore deveria usar os dois cortes de utilização na raiz, já que os dois têm ganho alto

c. Que existe um ótimo matemático em 57,5%, encontrado derivando a função de ganho

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As dezesseis propostas no plano utilização por atraso, a árvore ao lado e, embaixo, a disputa: uma barra por corte candidato, azul para utilização e laranja para atraso, com altura igual ao ganho. O vencedor é utilização $\leq 57,5\%$, com redução de Gini de 0,281; ele parte a base em 8 casos com 1 default e 8 casos com 7 defaults. O segundo colocado é o corte vizinho, utilização $\leq 52,5\%$, com 0,198; o melhor corte de atraso fica em 0,071, quase quatro vezes atrás. O bloco de avaliação repete a conta da página anterior para qualquer candidato. O botão Deixar a árvore crescer acrescenta um nível por segundo, até a profundidade 3; profundidade máxima, mínimo por folha e proposta retirada são o assunto das páginas 14 e 16. O perfil irregular das barras diz o essencial: não há fórmula fechada nem gradiente; a árvore avalia todos os candidatos e fica com o maior ganho. Leia duas margens. Sobre o atraso, folgada: a variável da raiz é estável. Sobre o vizinho, apertada: o ponto exato do corte depende de poucas propostas.

O QUE ESTÁ NA TELA

Mova o corte candidato e compare as barras.

PARA DISCUTIR EM AULA

O que acontece se o primeiro e o segundo colocados tiverem ganhos quase iguais?

A SEGUIR O vencedor vira a raiz.

5.8 A raiz escolhida, e o que ela já resolve

complementar, de estudo · 8 min

Um corte já separa a base em 12,5% e 87,5% de default.

UTILIZAÇÃO $\leq 57,5\%$

12,5%

1 default em 8 propostas

#1, #2, #3, #4, #5, #6, #7, #8

UTILIZAÇÃO $> 57,5\%$


87,5%

7 defaults em 8 propostas

#9, #10, #11, #12, #13, #14, #15, #16

O mesmo corte sai do navegador, do gerador em Python e do scikit-learn com profundidade 1.

atraso, dias



A #2 deu default no grupo bom; a #15 pagou no grupo ruim. Um corte só não dá conta delas.

Página 5.8, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A raiz em utilização $\leq 57,5\%$ e os seus dois lados. À esquerda, os grupos: até 57,5%, as propostas #1 a #8, com 1 default em 8, taxa de 12,5%; acima, as #9 a #16, com 7 defaults em 8, taxa de 87,5%. O mesmo corte sai do núcleo do navegador, do gerador em Python e do scikit-learn com profundidade 1. À direita, o plano com o corte e duas propostas de anel dourado: a #2 deu default no grupo bom e a #15 pagou no grupo ruim. Um corte só não dá conta delas, e a tentação é continuar dividindo até dar, o que o capítulo 2 já mostrou aonde leva. Uma única divisão levou a taxa de 50% para 12,5% e 87,5%. Para ordenar, isso é muito bom. Para decidir, falta saber quanto se pode confiar em cada taxa: a de 12,5% se apoia em oito propostas, e a página 13 calcula o intervalo. O que sobra em cada lado é o problema seguinte.

O QUE ESTÁ NA TELA

Duas propostas ficam do lado errado: a #2 e a #15.

PARA PENSAR NO ESTUDO

Uma divisão que leva a taxa de 50% para 12,5% e 87,5% é boa?

A SEGUIR Dentro de cada lado, a mesma pergunta de novo.

5.9

Recursão: a busca recomeça em cada lado

complementar, de estudo · 9 min

Cada nó resolve o seu problema só com os casos que chegaram até ele.

RECURSÃO · A BUSCA DO NÍVEL 2 · 8 PROPOSTAS DE CADA VEZ · NADA DE NOVO

Depois da primeira divisão, cada lado vira um problema independente, com a mesma busca exaustiva.


lado esquerdo

lado direito

Nó esquerdo, utilização ≤ 57,5%: 8 propostas e 1 default, Gini 0,21875. Vence utilização ≤ 27,5% com ganho local 0,09375, novas folhas com 2 e 6 casos. A busca recomeça somente com os casos deste nó.

NÓ ESQUERDO: UTILIZAÇÃO ≤ 57,5%


Gini deste nó 0,21875, com 1 default em 8 propostas



VARIÁVEL	CORTE	ESQ / DIR	GANHO
UTILIZAÇÃO	27,5	2 / 6	0,09375
UTILIZAÇÃO	32,5	3 / 5	0,05208
ATRASSO	15,0	5 / 3	0,05208
UTILIZAÇÃO	37,5	4 / 4	0,03125

NÓ DIREITO: UTILIZAÇÃO > 57,5%

Gini deste nó 0,21875, com 7 defaults em 8 propostas



VARIÁVEL	CORTE	ESQ / DIR	GANHO
UTILIZAÇÃO	87,5	6 / 2	0,09375
ATRASSO	2,5	2 / 6	0,09375
UTILIZAÇÃO	82,5	5 / 3	0,05208
UTILIZAÇÃO	77,5	4 / 4	0,03125

DUAS PROPRIEDADES DA RECURSÃO

A variável da raiz pode voltar com outro corte, como nos dois lados desta base. E cada lado escolhe sem olhar o outro: a busca é local, nó a nó.

O CUSTO DE SER LOCAL

A árvore é gulosa: fica com o melhor corte agora, sem testar se um corte pior abriria cortes melhores depois. Nada garante a melhor árvore possível.

Página 5.9, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois painéis, um por lado da raiz, com botões para alternar. Cada um mostra o plano com os oito casos do nó, os quatro melhores candidatos e o corte escolhido. Nó esquerdo, utilização $\leq 57,5\%$: 1 default em 8, Gini 0,21875; vence utilização $\leq 27,5\%$, com ganho local 0,09375 e novas folhas de 2 e 6 casos. Nó direito, utilização $> 57,5\%$: 7 defaults em 8, Gini 0,21875; utilização $\leq 87,5\%$ e atraso $\leq 2,5$ dias empatam em 0,09375, e a ordem de avaliação decide pela utilização. Recursão significa repetir a mesma pergunta: qual corte reduz mais a mistura aqui dentro? A busca recomeça somente com os casos deste nó. Duas propriedades: a variável da raiz pode ser escolhida de novo, como acontece nos dois lados; e a melhor divisão de um lado é escolhida sem consideração sobre o outro. O custo de ser local: a árvore é gulosa, escolhe o melhor corte agora sem verificar se um corte pior permitiria dois muito melhores depois.

O QUE ESTÁ NA TELA

Alterne os dois lados e veja a mesma varredura dar regras diferentes.

PARA PENSAR NO ESTUDO

A árvore encontrada é a melhor árvore de profundidade 2 possível?


A SEGUIR Feita a recursão, a árvore está completa.

5.10 Uma proposta dentro da árvore

essencial, vista em aula · 9 min

A folha dá uma taxa; o tamanho da folha diz quanto ela vale.


O caminho da #15 90% de utilização, sem atraso, pagou

**A FOLHA DA #15**

50%

1 default em 2 propostas

Na folha estão a #15, que pagou, e a #16, que deu default.



Intervalo de 95%: 9,5% a 90,5%, **81 pontos** de largura.

utilização $\leq 57,5\%$? **não** → utilização $\leq 87,5\%$? **não**

Taxa sem o tamanho da folha não é informação: com 2 propostas, a folha não separa um grupo excelente de um péssimo.

Página 5.10, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · O QUE A FOLHA AUTORIZA**

A proposta #15 chega a uma folha com duas propostas, uma delas em default. O que essa folha autoriza a afirmar?

- Que a #15 deu default, já que caiu numa folha de risco 50%
- Que a taxa observada daquele grupo é 50%, com intervalo de 9,5% a 90,5%: com duas propostas a folha não distingue um grupo excelente de um péssimo
- Que o risco do grupo é 50%, e esse é o melhor número disponível para decidir

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A proposta #15 da base de 16: utilização de 90%, sem atraso, e pagou. À esquerda, a árvore com o caminho dela aceso: utilização até 57,5%? Não, ramo direito. Até 87,5%? Não, folha extrema. À direita, a folha: 1 default em 2 propostas, taxa de 50%. Antes de ler adiante, pergunte-se por que a taxa é 50%. A folha tem duas propostas: a #15, que pagou, e a #16, que deu default; a taxa é a contagem dos rótulos, 1 em 2. Ela resume o grupo e não diz nada sobre o desfecho individual: a #15 pagou e recebe 50%. Agora o tamanho. O intervalo de 95% vai de 9,5% a 90,5%, 81 pontos de largura: com duas propostas, a folha não separa um grupo excelente de um péssimo. Taxa sem o tamanho da folha não é informação. O caminho é auditável, mas a estimativa é instável; profundidade, folha mínima e validação continuam necessárias.

PARA DISCUTIR EM AULA

A proposta #15 deu default? E o que esta folha autoriza a afirmar sobre o risco do grupo?

A SEGUIR *A taxa da folha explica a árvore; falta testar se ela generaliza.*

5.11

Percorrer a árvore

complementar, de estudo · 9 min

O caminho da raiz à folha é a explicação completa da decisão.

PERCORRER A ÁRVORE · A EXPLICAÇÃO COMPLETA DE UMA DECISÃO · REGRA POR REGRA

O caminho da raiz até a folha é a justificativa integral da previsão, e qualquer pessoa consegue ler.

#3

#8

proposta nova

#16

Utilização 72% e atraso 8 dias:

Utilização do limite ≤ 57,5%? não; Utilização do limite ≤ 87,5%? sim. Folha com 6 de 6: PD 100,0%. A logística do capítulo 4 estima 69,3% para a mesma proposta.

Utilização do limite

72%

O caminho aceso

as caixas atravessadas ficam em destaque

Maior atraso em 6 meses

8 dias

PASSO	PERGUNTA	VALOR	RESPOSTA	VAI PARA
1	Utilização do limite ≤ 57,5%?	72,0%	não	nó com 8 propostas
2	Utilização do limite ≤ 87,5%?	72,0%	sim	nó com 6 propostas

PD DA FOLHA

100,0%

BASE DA FOLHA

6 / 6

defaults observados sobre propostas

Onde a proposta cai

as quatro regiões da árvore e o ponto

Página 5.11, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois controles, utilização (10% a 100%) e atraso (0 a 45 dias), e quatro atalhos: #3, #8, proposta nova e #16. Para a proposta nova, utilização 72% e atraso 8 dias, a tabela de passos escreve a decisão de cada bifurcação. Passo 1: utilização ≤ 57,5%? Valor 72,0, não, vai para o nó com 8 propostas. Passo 2: utilização ≤ 87,5%? Sim, vai para o nó com 6 propostas. PD da folha 100,0%, base da folha 6 de 6 defaults. O diagrama acende as caixas atravessadas. A logística do capítulo 4 estima 69,3% para a mesma proposta: as duas famílias discordam, e o capítulo 7 define o critério para escolher. Mova o atraso e note que, neste caminho, ele nem é consultado; só a utilização decide. A árvore dá o mesmo valor a todos da folha; a logística varia continuamente, e perto das fronteiras a discordância é máxima. O caminho é a justificativa integral da previsão, legível por qualquer pessoa.

O QUE ESTÁ NA TELA

Mova os valores e siga o caminho aceso, regra por regra.

PARA PENSAR NO ESTUDO

Por que a árvore e a logística discordam nesta proposta?

A SEGUIR A folha devolve uma taxa. De onde vem essa taxa?

5.12 A previsão da folha é a frequência da folha

complementar, de estudo · 9 min


É o valor que minimiza a log loss no grupo, como no capítulo 2.

UMA FOLHA: 1 DEFAULT EM 2 PROPOSTAS

VALOR ATRIBUÍDO	PERDA MÉDIA
10,0%	1,20397
25,0%	0,83699
50,0%	0,69315
75,0%	0,83699
90,0%	1,20397

O mínimo está na frequência observada:
 $1 \div 2 = 50,0\%$. Não foi escolhido: foi calculado.

Log loss média na folha, por valor atribuído



É a mesma conta da PD constante do capítulo 2 e do ponto de partida do boosting, no capítulo 6.

No treino, a folha fica calibrada por construção; fora do tempo, só o capítulo 7 diz.

Folha pura devolve 0% ou 100%: afirma uma certeza que não tem.

Página 5.12, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Uma folha desta árvore, com 1 default em 2 propostas, e cinco candidatos a valor da folha. À esquerda, a tabela: atribuir 10% custa perda média de 1,20397; 25%, 0,83699; 50%, 0,69315; 75%, 0,83699; 90%, 1,20397. À direita, a curva inteira, com o mínimo marcado em 50,0%. O mínimo está exatamente na frequência observada, $1 \div 2 = 50\%$: não foi escolhido, foi calculado. Embaixo, três consequências. É a mesma conta da PD constante do capítulo 2 e do ponto de partida do boosting, no capítulo 6. No treino, a folha fica calibrada por construção, porque devolve a frequência observada; fora do tempo, só o capítulo 7 diz. E a folha pura devolve 0% ou 100%, uma certeza que não tem: previsão de 0% sobre um default tem perda infinita, e as implementações aplicam um piso.

PARA PENSAR NO ESTUDO


Por que a curva sobe tão rápido perto de zero?

A SEGUIR Quanto uma folha realmente afirma?

5.13 Quanto cada folha afirma

complementar, de estudo · 10 min

Folhas pequenas produzem intervalos largos demais para decidir.



Página 5.13, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O QUE A FOLHA AFIRMA
Uma folha tem zero defaults em seis propostas. Qual afirmação se sustenta?

- a. O risco desse grupo é zero, porque nenhuma proposta deu default
- b. A estimativa pontual é 0% e o intervalo de 95% vai até 39,0%, então o nível de risco não está determinado
- c. Como o intervalo desta folha não encosta no da folha de 100%, está provado que as duas têm risco diferente

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As quatro folhas da árvore, com o intervalo de Wilson a 95%. À esquerda, a tabela: folha 1, 2 propostas, 1 default, PD de 50%, intervalo de 9,5% a 90,5%; folha 2, 6 propostas, nenhum default, 0%, de 0% a 39,0%; folha 3, 6 propostas, 6 defaults, 100%, de 61,0% a 100%; folha 4, igual à primeira. À direita, as mesmas folhas em barras. Compare a largura de cada barra com a distância entre elas: as folhas de 50% se sobrepõem a todas as outras, e só a de 0% e a de 100% ficam afastadas. As folhas de 50% têm 81 pontos de largura: quase não afirmam nada. Com 600 propostas e nenhum default, o intervalo seria de 0% a 0,6%: o mesmo número de PD, com evidência incomparável. O tamanho mínimo de folha existe por isso. Sobreposição, porém, não é teste de diferença; o teste está no capítulo 7. Antes da questão sobre a folha de zero defaults, olhe o limite superior do intervalo dela.

PARA PENSAR NO ESTUDO

A folha de 0% prova que aquele grupo não dá default?

A SEGUIR Se folhas pequenas não afirmam nada, é preciso impedir que elas apareçam.

5.14

Os dois freios da árvore

complementar, de estudo · 10 min

Profundidade limita as perguntas; o mínimo por folha limita o tamanho do grupo.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Ajuste os dois freios e veja a árvore obedecer.

Plano das variáveis 4 folhas · clique numa proposta para retirá-la

● deu default

● pagou

○ retirada da base

Deixar a árvore crescer

Árvore de referência

A árvore 4 folhas · profundidade 2

Profundidade máxima 2

Mínimo de propostas por folha 2

Proposta retirada da base nenhuma, base completa

RAIZ ESCOLHIDA
utilização ≤ 57,5%
ganho 0,28125

DIVISÃO DO NÓ DIREITO
utilização ≤ 87,5%
ganho 0,09375

FOLHAS · ERROS NAS 16
4 · 2
menor folha com 2 propostas

PIOR INTERVALO DE FOLHA
81%
largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato os candidatos são os pontos médios entre valores consecutivos

Utilização do limite

Maior atraso em 6 meses

Ponto de corte utilização ≤ 62,5%

LADO	PROPOSTAS	DEFAULTS	PROPORÇÃO	GINI
≤ CORTE	9	2	22,2%	0,34568
> CORTE	7	6	85,7%	0,24490
GANHO	0,50000 − (9 ÷ 16 × 0,3457 + 7 ÷ 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125			

A disputa: ganho de cada candidato vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 52,5% com 0,198

Prof. Genaro Dueire Lins · FGV · 2026

20 de 28

COMO LER ESTA PÁGINA

Dois controles, profundidade máxima (0 a 4) e mínimo de propostas por folha (1 a 4), e quatro contadores: raiz escolhida, divisão do nó direito, folhas e erros nas 16, com a menor folha embaixo, e pior intervalo de folha. Com profundidade 2 e mínimo 2: 4 folhas, 2 erros, menor folha com 2 propostas e pior intervalo com 81% de largura. Nenhuma folha unitária; o erro na amostra não é zero, e isso não é defeito. A árvore ao lado e a partição no plano são reconstruídas a cada movimento. Os dois freios agem por caminhos diferentes: a profundidade impede perguntas adicionais mesmo quando o grupo é grande; o mínimo por folha impede grupos pequenos mesmo quando ainda há profundidade disponível. Leia a menor folha e o pior intervalo, não o erro: o erro na amostra sempre cai com complexidade. Fixe o mínimo em 1 e suba a profundidade até 4; depois mantenha 4 e suba o mínimo. Os dois caminhos levam a árvores diferentes. Os dois são hiperparâmetros, e a escolha é na validação, como no capítulo 2.

O QUE ESTÁ NA TELA

Mova os dois controles e olhe a menor folha, não o erro.

PARA PENSAR NO ESTUDO

Qual dos dois freios você usaria em uma carteira de 200 mil propostas?

A SEGUIR Há uma terceira forma de controlar a complexidade, depois de construir.

5.15 Poda: crescer e depois cortar

complementar, de estudo · 9 min

Cada folha tem um preço; a poda pesa impureza contra número de folhas.

PODA · CRESCER PRIMEIRO, CORTAR DEPOIS · UM PREÇO POR FOLHA · QUATRO ÁRVORES DA MESMA BASE

Mova o preço da folha e veja qual árvore vence. A de quatro folhas nunca vence, para nenhum α .

$\alpha = 0,00$

$\alpha = 0,03$

$\alpha = 0,10$

$\alpha = 0,30$

$\alpha = 0,030$: vence profundidade 3, folhas de 1, com custo 0,18000. Pontos de troca: $\alpha = 0,0547$ entre seis e duas folhas, e $\alpha = 0,2813$ entre duas folhas e a raiz. A árvore de quatro folhas não vence em nenhum ponto.

Preço de cada folha, α

0,030

ÁRVORE	FOLHAS	IMPUREZA	$\alpha \times$ FOLHAS	CUSTO
● SÓ A RAIZ	1	0,50000	0,03000	0,53000
● PROFUNDIDADE 1	2	0,21875	0,06000	0,27875
● PROFUNDIDADE 2	4	0,12500	0,12000	0,24500
● PROFUNDIDADE 3, FOLHAS DE 1	6	0,00000	0,18000	0,18000

$\text{custo}(T) = \text{impureza ponderada de } T + \alpha \times \text{número de folhas de } T$

Com α zero, vence a árvore mais complexa; com α alto, só a raiz. Entre os extremos, a poda percorre uma sequência de árvores.

Custo de cada árvore em função de α a vencedora é a linha mais baixa em cada ponto

custo total

α , preço de cada folha

troca em 0,0547

troca em 0,2813

UM RESULTADO QUE SURPREENDE

Aqui a árvore de quatro folhas nunca vence: a poda salta de seis folhas para duas, porque o último nível rende pouco perto do penúltimo. Por isso se poda pelo elo mais fraco, e não testando profundidades.

Na prática, α sai da validação cruzada; escolhido no treino, repete o problema do capítulo 2.

Página 5.15, como aparece na plataforma, onde é interativa.

Prof. Genaro Dueire Lins · FGV · 2026

21 de 28

COMO LER ESTA PÁGINA

Quatro árvores da mesma base avaliadas pelo mesmo critério: custo = impureza ponderada + $\alpha \times$ número de folhas. Só a raiz: 1 folha, impureza 0,50000. Profundidade 1: 2 folhas, 0,21875. Profundidade 2: 4 folhas, 0,12500. Profundidade 3 com folhas de 1: 6 folhas, 0,00000. Mova o preço de cada folha, α , de 0 a 0,35, com atalhos em 0, 0,03, 0,10 e 0,30. Com $\alpha = 0,030$ vence a árvore de seis folhas, custo 0,18000. Os pontos de troca são $\alpha = 0,0547$, entre seis e duas folhas, e $\alpha = 0,2813$, entre duas folhas e a raiz. No gráfico, cada árvore é uma reta com inclinação igual ao número de folhas, e vence a linha mais baixa. Um resultado que surpreende: a árvore de quatro folhas nunca vence, para nenhum α ; a poda salta de seis folhas direto para duas, porque a redução de impureza do último nível é desproporcional à do penúltimo. É por isso que a poda é feita por elo mais fraco.

O QUE ESTÁ NA TELA

Mova o preço da folha e veja qual árvore vence.

PARA PENSAR NO ESTUDO

Por que as linhas do gráfico são retas?


A SEGUIR *Falta olhar a estabilidade da estrutura.*

5.16

Instabilidade: uma proposta pode trocar a estrutura

complementar, de estudo · 8 min

Com ganhos empatados, tirar um caso muda a variável escolhida.



Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Retirar uma proposta da base recalcula a raiz, o nó direito e a árvore inteira. Com a base completa, a raiz é utilização $\leq 57,5\%$, ganho 0,28125, e o nó direito é utilização $\leq 87,5\%$, ganho 0,09375: a árvore de referência do capítulo. Percorra a lista e observe os dois contadores: a raiz resiste a qualquer retirada; o nó direito não. Na raiz, o vencedor tem 0,28125, o corte vizinho 0,19841 e o melhor corte de atraso 0,07143; sem a #8 ou a #9, muda o ponto médio, não a divisão. No nó direito, os dois primeiros empatam exatamente em 0,09375, e o empate é decidido pela ordem de avaliação. Retirar a #10 troca a variável do nó de utilização para atraso. Instabilidade de estrutura não é o mesmo que instabilidade de previsão: duas árvores com variáveis diferentes podem produzir PDs parecidas. O que se perde é a leitura, a explicação da decisão que muda de um mês para o outro, com consequência em governança e na comunicação com o cliente. Responda à questão sobre o empate antes de mover o controle.

O QUE ESTÁ NA TELA

Retire uma proposta: a raiz resiste, o nó direito não.

PARA PENSAR NO ESTUDO

Instabilidade de estrutura invalida o modelo?

A SEGUIR Falta comparar as duas famílias com honestidade.

5.17 Gini ou entropia: a conclusão não muda

complementar, de estudo · 8 min

Trocar a medida de impureza raramente muda a árvore.

VARIÁVEL	MELHOR CORTE, GINI	GANHO	MELHOR CORTE, ENTROPIA	GANHO
UTILIZAÇÃO DO LIMITE	57,5	0,28125	57,5	0,45644
MAIOR ATRASO EM 6 MESES	15 ou 27,5	0,07143	27,5	0,13793

Os dois critérios escolhem a mesma raiz. Os ganhos estão em escalas diferentes (a entropia é medida em bits): compare o corte, não o número.

O QUE MAIS MUDA A ÁRVORE

1. A amostra
2. O mínimo de casos por folha
3. A profundidade
4. Muito depois, o critério de impureza

QUANDO O CRITÉRIO IMPORTA

Quase nunca na escolha do corte

Às vezes com alvo de mais de duas classes

Sempre na declaração: o relatório diz qual foi usado

Página 5.17, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A varredura da raiz refeita com entropia, lado a lado com a de Gini. Utilização: melhor corte em 57,5 pelos dois critérios, com ganho de 0,28125 por Gini e 0,45644 por entropia. Atraso: o Gini empata os cortes de 15 e 27,5 dias, em 0,07143, e não escolhe entre eles; a entropia prefere 27,5, com 0,13793. A raiz é a mesma, utilização $\leq 57,5\%$, e vence pelos dois critérios com margem de mais de três vezes. Os ganhos estão em escalas diferentes, porque a entropia é medida em bits; comparar os números entre as colunas não tem significado. O que se compara é o corte escolhido. Ao lado, quando o critério importa: quase nunca na escolha do corte; às vezes com alvo de mais de duas classes; sempre na declaração, porque o relatório precisa dizer qual foi usado. E o que muda a árvore, por impacto: a amostra, o mínimo por folha, a profundidade e, muito depois, o critério.

O QUE ESTÁ NA TELA

A varredura da página 7, refeita com entropia.

PARA PENSAR NO ESTUDO

Por que não comparar os valores de ganho entre os dois critérios?

A SEGUIR A comparação que importa é entre famílias.

5.18

Logística e árvore nos mesmos casos

essencial, vista em aula · 10 min

Uma fronteira suave contra regiões em degraus, proposta a proposta.

ÁRVORE CONTRA LOGÍSTICA · OS MESMOS 16 DADOS · RETA CONTRA ESCADA

As duas famílias erram de maneiras diferentes. A escolha depende do uso, não de superioridade geral.

#5

#10

#15

Proposta #5, utilização 40% e atraso 20 d, y = 0: logística 52,6%, árvore 0%, 52,6 pontos de diferença. A reta logística vê risco moderado; a árvore caiu numa folha sem defaults.

Reta contra escada

linha: PD 50% da logística · regiões: a folha da árvore e sua taxa · clique numa proposta

maior atraso em 6 meses

árvore 50%

árvore 0%

árvore 100%

árvore 50%

LOGÍSTICA

52,6%

soma ponderada, fronteira reta

ÁRVORE

0%

taxa da folha, constante na região

LOG LOSS DA LOGÍSTICA

0,43282

LOG LOSS DA ÁRVORE

0,18844

piso e teto de 2% e 98% nas folhas puras

ESTE NÚMERO NÃO DECIDE NADA

As duas perdas são calculadas na mesma amostra em que os dois modelos foram estimados. O capítulo 2 já mostrou que essa comparação é vazia. Com dezesseis propostas não existe amostra separada possível, e a comparação de verdade acontece no capítulo 7, na base de 5.000, com teste estatístico.

#	UTIL.	ATRASO	Y	LOGÍSTICA	ÁRVORE	DIFERENÇA
#1	20%	25 d	0	33,5%	50%	16,5 pp
#2	25%	20 d	1	26,7%	50%	23,3 pp
#3	30%	5 d	0	6,1%	0%	-6,1 pp
#4	35%	10 d	0	15,9%	0%	-15,9 pp
#5	40%	20 d	0	52,6%	0%	-52,6 pp
#6	45%	0 d	0	9,0%	0%	-9,0 pp
#7	50%	0 d	0	12,6%	0%	-12,6 pp
#8	55%	5 d	0	29,5%	0%	-29,5 pp
#9	60%	20 d	1	83,1%	100%	16,9 pp
#10	65%	0 d	1	30,5%	100%	69,5 pp
#11	70%	5 d	1	56,2%	100%	43,8 pp
#12	75%	40 d	1	99,6%	100%	0,4 pp
#13	80%	5 d	1	73,0%	100%	27,0 pp
#14	85%	30 d	1	99,2%	100%	0,8 pp
#15	90%	0 d	0	73,9%	50%	-23,9 pp
#16	95%	20 d	1	98,5%	50%	-48,5 pp

Linhas em rosa: discordância acima de 35 pontos de PD.

O QUE CADA FAMÍLIA ENTREGA

	LOGÍSTICA	ÁRVORE
FRONTEIRA	reta	escalonada
INTERAÇÃO	só se escrita	automática
PD	contínua	constante por região
EXPLICAÇÃO INDIVIDUAL	contribuições somadas	caminho de regras
ESTABILIDADE	alta	baixa
EXTRAPOLAÇÃO	continua a reta	repete a folha da borda

Página 5.18, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O QUE A PERDA DE TREINO DECIDE

Nas dezesseis propostas, a log loss é 0,43282 na logística e 0,18844 na árvore. O que esse par de números decide?

a. Que a árvore é o melhor modelo nesta base, e por margem larga

b. Nada: as duas foram avaliadas na mesma amostra em que a árvore criou as folhas, e perda de treino desce com qualquer complexidade acrescentada

c. Que a árvore está sobreajustada, e por isso a logística deve ser escolhida

Prof. Genaro Dueire Lins · FGV · 2026

25 de 28

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As dezesseis propostas no plano, com a reta de PD 50% da logística e as quatro regiões da árvore, cada uma com sua taxa. Clique numa proposta ou use os atalhos #5, #10 e #15. A #5, utilização 40% e atraso 20 dias, pagou: logística 52,6%, árvore 0%, 52,6 pontos de diferença; a reta vê risco moderado, a árvore caiu numa folha sem defaults. A #10, 65% e 0 dias, deu default: 30,5% contra 100%. A #15, 90% e 0 dias, pagou: 73,9% contra 50%. A tabela lista as dezesseis linhas, com discordâncias acima de 35 pontos em rosa. As perdas de treino, log loss 0,43282 da logística contra 0,18844 da árvore, com piso e teto de 2% e 98% nas folhas puras, não decidem nada: a árvore foi avaliada na amostra que usou para criar as folhas. A tabela final resume o que cada família entrega: fronteira reta ou escalonada, PD contínua ou constante por região, estabilidade alta ou baixa. A comparação de verdade está no capítulo 7.

O QUE ESTÁ NA TELA

Use #5, #10 e #15 ou clique numa proposta e compare o modo de errar.

PARA DISCUTIR EM AULA

Onde as duas famílias mais discordam?

A SEGUIR Se a árvore é instável e a logística é rígida, existe uma terceira via.

5.19 Síntese: regras locais e controle de variância

complementar, de estudo · 9 min

Partição por busca gulosa, previsão por frequência e complexidade sob controle.

3 IDEIAS PARA LEVAR

A árvore aprende cortes fáceis de explicar e fáceis de sobreajustar.

1. **Corte.** O que vence a disputa por um nó?

| O corte que mais reduz a impureza ponderada.

2. **Folha.** De onde vem a PD?

| Da frequência observada entre os casos que chegaram à folha.

3. **Controle.** O que evita folhas frágeis?

| Profundidade, número mínimo de casos e poda escolhidos fora do treino.

COMO LER ESTA PÁGINA

Três ideias para levar, uma por botão: Corte, Folha e Controle. A frase à esquerda resume: a árvore aprende cortes fáceis de explicar e fáceis de sobreajustar. O Corte que vence a disputa por um nó é o que mais reduz a impureza ponderada. A Folha devolve a frequência observada entre os casos que chegaram a ela, e essa frequência vale junto com o tamanho da folha. O Controle, com profundidade, número mínimo de casos e poda, é escolhido fora do treino. Antes de clicar, escolha uma das três e explique com suas palavras. Depois aplique as três a dois casos da aula. A #10, default com 65% de utilização e sem atraso, cai numa folha de seis defaults e recebe 100%, onde a reta dava 30,5%. A #15 fica numa folha de duas propostas, com 50%. Qual ideia explica cada caso? O capítulo 6 parte dessa tensão: a logística é rígida, a árvore é instável, e a terceira via soma árvores pequenas.

O QUE ESTÁ NA TELA

Explique cada ideia com suas palavras antes de revelar.

PARA PENSAR NO ESTUDO

O que a árvore faz com a #10 e com a #15, e qual ideia explica cada caso?

A SEGUIR A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.

Fecho do capítulo

Antes da próxima aula, você deve conseguir explicar

- **5.1** Ler uma previsão como o caminho da raiz até uma folha.
- **5.3** Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa.
- **5.4** Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.
- **5.7** Vence o corte de maior ganho, não o que parece melhor no desenho.
- **5.10** A folha dá uma taxa; o tamanho da folha diz quanto ela vale.
- **5.18** Uma fronteira suave contra regiões em degraus, proposta a proposta.

Erros comuns: o que se confunde

#	Erro	Confusão por trás
5.2	Concluir que a árvore é superior	Lê flexibilidade como qualidade sem contabilizar o custo.
5.3	Contar profundidade incluindo a folha	Conta nós em vez de regras.
5.4	Confundir impureza baixa com PD baixa	Lê a medida como nível de risco.
5.4	Ler o Gini como a taxa de erro do nó	Toma a chance de errar com rótulo sorteado pelo erro de prever a maioria.
5.5	Achar que Gini 0,5 indica base ruim	Lê impureza máxima como problema.
5.6	Esquecer a ponderação pelo tamanho	Faz a média simples dos dois Ginis.
5.6	Procurar o corte que deixa um lado puro	Persegue pureza em vez de ganho ponderado.
5.7	Achar que a busca é otimização	Imagina que existe gradiente ou fórmula fechada.
5.7	Ignorar a margem	Trata o vencedor como escolha determinada.
5.8	Concluir que o modelo já está pronto	Confunde separação na amostra com capacidade preditiva.
5.9	Achar que cada variável só pode ser usada uma vez	Transfere a intuição de regressão para a árvore.
5.9	Tomar maior ganho no passo por melhor resultado no fim	Confunde ótimo local com ótimo global.
5.10	Ler 100%	Conta dois casos como dois defaults.
5.11	Achar que a árvore usa as duas variáveis sempre	Espera que todo caminho passe por todas as variáveis.
5.12	Achar que o valor da folha é a média das PDs dos clientes	Imagina um modelo dentro da folha.
5.13	Usar sobreposição de intervalos como teste	Trata intervalos individuais como teste de diferença entre grupos.
5.13	Reportar a taxa da folha sem o n	Apresenta estimativa sem evidência.

#	Erro	Confusão por trás
5.14	Otimizar os freios pelo erro na amostra	Usa a amostra de treino para escolher hiperparâmetro.
5.14	Fixar mínimo em número absoluto sem olhar a base	Ignora a proporção que o mínimo representa.
5.15	Escolher α pelo desempenho na amostra de treino	Repete o erro de usar treino para escolher hiperparâmetro.
5.16	Concluir que árvores não servem	Generaliza a partir de uma base de dezesseis.
5.17	Concluir que entropia é melhor por ter ganho maior	Compara valores em escalas distintas.
5.18	Declarar vencedor pela perda de treino	Compara modelos na amostra em que foram estimados.
5.19	Ler os 50% da #15 como risco médio	Toma a frequência de uma folha de duas propostas como estimativa firme.