

## LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2 · VERSÃO DO ALUNO

# 05

## CAPÍTULO 5 DE 11 · INFOGRÁFICO DE ABERTURA

### Árvores de decisão

Como perguntas sucessivas dividem a população em grupos de risco?

#### 1 · PERGUNTAS SUCESSIVAS CRIAM REGIÕES DE RISCO (BASE DIDÁTICA DE 16 PROPOSTAS)

##### 1. Raiz

16 propostas, 8 defaults: metade a metade, Gini 0,500, impureza máxima. É o ponto de partida.

##### 2. Corte vencedor

Utilização  $\leq 57,5\%$ : redução de Gini de 0,281, a maior entre todos os candidatos. Lado sim: 8 casos, 1 default. Lado não: 8 casos, 7 defaults.

##### 3. Recursão

Cada lado recomeça a busca só com os casos que chegaram até ele. No lado esquerdo, utilização  $\leq 27,5\%$  dá ganho local de 0,094.

##### 4. Folha

A previsão é a frequência da folha: 1 default em 2 propostas é PD de 50%, com intervalo de 95% de 9,5% a 90,5%.

#### 2 · TRÊS NÚMEROS QUE A ÁRVORE COMPARA

**0,500**

Gini da raiz  
Impureza máxima: o grupo está meio a meio.  
Zero quando todos têm o mesmo desfecho.

**0,281**

redução do melhor corte  
Ganho ponderado pelo tamanho dos dois filhos; o maior ganho permitido vence.

**12,5% e 87,5%**

taxas após a raiz  
Uma única divisão já separa dois grupos com risco muito diferente.

**Ganho = Gini(pai) – média ponderada dos Gini(filhos)**

Na raiz desta base:  $0,500 - 0,21875 = 0,281$ .

#### 3 · ONDE A ÁRVORE ERRA, E COMO SE CONTROLA

##### Folhas pequenas, intervalos largos

Intervalo de 95% da taxa de cada folha:

|                     |                       |
|---------------------|-----------------------|
| 2 casos, 1 default  | 50%: de 9,5% a 90,5%  |
| 6 casos, 0 default  | 0%: de 0% a 39,0%     |
| 6 casos, 6 defaults | 100%: de 61,0% a 100% |

Os intervalos se sobrepõem: a árvore não sustenta a decisão

##### Poda: um preço por folha ( $\alpha = 0,030$ )

Custo = impureza +  $\alpha \times$  folhas:

|            |       |
|------------|-------|
| Só a raiz  | 0,530 |
| Profund. 1 | 0,279 |
| Profund. 2 | 0,245 |

Crescer primeiro, cortar depois: a árvore de profundidade 2 vence a este preço.

##### Os freios e a instabilidade

- Profundidade máxima limita quantas perguntas se pode fazer.
- Mínimo de casos por folha limita quão pequeno um grupo pode ficar.
- Quando dois cortes têm ganhos próximos, retirar uma observação pode trocar a raiz: a árvore parece outro modelo.

#### TRÊS IDEIAS PARA LEVAR

##### Corte

O que vence a disputa por um nó? O corte que mais reduz a impureza, ponderado pelo tamanho dos filhos.

##### Folha

O que a folha prevê? A frequência observada nela, com o intervalo que o tamanho permite.

##### Controle

O que segura o sobreajuste? Profundidade, mínimo por folha e poda com preço por folha.

Prof. Genaro Dueire Lins · FGV · Edição 2026 · material derivado da plataforma [decisaodecredito.com](https://decisaodecredito.com) · os números do material são reconstruções didáticas ou exemplos sintéticos, salvo indicação de fonte.

## 05

CAPÍTULO 5 DE 11 · AULA 2: ENTENDER AS TRÊS TÉCNICAS

## Árvores de decisão

*Como perguntas sucessivas dividem a população em grupos de risco?*

**O QUE VOCÊ APRENDE**

Nó, regra, ramo, folha, profundidade, critério de impureza, escolha da divisão por busca, previsão na folha, incerteza da folha, complexidade e poda.

**POR QUE IMPORTA**

Como separar clientes em grupos com comportamentos diferentes usando perguntas simples?

**A ATIVIDADE**

Calcular o ganho de dois cortes candidatos e escolher a divisão da raiz.


**ANTES DE COMEÇAR**

Capítulo 2, em especial variabilidade e generalização.

**Onde isto é usado depois.** É o bloco de construção do capítulo 6.

**A ideia central**

Uma árvore faz perguntas sucessivas sobre as variáveis e divide a população em grupos cada vez mais homogêneos em relação ao evento. Em cada nó ela testa todos os cortes possíveis e escolhe o que mais reduz a impureza (Gini ou entropia) dos filhos; a previsão de uma folha é a taxa de default observada nela. A árvore captura interações e limiares sem que ninguém os declare, e é fácil de explicar caso a caso (basta seguir o caminho). O preço é a variância: folhas pequenas têm taxas instáveis (o intervalo de Wilson mostra quanto), e árvores profundas decoram a amostra. Profundidade, folha mínima e poda são os freios; a validação temporal diz se estão bem calibrados.



À esquerda, a busca pelo corte que mais reduz a impureza. À direita, a incerteza da taxa de uma folha com 20% de default conforme o número de casos: com 20 casos o intervalo vai de 8% a 42%.

**COMO USAR ESTE MATERIAL**

- Cada página traz a captura da plataforma e o texto **Como ler esta página**: o que o visual mostra, como ler e o que levar. Na plataforma os visuais são interativos; mova os controles descritos no texto.
- As 6 páginas essenciais são as vistas em aula; as complementares aprofundam no seu estudo. **Para discutir em aula** é a pergunta que o professor vai fazer.
- Responda às questões antes de abrir a plataforma: lá, cada resposta recebe o diagnóstico. O fecho lista o que você deve conseguir explicar.

**O FIO DA AULA 2: ENTENDER AS TRÊS TÉCNICAS**

As mesmas 16 propostas atravessam os três capítulos, cada uma com utilização, atraso e desfecho observado. Cada capítulo parte do caso que o anterior deixou em aberto, e a aula termina com as três PDs lado a lado.

| Capítulo                                                         | A pergunta                                                        | Como termina                                                                                                                                                                    |
|------------------------------------------------------------------|-------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Capítulo 4</b><br>Regressão logística                         | Como características viram probabilidade?                         | Nenhuma reta separa a #15, que pagou, da #2, que deu default. O capítulo 5 troca a soma por perguntas sucessivas, nas mesmas 16 propostas.                                      |
| <b>Capítulo 5</b><br>Árvores de decisão<br><b>VOCÊ ESTÁ AQUI</b> | Como perguntas sucessivas dividem a população em grupos de risco? | A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra. |
| <b>Capítulo 6</b><br>Gradient boosting com árvores               | Como uma sequência de árvores melhora uma previsão?               | Aula 3, capítulo 7: como escolher entre modelos fora da amostra.                                                                                                                |

**Mapa do capítulo**

| #  | Página                                                   | O que ela entrega                                                              | min |
|----|----------------------------------------------------------|--------------------------------------------------------------------------------|-----|
| 1  | <b>Árvores de decisão</b>                                | Ler uma previsão como o caminho da raiz até uma folha.                         | 4   |
| 2  | <b>Perguntas em sequência fazem o que a soma não faz</b> | O efeito de uma variável passa a depender das outras, sem termo de interação.  | 8   |
| 3  | <b>Anatomia da árvore</b>                                | Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa. | 8   |
| 4  | <b>Impureza: o quanto o grupo está misturado</b>         | Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.         | 8   |
| 5  | <b>Impureza na raiz</b>                                  | O Gini de um grupo, contado à mão.                                             | 9   |
| 6  | <b>Avaliar um corte candidato</b>                        | O ganho é a impureza que o corte remove, ponderada pelo tamanho de cada lado.  | 10  |
| 7  | <b>A disputa pela raiz</b>                               | Vence o corte de maior ganho, não o que parece melhor no desenho.              | 10  |
| 8  | <b>A raiz escolhida, e o que ela já resolve</b>          | Um corte já separa a base em 12,5% e 87,5% de default.                         | 8   |
| 9  | <b>Recursão: a busca recomeça em cada lado</b>           | Cada nó resolve o seu problema só com os casos que chegaram até ele.           | 9   |
| 10 | <b>Uma proposta dentro da árvore</b>                     | A folha dá uma taxa; o tamanho da folha diz quanto ela vale.                   | 9   |
| 11 | <b>Percorrer a árvore</b>                                | O caminho da raiz à folha é a explicação completa da decisão.                  | 9   |
| 12 | <b>A previsão da folha é a frequência da folha</b>       | É o valor que minimiza a log loss no grupo, como no capítulo 2.                | 9   |
| 13 | <b>Quanto cada folha afirma</b>                          | Folhas pequenas produzem intervalos largos demais para decidir.                | 10  |

| #  | Página                                                     | O que ela entrega                                                               | min |
|----|------------------------------------------------------------|---------------------------------------------------------------------------------|-----|
| 14 | <b>Os dois freios da árvore</b>                            | Profundidade limita as perguntas; o mínimo por folha limita o tamanho do grupo. | 10  |
| 15 | <b>Poda: crescer e depois cortar</b>                       | Cada folha tem um preço; a poda pesa impureza contra número de folhas.          | 9   |
| 16 | <b>Instabilidade: uma proposta pode trocar a estrutura</b> | Com ganhos empatados, tirar um caso muda a variável escolhida.                  | 8   |
| 17 | <b>Gini ou entropia: a conclusão não muda</b>              | Trocar a medida de impureza raramente muda a árvore.                            | 8   |
| 18 | <b>Logística e árvore nos mesmos casos</b>                 | Uma fronteira suave contra regiões em degraus, proposta a proposta.             | 10  |
| 19 | <b>Síntese: regras locais e controle de variância</b>      | Partição por busca gulosa, previsão por frequência e complexidade sob controle. | 9   |

Páginas em cinza são complementares: aprofundam no estudo e não entram no tempo de aula (6 essenciais, 49 min).

## 5.1 Árvores de decisão

essencial, vista em aula · 4 min

Ler uma previsão como o caminho da raiz até uma folha.

# 05

O DESAFIO DESTE CAPÍTULO

### Uma sequência de perguntas pode criar regiões de risco.

Cortes sucessivos formam grupos homogêneos; cada folha entrega a sua taxa.

#### 1 Corte


Cada pergunta compete por redução de impureza.

#### 2 Caminho

Uma proposta percorre regras até uma folha.

#### 3 Freio

Profundidade, folha mínima e poda controlam variância.



A raiz pergunta: utilização até 57,5%? É o corte que mais separa quem pagou de quem deu default.

Página 5.1, como aparece na plataforma, onde é interativa.

### COMO LER ESTA PÁGINA

A abertura tem duas metades. À esquerda, o desafio do capítulo, uma sequência de perguntas pode criar regiões de risco, e as três etapas: corte, caminho e freio. À direita, a árvore das 16 propostas, com duas perguntas e quatro folhas. Clique em cada etapa e veja a parte da árvore que ela acende. Corte: a regra da raiz, utilização até 57,5%, o corte que mais separa quem pagou de quem deu default.

Caminho: a #15, com 90% de utilização e sem atraso, responde não e não e cai numa folha de duas propostas, com PD de 50%. Freio: cada nível a mais faz folhas menores e menos confiáveis, e por isso a profundidade precisa de limite. A árvore responde à limitação que fechou o capítulo 4, a soma que não captura interação, e é o bloco de construção do capítulo 6. Guarde a pergunta do capítulo: como perguntas sucessivas dividem a população em grupos de risco?

### PARA DISCUTIR EM AULA

Quem já usou árvore em produção? Para quê?


**A SEGUIR** Começamos pela limitação que motivou a mudança de família.

5.2

Perguntas em sequência fazem o que a soma não faz

complementar, de estudo · 8 min

O efeito de uma variável passa a depender das outras, sem termo de interação.



Página 5.2, como aparece na plataforma, onde é interativa.

**COMO LER ESTA PÁGINA**

As mesmas dezesseis propostas em dois planos, na mesma escala. À esquerda, a logística do capítulo 4: uma reta de PD 50%, o mesmo efeito de cada variável em todo o plano. Do lado errado ficam quatro propostas, com anel dourado: a #2 e a #10, que deram default abaixo da reta, e a #5 e a #15, que pagaram acima dela. Deslocar a reta troca quem erra, e o mínimo são três erros. À direita, a árvore do capítulo: três cortes em utilização criam quatro regiões, cada uma com a sua taxa. Duas são puras, 0% e 100%; as outras duas ficam em 50%, e nelas estão a #2 e a #15, com uma vizinha cada. Embaixo, o balanço. A árvore ganha interação sem escrever o termo, efeito que sobe e desce sem transformar a variável e regra legível, que vira política. Perde suavidade, porque a PD salta na fronteira, e estabilidade, porque uma proposta a menos pode mudar um corte. Pergunte-se quantos cortes a mais isolariam a #15 e o que sobraria na folha.

**PARA PENSAR NO ESTUDO**

Quantos cortes a mais a árvore precisaria para isolar a #15?

**A SEGUIR** Para construir a árvore, primeiro os nomes das partes.

5.3

Anatomia da árvore

essencial, vista em aula · 8 min

Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa.

ANATOMIA DA ÁRVORE · 16 PROPOSTAS · DUAS DIVISÕES · O DIAGRAMA USADO EM TODO O CAPÍTULO

Cinco palavras, e cada uma tem lugar no desenho. A profundidade conta divisões, não nós.

Nó

Regra

Ramo

Folha

Profundidade

Nó:

um grupo de propostas. A raiz é o nó que contém todas as 16.

A árvore de profundidade 2

cada caixa traz quantas propostas chegaram ali, quantas deram default e a taxa

utilização ≤ 57,5%?  
16 prop. · 8 def. · PD 50%  
ganho 0,281

sim

utilização ≤ 27,5%?  
8 prop. · 1 def. · PD 13%  
ganho 0,094

não

utilização ≤ 87,5%?  
8 prop. · 7 def. · PD 88%  
ganho 0,094

sim

2 prop. · 1 def.  
PD 50%

não

6 prop. · 0 def.  
PD 0%

sim

6 prop. · 6 def.  
PD 100%

não

2 prop. · 1 def.  
PD 50%

AS CINCO PALAVRAS

NÓ

um grupo de propostas. A raiz é o nó que contém todas as 16.

REGRA

a pergunta que divide o nó. Sempre da forma variável menor ou igual a valor.

RAMO

cada uma das duas saídas da regra. Sempre duas, nesta construção.

FOLHA

nó que não é mais dividido. É onde a previsão é produzida.

PROFUNDIDADE

número de regras entre a raiz e a folha. Esta árvore tem profundidade 2.

QUANTAS FOLHAS UMA PROFUNDIDADE PERMITE

profundidade máxima  $d$

3 → até 8 folhas

1

2

3

4

5

6

7

8

9

10

Profundidade  $d$  permite até  $2^d$  folhas: 3 dá 8; 10 dá 1.024. Por isso a profundidade é o principal freio.

DUAS PROPRIEDADES QUE DECORREM DA FORMA

Toda proposta cai em exatamente uma folha: sem sobreposição e sem buraco. E o caminho até a folha explica a previsão inteira, linha a linha.

Página 5.3, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · PROFUNDIDADE CONTA O QUÊ

Nesta árvore uma proposta atravessa três caixas da raiz até a folha. Qual é a profundidade da árvore?

a. 3, porque são três caixas no caminho

b. 2, porque profundidade conta as regras aplicadas, e a folha não faz pergunta

c. 4, porque a árvore tem quatro folhas

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

Prof. Genaro Dueire Lins · FGV · 2026

7 de 28

**COMO LER ESTA PÁGINA**

A árvore de duas divisões que serve a todo o capítulo, com cada elemento aceso ao toque dos cinco botões: nó, regra, ramo, folha, profundidade. A raiz pergunta se a utilização é menor ou igual a 57,5%. À esquerda, a pergunta seguinte é 27,5%, e as folhas têm 2 propostas com 1 default (50%) e 6 com 0 (0%). À direita, 87,5%, com folhas de 6 propostas e 6 defaults (100%) e 2 com 1 (50%). São 7 nós, 3 regras, 6 ramos e 4 folhas, que somam 16 propostas e 8 defaults, sem sobreposição e sem buraco. Profundidade conta regras entre a raiz e a folha: esta árvore tem profundidade 2. O controle de profundidade máxima  $d$ , de 1 a 10, mostra quantas folhas ela permite: 2 elevado a  $d$ , então 8 em profundidade 3 e 1.024 em profundidade 10. Duas propriedades decorrem da forma: toda proposta cai em exatamente uma folha, e o caminho até ela é a explicação completa da previsão.

**O QUE ESTÁ NA TELA**

Clique em cada termo e veja a parte correspondente acesa.

**PARA DISCUTIR EM AULA**


Qual é a profundidade desta árvore, e quantas caixas um caso atravessa da raiz até a folha?

**A SEGUIR** Falta o critério que escolhe a regra de cada nó.

**5.4 Impureza: o quanto o grupo está misturado**

essencial, vista em aula · 8 min

*Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.*



Página 5.4, como aparece na plataforma, onde é interativa.

**ANTES DE LER A EXPLICAÇÃO, RESPONDA****QUESTÃO · O QUE O GINI MEDE**

**Um grupo tem 10% de defaults e outro tem 90%. Como os dois se comparam em Gini?**

- O grupo de 10% tem Gini muito menor, porque o risco dele é menor
- Os dois têm exatamente o mesmo Gini, 0,18, porque a medida é simétrica e mede mistura, não nível de risco
- O grupo de 90% tem Gini 0,90, porque a impureza acompanha a proporção de defaults

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.



**COMO LER ESTA PÁGINA**

Duas medidas de mistura, fórmulas no alto:  $Gini(p) = 2p(1 - p)$  e a entropia  $H(p) = -p \log_2 p - (1 - p) \log_2(1 - p)$ , em bits, onde  $p$  é a proporção de defaults no grupo. À esquerda, as curvas zeram em 0% e em 100% e chegam ao máximo em 50%, Gini 0,5 e entropia 1 bit, como na raiz desta base. Em 10% e em 90%, Gini 0,18 e entropia 0,469: as medidas são simétricas. Ao centro, o quadrado ensina a ler o Gini: sorteie uma proposta e dê a ela um rótulo sorteado na mesma proporção; as células em vinho são os erros e, somadas, dão  $2p(1 - p)$ , o próprio Gini. A linha pontilhada é a taxa de erro do nó,  $\min(p, 1 - p)$ , o erro de prever a maioria. Em 10%, ela vale 10%, contra 18% do Gini. Reta por partes, ela pode não acusar uma divisão que purifica: no 2º nível desta base, o Gini ponderado cai de 0,21875 para 0,12500 e os erros seguem 2 em 16. Baixa impureza significa homogeneidade, não risco baixo.

**O QUE ESTÁ NA TELA**

Mova a proporção de defaults e compare Gini, entropia e taxa de erro do nó.

**PARA DISCUTIR EM AULA**

Um grupo com 90% de defaults é puro?

**A SEGUIR** Com a medida definida, dá para pontuar um corte.

**5.5 Impureza na raiz**

complementar, de estudo · 9 min

*O Gini de um grupo, contado à mão.*

AULA 2 · CAPÍTULO 5 · ÁRVORES DE DECISÃO

05 / 19

## Impureza na raiz

O Gini de um grupo, contado à mão na base das 16 propostas.

**PROPORÇÃO DE DEFAULTS**  
 $p = \text{defaults} / \text{propostas}$

**GINI**  
 $Gini = 1 - p^2 - (1 - p)^2 = 2p(1 - p)$

**A base: as 16 propostas**

| #  | Utilização, % | Atraso, dias | Default |
|----|---------------|--------------|---------|
| 1  | 20            | 25           | não     |
| 2  | 25            | 20           | sim     |
| 3  | 30            | 5            | não     |
| 4  | 35            | 10           | não     |
| 5  | 40            | 20           | não     |
| 6  | 45            | 0            | não     |
| 7  | 50            | 0            | não     |
| 8  | 55            | 5            | não     |
| 9  | 60            | 20           | sim     |
| 10 | 65            | 0            | sim     |
| 11 | 70            | 5            | sim     |
| 12 | 75            | 40           | sim     |
| 13 | 80            | 5            | sim     |
| 14 | 85            | 30           | sim     |
| 15 | 90            | 0            | não     |
| 16 | 95            | 20           | sim     |

**A conta do grupo**  
As 16 propostas da base

Default 8 2 9 10 11 12 13 14 16

Pagou 8 1 3 4 5 6 7 8 15

$p = \frac{8}{16} = 0,5000$

$Gini = 2 \times 0,5000 \times 0,5000 = 0,50000$

Confira na tabela: conte os sim nas linhas acesas.

**Escolha o grupo**

☒ Raiz ☐ Folha pura ☐ Folha mista

Propostas **16**

Defaults **8**

Gini **0,50000**

Metade default, metade não: a mistura máxima.

**A referência**  
A raiz tem 8 defaults em 16: Gini 0,5, o máximo com alvo binário. Todo ganho parte daqui.

**Folha pura**  
0 default em 6: Gini zero, nada a reduzir.

**O tamanho conta**  
A folha mista tem o 0,5 da raiz com 2 propostas: pesa 2 em 16, o que a próxima página usa.

A seguir: um corte avaliado contra essa referência

Página 5.5, como aparece na plataforma, onde é interativa.

**COMO LER ESTA PÁGINA**

Três grupos à escolha no painel: a raiz e duas folhas da árvore de profundidade 2. A tabela à esquerda é a base das 16 propostas, com utilização, atraso e desfecho; as linhas do grupo escolhido ficam acesas. Ao centro, as propostas do grupo em duas fileiras, default e pagou, e a conta em duas linhas. Na raiz, 8 defaults em 16:  $p = 8 \div 16 = 0,5$  e  $Gini = 2 \times 0,5 \times 0,5 = 0,50000$ , a mistura máxima. A folha pura, utilização entre 27,5% e 57,5% (#3 a #8), tem 0 default em 6 e Gini zero: não há o que reduzir. A folha mista, utilização acima de 87,5% (#15 e #16), tem 1 default em 2 e Gini 0,5 de novo, mas pesa 2 em 16, e esse peso é o que a próxima página usa. Confira sempre na tabela, contando os sim nas linhas acesas. Esta base foi montada meio a meio de propósito; em carteira real com 10% de default, o Gini da raiz seria 0,18.

**O QUE ESTÁ NA TELA**

Compare a raiz, uma folha pura e uma folha mista.

**PARA PENSAR NO ESTUDO**

O Gini da raiz depende de quais variáveis existem?

**A SEGUIR** Agora, um corte candidato avaliado com essa referência.

**5.6 Avaliar um corte candidato**

complementar, de estudo · 10 min

*O ganho é a impureza que o corte remove, ponderada pelo tamanho de cada lado.*

AULA 2 · CAPÍTULO 5 · ÁRVORES DE DECISÃO

06 / 19

## Avaliar um corte candidato

O ganho é a impureza que o corte remove, ponderada pelo tamanho de cada lado.

**GANHO DE UM CORTE**

$$\text{ganho} = Gini_{\text{antes}} - \left( \frac{n_e}{n} Gini_e + \frac{n_d}{n} Gini_d \right)$$

**GINI DE CADA GRUPO**

$$Gini = 2p(1-p)$$

**Onde cortar?**

Em ordem de utilização, em %

|     |    |   |
|-----|----|---|
| #1  | 20 | ✓ |
| #2  | 25 | D |
| #3  | 30 | ✓ |
| #4  | 35 | ✓ |
| #5  | 40 | ✓ |
| #6  | 45 | ✓ |
| #7  | 50 | ✓ |
| #8  | 55 | ✓ |
| #9  | 60 | D |
| #10 | 65 | D |
| #11 | 70 | D |
| #12 | 75 | D |
| #13 | 80 | D |
| #14 | 85 | D |
| #15 | 90 | ✓ |
| #16 | 95 | D |

corte ≤ 62,5%

**A conta, passo a passo**

1 · antes do corte

**Raiz**

16 propostas · 8 D

Gini 0,50000

peso 9/16      peso 7/16

2 · cada lado

**e: ≤ 62,5%**

9 propostas · 2 D

Gini 0,34568

**d: > 62,5%**

7 propostas · 6 D

Gini 0,24490

3 · ponderada  $\frac{9}{16} \times 0,34568 + \frac{7}{16} \times 0,24490 = 0,30159$

4 · ganho  $0,50000 - 0,30159 = 0,19841$

**Mova o corte**

Utilização    Atraso

Ir para 22,5% 27,5% 57,5% 62,5%

Corte: ≤ 62,5% · candidato 9 de 15

Ganho **0,19841**

Ganho positivo, mas há corte melhor: a próxima página testa todos.

Comparar com a média simples

Restaurar exemplo

**Pesa o tamanho**

Em 22,5%, o lado puro tem 1 proposta, peso 1/16: ganho de só 0,03333.

A seguir: a disputa pela raiz · e, d: lados do corte

**Ganho zero**

Em 27,5%, os dois lados seguem meio a meio: o corte não informa nada.

**O melhor da raiz**

Utilização ≤ 57,5%, ganho 0,28125. A próxima página confere os 21 candidatos.

Página 5.6, como aparece na plataforma, onde é interativa.

**ANTES DE LER A EXPLICAÇÃO, RESPONDA****QUESTÃO · GANHO DE UMA DIVISÃO**

**Um corte deixa uma única proposta de um lado, com Gini zero, e quinze do outro, com oito defaults. Esse corte tem ganho alto?**

- Sim, porque um dos lados ficou completamente puro
- Não, porque a média das impurezas é ponderada pelo tamanho e o lado puro pesa apenas um de dezesseis
- Não é possível avaliar sem conhecer o Gini da raiz

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

**COMO LER ESTA PÁGINA**

Escolha a variável no painel, utilização ou atraso, e o corte: pelos atalhos, pelo controle ou clicando nas marcas da lista. A lista à esquerda põe as 16 propostas em ordem da variável; cada marca entre dois valores diferentes é um candidato, o ponto médio dos vizinhos, e dentro de um empate não há marca, porque nenhum corte separa valores iguais. Ao centro, a conta em quatro passos. No exemplo, utilização  $\leq 62,5\%$ : antes, a raiz com Gini 0,50000; cada lado, 9 propostas com 2 defaults e Gini 0,34568, e 7 com 6 e Gini 0,24490; a média ponderada,  $9/16 \times 0,34568 + 7/16 \times 0,24490 = 0,30159$ ; e o ganho,  $0,50000 - 0,30159 = 0,19841$ . Positivo, mas o melhor corte da raiz é utilização  $\leq 57,5\%$ , com 0,28125. Antes de responder à questão, vá a 22,5%, que deixa uma só proposta de um lado, e ligue Comparar com a média simples para ver o que a ponderação pelo tamanho faz com um lado perfeitamente puro.

**O QUE ESTÁ NA TELA**

Escolha a variável e mova o corte: as contas aparecem na hora.

**PARA PENSAR NO ESTUDO**

Existe corte com ganho negativo?


**A SEGUIR** Testar um por um é o que o algoritmo faz, e depressa.

5.7

A disputa pela raiz

essencial, vista em aula · 10 min

Vence o corte de maior ganho, não o que parece melhor no desenho.



Página 5.7, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · AS DUAS MARGENS DA RAIZ

Na raiz, utilização ≤ 57,5% vence com ganho 0,28125. O corte vizinho, utilização ≤ 52,5%, fica em 0,19841, e o melhor corte de atraso fica em 0,07143. O que essas duas margens dizem?

a. Que a escolha da variável é estável e a do ponto de corte não: a margem sobre o atraso é de quase quatro vezes, e sobre o corte vizinho é de 1,4 vez

b. Que a árvore deveria usar os dois cortes de utilização na raiz, já que os dois têm ganho alto

c. Que existe um ótimo matemático em 57,5%, encontrado derivando a função de ganho

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

### COMO LER ESTA PÁGINA

As dezesseis propostas no plano utilização por atraso, a árvore ao lado e, embaixo, a disputa: uma barra por corte candidato, azul para utilização e laranja para atraso, com altura igual ao ganho. O vencedor é utilização  $\leq 57,5\%$ , com redução de Gini de 0,281; ele parte a base em 8 casos com 1 default e 8 casos com 7 defaults. O segundo colocado é o corte vizinho, utilização  $\leq 52,5\%$ , com 0,198; o melhor corte de atraso fica em 0,071, quase quatro vezes atrás. O bloco de avaliação repete a conta da página anterior para qualquer candidato. O botão Deixar a árvore crescer acrescenta um nível por segundo, até a profundidade 3; profundidade máxima, mínimo por folha e proposta retirada são o assunto das páginas 14 e 16. O perfil irregular das barras diz o essencial: não há fórmula fechada nem gradiente; a árvore avalia todos os candidatos e fica com o maior ganho. Leia duas margens. Sobre o atraso, folgada: a variável da raiz é estável. Sobre o vizinho, apertada: o ponto exato do corte depende de poucas propostas.

### O QUE ESTÁ NA TELA

Mova o corte candidato e compare as barras.

### PARA DISCUTIR EM AULA

O que acontece se o primeiro e o segundo colocados tiverem ganhos quase iguais?

**A SEGUIR** O vencedor vira a raiz.

## 5.8 A raiz escolhida, e o que ela já resolve

complementar, de estudo · 8 min

Um corte já separa a base em 12,5% e 87,5% de default.

UTILIZAÇÃO  $\leq 57,5\%$

**12,5%**

1 default em 8 propostas

#1, #2, #3, #4, #5, #6, #7, #8

UTILIZAÇÃO  $> 57,5\%$


**87,5%**

7 defaults em 8 propostas

#9, #10, #11, #12, #13, #14, #15, #16

O mesmo corte sai do navegador, do gerador em Python e do scikit-learn com profundidade 1.

atraso, dias



A #2 deu default no grupo bom; a #15 pagou no grupo ruim. Um corte só não dá conta delas.

Página 5.8, como aparece na plataforma, onde é interativa.

### COMO LER ESTA PÁGINA

A raiz em utilização  $\leq 57,5\%$  e os seus dois lados. À esquerda, os grupos: até 57,5%, as propostas #1 a #8, com 1 default em 8, taxa de 12,5%; acima, as #9 a #16, com 7 defaults em 8, taxa de 87,5%. O mesmo corte sai do núcleo do navegador, do gerador em Python e do scikit-learn com profundidade 1. À direita, o plano com o corte e duas propostas de anel dourado: a #2 deu default no grupo bom e a #15 pagou no grupo ruim. Um corte só não dá conta delas, e a tentação é continuar dividindo até dar, o que o capítulo 2 já mostrou aonde leva. Uma única divisão levou a taxa de 50% para 12,5% e 87,5%. Para ordenar, isso é muito bom. Para decidir, falta saber quanto se pode confiar em cada taxa: a de 12,5% se apoia em oito propostas, e a página 13 calcula o intervalo. O que sobra em cada lado é o problema seguinte.

O QUE ESTÁ NA TELA

Duas propostas ficam do lado errado: a #2 e a #15.

PARA PENSAR NO ESTUDO

Uma divisão que leva a taxa de 50% para 12,5% e 87,5% é boa?

A SEGUIR Dentro de cada lado, a mesma pergunta de novo.

5.9

Recursão: a busca recomeça em cada lado

complementar, de estudo · 9 min

Cada nó resolve o seu problema só com os casos que chegaram até ele.

RECURSÃO · A BUSCA DO NÍVEL 2 · 8 PROPOSTAS DE CADA VEZ · NADA DE NOVO

Depois da primeira divisão, cada lado vira um problema independente, com a mesma busca exaustiva.

lado esquerdo


lado direito

Nó esquerdo, utilização ≤ 57,5%: 8 propostas e 1 default, Gini 0,21875. Vence utilização ≤ 27,5% com ganho local 0,09375, novas folhas com 2 e 6 casos. A busca recomeça somente com os casos deste nó.

NÓ ESQUERDO: UTILIZAÇÃO ≤ 57,5%

Gini deste nó 0,21875, com 1 default em 8 propostas

utilização ≤ 27,5% · ganho 0,094




| VARIÁVEL   | CORTE | ESQ / DIR | GANHO   |
|------------|-------|-----------|---------|
| UTILIZAÇÃO | 27,5  | 2 / 6     | 0,09375 |
| UTILIZAÇÃO | 32,5  | 3 / 5     | 0,05208 |
| ATRASSO    | 15,0  | 5 / 3     | 0,05208 |
| UTILIZAÇÃO | 37,5  | 4 / 4     | 0,03125 |

NÓ DIREITO: UTILIZAÇÃO > 57,5%

Gini deste nó 0,21875, com 7 defaults em 8 propostas

utilização ≤ 87,5% · ganho 0,094



| VARIÁVEL   | CORTE | ESQ / DIR | GANHO   |
|------------|-------|-----------|---------|
| UTILIZAÇÃO | 87,5  | 6 / 2     | 0,09375 |
| ATRASSO    | 2,5   | 2 / 6     | 0,09375 |
| UTILIZAÇÃO | 82,5  | 5 / 3     | 0,05208 |
| UTILIZAÇÃO | 77,5  | 4 / 4     | 0,03125 |

DUAS PROPRIEDADES DA RECURSÃO

A variável da raiz pode voltar com outro corte, como nos dois lados desta base. E cada lado escolhe sem olhar o outro: a busca é local, nó a nó.

O CUSTO DE SER LOCAL

A árvore é gulosa: fica com o melhor corte agora, sem testar se um corte pior abriria cortes melhores depois. Nada garante a melhor árvore possível.

Página 5.9, como aparece na plataforma, onde é interativa.

**COMO LER ESTA PÁGINA**

Dois painéis, um por lado da raiz, com botões para alternar. Cada um mostra o plano com os oito casos do nó, os quatro melhores candidatos e o corte escolhido. Nó esquerdo, utilização  $\leq 57,5\%$ : 1 default em 8, Gini 0,21875; vence utilização  $\leq 27,5\%$ , com ganho local 0,09375 e novas folhas de 2 e 6 casos. Nó direito, utilização  $> 57,5\%$ : 7 defaults em 8, Gini 0,21875; utilização  $\leq 87,5\%$  e atraso  $\leq 2,5$  dias empatam em 0,09375, e a ordem de avaliação decide pela utilização. Recursão significa repetir a mesma pergunta: qual corte reduz mais a mistura aqui dentro? A busca recomeça somente com os casos deste nó. Duas propriedades: a variável da raiz pode ser escolhida de novo, como acontece nos dois lados; e a melhor divisão de um lado é escolhida sem consideração sobre o outro. O custo de ser local: a árvore é gulosa, escolhe o melhor corte agora sem verificar se um corte pior permitiria dois muito melhores depois.

**O QUE ESTÁ NA TELA**

Alterne os dois lados e veja a mesma varredura dar regras diferentes.

**PARA PENSAR NO ESTUDO**

A árvore encontrada é a melhor árvore de profundidade 2 possível?


**A SEGUIR** Feita a recursão, a árvore está completa.

**5.10 Uma proposta dentro da árvore**

essencial, vista em aula · 9 min

*A folha dá uma taxa; o tamanho da folha diz quanto ela vale.*


**O caminho da #15** 90% de utilização, sem atraso, pagou

**A FOLHA DA #15**

**50%**

1 default em 2 propostas

Na folha estão a #15, que pagou, e a #16, que deu default.



Intervalo de 95%: 9,5% a 90,5%, **81 pontos** de largura.

utilização  $\leq 57,5\%$ ? **não** → utilização  $\leq 87,5\%$ ? **não**

Taxa sem o tamanho da folha não é informação: com 2 propostas, a folha não separa um grupo excelente de um péssimo.

Página 5.10, como aparece na plataforma, onde é interativa.

**ANTES DE LER A EXPLICAÇÃO, RESPONDA****QUESTÃO · O QUE A FOLHA AUTORIZA**

**A proposta #15 chega a uma folha com duas propostas, uma delas em default. O que essa folha autoriza a afirmar?**

- Que a #15 deu default, já que caiu numa folha de risco 50%
- Que a taxa observada daquele grupo é 50%, com intervalo de 9,5% a 90,5%: com duas propostas a folha não distingue um grupo excelente de um péssimo
- Que o risco do grupo é 50%, e esse é o melhor número disponível para decidir

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

**COMO LER ESTA PÁGINA**

A proposta #15 da base de 16: utilização de 90%, sem atraso, e pagou. À esquerda, a árvore com o caminho dela aceso: utilização até 57,5%? Não, ramo direito. Até 87,5%? Não, folha extrema. À direita, a folha: 1 default em 2 propostas, taxa de 50%. Antes de ler adiante, pergunte-se por que a taxa é 50%. A folha tem duas propostas: a #15, que pagou, e a #16, que deu default; a taxa é a contagem dos rótulos, 1 em 2. Ela resume o grupo e não diz nada sobre o desfecho individual: a #15 pagou e recebe 50%. Agora o tamanho. O intervalo de 95% vai de 9,5% a 90,5%, 81 pontos de largura: com duas propostas, a folha não separa um grupo excelente de um péssimo. Taxa sem o tamanho da folha não é informação. O caminho é auditável, mas a estimativa é instável; profundidade, folha mínima e validação continuam necessárias.

**PARA DISCUTIR EM AULA**

A proposta #15 deu default? E o que esta folha autoriza a afirmar sobre o risco do grupo?

**A SEGUIR** *A taxa da folha explica a árvore; falta testar se ela generaliza.*



5.11

Percorrer a árvore

complementar, de estudo · 9 min

O caminho da raiz à folha é a explicação completa da decisão.

PERCORRER A ÁRVORE · A EXPLICAÇÃO COMPLETA DE UMA DECISÃO · REGRA POR REGRA

O caminho da raiz até a folha é a justificativa integral da previsão, e qualquer pessoa consegue ler.

#3

#8

proposta nova

#16

Utilização 72% e atraso 8 dias:

Utilização do limite ≤ 57,5%? não; Utilização do limite ≤ 87,5%? sim. Folha com 6 de 6: PD 100,0%. A logística do capítulo 4 estima 69,3% para a mesma proposta.

Utilização do limite

72%

O caminho aceso

as caixas atravessadas ficam em destaque

Maior atraso em 6 meses

8 dias

| PASSO | PERGUNTA                      | VALOR | RESPOSTA | VAI PARA           |
|-------|-------------------------------|-------|----------|--------------------|
| 1     | Utilização do limite ≤ 57,5%? | 72,0% | não      | nó com 8 propostas |
| 2     | Utilização do limite ≤ 87,5%? | 72,0% | sim      | nó com 6 propostas |

PD DA FOLHA

100,0%

BASE DA FOLHA

6 / 6

defaults observados sobre propostas

Diagrama de árvore de decisão:

utilização ≤ 57,5%? 16 prop. · 8 def. · PD 50% · ganho 0,281

sim: utilização ≤ 27,5%? 8 prop. · 1 def. · PD 13% · ganho 0,094

não: utilização ≤ 87,5%? 8 prop. · 7 def. · PD 88% · ganho 0,094

utilização ≤ 27,5%? 2 prop. · 1 def. · PD 50%

utilização ≤ 87,5%? 6 prop. · 6 def. · PD 100%

Compare com a logística do capítulo 4, que para a mesma proposta estima 69,3%. As duas famílias discordam, e o capítulo 7 define com qual critério se decide entre elas.

Onde a proposta cai

as quatro regiões da árvore e o ponto

Gráfico de dispersão de utilização (0% a 100%) vs. atraso (0 d a 40 d). Regiões coloridas representam diferentes nós da árvore de decisão com seus respectivos PDs: 50%, 0%, 100%, 50%.

Página 5.11, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois controles, utilização (10% a 100%) e atraso (0 a 45 dias), e quatro atalhos: #3, #8, proposta nova e #16. Para a proposta nova, utilização 72% e atraso 8 dias, a tabela de passos escreve a decisão de cada bifurcação. Passo 1: utilização ≤ 57,5%? Valor 72,0, não, vai para o nó com 8 propostas. Passo 2: utilização ≤ 87,5%? Sim, vai para o nó com 6 propostas. PD da folha 100,0%, base da folha 6 de 6 defaults. O diagrama acende as caixas atravessadas. A logística do capítulo 4 estima 69,3% para a mesma proposta: as duas famílias discordam, e o capítulo 7 define o critério para escolher. Mova o atraso e note que, neste caminho, ele nem é consultado; só a utilização decide. A árvore dá o mesmo valor a todos da folha; a logística varia continuamente, e perto das fronteiras a discordância é máxima. O caminho é a justificativa integral da previsão, legível por qualquer pessoa.

O QUE ESTÁ NA TELA

Mova os valores e siga o caminho aceso, regra por regra.

PARA PENSAR NO ESTUDO

Por que a árvore e a logística discordam nesta proposta?

**A SEGUIR** A folha devolve uma taxa. De onde vem essa taxa?

## 5.12 A previsão da folha é a frequência da folha

complementar, de estudo · 9 min


É o valor que minimiza a log loss no grupo, como no capítulo 2.

### UMA FOLHA: 1 DEFAULT EM 2 PROPOSTAS

| VALOR ATRIBUÍDO | PERDA MÉDIA    |
|-----------------|----------------|
| 10,0%           | 1,20397        |
| 25,0%           | 0,83699        |
| 50,0%           | <b>0,69315</b> |
| 75,0%           | 0,83699        |
| 90,0%           | 1,20397        |

O mínimo está na frequência observada:  
 $1 \div 2 = 50,0\%$ . Não foi escolhido: foi calculado.

### Log loss média na folha, por valor atribuído



É a mesma conta da PD constante do capítulo 2 e do ponto de partida do boosting, no capítulo 6.

No treino, a folha fica calibrada por construção; fora do tempo, só o capítulo 7 diz.

Folha pura devolve 0% ou 100%: afirma uma certeza que não tem.

Página 5.12, como aparece na plataforma, onde é interativa.

### COMO LER ESTA PÁGINA

Uma folha desta árvore, com 1 default em 2 propostas, e cinco candidatos a valor da folha. À esquerda, a tabela: atribuir 10% custa perda média de 1,20397; 25%, 0,83699; 50%, 0,69315; 75%, 0,83699; 90%, 1,20397. À direita, a curva inteira, com o mínimo marcado em 50,0%. O mínimo está exatamente na frequência observada,  $1 \div 2 = 50\%$ : não foi escolhido, foi calculado. Embaixo, três consequências. É a mesma conta da PD constante do capítulo 2 e do ponto de partida do boosting, no capítulo 6. No treino, a folha fica calibrada por construção, porque devolve a frequência observada; fora do tempo, só o capítulo 7 diz. E a folha pura devolve 0% ou 100%, uma certeza que não tem: previsão de 0% sobre um default tem perda infinita, e as implementações aplicam um piso.

### PARA PENSAR NO ESTUDO


Por que a curva sobe tão rápido perto de zero?

**A SEGUIR** Quanto uma folha realmente afirma?

5.13 Quanto cada folha afirma

complementar, de estudo · 10 min

Folhas pequenas produzem intervalos largos demais para decidir.



Página 5.13, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O QUE A FOLHA AFIRMA  
Uma folha tem zero defaults em seis propostas. Qual afirmação se sustenta?

- a. O risco desse grupo é zero, porque nenhuma proposta deu default
- b. A estimativa pontual é 0% e o intervalo de 95% vai até 39,0%, então o nível de risco não está determinado
- c. Como o intervalo desta folha não encosta no da folha de 100%, está provado que as duas têm risco diferente

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As quatro folhas da árvore, com o intervalo de Wilson a 95%. À esquerda, a tabela: folha 1, 2 propostas, 1 default, PD de 50%, intervalo de 9,5% a 90,5%; folha 2, 6 propostas, nenhum default, 0%, de 0% a 39,0%; folha 3, 6 propostas, 6 defaults, 100%, de 61,0% a 100%; folha 4, igual à primeira. À direita, as mesmas folhas em barras. Compare a largura de cada barra com a distância entre elas: as folhas de 50% se sobrepõem a todas as outras, e só a de 0% e a de 100% ficam afastadas. As folhas de 50% têm 81 pontos de largura: quase não afirmam nada. Com 600 propostas e nenhum default, o intervalo seria de 0% a 0,6%: o mesmo número de PD, com evidência incomparável. O tamanho mínimo de folha existe por isso. Sobreposição, porém, não é teste de diferença; o teste está no capítulo 7. Antes da questão sobre a folha de zero defaults, olhe o limite superior do intervalo dela.

PARA PENSAR NO ESTUDO

A folha de 0% prova que aquele grupo não dá default?

A SEGUIR Se folhas pequenas não afirmam nada, é preciso impedir que elas apareçam.

5.14

Os dois freios da árvore

complementar, de estudo · 10 min

Profundidade limita as perguntas; o mínimo por folha limita o tamanho do grupo.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Ajuste os dois freios e veja a árvore obedecer.

Plano das variáveis 4 folhas · clique numa proposta para retirá-la

● deu default

● pagou

○ retirada da base

Deixar a árvore crescer

Árvore de referência

A árvore 4 folhas · profundidade 2

Profundidade máxima 2

Mínimo de propostas por folha 2

Proposta retirada da base nenhuma, base completa

RAIZ ESCOLHIDA  
utilização ≤ 57,5%  
ganho 0,28125

DIVISÃO DO NÓ DIREITO  
utilização ≤ 87,5%  
ganho 0,09375

FOLHAS · ERROS NAS 16  
4 · 2  
menor folha com 2 propostas

PIOR INTERVALO DE FOLHA  
81%  
largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato os candidatos são os pontos médios entre valores consecutivos

Utilização do limite

Maior atraso em 6 meses

Ponto de corte utilização ≤ 62,5%

| LADO    | PROPOSTAS                                                                                           | DEFAULTS | PROPORÇÃO | GINI    |
|---------|-----------------------------------------------------------------------------------------------------|----------|-----------|---------|
| ≤ CORTE | 9                                                                                                   | 2        | 22,2%     | 0,34568 |
| > CORTE | 7                                                                                                   | 6        | 85,7%     | 0,24490 |
| GANHO   | 0,50000 − (9 ÷ 16 × 0,3457 + 7 ÷ 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125 |          |           |         |

A disputa: ganho de cada candidato vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 52,5% com 0,198

Página 5.14, como aparece na plataforma, onde é interativa.

Prof. Genaro Dueire Lins · FGV · 2026

20 de 28

**COMO LER ESTA PÁGINA**

Dois controles, profundidade máxima (0 a 4) e mínimo de propostas por folha (1 a 4), e quatro contadores: raiz escolhida, divisão do nó direito, folhas e erros nas 16, com a menor folha embaixo, e pior intervalo de folha. Com profundidade 2 e mínimo 2: 4 folhas, 2 erros, menor folha com 2 propostas e pior intervalo com 81% de largura. Nenhuma folha unitária; o erro na amostra não é zero, e isso não é defeito. A árvore ao lado e a partição no plano são reconstruídas a cada movimento. Os dois freios agem por caminhos diferentes: a profundidade impede perguntas adicionais mesmo quando o grupo é grande; o mínimo por folha impede grupos pequenos mesmo quando ainda há profundidade disponível. Leia a menor folha e o pior intervalo, não o erro: o erro na amostra sempre cai com complexidade. Fixe o mínimo em 1 e suba a profundidade até 4; depois mantenha 4 e suba o mínimo. Os dois caminhos levam a árvores diferentes. Os dois são hiperparâmetros, e a escolha é na validação, como no capítulo 2.

**O QUE ESTÁ NA TELA**

Mova os dois controles e olhe a menor folha, não o erro.

**PARA PENSAR NO ESTUDO**

Qual dos dois freios você usaria em uma carteira de 200 mil propostas?

**A SEGUIR** Há uma terceira forma de controlar a complexidade, depois de construir.

**5.15 Poda: crescer e depois cortar**

complementar, de estudo · 9 min

*Cada folha tem um preço; a poda pesa impureza contra número de folhas.*

**PODA · CRESCER PRIMEIRO, CORTAR DEPOIS · UM PREÇO POR FOLHA · QUATRO ÁRVORES DA MESMA BASE**

**Mova o preço da folha e veja qual árvore vence. A de quatro folhas nunca vence, para nenhum  $\alpha$ .**

$\alpha = 0,00$     $\alpha = 0,03$     $\alpha = 0,10$     $\alpha = 0,30$

$\alpha = 0,030$ : vence profundidade 3, folhas de 1, com custo 0,18000. Pontos de troca:  $\alpha = 0,0547$  entre seis e duas folhas, e  $\alpha = 0,2813$  entre duas folhas e a raiz. A árvore de quatro folhas não vence em nenhum ponto.

**Preço de cada folha,  $\alpha$**    0,030




| ÁRVORE                        | FOLHAS | IMPUREZA | $\alpha \times$<br>FOLHAS | CUSTO   |
|-------------------------------|--------|----------|---------------------------|---------|
| ● SÓ A RAIZ                   | 1      | 0,50000  | 0,03000                   | 0,53000 |
| ● PROFUNDIDADE 1              | 2      | 0,21875  | 0,06000                   | 0,27875 |
| ● PROFUNDIDADE 2              | 4      | 0,12500  | 0,12000                   | 0,24500 |
| ● PROFUNDIDADE 3, FOLHAS DE 1 | 6      | 0,00000  | 0,18000                   | 0,18000 |

$\text{custo}(T) = \text{impureza ponderada de } T + \alpha \times \text{número de folhas de } T$

Com  $\alpha$  zero, vence a árvore mais complexa; com  $\alpha$  alto, só a raiz. Entre os extremos, a poda percorre uma sequência de árvores.

**Custo de cada árvore em função de  $\alpha$**  a vencedora é a linha mais baixa em cada ponto



**UM RESULTADO QUE SURPREENDE**

**Aqui a árvore de quatro folhas nunca vence: a poda salta de seis folhas para duas, porque o último nível rende pouco perto do penúltimo. Por isso se poda pelo elo mais fraco, e não testando profundidades.**

Na prática,  $\alpha$  sai da validação cruzada; escolhido no treino, repete o problema do capítulo 2.

Página 5.15, como aparece na plataforma, onde é interativa.

**COMO LER ESTA PÁGINA**

Quatro árvores da mesma base avaliadas pelo mesmo critério: custo = impureza ponderada +  $\alpha \times$  número de folhas. Só a raiz: 1 folha, impureza 0,50000. Profundidade 1: 2 folhas, 0,21875. Profundidade 2: 4 folhas, 0,12500. Profundidade 3 com folhas de 1: 6 folhas, 0,00000. Mova o preço de cada folha,  $\alpha$ , de 0 a 0,35, com atalhos em 0, 0,03, 0,10 e 0,30. Com  $\alpha = 0,030$  vence a árvore de seis folhas, custo 0,18000. Os pontos de troca são  $\alpha = 0,0547$ , entre seis e duas folhas, e  $\alpha = 0,2813$ , entre duas folhas e a raiz. No gráfico, cada árvore é uma reta com inclinação igual ao número de folhas, e vence a linha mais baixa. Um resultado que surpreende: a árvore de quatro folhas nunca vence, para nenhum  $\alpha$ ; a poda salta de seis folhas direto para duas, porque a redução de impureza do último nível é desproporcional à do penúltimo. É por isso que a poda é feita por elo mais fraco.

**O QUE ESTÁ NA TELA**

Mova o preço da folha e veja qual árvore vence.

**PARA PENSAR NO ESTUDO**

Por que as linhas do gráfico são retas?

**A SEGUIR** *Falta olhar a estabilidade da estrutura.*

5.16

Instabilidade: uma proposta pode trocar a estrutura

complementar, de estudo · 8 min

Com ganhos empatados, tirar um caso muda a variável escolhida.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Retire uma proposta. A raiz resiste; o nó direito, não.

Plano das variáveis 4 folhas · clique numa proposta para retirá-la

Deixar a árvore crescer

Árvore de referência

A árvore 4 folhas · profundidade 2

Profundidade máxima 2

Mínimo de propostas por folha 1

Proposta retirada da base nenhuma, base completa

RAIZ ESCOLHIDA  
utilização ≤ 57,5%  
ganho 0,28125 · igual à base completa

DIVISÃO DO NÓ DIREITO  
utilização ≤ 87,5%  
ganho 0,09375 · igual à base completa

FOLHAS · ERROS NAS 16  
4 · 2  
menor folha com 2 propostas

PIOR INTERVALO DE FOLHA  
81%  
largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato os candidatos são os pontos médios entre valores consecutivos

Utilização do limite

Maior atraso em 6 meses

Ponto de corte utilização ≤ 62,5%

| LADO    | PROPOSTAS                                                                                           | DEFAULTS | PROPORÇÃO | GINI    |
|---------|-----------------------------------------------------------------------------------------------------|----------|-----------|---------|
| ≤ CORTE | 9                                                                                                   | 2        | 22,2%     | 0,34568 |
| > CORTE | 7                                                                                                   | 6        | 85,7%     | 0,24490 |
| GANHO   | 0,50000 – (9 ÷ 16 × 0,3457 + 7 ÷ 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125 |          |           |         |

A disputa: ganho de cada candidato vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 52,5% com 0,198

Página 5.16, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · EMPATE DE GANHO

No nó direito desta base, os dois melhores cortes empatam em ganho de 0,09375. O que isso indica?

- a. Que os dois são equivalentes e a escolha não tem consequência
- b. Que a escolha é decidida por desempate de implementação e que pequena mudança na amostra pode inverter a variável do nó
- c. Que o nó não deveria ser dividido, porque o critério não distingue os candidatos

Prof. Genaro Dueire Lins · FGV · 2026

23 de 28

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

### COMO LER ESTA PÁGINA

Retirar uma proposta da base recalcula a raiz, o nó direito e a árvore inteira. Com a base completa, a raiz é utilização  $\leq 57,5\%$ , ganho 0,28125, e o nó direito é utilização  $\leq 87,5\%$ , ganho 0,09375: a árvore de referência do capítulo. Percorra a lista e observe os dois contadores: a raiz resiste a qualquer retirada; o nó direito não. Na raiz, o vencedor tem 0,28125, o corte vizinho 0,19841 e o melhor corte de atraso 0,07143; sem a #8 ou a #9, muda o ponto médio, não a divisão. No nó direito, os dois primeiros empatam exatamente em 0,09375, e o empate é decidido pela ordem de avaliação. Retirar a #10 troca a variável do nó de utilização para atraso. Instabilidade de estrutura não é o mesmo que instabilidade de previsão: duas árvores com variáveis diferentes podem produzir PDs parecidas. O que se perde é a leitura, a explicação da decisão que muda de um mês para o outro, com consequência em governança e na comunicação com o cliente. Responda à questão sobre o empate antes de mover o controle.

#### O QUE ESTÁ NA TELA

Retire uma proposta: a raiz resiste, o nó direito não.

#### PARA PENSAR NO ESTUDO

Instabilidade de estrutura invalida o modelo?

**A SEGUIR** Falta comparar as duas famílias com honestidade.

## 5.17 Gini ou entropia: a conclusão não muda

complementar, de estudo · 8 min

*Trocar a medida de impureza raramente muda a árvore.*

| VARIÁVEL                | MELHOR CORTE, GINI | GANHO   | MELHOR CORTE, ENTROPIA | GANHO   |
|-------------------------|--------------------|---------|------------------------|---------|
| UTILIZAÇÃO DO LIMITE    | 57,5               | 0,28125 | 57,5                   | 0,45644 |
| MAIOR ATRASO EM 6 MESES | 15 ou 27,5         | 0,07143 | 27,5                   | 0,13793 |

Os dois critérios escolhem a mesma raiz. Os ganhos estão em escalas diferentes (a entropia é medida em bits): compare o corte, não o número.

#### O QUE MAIS MUDA A ÁRVORE

1. A amostra
2. O mínimo de casos por folha
3. A profundidade
4. Muito depois, o critério de impureza

#### QUANDO O CRITÉRIO IMPORTA

**Quase nunca** na escolha do corte

**Às vezes** com alvo de mais de duas classes

**Sempre** na declaração: o relatório diz qual foi usado

Página 5.17, como aparece na plataforma, onde é interativa.

### COMO LER ESTA PÁGINA

A varredura da raiz refeita com entropia, lado a lado com a de Gini. Utilização: melhor corte em 57,5 pelos dois critérios, com ganho de 0,28125 por Gini e 0,45644 por entropia. Atraso: o Gini empata os cortes de 15 e 27,5 dias, em 0,07143, e não escolhe entre eles; a entropia prefere 27,5, com 0,13793. A raiz é a mesma, utilização  $\leq 57,5\%$ , e vence pelos dois critérios com margem de mais de três vezes. Os ganhos estão em escalas diferentes, porque a entropia é medida em bits; comparar os números entre as colunas não tem significado. O que se compara é o corte escolhido. Ao lado, quando o critério importa: quase nunca na escolha do corte; às vezes com alvo de mais de duas classes; sempre na declaração, porque o relatório precisa dizer qual foi usado. E o que muda a árvore, por impacto: a amostra, o mínimo por folha, a profundidade e, muito depois, o critério.

#### O QUE ESTÁ NA TELA

A varredura da página 7, refeita com entropia.

#### PARA PENSAR NO ESTUDO

Por que não comparar os valores de ganho entre os dois critérios?




**A SEGUIR** A comparação que importa é entre famílias.

**5.18 Logística e árvore nos mesmos casos**

essencial, vista em aula · 10 min

Uma fronteira suave contra regiões em degraus, proposta a proposta.



Página 5.18, como aparece na plataforma, onde é interativa.

**ANTES DE LER A EXPLICAÇÃO, RESPONDA**

- QUESTÃO · O QUE A PERDA DE TREINO DECIDE**
- Nas dezesseis propostas, a log loss é 0,43282 na logística e 0,18844 na árvore. O que esse par de números decide?**
- a. Que a árvore é o melhor modelo nesta base, e por margem larga
  - b. Nada: as duas foram avaliadas na mesma amostra em que a árvore criou as folhas, e perda de treino desce com qualquer complexidade acrescentada
  - c. Que a árvore está sobreajustada, e por isso a logística deve ser escolhida

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

### COMO LER ESTA PÁGINA

As dezesseis propostas no plano, com a reta de PD 50% da logística e as quatro regiões da árvore, cada uma com sua taxa. Clique numa proposta ou use os atalhos #5, #10 e #15. A #5, utilização 40% e atraso 20 dias, pagou: logística 52,6%, árvore 0%, 52,6 pontos de diferença; a reta vê risco moderado, a árvore caiu numa folha sem defaults. A #10, 65% e 0 dias, deu default: 30,5% contra 100%. A #15, 90% e 0 dias, pagou: 73,9% contra 50%. A tabela lista as dezesseis linhas, com discordâncias acima de 35 pontos em rosa. As perdas de treino, log loss 0,43282 da logística contra 0,18844 da árvore, com piso e teto de 2% e 98% nas folhas puras, não decidem nada: a árvore foi avaliada na amostra que usou para criar as folhas. A tabela final resume o que cada família entrega: fronteira reta ou escalonada, PD contínua ou constante por região, estabilidade alta ou baixa. A comparação de verdade está no capítulo 7.

### O QUE ESTÁ NA TELA

Use #5, #10 e #15 ou clique numa proposta e compare o modo de errar.

### PARA DISCUTIR EM AULA

Onde as duas famílias mais discordam?

**A SEGUIR** Se a árvore é instável e a logística é rígida, existe uma terceira via.

## 5.19 Síntese: regras locais e controle de variância

complementar, de estudo · 9 min

*Partição por busca gulosa, previsão por frequência e complexidade sob controle.*

### 3 IDEIAS PARA LEVAR

#### A árvore aprende cortes fáceis de explicar e fáceis de sobreajustar.

1. **Corte.** O que vence a disputa por um nó?

| O corte que mais reduz a impureza ponderada.

2. **Folha.** De onde vem a PD?

| Da frequência observada entre os casos que chegaram à folha.

3. **Controle.** O que evita folhas frágeis?

| Profundidade, número mínimo de casos e poda escolhidos fora do treino.

### COMO LER ESTA PÁGINA

Três ideias para levar, uma por botão: Corte, Folha e Controle. A frase à esquerda resume: a árvore aprende cortes fáceis de explicar e fáceis de sobreajustar. O Corte que vence a disputa por um nó é o que mais reduz a impureza ponderada. A Folha devolve a frequência observada entre os casos que chegaram a ela, e essa frequência vale junto com o tamanho da folha. O Controle, com profundidade, número mínimo de casos e poda, é escolhido fora do treino. Antes de clicar, escolha uma das três e explique com suas palavras. Depois aplique as três a dois casos da aula. A #10, default com 65% de utilização e sem atraso, cai numa folha de seis defaults e recebe 100%, onde a reta dava 30,5%. A #15 fica numa folha de duas propostas, com 50%. Qual ideia explica cada caso? O capítulo 6 parte dessa tensão: a logística é rígida, a árvore é instável, e a terceira via soma árvores pequenas.

### O QUE ESTÁ NA TELA

Explique cada ideia com suas palavras antes de revelar.

### PARA PENSAR NO ESTUDO

O que a árvore faz com a #10 e com a #15, e qual ideia explica cada caso?

**A SEGUIR** A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.

## Fecho do capítulo

### Antes da próxima aula, você deve conseguir explicar

- **5.1** Ler uma previsão como o caminho da raiz até uma folha.
- **5.3** Nó, regra, ramo, folha e profundidade, no diagrama que o capítulo inteiro usa.
- **5.4** Máxima com metade de defaults, zero quando todos têm o mesmo desfecho.
- **5.7** Vence o corte de maior ganho, não o que parece melhor no desenho.
- **5.10** A folha dá uma taxa; o tamanho da folha diz quanto ela vale.
- **5.18** Uma fronteira suave contra regiões em degraus, proposta a proposta.

### Erros comuns: o que se confunde

| #    | Erro                                                             | Confusão por trás                                                         |
|------|------------------------------------------------------------------|---------------------------------------------------------------------------|
| 5.2  | <b>Concluir que a árvore é superior</b>                          | Lê flexibilidade como qualidade sem contabilizar o custo.                 |
| 5.3  | <b>Contar profundidade incluindo a folha</b>                     | Conta nós em vez de regras.                                               |
| 5.4  | <b>Confundir impureza baixa com PD baixa</b>                     | Lê a medida como nível de risco.                                          |
| 5.4  | <b>Ler o Gini como a taxa de erro do nó</b>                      | Toma a chance de errar com rótulo sorteado pelo erro de prever a maioria. |
| 5.5  | <b>Achar que Gini 0,5 indica base ruim</b>                       | Lê impureza máxima como problema.                                         |
| 5.6  | <b>Esquecer a ponderação pelo tamanho</b>                        | Faz a média simples dos dois Ginis.                                       |
| 5.6  | <b>Procurar o corte que deixa um lado puro</b>                   | Persegue pureza em vez de ganho ponderado.                                |
| 5.7  | <b>Achar que a busca é otimização</b>                            | Imagina que existe gradiente ou fórmula fechada.                          |
| 5.7  | <b>Ignorar a margem</b>                                          | Trata o vencedor como escolha determinada.                                |
| 5.8  | <b>Concluir que o modelo já está pronto</b>                      | Confunde separação na amostra com capacidade preditiva.                   |
| 5.9  | <b>Achar que cada variável só pode ser usada uma vez</b>         | Transfere a intuição de regressão para a árvore.                          |
| 5.9  | <b>Tomar maior ganho no passo por melhor resultado no fim</b>    | Confunde ótimo local com ótimo global.                                    |
| 5.10 | <b>Ler 100%</b>                                                  | Conta dois casos como dois defaults.                                      |
| 5.11 | <b>Achar que a árvore usa as duas variáveis sempre</b>           | Espera que todo caminho passe por todas as variáveis.                     |
| 5.12 | <b>Achar que o valor da folha é a média das PDs dos clientes</b> | Imagina um modelo dentro da folha.                                        |
| 5.13 | <b>Usar sobreposição de intervalos como teste</b>                | Trata intervalos individuais como teste de diferença entre grupos.        |
| 5.13 | <b>Reportar a taxa da folha sem o n</b>                          | Apresenta estimativa sem evidência.                                       |

| #    | Erro                                                                     | Confusão por trás                                                       |
|------|--------------------------------------------------------------------------|-------------------------------------------------------------------------|
| 5.14 | <b>Otimizar os freios pelo erro na amostra</b>                           | Usa a amostra de treino para escolher hiperparâmetro.                   |
| 5.14 | <b>Fixar mínimo em número absoluto sem olhar a base</b>                  | Ignora a proporção que o mínimo representa.                             |
| 5.15 | <b>Escolher <math>\alpha</math> pelo desempenho na amostra de treino</b> | Repete o erro de usar treino para escolher hiperparâmetro.              |
| 5.16 | <b>Concluir que árvores não servem</b>                                   | Generaliza a partir de uma base de dezesseis.                           |
| 5.17 | <b>Concluir que entropia é melhor por ter ganho maior</b>                | Compara valores em escalas distintas.                                   |
| 5.18 | <b>Declarar vencedor pela perda de treino</b>                            | Compara modelos na amostra em que foram estimados.                      |
| 5.19 | <b>Ler os 50% da #15 como risco médio</b>                                | Toma a frequência de uma folha de duas propostas como estimativa firme. |