

LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2 · VERSÃO DO ALUNO

05

CAPÍTULO 5 DE 11 · INFOGRÁFICO DE ABERTURA

Árvores de decisão

Como perguntas sucessivas dividem a população em grupos de risco?

1 · PERGUNTAS SUCESSIVAS CRIAM REGIÕES DE RISCO (BASE DIDÁTICA DE 16 PROPOSTAS)

1. Raiz

16 propostas, 8 defaults: metade a metade, Gini 0,500, impureza máxima. É o ponto de partida.

2. Corte vencedor

Utilização $\leq 57,5\%$: redução de Gini de 0,281, a maior entre todos os candidatos. Lado sim: 8 casos, 1 default. Lado não: 8 casos, 7 defaults.

3. Recursão

Cada lado recomeça a busca só com os casos que chegaram até ele. No lado esquerdo, utilização $\leq 27,5\%$ dá ganho local de 0,094.

4. Folha

A previsão é a frequência da folha: 1 default em 2 propostas é PD de 50%, com intervalo de 95% de 9,5% a 90,5%.

2 · TRÊS NÚMEROS QUE A ÁRVORE COMPARA

0,500

Gini da raiz

Impureza máxima: o grupo está meio a meio. Zero quando todos têm o mesmo desfecho.

0,281

redução do melhor corte

Ganho ponderado pelo tamanho dos filhos; o maior ganho permitido vence.

12,5% e 87,5%

taxas após a raiz

Uma única divisão já separa dois grupos com risco muito diferente.

Ganho = Gini(pai) – média ponderada dos Gini(filhos)

Na raiz desta base: $0,500 - 0,21875 = 0,281$.

3 · ONDE A ÁRVORE ERRA, E COMO SE CONTROLA

Folhas pequenas, intervalos largos

Intervalo de 95% da taxa de cada folha:

2 casos, 1 default 50%: de 9,5% a 90,5%

6 casos, 0 default 0%: de 0% a 39,0%

6 casos, 6 defaults 100%: de 61,0% a 100%

Os intervalos se sobrepõem: a árvore não sustenta a decisão

Poda: um preço por folha ($\alpha = 0,030$)

Custo = impureza + $\alpha \times$ folhas:

Só a raiz 0,530

Profund. 1 0,279

Profund. 2 0,245

Crescer primeiro, cortar depois: a árvore de profundidade 2 vence a este preço.

Os freios e a instabilidade

- Profundidade máxima limita quantas perguntas se pode fazer.
- Mínimo de casos por folha limita quão pequeno um grupo pode ficar.
- Quando dois cortes têm ganhos próximos, retirar uma observação pode trocar a raiz: a árvore parece outro modelo.

TRÊS IDEIAS PARA LEVAR

Corte

O que vence a disputa por um nó? O corte que mais reduz a impureza, ponderado pelo tamanho dos filhos.

Folha

O que a folha prevê? A frequência observada nela, com o intervalo que o tamanho permite.

Controle

O que segura o sobreajuste? Profundidade, mínimo por folha e poda com preço por folha.

Prof. Genaro Dueire Lins · FGV · Edição 2026 · material derivado da plataforma decisaodecredito.com · os números do material são reconstruções didáticas ou exemplos sintéticos, salvo indicação de fonte.

05

CAPÍTULO 5 DE 11 · AULA 2: ENTENDER AS TRÊS TÉCNICAS

Árvores de decisão

Como perguntas sucessivas dividem a população em grupos de risco?

O QUE VOCÊ APRENDE

Nó, regra, ramo, folha, profundidade, critério de impureza, escolha da divisão por busca, previsão na folha, incerteza da folha, complexidade e poda.

POR QUE IMPORTA

Como separar clientes em grupos com comportamentos diferentes usando perguntas simples?

A ATIVIDADE

Calcular o ganho de dois cortes candidatos e escolher a divisão da raiz.


ANTES DE COMEÇAR

Capítulo 2, em especial variabilidade e generalização.

Onde isto é usado depois. É o bloco de construção do capítulo 6.

A ideia central

Uma árvore faz perguntas sucessivas sobre as variáveis e divide a população em grupos cada vez mais homogêneos em relação ao evento. Em cada nó ela testa todos os cortes possíveis e escolhe o que mais reduz a impureza (Gini ou entropia) dos filhos; a previsão de uma folha é a taxa de default observada nela. A árvore captura interações e limiares sem que ninguém os declare, e é fácil de explicar caso a caso (basta seguir o caminho). O preço é a variância: folhas pequenas têm taxas instáveis (o intervalo de Wilson mostra quanto), e árvores profundas decoram a amostra. Profundidade, folha mínima e poda são os freios; a validação temporal diz se estão bem calibrados.



À esquerda, a busca pelo corte que mais reduz a impureza. À direita, a incerteza da taxa de uma folha com 20% de default conforme o número de casos: com 20 casos o intervalo vai de 8% a 42%.

COMO USAR ESTE MATERIAL

- Cada página traz a captura da plataforma e o texto **Como ler esta página**: o que o visual mostra, como ler e o que levar. Na plataforma os visuais são interativos; mova os controles descritos no texto.
- As 6 páginas essenciais são as vistas em aula; as complementares aprofundam no seu estudo. **Para discutir em aula** é a pergunta que o professor vai fazer.
- Responda às questões antes de abrir a plataforma: lá, cada resposta recebe o diagnóstico. O fecho lista o que você deve conseguir explicar.

O FIO DA AULA 2: ENTENDER AS TRÊS TÉCNICAS

As mesmas 16 propostas atravessam os três capítulos, cada uma com utilização, atraso e desfecho observado. Cada capítulo parte do caso que o anterior deixou em aberto, e a aula termina com as três PDs lado a lado.

Capítulo	A pergunta	Como termina
Capítulo 4 Regressão logística	Como características viram probabilidade?	Nenhuma reta separa a #15, que pagou, da #2, que deu default. O capítulo 5 troca a soma por perguntas sucessivas, nas mesmas 16 propostas.
Capítulo 5 Árvores de decisão VOCÊ ESTÁ AQUI	Como perguntas sucessivas dividem a população em grupos de risco?	A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.
Capítulo 6 Gradient boosting com árvores	Como uma sequência de árvores melhora uma previsão?	Aula 3, capítulo 7: como escolher entre modelos fora da amostra.

Mapa do capítulo

#	Página	O que ela entrega	min
1	Árvores de decisão	Ler uma previsão como um caminho verificável da raiz até uma folha.	4
2	A pergunta condicionada resolve o que a soma não resolve	Perguntas sucessivas permitem que o efeito de uma variável dependa do valor das outras, sem que a interação precise ser escrita à mão.	8
3	Anatomia: nó, regra, ramo, folha, profundidade	Cada elemento da árvore tem nome e função, e a profundidade conta divisões, não nós.	8
4	Impureza: uma medida de quanto o grupo está misturado	Impureza é máxima quando o grupo está meio a meio e zero quando todos têm o mesmo desfecho, e é a quantidade que a divisão tenta reduzir.	8
5	Impureza na raiz	Interpretar o Gini como mistura de desfechos dentro de um nó.	9
6	Avaliar um corte candidato	Um corte é avaliado pela redução da impureza que produz, ponderada pelo tamanho dos dois grupos resultantes.	10
7	A disputa entre os cortes da raiz	Comparar candidatos pela redução ponderada de impureza, não pela aparência do diagrama.	10
8	A raiz escolhida, e o que ela já resolve	Uma única divisão já separa a base em dois grupos com taxas de default muito diferentes, e o que sobra em cada lado é o problema seguinte.	8
9	Recursão: a busca recomeça em cada lado	Entender que cada nó filho resolve um problema local com apenas os casos que chegaram até ele.	9
10	Uma proposta dentro da árvore	Seguir um caso concreto e interpretar a taxa da folha junto com seu tamanho.	9

#	Página	O que ela entrega	min
11	Percorrer a árvore: a explicação completa de uma decisão	O caminho da raiz até a folha é a justificativa integral da previsão de uma proposta, e pode ser lido por qualquer pessoa.	9
12	A previsão da folha é a frequência da folha, e isso não é convenção	O valor que minimiza a log loss dentro de um grupo é a proporção observada nesse grupo, o mesmo resultado obtido no capítulo 2.	9
13	A confiabilidade de cada folha, calculada	A taxa de uma folha é uma estimativa com intervalo, e folhas pequenas produzem intervalos largos demais para sustentar decisão.	10
14	Os dois freios: profundidade e mínimo de casos por folha	Profundidade limita quantas perguntas se pode fazer e o mínimo por folha limita quão pequeno um grupo pode ficar, e os dois são hiperparâmetros.	10
15	Poda: crescer primeiro, cortar depois, com um preço por folha	A poda por custo de complexidade compara impureza e número de folhas usando um parâmetro que define o preço de cada folha.	9
16	Instabilidade: uma observação pode trocar a estrutura	Quando dois cortes candidatos têm ganhos próximos, remover uma única observação pode mudar a variável escolhida, e a árvore resultante parece outro modelo.	8
17	Gini ou entropia: o critério não muda a conclusão aqui	Trocar a medida de impureza raramente muda a árvore, e afirmar que uma é superior exige evidência que geralmente não existe.	8
18	Logística e árvore nos mesmos casos	Comparar como uma fronteira suave e regiões em degraus tratam a mesma proposta.	10
19	Síntese: regras locais e controle de variância	A árvore é uma partição escolhida por busca gulosa, com previsão por frequência na folha e complexidade controlada por hiperparâmetros.	9

Páginas em cinza são complementares: aprofundam no estudo e não entram no tempo de aula (6 essenciais, 49 min).

5.1 Árvores de decisão

essencial, vista em aula · 4 min

Ler uma previsão como um caminho verificável da raiz até uma folha.

O DESAFIO DESTE CAPÍTULO

Uma sequência de perguntas pode criar regiões de risco.

A árvore procura cortes que deixam os grupos mais homogêneos e entrega uma frequência em cada folha.

1. **Corte.** Cada pergunta compete por redução de impureza.
2. **Caminho.** Uma proposta percorre regras até uma folha.
3. **Freio.** Profundidade, folha mínima e poda controlam variância.

COMO LER ESTA PÁGINA

O painel abre o capítulo em três etapas: corte, caminho e freio. Leia da esquerda para a direita. Primeiro, como um corte é escolhido: cada pergunta compete por redução de impureza, e vence a que deixa os grupos mais homogêneos. Depois, o caminho: uma proposta desce da raiz até uma folha, e a folha entrega a frequência dos casos que seguiram o mesmo trajeto. Por fim, o freio: sem profundidade máxima e mínimo por folha, a árvore divide até decorar a amostra. A frase central resume: uma sequência de perguntas pode criar regiões de risco. A árvore é a resposta à limitação que fechou o capítulo 4, a soma que não captura interação, e é o bloco de construção do capítulo 6. Guarde a pergunta do capítulo: como perguntas sucessivas dividem a população em grupos de risco?

O QUE ESTÁ NA TELA

Uma árvore divide propostas semelhantes. Cada corte é uma pergunta; cada folha resume os casos que seguiram o mesmo caminho.

PARA DISCUTIR EM AULA


Quem já usou árvore em produção? Para quê?

A SEGUIR Começamos pela limitação que motivou a mudança de família.

5.2 A pergunta condicionada resolve o que a soma não resolve complementar, de estudo · 8 min


Perguntas sucessivas permitem que o efeito de uma variável dependa do valor das outras, sem que a interação precise ser escrita à mão.

LOGÍSTICA: UMA RETA, INCLINAÇÃO FIXA



Nenhuma posição da reta acerta as dezesseis. Nesta, de $PD = 50\%$, quatro ficam do lado errado: a #2 e a #10 deram default com PD abaixo de 31%; a #5 e a #15 pagaram com PD acima de 52%. Deslocar a reta troca quais erram, e o melhor que se consegue são três erros.

ÁRVORE: CORTES PARALELOS AOS EIXOS



Cada corte separa por uma única variável. Combinando cortes, a região resultante pode ter qualquer formato escalonado.

O que a árvore ganha

Interação sem escrever termo de interação, não monotonicidade sem transformar variável, e leitura por regra em vez de por coeficiente. Uma regra do tipo utilização acima de 57,5% e atraso acima de 2,5 dias é diretamente operacionalizável em política.

O que a árvore perde

Suavidade. A PD estimada é constante dentro de cada região e salta na fronteira, então duas propostas quase idênticas separadas por décimo de ponto recebem PDs muito diferentes. E a estrutura é instável: pequena mudança na amostra pode trocar a variável da raiz.

Página 5.2, como aparece na plataforma.

COMO LER ESTA PÁGINA

As mesmas dezesseis propostas em duas dispersões. À esquerda, a logística: uma reta de $PD = 50\%$, com quatro propostas do lado errado, a #2 e a #10 aprovadas tendo dado default e a #5 e a #15 recusadas tendo pago. À direita, a árvore: cortes paralelos aos eixos, o primeiro em utilização 57,5%. Cada corte separa por uma única variável; combinando cortes, a região resultante pode ter qualquer formato escalonado. Compare as duas caixas. O que a árvore ganha: interação sem escrever termo de interação, não monotonicidade sem transformar variável, e leitura por regra em vez de por coeficiente; uma regra como utilização acima de 57,5% e atraso acima de 2,5 dias é diretamente operacionalizável em política. O que a árvore perde: suavidade, porque a PD é constante dentro de cada região e salta na fronteira, e estabilidade, porque pequena mudança na amostra pode trocar a variável da raiz. Pergunte-se quantos cortes seriam necessários para isolar a #15 e o que sobraria na folha.

O QUE ESTÁ NA TELA

A mesma base, duas maneiras de dividir o plano. Uma soma parcelas, a outra corta em retângulos.

PARA PENSAR NO ESTUDO

Quantos cortes seriam necessários para isolar a #15?

A SEGUIR Para construir a árvore é preciso primeiro nomear suas partes.

5.3

Anatomia: nó, regra, ramo, folha, profundidade

essencial, vista em aula · 8 min

Cada elemento da árvore tem nome e função, e a profundidade conta divisões, não nós.

ANATOMIA DA ÁRVORE · 16 PROPOSTAS · DUAS DIVISÕES · O DIAGRAMA USADO EM TODO O CAPÍTULO

Cinco palavras, e cada uma tem lugar no desenho. A profundidade conta divisões, não nós.

- Nó
- Regra
- Ramo
- Folha
- Profundidade

Nó: um grupo de propostas. A raiz é o nó que contém todas as 16. Esta árvore tem 7 nós, 3 regras, 6 ramos, 4 folhas e profundidade 2; as folhas somam 16 propostas e 8 defaults, sem sobreposição e sem buraco.

A árvore de profundidade 2 cada caixa traz quantas propostas chegaram ali, quantas deram default e a taxa




AS CINCO PALAVRAS

NÓ	um grupo de propostas. A raiz é o nó que contém todas as 16.
REGRA	a pergunta que divide o nó. Sempre da forma variável menor ou igual a valor.
RAMO	cada uma das duas saídas da regra. Sempre duas, nesta construção.
FOLHA	nó que não é mais dividido. É onde a previsão é produzida.
PROFUNDIDADE	número de regras entre a raiz e a folha. Esta árvore tem profundidade 2.

QUANTAS FOLHAS UMA PROFUNDIDADE PERMITE

profundidade máxima d 3 → até 8 folhas



Uma árvore com profundidade máxima d tem no máximo 2^d folhas. Profundidade 3 chega a 8, profundidade 10 chega a 1.024. O número cresce rápido e é por isso que a profundidade é o principal freio.

DUAS PROPRIEDADES QUE DECORREM DA FORMA

Toda proposta cai em exatamente uma folha, então as folhas particionam a população sem sobreposição e sem buraco. E o caminho até a folha é a explicação completa da previsão daquela proposta, o que torna a árvore auditável linha a linha.

Página 5.3, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · PROFUNDIDADE CONTA O QUÊ

Nesta árvore uma proposta atravessa três caixas da raiz até a folha. Qual é a profundidade da árvore?

a. 3, porque são três caixas no caminho

b. 2, porque profundidade conta as regras aplicadas, e a folha não faz pergunta

c. 4, porque a árvore tem quatro folhas

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A árvore de duas divisões que serve a todo o capítulo, com cada elemento acionado ao toque dos cinco botões: nó, regra, ramo, folha, profundidade. A raiz pergunta se a utilização é menor ou igual a 57,5%. À esquerda, a pergunta seguinte é 27,5%, e as folhas têm 2 propostas com 1 default (50%) e 6 com 0 (0%). À direita, 87,5%, com folhas de 6 propostas e 6 defaults (100%) e 2 com 1 (50%). São 7 nós, 3 regras, 6 ramos e 4 folhas, que somam 16 propostas e 8 defaults, sem sobreposição e sem buraco. Profundidade conta regras entre a raiz e a folha: esta árvore tem profundidade 2. O controle de profundidade máxima d , de 1 a 10, mostra quantas folhas ela permite: 2 elevado a d , então 8 em profundidade 3 e 1.024 em profundidade 10. Duas propriedades decorrem da forma: toda proposta cai em exatamente uma folha, e o caminho até ela é a explicação completa da previsão.

O QUE ESTÁ NA TELA

Uma árvore de duas divisões com todas as partes rotuladas. O diagrama é o mesmo que será usado em todo o capítulo.

PARA DISCUTIR EM AULA

Qual é a profundidade desta árvore, e quantas caixas um caso atravessa da raiz até a folha?

A SEGUIR Falta o critério que escolhe a regra de cada nó.

5.4 Impureza: uma medida de quanto o grupo está misturado

essencial, vista em aula · 8 min

Impureza é máxima quando o grupo está meio a meio e zero quando todos têm o mesmo desfecho, e é a quantidade que a divisão tenta reduzir.

IMPUREZA · QUANTO O GRUPO ESTÁ MISTURADO · GINI E ENTROPIA

Máxima meio a meio, zero quando todos têm o mesmo desfecho. É a quantidade que a divisão tenta reduzir.

0% 10% 50% 90%

Proporção de defaults 50%: Gini 0,5000, entropia 1,0000 bits. Grupo máximo em impureza. É o ponto de partida da raiz nesta base.

Proporção de defaults no grupo

50%

GINI


0,5000

ENTROPIA, EM BITS

1,0000


$Gini = 2 \times p \times (1 - p)$ · entropia = $-p \times \log_2(p) - (1 - p) \times \log_2(1 - p)$

Como ler o Gini sorteie uma proposta e um rótulo com a mesma proporção: a área rosa é a chance de erro



erro = $2 \times p \times (1 - p) = 50,0\%$

Impureza em função da proporção Gini cheio, entropia tracejada

**COMO LER O GINI**

É a probabilidade de errar ao classificar uma proposta sorteada do grupo usando um rótulo sorteado com a mesma proporção. Grupo puro: nunca erra, Gini zero. Grupo meio a meio: erra metade das vezes, Gini 0,5.

Gini é a que este curso usa, por ser a que aparece na maioria das implementações e por dispensar logaritmo. A entropia produz árvores quase sempre idênticas nesta base.

Página 5.4, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O QUE O GINI MEDE

Um grupo tem 10% de defaults e outro tem 90%. Como os dois se comparam em Gini?

- a. O grupo de 10% tem Gini muito menor, porque o risco dele é menor
- b. Os dois têm exatamente o mesmo Gini, 0,18, porque a medida é simétrica e mede mistura, não nível de risco
- c. O grupo de 90% tem Gini 0,90, porque a impureza acompanha a proporção de defaults

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Um controle para a proporção de defaults no grupo, de 0% a 100%, com atalhos em 0%, 10%, 50% e 90%, e duas medidas recalculadas: Gini e entropia em bits. Em 50%, Gini 0,5000 e entropia 1,0000, o máximo das duas e o ponto de partida da raiz nesta base. Em 0% e em 100%, as duas zeram. Em 10% de defaults, Gini 0,18 e entropia 0,469; em 90%, o mesmo Gini, porque a medida é simétrica. As duas curvas em forma de morro mostram isso à direita: Gini cheio, entropia tracejada. O quadrado da esquerda ensina a ler o Gini: sorteie uma proposta do grupo e um rótulo com a mesma proporção; a área rosa é a chance de errar, $2 \times p \times (1 - p)$. Grupo puro nunca erra; grupo meio a meio erra metade das vezes. Baixa impureza não significa risco baixo: significa homogeneidade. O curso usa Gini, por aparecer na maioria das implementações e dispensar logaritmo; a entropia produz árvores quase sempre idênticas.

O QUE ESTÁ NA TELA

Mova a composição do grupo e acompanhe as duas medidas mais usadas. A escolha entre elas raramente muda a árvore.

PARA DISCUTIR EM AULA

Um grupo com 90% de defaults é puro?

A SEGUIR Com a medida definida, é possível pontuar um corte.

5.5

Impureza na raiz

complementar, de estudo · 9 min

Interpretar o Gini como mistura de desfechos dentro de um nó.

O GINI DA RAIZ, CALCULADO À MÃO · A REFERÊNCIA CONTRA A QUAL TODO GANHO SERÁ MEDIDO

Uma conta de duas linhas sobre as dezesseis propostas. Ela é a referência do capítulo inteiro.

raiz

folha pura

folha mista

A raiz: as 16 propostas: 8 defaults em 16 propostas, $p = 0,5000$, $Gini = 2 \times 0,500 \times 0,500 = 0,50000$. Metade default, metade não default: máxima mistura.

O grupo

D marca default, ✓ marca quem pagou

D D D D D D D D ✓ ✓ ✓ ✓ ✓ ✓ ✓ ✓

8 D e 8 ✓ · $p = 8 \div 16 = 0,5000$
 $Gini = 2 \times p \times (1 - p) = 0,50000$

PROPOSTAS NO GRUPO	16
DEFAULTS	8
PROPORÇÃO P	$8 \div 16 = 0,5000$
$GINI = 2 \times P \times (1 - P)$	$2 \times 0,500 \times 0,500 = 0,50000$

$Gini(t) = 2 \times p(t) \times (1 - p(t))$

Na raiz, 0,5 é o valor máximo que o Gini pode assumir com alvo binário. Esta base foi construída assim de propósito, para que os ganhos apareçam com números redondos. Em carteira real com 10% de default, o Gini da raiz seria 0,1800.

#	UTIL.	ATRASSO	DEFAULT?
1	20%	25 d	não
2	25%	20 d	sim
3	30%	5 d	não
4	35%	10 d	não
5	40%	20 d	não
6	45%	0 d	não
7	50%	0 d	não
8	55%	5 d	não
9	60%	20 d	sim
10	65%	0 d	sim
11	70%	5 d	sim
12	75%	40 d	sim
13	80%	5 d	sim
14	85%	30 d	sim
15	90%	0 d	não
16	95%	20 d	sim

Confira: conte os sim na última coluna.

O QUE SIGNIFICA REDUZIR A IMPUREZA

Uma divisão reduz a impureza quando produz dois grupos mais homogêneos que o grupo original. O ganho é a diferença entre a impureza antes e a média ponderada das impurezas depois. Ponderada pelo tamanho, porque um grupo de doze pesa mais que um de quatro.

Página 5.5, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Três botões: raiz, folha pura e folha mista. Na raiz, as 16 propostas em caixas, D para default e ✓ para quem pagou: 8 D e 8 ✓, $p = 8 \div 16 = 0,5$, $Gini = 2 \times 0,5 \times 0,5 = 0,50000$, a mistura máxima. A folha pura, utilização entre 27,5% e 57,5%, tem 0 defaults em 6 e Gini zero: uma divisão ali não teria o que reduzir. A folha mista, utilização acima de 87,5%, tem 1 default em 2 e Gini 0,5 de novo, mas com peso 2 em 16. A tabela da direita lista as dezesseis propostas com utilização, atraso e desfecho; confira contando os sim na última coluna. Reduzir a impureza é produzir dois grupos mais homogêneos que o original; o ganho é a diferença entre a impureza antes e a média ponderada das impurezas depois, ponderada pelo tamanho. Esta base foi construída meio a meio de propósito; em carteira real com 10% de default, o Gini da raiz seria 0,18.

O QUE ESTÁ NA TELA

Compare a raiz, uma folha pura e uma folha mista. A árvore procura cortes que reduzam essa mistura.

PARA PENSAR NO ESTUDO

O Gini da raiz depende de quais variáveis existem?

A SEGUIR Agora um corte candidato, avaliado com essa referência.


Prof. Genaro Dueire Lins · FGV · 2026

10 de 31

5.6 Avaliar um corte candidato

complementar, de estudo · 10 min

Um corte é avaliado pela redução da impureza que produz, ponderada pelo tamanho dos dois grupos resultantes.



Página 5.6, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · GANHO DE UMA DIVISÃO

Um corte deixa uma única proposta de um lado, com Gini zero, e quinze do outro, com sete defaults. Esse corte tem ganho alto?

- Sim, porque um dos lados ficou completamente puro
- Não, porque a média das impurezas é ponderada pelo tamanho e o lado puro pesa apenas um de dezesseis
- Não é possível avaliar sem conhecer o Gini da raiz

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Escolha a variável, utilização do limite ou maior atraso em 6 meses, e mova o ponto de corte: o controle percorre apenas os pontos médios entre valores consecutivos observados, porque qualquer valor entre dois vizinhos produz a mesma divisão. No exemplo, utilização $\leq 62,5\%$. Lado esquerdo: 9 propostas, 2 defaults, proporção 22,2%, Gini 0,34568 (#1 a #9). Lado direito: 7 propostas, 6 defaults, 85,7%, Gini 0,24490 (#10 a #16). A conta do ganho: Gini antes 0,50000; média ponderada depois, $9 \div 16 \times 0,3457 + 7 \div 16 \times 0,2449 = 0,30159$; ganho 0,19841. Positivo, mas existe corte melhor: utilização $\leq 57,5\%$, com 0,28125. As barras comparam antes, esquerda, direita e depois ponderada. Antes de responder à questão, mova o corte para o primeiro candidato, que deixa uma só proposta de um lado, e observe o que a ponderação pelo tamanho faz com um lado perfeitamente puro.

O QUE ESTÁ NA TELA

Escolha a variável e o ponto de corte. Todas as contas aparecem, inclusive quais propostas foram para cada lado.

PARA PENSAR NO ESTUDO

Existe corte com ganho negativo?

A SEGUIR Testar um por um é exatamente o que o algoritmo faz, e ele faz depressa.

5.7 A disputa entre os cortes da raiz

essencial, vista em aula · 10 min

Comparar candidatos pela redução ponderada de impureza, não pela aparência do diagrama.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Deixe a árvore crescer. Cada corte é o vencedor de uma disputa.

Deixar a árvore crescer

Árvore de referência

Plano das variáveis 2 folhas · clique numa proposta para retirá-la

● deu default ● pagou ○ retirada da base
■ corte candidato em avaliação

A árvore 2 folhas · profundidade 1

Profundidade máxima 1

Mínimo de propostas por folha 1

Proposta retirada da base
nenhuma, base completa

RAIZ ESCOLHIDA
utilização ≤ 57,5%
ganho 0,28125

DIVISÃO DO NÓ DIREITO
folha
sem corte neste nível

FOLHAS · ERROS NAS 16
2 · 2
menor folha com 8 propostas

PIOR INTERVALO DE FOLHA
45%
largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato os candidatos são os pontos médios entre valores consecutivos

Utilização do limite

Maior atraso em 6 meses

Ponto de corte utilização ≤ 62,5%

LADO	PROPOSTAS	DEFAULTS	PROPORÇÃO	GINI
≤ CORTE	9	2	22,2%	0,34568
> CORTE	7	6	85,7%	0,24490
GANHO	0,50000 – (9 + 16 × 0,3457 + 7 + 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125			

A disputa: ganho de cada candidato vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 62,5% com 0,198

Página 5.7, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

Prof. Genaro Dueire Lins · FGV · 2026

12 de 31

QUESTÃO · AS DUAS MARGENS DA RAIZ

Na raiz, utilização $\leq 57,5\%$ vence com ganho 0,28125. O corte vizinho, utilização $\leq 52,5\%$, fica em 0,19841, e o melhor corte de atraso fica em 0,07143. O que essas duas margens dizem?

- Que a escolha da variável é estável e a do ponto de corte não: a margem sobre o atraso é de quase quatro vezes, e sobre o corte vizinho é de 1,4 vez
- Que a árvore deveria usar os dois cortes de utilização na raiz, já que os dois têm ganho alto
- Que existe um ótimo matemático em 57,5%, encontrado derivando a função de ganho

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As dezesseis propostas no plano utilização por atraso, a árvore ao lado e, embaixo, a disputa: uma barra por corte candidato, azul para utilização e laranja para atraso, com altura igual ao ganho. O vencedor é utilização $\leq 57,5\%$, com redução de Gini de 0,281; ele parte a base em 8 casos com 1 default e 8 casos com 7 defaults. O segundo colocado é o corte vizinho, utilização $\leq 52,5\%$, com 0,198; o melhor corte de atraso fica em 0,071, quase quatro vezes atrás. O bloco de avaliação repete a conta da página anterior para qualquer candidato. O botão Deixar a árvore crescer acrescenta um nível por segundo, até a profundidade 3; profundidade máxima, mínimo por folha e proposta retirada são o assunto das páginas 14 e 16. O perfil irregular das barras diz o essencial: não há fórmula fechada nem gradiente; a árvore avalia todos os candidatos e fica com o maior ganho. Leia duas margens. Sobre o atraso, folgada: a variável da raiz é estável. Sobre o vizinho, apertada: o ponto exato do corte depende de poucas propostas.

O QUE ESTÁ NA TELA

Abra três candidatos. O vencedor é aquele que deixa os dois lados mais homogêneos.

PARA DISCUTIR EM AULA

O que acontece se o primeiro e o segundo colocados tiverem ganhos quase iguais?


A SEGUIR Escolhido o vencedor, ele vira a raiz.

5.8

A raiz escolhida, e o que ela já resolve

complementar, de estudo · 8 min

Uma única divisão já separa a base em dois grupos com taxas de default muito diferentes, e o que sobra em cada lado é o problema seguinte.



Página 5.8, como aparece na plataforma.

COMO LER ESTA PÁGINA

A raiz em utilização ≤ 57,5% e seus dois lados. Esquerda: #1 a #8, 1 default em 8, taxa 12,5%, Gini 0,21875. Direita: #9 a #16, 7 defaults em 8, taxa 87,5%, Gini 0,21875. A conferência independente confirma o corte em três fontes: núcleo do navegador, gerador em Python e scikit-learn com profundidade 1. A dispersão destaca as duas exceções. A #2 está no grupo bom e deu default; a #15 está no grupo ruim e pagou. Uma divisão só não dá conta delas, e a tentação é continuar dividindo até dar, o que o capítulo 2 já mostrou aonde leva. Uma única divisão levou a taxa de 50% para 12,5% e 87,5%. Para ordenar, isso é muito bom. Para decidir, falta saber quanto se pode confiar em cada taxa: a de 12,5% está sustentada por oito propostas, e a página 13 calcula o intervalo. O que sobra em cada lado é o problema seguinte.

O QUE ESTÁ NA TELA

Utilização em 57,5%. Duas propostas ficam do lado errado, e elas serão o tema do resto do capítulo.

PARA PENSAR NO ESTUDO

Uma divisão que leva a taxa de 50% para 12,5% e 87,5% é boa?

A **SEGUIR** Dentro de cada lado, a mesma pergunta de novo.

5.9

Recursão: a busca recomeça em cada lado

complementar, de estudo · 9 min

Entender que cada nó filho resolve um problema local com apenas os casos que chegaram até ele.

RECURSÃO · A BUSCA DO NÍVEL 2 · 8 PROPOSTAS DE CADA VEZ · NADA DE NOVO

Depois da primeira divisão, cada lado vira um problema independente, com a mesma busca exaustiva.

lado esquerdo

lado direito

Nó esquerdo, utilização ≤ 57,5%: 8 propostas e 1 default, Gini 0,21875. Vence utilização ≤ 27,5% com ganho local 0,09375, novas folhas com 2 e 6 casos. A busca recomeça somente com os casos deste nó.

NÓ ESQUERDO: UTILIZAÇÃO ≤ 57,5%

Gini deste nó 0,21875, com 1 default em 8 propostas

utilização ≤ 27,5% · ganho 0,094

VARIÁVEL	CORTE	ESQ / DIR	GANHO
UTILIZAÇÃO	27,5	2 / 6	0,09375
UTILIZAÇÃO	32,5	3 / 5	0,05208
ATRASSO	15,0	5 / 3	0,05208
UTILIZAÇÃO	37,5	4 / 4	0,03125

NÓ DIREITO: UTILIZAÇÃO > 57,5%

Gini deste nó 0,21875, com 7 defaults em 8 propostas

utilização ≤ 87,5% · ganho 0,094

VARIÁVEL	CORTE	ESQ / DIR	GANHO
UTILIZAÇÃO	87,5	6 / 2	0,09375
ATRASSO	2,5	2 / 6	0,09375
UTILIZAÇÃO	82,5	5 / 3	0,05208
UTILIZAÇÃO	77,5	4 / 4	0,03125

DUAS PROPRIEDADES DA RECURSÃO

A variável da raiz pode ser escolhida de novo, com outro ponto de corte, e é o que acontece nos dois lados desta base. E a melhor divisão de um lado é escolhida sem nenhuma consideração sobre o outro: a busca é local, nó a nó.

O CUSTO DE SER LOCAL

A árvore é construída de forma gulosa. Ela escolhe o melhor corte agora, sem verificar se um corte pior agora permitiria dois cortes muito melhores depois. Não existe garantia de que a árvore encontrada seja a melhor árvore possível com aquela profundidade.

Página 5.9, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois painéis, um por lado da raiz, com botões para alternar. Cada um mostra o plano com os oito casos do nó, os quatro melhores candidatos e o corte escolhido. Nó esquerdo, utilização ≤ 57,5%: 1 default em 8, Gini 0,21875; vence utilização ≤ 27,5%, com ganho local 0,09375 e novas folhas de 2 e 6 casos. Nó direito, utilização > 57,5%: 7 defaults em 8, Gini 0,21875; utilização ≤ 87,5% e atraso ≤ 2,5 dias empatam em 0,09375, e a ordem de avaliação decide pela utilização. Recursão significa repetir a mesma pergunta: qual corte reduz mais a mistura aqui dentro? A busca recomeça somente com os casos deste nó. Duas propriedades: a variável da raiz pode ser escolhida de novo, como acontece nos dois lados; e a melhor divisão de um lado é escolhida sem consideração sobre o outro. O custo de ser local: a árvore é gulosa, escolhe o melhor corte agora sem verificar se um corte pior permitiria dois muito melhores depois.

Prof. Genaro Dueire Lins · FGV · 2026

15 de 31

O QUE ESTÁ NA TELA

Alterne os dois lados da raiz e veja como a mesma varredura produz regras diferentes.

PARA PENSAR NO ESTUDO

A árvore encontrada é a melhor árvore de profundidade 2 possível?

A SEGUIR Executada a recursão, a árvore está completa.

5.10 Uma proposta dentro da árvore

essencial, vista em aula · 9 min

Seguir um caso concreto e interpretar a taxa da folha junto com seu tamanho.

1	2	3	4
Proposta #15 Utilização 90% atraso 0 dia observado: não default	Utilização > 57,5%? Sim. Segue para o ramo direito.	Utilização > 87,5%? Sim. Entra na folha extrema.	Folha 1 default em 2 PD observada: 50% IC 95%: 9,5% a 90,5%
Por que não é 100%? #15: não default · #16: default. O caminho é auditável, mas $n=2$ produz uma estimativa instável; profundidade, folha mínima e validação continuam necessários.			
Quanto esta folha autoriza a afirmar A taxa é 50%, e o intervalo de 95% vai de 9,5% a 90,5% : 81 pontos de largura. Com duas propostas, a folha não distingue um grupo excelente de um grupo péssimo. Taxa da folha sem o n da folha não é informação.			

Página 5.10, como aparece na plataforma.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · O QUE A FOLHA AUTORIZA**

A proposta #15 chega a uma folha com duas propostas, uma delas em default. O que essa folha autoriza a afirmar?

- Que a #15 deu default, já que caiu numa folha de risco 50%
- Que a taxa observada daquele grupo é 50%, com intervalo de 9,5% a 90,5%: com duas propostas a folha não distingue um grupo excelente de um péssimo
- Que o risco do grupo é 50%, e esse é o melhor número disponível para decidir

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A proposta #15 da base didática: utilização 90%, atraso 0 dia, desfecho observado não default. Siga o caminho. Utilização acima de 57,5%? Sim, ramo direito. Utilização acima de 87,5%? Sim, folha extrema. A folha tem 1 default em 2, PD observada de 50%. Antes de olhar a explicação, pergunte-se por que não é 100%. A folha tem duas propostas: a #15, que não deu default, e a #16, que deu; a frequência é a contagem dos rótulos, 1 em 2. O caminho é auditável, mas $n = 2$ produz uma estimativa instável. A taxa da folha explica a árvore, e não diz nada sobre o desfecho individual de quem está nela: a #15 pagou e recebe 50%. Profundidade, folha mínima e validação continuam necessários. Este caso #15 não é o cliente VAL-0187 usado na comparação posterior; é a base de 16 propostas.

O QUE ESTÁ NA TELA

Este é o caso #15 da base didática de 16 propostas. Ele não é o cliente VAL-0187 usado na comparação posterior.

PARA DISCUTIR EM AULA

A proposta #15 deu default? E o que esta folha autoriza a afirmar sobre o risco do grupo?

A SEGUIR A taxa da folha explica a árvore; agora precisamos testar se ela generaliza.

5.11

Percorrer a árvore: a explicação completa de uma decisão

complementar, de estudo · 9 min

O caminho da raiz até a folha é a justificativa integral da previsão de uma proposta, e pode ser lido por qualquer pessoa.

PERCORRER A ÁRVORE · A EXPLICAÇÃO COMPLETA DE UMA DECISÃO · REGRA POR REGRA

O caminho da raiz até a folha é a justificativa integral da previsão, e qualquer pessoa consegue ler.

#3

#8

proposta nova

#16

Utilização 72% e atraso 8 dias: Utilização do limite ≤ 57,5%? não; Utilização do limite ≤ 87,5%? sim. Folha com 6 de 6: PD 100,0%. A logística do capítulo 4 estima 69,3% para a mesma proposta.

Utilização do limite72%

Maior atraso em 6 meses8 dias

PASSO	PERGUNTA	VALOR	RESPOSTA	VAI PARA
1	Utilização do limite ≤ 57,5%?	72,0%	não	nó com 8 propostas
2	Utilização do limite ≤ 87,5%?	72,0%	sim	nó com 6 propostas

PD DA FOLHA100,0%

BASE DA FOLHA6 / 6
defaults observados sobre propostas

Onde a proposta cai

as quatro regiões da árvore e o ponto

O caminho aceso

as caixas atravessadas ficam em destaque

Compare com a logística do capítulo 4, que para a mesma proposta estima **69,3%**. As duas famílias discordam, e o capítulo 7 define com qual critério se decide entre elas.

Página 5.11, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois controles, utilização (10% a 100%) e atraso (0 a 45 dias), e quatro atalhos: #3, #8, proposta nova e #16. Para a proposta nova, utilização 72% e atraso 8 dias, a tabela de passos escreve a decisão de cada bifurcação. Passo 1: utilização ≤ 57,5%? Valor 72,0, não, vai para o nó com 8 propostas. Passo 2: utilização ≤ 87,5%? Sim, vai para o nó com 6 propostas. PD da folha 100,0%, base da folha 6 de 6 defaults. O diagrama acende as caixas atravessadas. A logística do capítulo 4 estima 69,3% para a mesma proposta: as duas famílias discordam, e o capítulo 7 define o critério para escolher. Mova o atraso e note que, neste caminho, ele nem é consultado; só a utilização decide. A árvore dá o mesmo valor a todos da folha; a logística varia continuamente, e perto das fronteiras a discordância é máxima. O caminho é a justificativa integral da previsão, legível por qualquer pessoa.

Prof. Genaro Dueire Lins · FGV · 2026

17 de 31

O QUE ESTÁ NA TELA

Escolha os valores e veja o caminho aceso, regra por regra, com a decisão de cada bifurcação escrita.

PARA PENSAR NO ESTUDO

Por que a árvore e a logística discordam nesta proposta?

A SEGUIR A folha devolve uma taxa. De onde vem essa taxa?

5.12 A previsão da folha é a frequência da folha, e isso não é convenção complementar, de estudo · 9 min

O valor que minimiza a log loss dentro de um grupo é a proporção observada nesse grupo, o mesmo resultado obtido no capítulo 2.

UMA FOLHA DESTA ÁRVORE: 1 DEFAULT EM 2 PROPOSTAS

VALOR ATRIBUÍDO À FOLHA	PERDA MÉDIA NA FOLHA
10,0%	1,20397
25,0%	0,83699
50,0%	0,69315
75,0%	0,83699
90,0%	1,20397

O mínimo está exatamente na frequência observada, $1 \div 2 = 50,0\%$. Não foi escolhido: foi calculado. [RECALCULADO AQUI](#)

Três aparições do mesmo resultado

Capítulo 2, escolhendo a PD constante de um grupo. Aqui, definindo o valor de cada folha. Capítulo 6, definindo o ponto de partida do boosting. É sempre a mesma conta, e é por isso que o capítulo de fundamentos não era digressão.

— perda dentro da folha

log loss

mínimo em 50,0%

valor atribuído à folha

Consequência para calibração

Se a folha devolve a frequência observada, a árvore é calibrada por construção na amostra de treino. Isso não garante calibração fora do tempo, e o capítulo 7 mostra a diferença entre as duas coisas.

E quando a folha é pura

Uma folha com zero defaults devolve PD de 0%, e uma com todos devolve 100%. Na log loss, previsão de 0% sobre um default tem perda infinita. Implementações reais aplicam um piso. O problema de fundo não é numérico: a folha está afirmando certeza que não tem.

Página 5.12, como aparece na plataforma.

COMO LER ESTA PÁGINA

Uma folha desta árvore, 1 default em 2 propostas, e cinco candidatos a valor da folha. Atribuir 10% custa perda média 1,20397; 25%, 0,83699; 50%, 0,69315; 75%, 0,83699; 90%, 1,20397. O mínimo está exatamente na frequência observada, $1 \div 2 = 50\%$. Não foi escolhido: foi calculado, como mostra a curva de log loss abaixo da tabela, com mínimo em 50,0%. É o mesmo resultado da página 11 do capítulo 2, quando se escolheu a PD constante de um grupo, e será o ponto de partida do boosting no capítulo 6. Sempre a mesma conta. Consequência para calibração: se a folha devolve a frequência observada, a árvore é calibrada por construção na amostra de treino, o que não garante calibração fora do tempo. E quando a folha é pura: zero defaults devolvem PD de 0%, e previsão de 0% sobre um default tem perda infinita. Implementações aplicam um piso, mas o problema de fundo é que a folha afirma certeza que não tem.

O QUE ESTÁ NA TELA

A folha não escolhe um valor arbitrário: ela resolve, dentro do grupo, exatamente o problema de minimização da página 11 do capítulo 2.

PARA PENSAR NO ESTUDO

Por que a curva sobe tão rápido perto de zero?


A SEGUIR Quanto uma folha realmente afirma?

5.13

A confiabilidade de cada folha, calculada

complementar, de estudo · 10 min

A taxa de uma folha é uma estimativa com intervalo, e folhas pequenas produzem intervalos largos demais para sustentar decisão.



Página 5.13, como aparece na plataforma.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

- QUESTÃO · O QUE A FOLHA AFIRMA
- Uma folha tem zero defaults em seis propostas. Qual afirmação se sustenta?
- a. O risco desse grupo é zero, porque nenhuma proposta deu default
 - b. A estimativa pontual é 0% e o intervalo de 95% vai até 39,0%, então o nível de risco não está determinado
 - c. Como o intervalo desta folha não encosta no da folha de 100%, está provado que as duas têm risco diferente

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As quatro folhas da árvore com intervalo de Wilson a 95%. Folha 1: $n = 2$, 1 default, PD 50%, intervalo de 9,5% a 90,5%, largura 81,1%. Folha 2: $n = 6$, 0 defaults, 0%, intervalo de 0% a 39,0%. Folha 3: $n = 6$, 6 defaults, 100%, de 61,0% a 100%. Folha 4: igual à primeira. Compare a largura de cada barra com a distância entre as folhas: as barras se sobrepõem, e com dezesseis propostas a árvore separa visualmente e não separa estatisticamente. Uma folha com a mesma taxa de 0% e 600 propostas teria intervalo de 0% a 0,6%: mesmo número de PD, evidência incomparável. O tamanho mínimo de folha existe por isso, não por estética. Sobreposição de intervalos, porém, não é teste de diferença; o teste para comparar duas proporções está no capítulo 7. Antes de responder à questão sobre a folha de zero defaults, olhe o limite superior do intervalo dela.

O QUE ESTÁ NA TELA

As quatro folhas da árvore, com intervalo de Wilson a 95%. Compare a largura com a distância entre as folhas.

PARA PENSAR NO ESTUDO

A folha de 0% prova que aquele grupo não dá default?

A SEGUIR *Se folhas pequenas não afirmam nada, é preciso impedir que elas apareçam.*

5.14

Os dois freios: profundidade e mínimo de casos por folha

complementar, de estudo · 10 min

Profundidade limita quantas perguntas se pode fazer e o mínimo por folha limita quão pequeno um grupo pode ficar, e os dois são hiperparâmetros.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Ajuste os dois freios e veja a árvore obedecer.

Plano das variáveis 4 folhas · clique numa proposta para retirá-la

maior atraso em 6 meses, dias

utilização do limite

● deu default ● pagou ○ retirada da base

Deixar a árvore crescer

Árvore de referência

A árvore 4 folhas · profundidade 2

Utilização do limite ≤ 57,5% ? · ganho 0,281

sim não

Utilização do limite ≤ 27,5% ? · ganho 0,094

sim não

Utilização do limite ≤ 87,5% ? · ganho 0,094

sim não

2 prop. · 1 def. PD 50%

6 prop. · 0 def. PD 0%

6 prop. · 6 def. PD 100%

2 prop. · 1 def. PD 50%

Profundidade máxima 2

Mínimo de propostas por folha 2

Proposta retirada da base nenhuma, base completa

RAIZ ESCOLHIDA utilização ≤ 57,5% ganho 0,28125

DIVISÃO DO NÓ DIREITO utilização ≤ 87,5% ganho 0,09375

FOLHAS · ERROS NAS 16 4 · 2 menor folha com 2 propostas

PIOR INTERVALO DE FOLHA 81% largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato os candidatos são os pontos médios entre valores consecutivos

Utilização do limite Maior atraso em 6 meses

Ponto de corte utilização ≤ 62,5%

LADO	PROPOSTAS	DEFAULTS	PROPORÇÃO	GINI
≤ CORTE	9	2	22,2%	0,34568
> CORTE	7	6	85,7%	0,24490
GANHO	0,50000 - (9 ÷ 16 × 0,3457 + 7 ÷ 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125			

A disputa: ganho de cada candidato vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 52,5% com 0,198

utilização, em %

atraso, em dias

Página 5.14, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois controles, profundidade máxima (0 a 4) e mínimo de propostas por folha (1 a 4), e quatro contadores: raiz escolhida, divisão do nó direito, folhas e erros nas 16, com a menor folha embaixo, e pior intervalo de folha. Com profundidade 2 e mínimo 2: 4 folhas, 2 erros, menor folha com 2 propostas e pior intervalo com 81% de largura. Nenhuma folha unitária; o erro na amostra não é zero, e isso não é defeito. A árvore ao lado e a partição no plano são reconstruídas a cada movimento. Os dois freios agem por caminhos diferentes: a profundidade impede perguntas adicionais mesmo quando o grupo é grande; o mínimo por folha impede grupos pequenos mesmo quando ainda há profundidade disponível. Leia a menor folha e o pior intervalo, não o erro: o erro na amostra sempre cai com complexidade. Fixe o mínimo em 1 e suba a profundidade até 4; depois mantenha 4 e suba o mínimo. Os dois caminhos levam a árvores diferentes. Os dois são hiperparâmetros, e a escolha é na validação, como no capítulo 2.

O QUE ESTÁ NA TELA

Ajuste os dois e acompanhe a árvore, o número de folhas, a menor folha e o erro na amostra ao mesmo tempo.

PARA PENSAR NO ESTUDO

Qual dos dois freios você usaria em uma carteira de 200 mil propostas?

A SEGUIR *Existe uma terceira forma de controlar complexidade, aplicada depois de construir.*

5.15 Poda: crescer primeiro, cortar depois, com um preço por folha

complementar, de estudo · 9 min

A poda por custo de complexidade compara impureza e número de folhas usando um parâmetro que define o preço de cada folha.

PODA · CRESCER PRIMEIRO, CORTAR DEPOIS · UM PREÇO POR FOLHA · QUATRO ÁRVORES DA MESMA BASE


Mova o preço da folha e veja qual árvore vence. A de quatro folhas nunca vence, para nenhum α .

 $\alpha = 0,00$ $\alpha = 0,03$ $\alpha = 0,10$ $\alpha = 0,30$

$\alpha = 0,030$: vence profundidade 3, folhas de 1, com custo 0,18000. Pontos de troca: $\alpha = 0,0547$ entre seis e duas folhas, e $\alpha = 0,2813$ entre duas folhas e a raiz. A árvore de quatro folhas não vence em nenhum ponto.

Preço de cada folha, α

0,030




ÁRVORE	FOLHAS	IMPUREZA	$\alpha \times$ FOLHAS	CUSTO
● SÓ A RAIZ	1	0,50000	0,03000	0,53000
● PROFUNDIDADE 1	2	0,21875	0,06000	0,27875
● PROFUNDIDADE 2	4	0,12500	0,12000	0,24500
● PROFUNDIDADE 3, FOLHAS DE 1	6	0,00000	0,18000	0,18000

$$\text{custo}(T) = \text{impureza ponderada de } T + \alpha \times \text{número de folhas de } T$$

Com α igual a zero, a árvore mais complexa sempre vence. Com α muito alto, a raiz sozinha vence. Entre os dois extremos existe uma sequência de árvores, e a poda percorre essa sequência.

Custo de cada árvore em função de α a vencedora é a linha mais baixa em cada ponto



UM RESULTADO QUE SURPREENDE

Nesta base, a árvore de quatro folhas nunca vence, para nenhum valor de α . A sequência de podas salta de seis folhas direto para duas. Isso acontece porque a redução de impureza do último nível é desproporcional à do penúltimo, e é a razão pela qual a poda é feita por elo mais fraco e não testando profundidades.

Em prática, α é escolhido por validação cruzada, como qualquer hiperparâmetro. Escolhê-lo pelo desempenho na amostra de treino reproduz o problema do capítulo 2.

Página 5.15, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Quatro árvores da mesma base avaliadas pelo mesmo critério: custo = impureza ponderada + $\alpha \times$ número de folhas. Só a raiz: 1 folha, impureza 0,50000. Profundidade 1: 2 folhas, 0,21875. Profundidade 2: 4 folhas, 0,12500. Profundidade 3 com folhas de 1: 6 folhas, 0,00000. Mova o preço de cada folha, α , de 0 a 0,35, com atalhos em 0, 0,03, 0,10 e 0,30. Com $\alpha = 0,030$ vence a árvore de seis folhas, custo 0,18000. Os pontos de troca são $\alpha = 0,0547$, entre seis e duas folhas, e $\alpha = 0,2813$, entre duas folhas e a raiz. No gráfico, cada árvore é uma reta com inclinação igual ao número de folhas, e vence a linha mais baixa. Um resultado que surpreende: a árvore de quatro folhas nunca vence, para nenhum α ; a poda salta de seis folhas direto para duas, porque a redução de impureza do último nível é desproporcional à do penúltimo. É por isso que a poda é feita por elo mais fraco.

O QUE ESTÁ NA TELA

Quatro árvores da mesma base, avaliadas pelo mesmo critério. Mova o preço da folha e veja qual vence.

PARA PENSAR NO ESTUDO

Por que as linhas do gráfico são retas?

A SEGUIR Falta olhar a estabilidade da estrutura.

5.16

Instabilidade: uma observação pode trocar a estrutura

complementar, de estudo · 8 min

Quando dois cortes candidatos têm ganhos próximos, remover uma única observação pode mudar a variável escolhida, e a árvore resultante parece outro modelo.

A ÁRVORE QUE CRESCE · GINI · 16 PROPOSTAS DIDÁTICAS

Retire uma proposta. A raiz resiste; o nó direito, não.

Plano das variáveis

4 folhas · clique numa proposta para retirá-la

Deixar a árvore crescer

Árvore de referência

A árvore

4 folhas · profundidade 2

Profundidade máxima

2

Mínimo de propostas por folha

1

Proposta retirada da base

nenhuma, base completa

RAIZ ESCOLHIDA

utilização ≤ 57,5%

ganho 0,28125 · igual à base completa

DIVISÃO DO NÓ DIREITO

utilização ≤ 87,5%

ganho 0,09375 · igual à base completa

FOLHAS · ERROS NAS 16

4 · 2

menor folha com 2 propostas

PIOR INTERVALO DE FOLHA

81%

largura do intervalo de Wilson a 95% na folha menos confiável

Avaliar um corte candidato

os candidatos são os pontos médios entre valores consecutivos

Utilização do limite

Maior atraso em 6 meses

Ponto de corte

utilização ≤ 62,5%

LADO	PROPOSTAS	DEFAULTS	PROPORÇÃO	GINI
≤ CORTE	9	2	22,2%	0,34568
> CORTE	7	6	85,7%	0,24490
GANHO	0,50000 - (9 ÷ 16 × 0,3457 + 7 ÷ 16 × 0,2449) = 0,19841 · o melhor é utilização ≤ 57,5% com 0,28125			

A disputa: ganho de cada candidato

vencedor utilização ≤ 57,5% com 0,281 · segundo utilização ≤ 52,5% com 0,198

Página 5.16, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · EMPATE DE GANHO

No nó direito desta base, os dois melhores cortes empatam em ganho de 0,09375. O que isso indica?

- a. Que os dois são equivalentes e a escolha não tem consequência
- b. Que a escolha é decidida por desempate de implementação e que pequena mudança na amostra pode inverter a variável do nó
- c. Que o nó não deveria ser dividido, porque o critério não distingue os candidatos

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Retirar uma proposta da base recalcula a raiz, o nó direito e a árvore inteira. Com a base completa, a raiz é utilização $\leq 57,5\%$, ganho 0,28125, e o nó direito é utilização $\leq 87,5\%$, ganho 0,09375: a árvore de referência do capítulo. Percorra a lista e observe os dois contadores: a raiz resiste a qualquer retirada; o nó direito não. Na raiz, o vencedor tem 0,28125, o corte vizinho 0,19841 e o melhor corte de atraso 0,07143; sem a #8 ou a #9, muda o ponto médio, não a divisão. No nó direito, os dois primeiros empatam exatamente em 0,09375, e o empate é decidido pela ordem de avaliação. Retirar a #10 troca a variável do nó de utilização para atraso. Instabilidade de estrutura não é o mesmo que instabilidade de previsão: duas árvores com variáveis diferentes podem produzir PDs parecidas. O que se perde é a leitura, a explicação da decisão que muda de um mês para o outro, com consequência em governança e na comunicação com o cliente. Responda à questão sobre o empate antes de mover o controle.

O QUE ESTÁ NA TELA

Retire uma proposta e observe a raiz e o nó direito.
A raiz resiste, e o nó direito não.

PARA PENSAR NO ESTUDO

Instabilidade de estrutura invalida o modelo?

A SEGUIR *Falta comparar as duas famílias com honestidade.*

5.17

Gini ou entropia: o critério não muda a conclusão aqui

complementar, de estudo · 8 min

Trocar a medida de impureza raramente muda a árvore, e afirmar que uma é superior exige evidência que geralmente não existe.

VARIÁVEL	MELHOR CORTE POR GINI	GANHO	MELHOR CORTE POR ENTROPIA	GANHO
UTILIZAÇÃO DO LIMITE	57,5	0,28125	57,5	0,45644
MAIOR ATRASO EM 6 MESES	27,5	0,07143	27,5	0,13793
RAIZ ESCOLHIDA	Utilização do limite ≤ 57,5		Utilização do limite ≤ 57,5	

Os ganhos têm escalas diferentes, porque a entropia é medida em bits e o Gini não. Comparar os valores absolutos entre as duas colunas não tem significado. O que se compara é o corte escolhido. [RECALCULADO AQUI](#)

Uma ressalva que a tabela esconde: por Gini, os cortes de atraso em 15 e em 27,5 dias empatam exatamente em 0,07143, e o critério não escolhe entre eles. Quem desempata é a entropia, que prefere 27,5. A raiz não muda por isso: utilização vence pelos dois critérios, com margem de quase quatro vezes.

QUANDO A ESCOLHA DO CRITÉRIO IMPORTA	
QUASE NUNCA	na escolha do corte, porque as duas medidas têm o mesmo formato e os mesmos extremos
ÀS VEZES	em alvos com mais de duas classes, onde a entropia tende a produzir divisões mais equilibradas
SEMPRE	na declaração: um relatório precisa dizer qual critério foi usado, para que a reprodução seja possível

O que realmente muda a árvore

Em ordem de impacto nesta base: a amostra, o mínimo de casos por folha, a profundidade e, muito depois, o critério de impureza. Discussões sobre Gini contra entropia costumam consumir tempo que deveria ser gasto no desenho da base.

Ambos os critérios estão implementados no núcleo deste material e produzem os mesmos valores em Python e no navegador.

Página 5.17, como aparece na plataforma.

COMO LER ESTA PÁGINA

A varredura da raiz refeita com entropia, lado a lado com a de Gini. Utilização: melhor corte 57,5 nas duas, ganho 0,28125 por Gini e 0,45644 por entropia. Atraso: 27,5 nas duas, 0,07143 e 0,13793. Raiz escolhida: utilização ≤ 57,5%, com qualquer dos critérios. Os ganhos têm escalas diferentes, porque a entropia é medida em bits e o Gini em probabilidade de erro; comparar os valores absolutos entre as colunas não tem significado. O que se compara é o corte escolhido. Quando a escolha do critério importa: quase nunca na escolha do corte, porque as duas medidas têm o mesmo formato e os mesmos extremos; às vezes em alvos com mais de duas classes; sempre na declaração, porque um relatório precisa dizer qual critério foi usado para que a reprodução seja possível. O que realmente muda a árvore, em ordem de impacto nesta base: a amostra, o mínimo por folha, a profundidade e, muito depois, o critério.

O QUE ESTÁ NA TELA

A mesma varredura da página 7, refeita com entropia. Compare os vencedores.

PARA PENSAR NO ESTUDO

Por que não comparar os valores de ganho entre os dois critérios?


A SEGUIR A comparação que de fato importa é entre famílias.

5.18

Logística e árvore nos mesmos casos

essencial, vista em aula · 10 min

Comparar como uma fronteira suave e regiões em degraus tratam a mesma proposta.



Página 5.18, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

- QUESTÃO · O QUE A PERDA DE TREINO DECIDE
- Nas dezesseis propostas, a log loss é 0,43282 na logística e 0,18844 na árvore. O que esse par de números decide?
- a. Que a árvore é o melhor modelo nesta base, e por margem larga

b. Nada: as duas foram avaliadas na mesma amostra em que a árvore criou as folhas, e perda de treino desce com qualquer complexidade acrescentada

c. Que a árvore está sobreajustada, e por isso a logística deve ser escolhida

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

As dezesseis propostas no plano, com a reta de PD 50% da logística e as quatro regiões da árvore, cada uma com sua taxa. Clique numa proposta ou use os atalhos #5, #10 e #15. A #5, utilização 40% e atraso 20 dias, pagou: logística 52,6%, árvore 0%, 52,6 pontos de diferença; a reta vê risco moderado, a árvore caiu numa folha sem defaults. A #10, 65% e 0 dias, deu default: 30,5% contra 100%. A #15, 90% e 0 dias, pagou: 73,9% contra 50%. A tabela lista as dezesseis linhas, com discordâncias acima de 35 pontos em rosa. As perdas de treino, log loss 0,43282 da logística contra 0,18844 da árvore, com piso e teto de 2% e 98% nas folhas puras, não decidem nada: a árvore foi avaliada na amostra que usou para criar as folhas. A tabela final resume o que cada família entrega: fronteira reta ou escalonada, PD contínua ou constante por região, estabilidade alta ou baixa. A comparação de verdade está no capítulo 7.

O QUE ESTÁ NA TELA

Use os três atalhos, #5, #10 e #15, ou clique em qualquer proposta do plano. O objetivo é entender o modo de errar de cada família, não proclamar um vencedor.

PARA DISCUTIR EM AULA

Onde as duas famílias mais discordam?

A SEGUIR Se a árvore é instável e a logística é rígida, existe uma terceira via.

5.19 Síntese: regras locais e controle de variância

complementar, de estudo · 9 min

A árvore é uma partição escolhida por busca gulosa, com previsão por frequência na folha e complexidade controlada por hiperparâmetros.

3 IDEIAS PARA LEVAR**A árvore aprende cortes fáceis de explicar e fáceis de sobreajustar.**

1. **Corte.** O que vence a disputa por um nó?
| *O corte que mais reduz a impureza ponderada.*
2. **Folha.** De onde vem a PD?
| *Da frequência observada entre os casos que chegaram à folha.*
3. **Controle.** O que evita folhas frágeis?
| *Profundidade, número mínimo de casos e poda escolhidos fora do treino.*

COMO LER ESTA PÁGINA

Três ideias para levar, uma por botão: Corte, Folha e Controle. A frase à esquerda resume: a árvore aprende cortes fáceis de explicar e fáceis de sobreajustar. O Corte que vence a disputa por um nó é o que mais reduz a impureza ponderada. A Folha devolve a frequência observada entre os casos que chegaram a ela, e essa frequência vale junto com o tamanho da folha. O Controle, com profundidade, número mínimo de casos e poda, é escolhido fora do treino. Antes de clicar, escolha uma das três e explique com suas palavras. Depois aplique as três a dois casos da aula. A #10, default com 65% de utilização e sem atraso, cai numa folha de seis defaults e recebe 100%, onde a reta dava 30,5%. A #15 fica numa folha de duas propostas, com 50%. Qual ideia explica cada caso? O capítulo 6 parte dessa tensão: a logística é rígida, a árvore é instável, e a terceira via soma árvores pequenas.

O QUE ESTÁ NA TELA

Escolha uma ideia e explique com suas próprias palavras antes de revelar a resposta.

PARA PENSAR NO ESTUDO

O que a árvore faz com a #10 e com a #15, e qual ideia explica cada caso?

A SEGUIR A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.

Fecho do capítulo

Antes da próxima aula, você deve conseguir explicar

- **5.1** Ler uma previsão como um caminho verificável da raiz até uma folha.
- **5.3** Cada elemento da árvore tem nome e função, e a profundidade conta divisões, não nós.
- **5.4** Impureza é máxima quando o grupo está meio a meio e zero quando todos têm o mesmo desfecho, e é a quantidade que a divisão tenta reduzir.
- **5.7** Comparar candidatos pela redução ponderada de impureza, não pela aparência do diagrama.
- **5.10** Seguir um caso concreto e interpretar a taxa da folha junto com seu tamanho.
- **5.18** Comparar como uma fronteira suave e regiões em degraus tratam a mesma proposta.

Erros comuns: o que se confunde

#	Erro	Confusão por trás
5.2	Concluir que a árvore é superior	Lê flexibilidade como qualidade sem contabilizar o custo.
5.3	Contar profundidade incluindo a folha	Conta nós em vez de regras.
5.4	Confundir impureza baixa com PD baixa	Lê a medida como nível de risco.
5.5	Achar que Gini 0,5 indica base ruim	Lê impureza máxima como problema.
5.6	Esquecer a ponderação pelo tamanho	Faz a média simples dos dois Ginis.
5.6	Procurar o corte que deixa um lado puro	Persegue pureza em vez de ganho ponderado.
5.7	Achar que a busca é otimização	Imagina que existe gradiente ou fórmula fechada.
5.7	Ignorar a margem	Trata o vencedor como escolha determinada.
5.8	Concluir que o modelo já está pronto	Confunde separação na amostra com capacidade preditiva.
5.9	Achar que cada variável só pode ser usada uma vez	Transfere a intuição de regressão para a árvore.
5.9	Tomar maior ganho no passo por melhor resultado no fim	Confunde ótimo local com ótimo global.
5.10	Ler 100%	Conta dois casos como dois defaults.
5.11	Achar que a árvore usa as duas variáveis sempre	Espera que todo caminho passe por todas as variáveis.
5.12	Achar que o valor da folha é a média das PDs dos clientes	Imagina um modelo dentro da folha.
5.13	Usar sobreposição de intervalos como teste	Trata intervalos individuais como teste de diferença entre grupos.
5.13	Reportar a taxa da folha sem o n	Apresenta estimativa sem evidência.

#	Erro	Confusão por trás
5.14	Otimizar os freios pelo erro na amostra	Usa a amostra de treino para escolher hiperparâmetro.
5.14	Fixar mínimo em número absoluto sem olhar a base	Ignora a proporção que o mínimo representa.
5.15	Escolher α pelo desempenho na amostra de treino	Repete o erro de usar treino para escolher hiperparâmetro.
5.16	Concluir que árvores não servem	Generaliza a partir de uma base de dezesseis.
5.17	Concluir que entropia é melhor por ter ganho maior	Compara valores em escalas distintas.
5.18	Declarar vencedor pela perda de treino	Compara modelos na amostra em que foram estimados.
5.19	Ler os 50% da #15 como risco médio	Toma a frequência de uma folha de duas propostas como estimativa firme.