

LABORATÓRIO DE DECISÃO DE CRÉDITO · AULA 2 · VERSÃO DO ALUNO

06

CAPÍTULO 6 DE 11 · INFOGRÁFICO DE ABERTURA

Gradient boosting com árvores

Como uma sequência de árvores melhora uma previsão?

1 · CORREÇÕES SUCESSIVAS SOBRE O ERRO QUE SOBROU (EXEMPLO DE REGRESSÃO, 8 PONTOS)

1. Palpite inicial

F_0 é a constante que minimiza o critério: a média dos oito valores, 6,50. Erro quadrático médio de 10,1875.

2. Resíduo

O erro vira o novo alvo. Em $x = 8$, observado 12,00 menos previsão 6,50 dá resíduo +5,50: a previsão precisa subir.

3. Árvore rasa

Uma pergunta sobre os resíduos: $x \leq 4,5$? Sim: corrigir -2,875. Não: corrigir +2,875. Agrupa resíduos com direção parecida.

4. Soma com taxa

$F_1 = 6,50 + 0,5 \times 2,875 = 7,94$ em $x = 8$. Com quatro árvores a previsão chega a 10,86 e o erro cai de 5,50 para 1,14.

2 · A FÓRMULA DEPOIS DA HISTÓRIA

$F_{m-1}(x)$

previsão anterior
O que a sequência já aprendeu até a etapa anterior.

η

taxa de aprendizagem
Quanto confiar nesta etapa: somar só um pedaço da correção torna o avanço mais lento e mais estável.

$h_m(x)$

nova correção
Uma árvore rasa ajustada ao erro atual; em classificação, ao resíduo $y - p$.


$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$$

Em crédito a soma acontece em log odds, onde vive o escore da logística; somar probabilidades passaria de 1.

3 · O QUE DECIDE O BOOSTING

Erro quadrático a cada árvore ($\eta = 0,50$)

Redução acumulada de 60,9% com uma árvore e de 90,9% com três:



η e M são acoplados

Árvores necessárias para levar a perda a 0,50:

$\eta = 0,10$	14 árvores ($\eta \times M = 1,40$)
$\eta = 0,20$	7 árvores (1,40)
$\eta = 0,40$	4 árvores (1,60)

Reduzir a taxa exige aumentar o número de árvores na mesma

Fora da amostra é onde se decide

- Mais árvores sempre melhoram o treino; fora do tempo, a partir de certo ponto, pioram.
- No treino desta base, AUC do boosting 0,8196 contra 0,6968 da logística: alarme de flexibilidade.
- Resposta proporcional: early stopping, menor profundidade e folha mínima maior.

TRÊS IDEIAS PARA LEVAR

Resíduo

O que a nova árvore tenta prever? O erro que o conjunto atual ainda comete.

Soma

Onde as correções se acumulam? Em log odds, multiplicadas pela taxa de aprendizagem.

Teste

Onde a complexidade é decidida? Fora da amostra, nunca no treino.

06

CAPÍTULO 6 DE 11 · AULA 2: ENTENDER AS TRÊS TÉCNICAS

Gradient boosting com árvores

*Como uma sequência de árvores melhora uma previsão?***O QUE VOCÊ APRENDE**

Resíduo como negativo do gradiente, árvore ajustada ao resíduo, taxa de aprendizagem, soma no escore, transição para classificação, hiperparâmetros e riscos.

POR QUE IMPORTA

Em vez de uma árvore enorme, é possível somar muitas correções pequenas?

A ATIVIDADE

Avançar o boosting uma árvore por vez e explicar o que cada uma acrescentou.


ANTES DE COMEÇAR

Capítulos 4 e 5: escore em log odds, função de perda e a árvore do capítulo 5, que aqui passa a prever um número.

Onde isto é usado depois. Entra na comparação de modelos do capítulo 7 e na decisão do capítulo 10.

A ideia central

O boosting constrói o modelo por correções sucessivas: começa com um palpite constante, calcula os resíduos (o que faltou explicar), ajusta uma árvore pequena a esses resíduos e soma uma fração dela ao palpite. Repete centenas de vezes. No caso da PD, o palpite e as correções vivem no log odds, exatamente como na logística; a diferença é que cada correção é uma árvore, o que permite não linearidades e interações. A taxa de aprendizado encolhe cada passo e troca velocidade por estabilidade; o número de iterações, a profundidade das árvores e a regularização são os freios. Nenhuma árvore isolada decide: a previsão é a soma, e explicá-la exige mostrar as correções acumuladas.



Cada iteração soma metade do resíduo ao palpite anterior. A previsão se aproxima do observado sem nunca dar o salto inteiro de uma vez.

COMO USAR ESTE MATERIAL

- Cada página traz a captura da plataforma e o texto **Como ler esta página**: o que o visual mostra, como ler e o que levar. Na plataforma os visuais são interativos; mova os controles descritos no texto.
- As 9 páginas essenciais são as vistas em aula; as complementares aprofundam no seu estudo. **Para discutir em aula** é a pergunta que o professor vai fazer.
- Responda às questões antes de abrir a plataforma: lá, cada resposta recebe o diagnóstico. O fecho lista o que você deve conseguir explicar.

O FIO DA AULA 2: ENTENDER AS TRÊS TÉCNICAS

As mesmas 16 propostas atravessam os três capítulos, cada uma com utilização, atraso e desfecho observado. Cada capítulo parte do caso que o anterior deixou em aberto, e a aula termina com as três PDs lado a lado.

Capítulo	A pergunta	Como termina
Capítulo 4 Regressão logística	Como características viram probabilidade?	Nenhuma reta separa a #15, que pagou, da #2, que deu default. O capítulo 5 troca a soma por perguntas sucessivas, nas mesmas 16 propostas.
Capítulo 5 Árvores de decisão	Como perguntas sucessivas dividem a população em grupos de risco?	A árvore acerta a #10, que a reta subestimava, e deixa a #15 numa folha de duas propostas. O capítulo 6 soma árvores pequenas, cada uma corrigindo o que o conjunto ainda erra.
Capítulo 6 Gradient boosting com árvores VOCÊ ESTÁ AQUI	Como uma sequência de árvores melhora uma previsão?	Aula 3, capítulo 7: como escolher entre modelos fora da amostra.

Mapa do capítulo

#	Página	O que ela entrega	min
1	Gradient boosting com árvores	Cada árvore aprende o erro que as anteriores deixaram.	4
2	A divisão de trabalho entre modelos	Selecionar, combinar em paralelo ou corrigir em sequência.	8
3	Oito pontos, uma tendência e erros locais	Prever um número e medir o erro na escala de y.	8
4	F₀: o melhor palpite constante	Em erro quadrático, o melhor valor único é a média.	8
5	O erro como novo alvo	O resíduo, observado menos previsto, é o que a próxima árvore aprende.	9
6	A primeira árvore de correção	Um toco devolve a correção média de cada lado; somada inteira, passa do ponto.	10
7	Taxa de aprendizagem: somar só um pedaço da correção	Cada correção entra multiplicada por η : avanço mais lento e mais estável.	9
8	O que cada árvore acrescentou	Cada árvore corrige uma região; a previsão é a soma das correções.	11
9	Quatro correções, uma previsão	A previsão final é o palpite mais quatro parcelas.	10
10	A fórmula depois da história	Cada termo da equação é uma parte do mecanismo já visto.	8
11	Voltando ao crédito: onde a soma acontece	Em classificação, as árvores somam em log odds, a escala do escore da logística.	9
12	O alvo da próxima árvore é $y - p$	Quem já está bem previsto quase não pesa na correção seguinte.	10

#	Página	O que ela entrega	min
13	Boosting de classificação, iteração por iteração	O mesmo procedimento, em classificação: a perda cai a cada árvore.	10
14	O que cada árvore acrescentou, em log odds	A PD final se decompõe em parcelas rastreáveis, árvore por árvore.	9
15	Os quatro hiperparâmetros	η , árvores, profundidade e mínimo por folha controlam a complexidade juntos.	10
16	η e M são acoplados	Reduzir η pela metade pede o dobro de árvores para o mesmo ajuste.	8
17	Fora da amostra: onde o boosting é decidido	Mais complexidade sempre melhora o treino; fora do tempo, a partir de um ponto, piora.	9
18	Três limites do boosting e como responder	Para cada fragilidade, um sinal e um controle verificável.	9
19	Síntese: pequenas correções formam o boosting	Palpite, correções em log odds e complexidade escolhida fora do treino.	6
20	Três modelos, as mesmas 16 propostas	Os três concordam onde o caso é claro e divergem na fronteira; o treino não decide.	6

Páginas em cinza são complementares: aprofundam no estudo e não entram no tempo de aula (9 essenciais, 73 min).

6.1 Gradient boosting com árvores

essencial, vista em aula · 4 min

*Cada árvore aprende o erro que as anteriores deixaram.***06****O DESAFIO DESTE CAPÍTULO****Um modelo fraco corrige o erro deixado pelo anterior.**

O boosting começa com um palpite simples e soma pequenas correções: a previsão é a soma, não uma árvore isolada.

1 Palpite


O primeiro valor ignora todas as variáveis.

2 Resíduo

O erro vira o alvo da próxima árvore.

3 Soma

A taxa de aprendizagem controla cada correção.



O palpite inicial é a média dos oito valores, 6,5: a mesma previsão para todos, sem olhar para x.

Página 6.1, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A abertura tem duas metades. À esquerda, o desafio do capítulo, um modelo fraco corrige o erro deixado pelo anterior, e as três etapas: palpite, resíduo e soma. À direita, os oito pontos de regressão que o capítulo usa até a página 10. Clique em cada etapa e veja o que ela acende. Palpite: a média dos oito valores, 6,5, a mesma previsão para todos, sem olhar para x. Resíduo: o que sobra de cada ponto até o palpite; em $x = 8$, faltam 5,5, e esse resto vira o alvo da próxima árvore. Soma: quatro árvores rasas somadas com $\eta = 0,5$ levam o erro quadrático médio de 10,19 a 0,45. Repare no que muda em relação ao capítulo 5: lá procurávamos uma árvore boa; aqui cada árvore é deliberadamente fraca e só reduz o que sobrou. O exemplo começa em regressão porque o erro é uma distância visível; a volta ao crédito acontece na página 11.

PARA DISCUTIR EM AULA

Quem já usou boosting? Quem consegue explicar o que a segunda árvore faz?

A SEGUIR A ideia, antes de qualquer fórmula.

6.2 A divisão de trabalho entre modelos

essencial, vista em aula · 8 min

Selecionar, combinar em paralelo ou corrigir em sequência.

A IDEIA · TRÊS ESTRATÉGIAS PARA COMBINAR MODELOS · A TERCEIRA É O BOOSTING

Em vez de procurar um modelo que acerte tudo, somar modelos fracos, cada um treinado no erro do conjunto anterior.

M1M2M3

SELECIONAR UM

Treinar candidatos e ficar com o vencedor. É o que o capítulo 5 fez ao escolher entre profundidades.

Simples e auditável. Descarta toda a informação dos modelos perdedores.

M1M2M3média

COMBINAR EM PARALELO

Modelos independentes, treinados em amostras diferentes, votam ou têm suas previsões médias. Reduz a instabilidade da página 16 do capítulo 5.

Cada modelo tenta resolver o problema inteiro, sozinho. Não há divisão de trabalho.

Fo+h1+h2F

CORRIGIR EM SEQUÊNCIA

Começar com um palpite simples, medir o que sobrou e treinar o modelo seguinte apenas sobre o que sobrou. Repetir.

Cada modelo é deliberadamente fraco e resolve uma fatia pequena. É o boosting.

0. Palpite: previsão para $x = 8$ de 6,50, erro restante 5,50 até o observado 12,00. Para o caso $x = 8$, o modelo inicial prevê a média, 6,50; o observado é 12,00.

A terceira estratégia em ação, sobre os oito pontos o degrau é a previsão acumulada; o traço vertical é o que sobrou para $x = 8$

0. Palpite1. Árvore 12. Árvore 23. Árvore 3

4. Árvore 4

$x = 8$: observado 12,00 - previsão 6,50

ERRO ABSOLUTO RESTANTE PARA $x = 8$

5,50

PASSO	PREVISÃO	ERRO
0. PALPITE	6,50	5,50
1. ÁRVORE 1	7,94	4,06
2. ÁRVORE 2	9,97	2,03
3. ÁRVORE 3	10,35	1,65
4. ÁRVORE 4	10,86	1,14

previsão final = palpite inicial + correção₁ + correção₂ + ... + correção_M

POR QUE FRACO DE PROPÓSITO

Se o primeiro modelo fosse forte, sobraria pouco para os seguintes e o conjunto seria essencialmente ele. A força do método vem de muitas correções pequenas, cada uma difícil de superajustar sozinha.

O RISCO QUE ISSO CRIA

Correções sucessivas no mesmo conjunto de dados acabam acompanhando o ruído daquele conjunto. O boosting não superajusta em uma iteração: ele superajusta na milésima. O controle é o número de iterações, e ele precisa ser escolhido fora da amostra de treino.

Página 6.2, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · ONDE A SEGUNDA ÁRVORE APRENDE

Em um boosting, em que dados a segunda árvore é treinada?

- a. Nos mesmos dados originais, como acontece na média de modelos independentes
- b. Nos resíduos deixados pela primeira, ou seja, no que falta para o modelo atual acertar
- c. Numa reamostragem dos dados originais, sorteada com reposição

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Três cartões, três formas de usar vários modelos. Selecionar um: treinar candidatos e ficar com o vencedor, como o capítulo 5 fez entre profundidades. Combinar em paralelo: modelos independentes votam ou têm a média tirada, cada um tentando resolver o problema inteiro. Corrigir em sequência: começar com um palpite simples, medir o que sobrou e treinar o modelo seguinte só sobre o que sobrou. O terceiro cartão é o boosting. Abaixo, ele roda sobre oito pontos: clique nos passos de 0 a 4 e acompanhe o caso $x = 8$, cujo valor observado é 12,00. A previsão vai de 6,50 (a média) para 7,94, 9,97, 10,35 e 10,86, e o erro restante cai de 5,50 para 1,14. O degrau dourado é a previsão acumulada; o traço vertical é o que ainda falta. A pergunta a guardar: em que dados a segunda árvore é treinada? No resíduo, não nos dados originais. É isso que separa boosting de média de modelos.

O QUE ESTÁ NA TELA

Avance as etapas: o erro de $x = 8$ encolhe a cada correção.

PARA DISCUTIR EM AULA

Se cada correção é pequena, por que a soma seria boa?

A SEGUIR Vamos ver isso acontecer com oito pontos.

6.3 Oito pontos, uma tendência e erros locais

complementar, de estudo · 8 min

Prever um número e medir o erro na escala de y .

REGRESSÃO · OITO PONTOS · PRIMEIRA RODADA

O palpite inicial é a média; o erro de cada ponto é o que sobra dela.

$x = 8, y = 12,0$. Erro inicial: $y - 6,5 = +5,5$. A previsão precisa subir; a próxima árvore tenta explicar esse erro.


PREVISÃO INICIAL

F_0

6,5

a média dos oito valores de y , sem olhar para x

Oito pontos e o palpite constante clique num ponto para ver o erro dele



Página 6.3, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Oito pontos com x de 1 a 8 e uma linha tracejada em $F_0 = 6,5$, a média dos oito valores de y , repetida no quadro ao lado do gráfico. Clique num ponto, ou chegue a ele com Tab e aperte Enter: o gráfico desenha o erro em relação ao palpite, $y - 6,5$, e o quadro de cima dá x , y e o erro. A página abre em $x = 8$: observado 12,0, erro +5,5, e a previsão precisa subir. Em $x = 1$, o observado é 2,0 e o erro, -4,5. A tarefa aqui é regressão: prever um número e medir o erro na mesma escala de y . Faça um teste mental: se a previsão para $x = 8$ fosse 10, o erro seria 2. Em regressão, erro é distância; guarde essa palavra, porque em classificação ela some. Os pontos sobem com x , e uma reta seria tentadora. Não vamos usar reta: vamos usar degraus, somados, porque o bloco de construção do capítulo é a árvore do capítulo 5, adaptada para prever número em vez de classe.

O QUE ESTÁ NA TELA

Clique num ponto para ver o erro dele.

PARA PENSAR NO ESTUDO

Qual é o erro do ponto x igual a 8 se a previsão for 10?

A SEGUIR Antes de qualquer árvore, o palpite mais simples possível.**6.4 Fo: o melhor palpite constante**

complementar, de estudo · 8 min

*Em erro quadrático, o melhor valor único é a média.***UM VALOR PARA OS OITO PONTOS**

VALOR CONSTANTE	ERRO QUADRÁTICO MÉDIO
4,00	16,43750
5,50	11,18750
6,50	10,18750
7,50	11,18750
9,00	16,43750

O mínimo está na média dos oito valores:
 $52,0 \div 8 = 6,50$. Não foi escolhido: foi calculado.

Erro quadrático médio, por valor constante

É o mesmo resultado da PD constante do capítulo 2 e do valor da folha do capítulo 5: o melhor constante é o que minimiza o critério.

Em erro quadrático, o melhor constante é a média; em log loss, é a proporção de defaults.

O que sobra de cada ponto até 6,50 é o resíduo: o alvo da próxima página.

Página 6.4, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Um único valor para os oito pontos: qual? À esquerda, cinco candidatos e o erro quadrático médio de cada um: 4,00 dá 16,4375; 5,50 e 7,50 dão 11,1875; 9,00 dá 16,4375; 6,50, a média, dá 10,1875, o menor, e confere com o gerador em Python. À direita, a curva inteira: uma parábola com fundo em 6,50, porque o erro de qualquer constante c é 10,1875 mais o quadrado da distância entre c e a média. O mínimo não foi escolhido: foi calculado. É o mesmo resultado da PD constante do capítulo 2 e do valor da folha do capítulo 5: o melhor constante é o que minimiza o critério. Em log loss, é a proporção; em erro quadrático, é a média. O critério escolhe o estimador, e não o contrário. O que sobra de cada ponto até 6,50 é o resíduo, o alvo da próxima página.


PARA PENSAR NO ESTUDO

Por que a média e não a mediana?

A SEGUIR O que sobra de cada ponto vira o alvo da próxima árvore.

6.5 O erro como novo alvo

essencial, vista em aula · 9 min

*O resíduo, observado menos previsto, é o que a próxima árvore aprende.***O que sobra de cada ponto** · vermelho: a previsão precisa subir · azul: precisa descer**O NOVO ALVO EM $x = 8$**

$$12,00 - 6,50 = +5,50$$

observado menos previsão atual

Sinal positivo: a previsão precisa subir.

Negativo: precisa descer.

A próxima árvore é ajustada a estes oito resíduos, não a y .Resíduo não é erro final: ele muda a cada árvore somada. Depois de quatro, em $x = 8$ sobram 1,14.

Página 6.5, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · SOMA ZERO É RUÍDO?****Depois de $F_0 = 6,50$, a soma dos oito resíduos é exatamente zero. Ainda há o que aprender?**

- Não: soma zero significa que o modelo já acertou na média, e o que sobra é ruído
- Sim: a soma é zero por construção, porque F_0 é a média, mas os quatro primeiros resíduos são negativos e os quatro últimos positivos, e isso é padrão
- Não, porque o resíduo é o erro final do modelo e ele já foi minimizado

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Os oito pontos, o palpite 6,5 e, em cada ponto, o resíduo desenhado e rotulado: observado menos previsão atual. Vermelho quando a previsão precisa subir, azul quando precisa descer. Em $x = 8$, a conta do quadro ao lado: $12,00 - 6,50 = +5,50$. Cada um dos oito casos ganha um alvo desse tipo, e a próxima árvore é ajustada a esses oito números, não ao y original. Repare numa propriedade: como F_0 é a média, a soma dos resíduos é zero. Isso não significa que não há o que aprender. Zero na soma não é zero em cada ponto: os quatro primeiros são negativos e os quatro últimos, positivos. O nível está certo e a forma está errada, a mesma distinção entre calibração agregada e por faixa que o capítulo 7 formaliza. E resíduo não é erro final: ele muda a cada árvore; depois de quatro, em $x = 8$ sobram 1,14.

PARA DISCUTIR EM AULA

Se a soma dos resíduos é zero, por que ainda há o que aprender?


A SEGUIR A árvore que ajusta o resíduo é a do capítulo 5, com outro critério.

6.6 A primeira árvore de correção

essencial, vista em aula · 10 min

Um toco devolve a correção média de cada lado; somada inteira, passa do ponto.

Palpite mais a correção inteira anel: resíduo que trocou de sinal



A REGRA DA ÁRVORE

$x \leq 4,5?$

sim: $-2,875$, o palpite está alto

não: $+2,875$, o palpite está baixo

Erro quadrático médio: $10,19 \rightarrow 1,92$

5 de 8

resíduos trocam de sinal; em $x = 5$, $+1,50$ vira $-1,375$

A direção está certa, mas o passo é grande demais: a correção inteira cai também sobre quem já estava perto. A taxa de aprendizagem, na próxima página, soma só um pedaço.

Página 6.6, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O QUE A ÁRVORE PREVÊ

Na primeira árvore de correção, com resíduos de $-2,875$ de um lado e $+2,875$ do outro, o que a árvore devolve para um caso com x maior que $4,5$?

- A previsão de y para aquele caso, que substitui o palpite anterior
- A correção a somar ao palpite anterior
- O erro que o modelo final ainda terá naquele caso

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A primeira árvore de correção é um toco com uma pergunta sobre os resíduos: $x \leq 4,5$? No gráfico, as duas regiões do corte: à esquerda, onde o palpite está alto, a correção é $-2,875$; à direita, onde está baixo, $+2,875$. A árvore não prevê y de novo; ela prevê quanto o modelo atual deve subir ou descer em cada região, e cada folha guarda a correção média do seu lado. A linha em degraus é o palpite mais a correção inteira: $3,625$ à esquerda e $9,375$ à direita. O erro quadrático médio cai de $10,19$ para $1,92$, mas os anéis mostram o custo: cinco dos oito resíduos trocam de sinal. Em $x = 5$, o resíduo era $+1,50$ e vira $-1,375$: a correção inteira caiu também sobre quem já estava perto. A direção está certa e o passo é grande demais. Em relação ao capítulo 5, só duas coisas mudaram: o alvo é o resíduo e a folha guarda uma média. A próxima página soma só um pedaço da correção.

PARA DISCUTIR EM AULA


Por que o valor da folha é a média e não a mediana dos resíduos?

A SEGUIR A saída é somar só um pedaço da correção.

6.7 Taxa de aprendizagem: somar só um pedaço da correção

essencial, vista em aula · 9 min

Cada correção entra multiplicada por η : avanço mais lento e mais estável.



Página 6.7, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · ESCOLHER A TAXA COM M FIXO

Com quatro árvores fixas, $\eta = 0,7$ produz o menor erro de treino da página, 0,14, e $\eta = 0,1$ ainda está em 5,48, mais da metade do erro inicial de 10,19. Isso estabelece que $\eta = 0,7$ é a melhor escolha?

- Sim, porque foi o valor que produziu o menor erro
- Não: η e M são acoplados, e comparar η com M fixo em quatro árvores não responde à pergunta. E o erro medido é de treino
- Não, porque η menor é sempre mais seguro contra sobreajuste

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Quatro árvores, sempre. O controle muda apenas a taxa de aprendizagem η , de 0,1 a 1, e os botões escolhem a etapa exibida, de F_0 até a quarta árvore. Com $\eta = 0,5$, as barras de erro por etapa mostram o erro quadrático médio caindo de 10,1875 (só F_0) para 3,9883 com uma árvore, 2,2200 com duas, 0,9291 com três e 0,4485 com quatro: redução acumulada de 95,6%, o valor do gerador em Python. No gráfico, a previsão em degraus se aproxima dos pontos e os segmentos de resíduo encolhem. Leve η a 1: a queda se concentra na primeira árvore, de 10,19 para 1,92. Leve a 0,1: o erro para em 5,48, e quatro árvores não bastam. Com quatro árvores fixas, o menor erro de treino sai de $\eta = 0,7$, com 0,14; acima disso ele volta a subir. Isso não faz de 0,7 a escolha: η pequeno exige mais árvores, e nenhuma delas domina o conjunto, o argumento de estabilidade do capítulo 5. A relação entre η e M é o assunto da página 16.

O QUE ESTÁ NA TELA

Mova η e compare o erro depois das quatro árvores.

PARA DISCUTIR EM AULA

Com quatro árvores fixas, qual η dá o menor erro de treino?

A SEGUIR Agora, o que cada uma das quatro árvores acrescentou.

6.8

O que cada árvore acrescentou

complementar, de estudo · 11 min

Cada árvore corrige uma região; a previsão é a soma das correções.


RESÍDUOS QUE ENCOLHEM · 8 PONTOS, UM PALPITE CONSTANTE E 4 TOCOS · O GERADOR DA AULA

Cada árvore é uma regra sobre os resíduos: um corte, duas correções médias, e o erro recalculado.

Reproduzir do início

Etapa 1: 1 árvore somada. Erro quadrático médio 3,9883, 60,9% abaixo do palpite inicial. Corte da árvore 1 em $x = 4,5$: $-2,875$ à esquerda, $+2,875$ à direita, cada um vezes $\eta = 0,5$.

Observado, previsão em degraus e resíduos segmento vermelho:
palpite baixo, precisa subir · azul: palpite alto



O que a árvore 1 propôs, já multiplicado por $\eta = 0,5$

x	y	antes	resíduo	$\eta \times \text{árvore}$	depois
1	2,0	6,50	-4,50	-1,44	5,06
2	3,0	6,50	-3,50	-1,44	5,06
3	4,5	6,50	-2,00	-1,44	5,06
4	5,0	6,50	-1,50	-1,44	5,06
5	8,0	6,50	1,50	1,44	7,94
6	8,5	6,50	2,00	1,44	7,94
7	9,0	6,50	2,50	1,44	7,94
8	12,0	6,50	5,50	1,44	7,94

ERRO ANTES → DEPOIS DA ÁRVORE 1

10,1875 → 3,9883

A primeira árvore separa os quatro primeiros dos quatro últimos: a correção mais grosseira e a que mais reduz o erro.

Página 6.8, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · POR QUE AQUI

A primeira árvore cortou em x igual a 4,5 e a segunda corta em x igual a 7,5. Por quê?

- a. Porque o algoritmo percorre os cortes candidatos em ordem crescente
- b. Porque depois da primeira correção o maior resíduo restante ficou concentrado em x igual a 8
- c. Porque cada ponto de corte só pode ser usado uma vez

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Avance uma árvore por vez com os botões de etapa. À esquerda, o gráfico mostra o que sobrava antes da árvore e como ficou a previsão em degraus depois. À direita, a tabela traz o que a árvore propôs, uma linha por ponto: x , y , previsão antes, resíduo, $\eta \times$ árvore, já multiplicado pela taxa de 0,5, e previsão depois. Na árvore 1, o corte é em $x = 4,5$ e o erro cai de 10,1875 para 3,9883. Os quatro primeiros casos recebem $-1,44$ e os quatro últimos $+1,44$; a previsão passa de 6,50 para 5,06 e 7,94. Confira em qualquer linha: previsão antes mais $\eta \times$ árvore dá a previsão depois. A sequência de cortes é 4,5, depois 7,5, 2,5 e 5,5. As árvores não são iguais e não repetem a divisão: cada uma vai onde sobrou erro. Antes de avançar, tente prever qual ponto a próxima árvore vai corrigir.

O QUE ESTÁ NA TELA

Avance uma árvore por vez e leia a tabela antes do próximo passo.

PARA PENSAR NO ESTUDO

Por que a segunda árvore corta em x igual a 7,5 e não em 4,5 de novo?

A SEGUIR As quatro correções, somadas.

6.9 Quatro correções, uma previsão

complementar, de estudo · 10 min

A previsão final é o palpite mais quatro parcelas.


RESÍDUOS QUE ENCOLHEM · 8 PONTOS, UM PALPITE CONSTANTE E 4 TOCOS · O GERADOR DA AULA

A previsão final de um ponto é uma soma visível: o palpite inicial mais quatro parcelas.

Reproduzir do início

Etapa 4: 4 árvores somadas. Erro quadrático médio 0,4485, 95,6% abaixo do palpite inicial. Corte da árvore 4 em $x = 5,5$: $-0,620$ à esquerda, $+1,033$ à direita, cada um vezes $\eta = 0,5$.

Observado, previsão em degraus e resíduos segmento vermelho: palpite baixo, precisa subir · azul: palpite alto



Previsão para $x = 8$ como soma de parcelas clique em outro ponto no gráfico

palpite F_0		$6,50 = 6,50$
árvore 1		$+1,44 = 7,94$
árvore 2		$+2,03 = 9,97$
árvore 3		$+0,38 = 10,35$
árvore 4		$+0,52 = 10,86$

OBSERVADO

12,00

PREVISÃO APÓS 4 ÁRVORES

10,86

erro de 5,50 para 1,14

F_0	árvore 1	árvore 2	árvore 3	árvore 4
-------	----------	----------	----------	-----------------

Taxa de aprendizagem η

0,5

Página 6.9, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A previsão de um único caso, lida como soma de parcelas. Para $x = 8$, a primeira linha vai até o palpite de 6,50 e cada linha seguinte acrescenta, em vermelho, a parcela de uma árvore; depois do sinal de igual vem a previsão acumulada, 7,94 após a árvore 1, 9,97 após a 2, 10,35 após a 3 e 10,86 após a 4. O observado é 12,00, a linha dourada, e o erro cai de 5,50 para 1,14. Clique nas etapas para ver cada parcela entrar; clique em outro ponto do gráfico para trocar o caso em foco. Repare que as parcelas não encolhem em ordem: para $x = 8$, a maior é a da árvore 2, +2,03, que corta em 7,5 e mira o ponto que sobrou mais longe. Cada árvore vai onde está o erro do momento. A queda cada vez menor do erro médio não é esgotamento do método: vinte árvores levariam o erro de treino a 0,0037 sem aprender nada além dos oito pontos. O que se esgota é o ganho fora da amostra.

O QUE ESTÁ NA TELA

Clique noutro ponto do gráfico para ver a soma dele.

PARA PENSAR NO ESTUDO

Quantas árvores seriam necessárias para erro zero no treino?

A SEGUIR Está na hora de escrever a fórmula.

6.10 A fórmula depois da história

essencial, vista em aula · 8 min

Cada termo da equação é uma parte do mecanismo já visto.

$F_{m-1}(x)$ previsão anterior o que a sequência já aprendeu	+	η taxa de aprendizagem o mesmo fator em todas as etapas, escolhido antes do treino	×	$h_m(x)$ nova correção o padrão encontrado no erro atual
$F_m(x) = F_{m-1}(x) + \eta h_m(x)$				
No caso $x = 8$ $6,50 + 0,5 \times 2,875 = 7,94$. Só então calculamos o novo resíduo: $12,00 - 7,94 = 4,06$. Resíduo, não erro final: ele vai mudar de novo na próxima árvore.				
η não é um peso por árvore Não é nota que o algoritmo dá a cada árvore conforme ela é boa. É um único número, igual para as M árvores, escolhido antes de treinar. O que muda de árvore para árvore é h_m, nunca η.				

Página 6.10, como aparece na plataforma.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · O QUE A TAXA MULTIPLICA**

Na fórmula $F_m(x) = F_{m-1}(x) + \eta \times h_m(x)$, o que exatamente η multiplica?

- Só a nova correção h_m . O palpite inicial e as correções já somadas entram inteiros em F_{m-1}
- Toda a expressão, inclusive o palpite inicial F_0
- A nova correção, com um valor diferente a cada árvore, conforme a qualidade dela

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A fórmula tem três termos e cada um é um objeto que você já viu. F com índice $m-1$ é a previsão anterior, o que a sequência já aprendeu. η é a taxa de aprendizagem, quanto confiar nesta etapa. h com índice m é a nova correção, o padrão encontrado no erro atual. A notação apenas comprime a história: previsão anterior mais uma fração da correção sugerida pela nova árvore. Para $x = 8$: $6,50 + 0,5 \times 2,875 = 7,94$, e só então se calcula o novo erro, $12,00 - 7,94 = 4,06$. Repare no que η multiplica: só a nova correção h_m ; F_0 e as correções já somadas entram inteiros. Por que o nome é gradient boosting e não residual boosting? Porque o resíduo é o caso particular do erro quadrático. Com outras perdas, o alvo da árvore é o gradiente negativo, que não é o resíduo comum. O nome cobre o caso geral, e é isso que permite a troca de critério da próxima página.

PARA DISCUTIR EM AULA

Por que gradient e não residual boosting?

A SEGUIR Agora, de volta ao crédito.

6.11 Voltando ao crédito: onde a soma acontece

complementar, de estudo · 9 min

Em classificação, as árvores somam em log odds, a escala do escore da logística.

SOMAR EM PROBABILIDADE

Ponto de partida	0,50
Correção 1	+0,30
Correção 2	+0,25
Resultado	1,05

Passa de 1. Truncar repete o problema da reta do capítulo 4.

SOMAR EM LOG ODDS

Ponto de partida	0,000
Correção 1	+1,200
Correção 2	+1,050
Escore	2,250

PD pela logística **90,47%**

Qualquer soma vira uma PD entre 0 e 1.

$$F_M(x) = F_0 + \eta \cdot \sum_m h_m(x) \quad PD(x) = \sigma(F_M(x)) \quad F_0 = \ln(\pi \div (1 - \pi))$$

Logística e boosting somam na mesma escala, log odds: por isso o capítulo 7 compara os dois.

F_0 é o log odds da prevalência: 50% dá 0; numa carteira com 10% de default, $-2,1972$.

Página 6.11, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Dois painéis lado a lado e, embaixo, a fórmula numa linha. No vermelho, somam-se probabilidades: ponto de partida 0,50, correção 1 de +0,30, correção 2 de +0,25, resultado 1,05. Nenhuma restrição impede isso, e truncar em 1 reintroduz o problema da reta na probabilidade do capítulo 4. No verde, soma-se em log odds: ponto de partida 0,000, correções de +1,200 e +1,050, escore final 2,250, e a logística traduz para PD de 90,47%. Qualquer soma, de qualquer tamanho, continua dentro do intervalo. É a propriedade da página 7 do capítulo 4, usada para outro fim. A consequência importa para o capítulo 7: a logística produz o escore como soma de coeficientes vezes variáveis; o boosting, como soma de árvores. As duas vivem em log odds e terminam na mesma curva de tradução, por isso são comensuráveis. O ponto de partida é o log odds da prevalência: nesta base didática, 50%, logo F_0 vale zero. Em carteira com 10% de default, F_0 valeria $-2,1972$.

PARA PENSAR NO ESTUDO

Por que F_0 é zero nesta base?

A SEGUIR Falta definir o que as árvores vão prever.

6.12

O alvo da próxima árvore é $y - p$

complementar, de estudo · 10 min

Quem já está bem previsto quase não pesa na correção seguinte.

A PERDA QUE CAI · 16 PROPOSTAS, LOG ODDS, ÁRVORES DE PROFUNDIDADE 2 · O GERADOR DA AULA

O alvo da próxima árvore é $y - p$: quem já está bem previsto quase não pesa na correção.

Reproduzir do início

Árvore 1 de 4. Perda 0,6931 → 0,6219, queda de 0,0713. $\eta = 0,4$. Raiz em utilização $\leq 57,5\%$; 4 folhas, cada uma com a correção média do grupo.

Plano das variáveis

cor do ponto: desfecho · número: PD atual · regiões: correção da árvore 1

Fo

árvore 1

árvore 2

árvore 3

árvore 4

Alvo da próxima árvore, $y - p$, proposta por proposta

ordenado do maior ao menor

#1 · pagou	-0,50
#2 · default	+0,50
#15 · pagou	-0,50
#16 · default	+0,50
#3 · pagou	-0,45
#4 · pagou	-0,45
#5 · pagou	-0,45
#6 · pagou	-0,45
#7 · pagou	-0,45
#8 · pagou	-0,45
#9 · default	+0,45
#10 · default	+0,45
#11 · default	+0,45
#12 · default	+0,45
#13 · default	+0,45
#14 · default	+0,45

LEITURA

Caso já bem previsto tem resíduo pequeno e pesa pouco na correção seguinte. Quem continua mal previsto puxa a árvore.

Página 6.12, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · O ALVO DA ÁRVORE

Na terceira iteração, uma proposta já bem prevista tem $y - p$ próximo de zero. Que efeito isso tem sobre a árvore seguinte?

a. Ela é removida da amostra para não atrapalhar

b. Ela continua na amostra e quase não influencia a árvore, porque seu alvo é quase zero

c. Ela recebe peso maior, para que o modelo não esqueça o que já aprendeu

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

O plano à esquerda traz as dezesseis propostas da base didática por utilização do limite e atraso, com a cor do desfecho e a PD atual escrita em cada ponto. À direita, o alvo da próxima árvore, $y - p$, proposta por proposta, ordenado do maior ao menor. Clique em F_0 : toda PD vale 50% e todo alvo vale $\pm 0,50$; um pagador tem $-0,50$, um default tem $+0,50$, e a primeira árvore trata todos por igual. Volte à árvore 1, onde a página abre: as propostas das pontas, #1, #2, #15 e #16, continuam com $\pm 0,50$, e as demais já estão em $\pm 0,45$. Daí em diante, quem já está bem previsto tem $y - p$ perto de zero, e quem continua mal previsto puxa a árvore. Os valores são contínuos entre -1 e $+1$, não rótulos 0 ou 1. Esse alvo é o gradiente negativo da log loss em relação ao escore, a mesma coluna $y - p$ do capítulo 4. Por isso uma proposta já bem prevista continua na amostra e quase não influencia a árvore seguinte: o método realoca a atenção sozinho.

O QUE ESTÁ NA TELA

Avance as árvores e veja o alvo encolher nas propostas bem previstas.

PARA PENSAR NO ESTUDO

O que acontece com $y - p$ de uma observação já bem prevista?

A SEGUIR Com o alvo definido, o procedimento é o mesmo.

6.13 Boosting de classificação, iteração por iteração

essencial, vista em aula · 10 min

O mesmo procedimento, em classificação: a perda cai a cada árvore.


A PERDA QUE CAI · 16 PROPOSTAS, LOG ODDS, ÁRVORES DE PROFUNDIDADE 2 · O GERADOR DA AULA

O mesmo procedimento de cinco linhas, agora em classificação: a perda cai a cada árvore somada.


Reproduzir do início

Árvore 1 de 4. Perda 0,6931 $\rightarrow$ 0,6219, queda de 0,0713. $\eta = 0,4$. Raiz em utilização $\leq 57,5\%$; 4 folhas, cada uma com a correção média do grupo.

Plano das variáveis cor do ponto: desfecho · número: PD atual · regiões: correção da árvore 1



Perda logarítmica por árvore linha tracejada: logística do capítulo 4



PERDA APÓS 1 ÁRVORE

0,6219

gerador: 0,6219


DISTÂNCIA ATÉ A LOGÍSTICA

0,1891

quatro árvores ainda não chegam lá; mais árvores chegam, a página 16 mostra quantas

F_0 **árvore 1** árvore 2 árvore 3 árvore 4

Taxa de aprendizagem η 0,4



Página 6.13, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · QUATRO ÁRVORES CONTRA A LOGÍSTICA

Quatro árvores levam a log loss de treino de 0,6931 a 0,4748, e a regressão logística do capítulo 4 atinge 0,43282 na mesma base. O boosting é pior?

- a. Sim, a logística venceu nesta base
- b. A comparação não decide nada: as duas perdas são de treino, e o número de árvores não foi escolhido por nenhum critério
- c. Não, basta acrescentar árvores até a perda passar de 0,43282

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A base de dezesseis propostas, em classificação, com $\eta = 0,4$. Avance uma árvore por vez: o plano mostra a PD de cada proposta e as regiões da árvore com a correção de cada uma; a curva à direita, a perda por árvore. Na árvore 1, toda PD parte de 50%. A árvore devolve $-0,20$ para os pagadores #3 a #8 e $+0,20$ para os defaults #9 a #14, e as PDs vão a 45% e 55%; as propostas #1, #2, #15 e #16 recebem 0,00 e ficam em 50%. A perda cai de 0,6931 para 0,6219, queda de 0,0713. A curva segue: 0,5630, 0,5150 e 0,4748 após quatro árvores, os números do gerador. A linha tracejada é a logística do capítulo 4, com 0,43282 na mesma base: quatro árvores ainda não chegam lá, e o contador mostra a distância. O procedimento é o mesmo da regressão; só o alvo e a escala mudaram. A mudança dos alvos y – p, árvore a árvore, está na página 12.

O QUE ESTÁ NA TELA

Avance uma árvore por vez e acompanhe a perda.

PARA DISCUTIR EM AULA

Por que quatro árvores ainda perdem para a logística nesta base?


A SEGUIR Agora, o que cada árvore somou a cada proposta.

6.14 O que cada árvore acrescentou, em log odds

complementar, de estudo · 9 min

A PD final se decompõe em parcelas rastreáveis, árvore por árvore.

A PERDA QUE CAI · 16 PROPOSTAS, LOG ODDS, ÁRVORES DE PROFUNDIDADE 2 · O GERADOR DA AULA

A PD final de uma proposta é rastreável: F_0 mais quatro parcelas em log odds, e a logística no fim.**Reproduzir do início****Árvore 4 de 4.** Perda 0,5150 → 0,4748, queda de 0,0402. $\eta = 0,4$. Raiz em utilização $\leq 57,5\%$; 4 folhas, cada uma com a correção média do grupo.**Plano das variáveis** cor do ponto: desfecho · número: PD atual · regiões: correção da árvore 4**Proposta #12: utilização 75%, atraso 40 d, desfecho default** clique em outra proposta no plano

F_0		0,000	0,000 → PD 50,0%
árvore 1		+0,200	0,200 → PD 55,0%
árvore 2		+0,183	0,383 → PD 59,5%
árvore 3		+0,165	0,549 → PD 63,4%
árvore 4		+0,152	0,701 → PD 66,8%

BOOSTING, 4 ÁRVORES**66,8%****LOGÍSTICA DO CAPÍTULO 4****99,6%****ÁRVORE DO CAPÍTULO 5****100,0%**

folha com 6 de 6

F_0	árvore 1	árvore 2	árvore 3	árvore 4
-------	----------	----------	----------	-----------------

Página 6.14, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Escolha uma proposta clicando no plano e leia a decomposição completa do escore. Para a #12 (utilização 75%, atraso 40 dias, default), F_0 vale 0,000 e PD 50,0%; a árvore 1 acrescenta +0,200 (PD 55,0%), a 2 acrescenta +0,183 (59,5%), a 3 acrescenta +0,165 (63,4%) e a 4 acrescenta +0,152, escore total 0,701 e PD de 66,8%. À direita, uma linha por etapa: o trecho que a árvore acrescentou em log odds, a partir da linha dourada do escore zero, e o escore acumulado com a PD. Compare com as outras famílias na mesma proposta: a regressão logística do capítulo 4 estima 99,6% e a árvore do capítulo 5 estima 100%. Depois troque para a #15, a proposta que contraria o padrão da base. A lição é sobre interpretabilidade. Com quatro árvores, a decomposição cabe numa tabela; com duzentas, ela existe do mesmo jeito e ninguém a lê. O boosting é rastreável. O que ele não tem é a legibilidade da logística, e essa diferença, não a ausência de explicação, é o que separa as duas famílias.

O QUE ESTÁ NA TELA

Clique numa proposta e leia a decomposição do escore.

PARA PENSAR NO ESTUDO

Onde as três famílias mais discordam?

A SEGUIR Falta escolher η , M , profundidade e mínimo por folha.

6.15

Os quatro hiperparâmetros

complementar, de estudo · 10 min

η, árvores, profundidade e mínimo por folha controlam a complexidade juntos.

OS QUATRO HIPERPARÂMETROS · BASE DIDÁTICA DE 16 PROPOSTAS · LOGÍSTICA DO CAPÍTULO 4 COMO REFERÊNCIA

Quatro controles, quatro caminhos para a complexidade.
Eles se escolhem em conjunto, e M se escolhe fora do treino.

a da aula

lenta e rasa

decorar

η 0,40, M 4, profundidade 2, mínimo 2: log loss de treino 0,47481 contra 0,43282 da logística, 16 folhas somadas, menor folha com 2, PD de 33% a 67%. Configuração razoável para esta base. Em base real, a escolha se faz por validação e não por inspeção.

Taxa de aprendizagem η0,40

Número de árvores M4

Profundidade de cada árvore2

Mínimo de propostas por folha2

LOG LOSS DE TREINO

0,47481

logística: 0,43282

FOLHAS SOMADAS

16

parâmetros estimados no total

MENOR FOLHA

2

propostas na folha mais específica

PD MÍNIMA E MÁXIMA

33% a 67%

o quanto o modelo ousa

Log loss de treino a cada árvore

tracejada: a logística do capítulo 4

Árvores acrescentadas	Log loss de treino	Logística
1	0,72	0,43282
2	0,58	0,43282
3	0,52	0,43282
4	0,47481	0,43282

O QUE CADA UM CONTROLA

η

quanto de cada correção é aceito. Menor significa avanço mais lento e menos dependência de cada árvore

M

quantas correções. É o freio contra o sobreajuste, e o único que precisa ser escolhido observando amostra fora do treino

Profundidade

quantas variáveis podem interagir dentro de uma árvore. Profundidade 1 não permite interação alguma; profundidade 2 permite pares

Mínimo por folha

quão específica pode ser uma correção. É a mesma função do capítulo 5, e o mesmo argumento de incerteza da folha

Página 6.15, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

Quatro controles deslizantes: taxa de aprendizagem η , número de árvores M , profundidade de cada árvore e mínimo de propostas por folha. Quatro indicadores respondem: log loss de treino, folhas somadas (os parâmetros estimados), menor folha e a faixa de PD. Na configuração da aula, η 0,40, M 4, profundidade 2 e mínimo 2, o log loss é 0,47481 contra 0,43282 da logística, 16 folhas somadas, menor folha com 2 e PD de 33% a 67%. À direita, a curva de log loss de treino a cada árvore, com a logística tracejada. Os atalhos aplicam três configurações: a da aula, lenta e rasa, e decorar. Leve M a 40 mantendo o resto: a perda cai a 0,17864, bem abaixo da logística, e continua descendo; o atalho decorar chega a 0,02539. O modelo melhorou? A curva de treino só desce e nunca indica onde parar. Na tabela: η decide quanto de cada correção entra; M , quantas correções, o freio contra o sobreajuste; profundidade, quantas variáveis interagem numa árvore; mínimo por folha, quão específica pode ser uma correção.

Prof. Genaro Dueire Lins · FGV · 2026

20 de 28

O QUE ESTÁ NA TELA

Mova os quatro controles e acompanhe a perda e a menor folha.

PARA PENSAR NO ESTUDO

Qual dos quatro exige amostra fora do treino para ser escolhido?

A SEGUIR Dois desses quatro não podem ser escolhidos separadamente.


6.16 η e M são acoplados

complementar, de estudo · 8 min

Reduzir η pela metade pede o dobro de árvores para o mesmo ajuste.

η	ÁRVORES ATÉ PERDA 0,50	$\eta \times$ ÁRVORES	PERDA, 60 ÁRVORES
0,10	14	1,40	0,28394
0,15	10	1,50	0,23680
0,20	7	1,40	0,20965
0,30	5	1,50	0,16621
0,40	4	1,60	0,13711
0,50	3	1,50	0,11702
0,60	3	1,80	0,10227
0,80	2	1,60	0,08165
1,00	2	2,00	0,06800

Árvores necessárias para a perda de treino chegar a 0,50 tracejada: $1,5 \div \eta$



$\eta \times$ árvores fica perto de 1,5: reduzir η pela metade pede o dobro de árvores.

A última coluna é de treino: 0,06800 com $\eta = 1$ é memorização, não desempenho.

η pequeno custa tempo, mas dá à validação mais pontos onde parar.

Página 6.16, como aparece na plataforma, onde é interativa.

COMO LER ESTA PÁGINA

A tabela responde, para cada taxa de aprendizagem, quantas árvores são necessárias até a perda de treino chegar a 0,50. Com η de 0,10, 14 árvores; com 0,20, 7; com 0,40, 4; com 1,00, 2. A terceira coluna, η vezes árvores, fica entre 1,40 e 2,00: quase constante. Reduzir η pela metade exige aproximadamente dobrar M, e a curva ao lado da tabela acompanha a hipérbole $1,5 \div \eta$, tracejada. A última coluna dá a perda com 60 árvores: 0,28394 para η de 0,10 e 0,06800 para η de 1,00. Se o resultado é o mesmo, por que preferir η pequeno? Porque o caminho não é idêntico: com η pequeno, o modelo passa por muitos estágios intermediários e a validação pode parar em qualquer um deles. A vantagem é granularidade. O custo é tempo: η de 0,01 com dez mil árvores custa cem vezes mais que η de 1 com cem. Em produção, a escolha típica fica entre 0,01 e 0,1.

PARA PENSAR NO ESTUDO

Por que a terceira coluna não é exatamente constante?

A SEGUIR Falta o comportamento fora da amostra.

6.17 Fora da amostra: onde o boosting é decidido

essencial, vista em aula · 9 min


Mais complexidade sempre melhora o treino; fora do tempo, a partir de um ponto, piora.

A DISTÂNCIA QUE SE ABRE · GRADE DE BOOSTING · 5.000 PROPOSTAS SINTÉTICAS, SEMENTE 20260501

Treino sobe sem exceção. Fora do tempo desce. Quem escolhe pelo treino escolhe o pior modelo da grade.

Escolher pelo treino

Escolher pela validação

60 árvores, 8 folhas. AUC de treino 0,8196, validação 0,6476, fora do tempo 0,6958. Distância treino menos fora do tempo: 0,1238.**AUC por número de árvores** contínua: treino · tracejada: fora do tempo
· área: a distância entre as duas · clique num ponto☐ mostrar a validação (pontilhada), a amostra que decide**AUC DE TREINO****0,8196**

sobe com árvores e com folhas, sem exceção

AUC FORA DO TEMPO**0,6958**

a melhor da grade, escolhida sem olhar o fora do tempo

DISTÂNCIA TREINO MENOS FORA DO TEMPO**0,1238**

máxima na grade: 0,3551

Escolha um critério. Os dois botões acima aplicam a mesma grade com critérios diferentes.

Página 6.17, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA**QUESTÃO · O QUE REPORTAR****A configuração com maior AUC de treino da grade atinge 0,9927 e tem AUC fora do tempo de 0,6376, a pior da grade. O que levar ao comitê?**

- A AUC de treino de 0,9927, por ser a melhor medida da capacidade do modelo
- A AUC fora do tempo da configuração escolhida na validação, declarando a grade inteira e o critério de escolha
- A média entre a AUC de treino e a de fora do tempo, para equilibrar as duas leituras

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

A grade completa do boosting na base de 5.000 propostas do curso: 4, 8 e 16 folhas por árvore, cruzadas com 60, 100, 160 e 240 árvores, com η de 0,05 e mínimo de 60 por folha. Linhas contínuas são AUC de treino; tracejadas, fora do tempo; mesma cor para o mesmo número de folhas. O treino sobe com árvores e com folhas, sem exceção, até 0,9927. Fora do tempo desce quando a complexidade cresce, chegando a 0,6376. A distância máxima é 0,3551. Clique num ponto para ler a configuração, ou use os botões: escolher pelo treino leva a 240 árvores e 16 folhas, a pior AUC fora do tempo da grade inteira; escolher pela validação leva a 60 árvores e 8 folhas. Marque a caixa para ver a validação, a amostra que decide. Por que 16 folhas piora mais rápido que 4? Cada árvore já captura interações de até quatro níveis. O número a reportar é a AUC fora do tempo da configuração escolhida na validação, com a grade e o critério declarados.

O QUE ESTÁ NA TELA

Escolha pelo treino e pela validação e compare a AUC fora do tempo.

PARA DISCUTIR EM AULA

Por que 16 folhas piora mais rápido que 4?

A SEGUIR Resta o custo de tudo isso.

6.18

Três limites do boosting e como responder

complementar, de estudo · 9 min

Para cada fragilidade, um sinal e um controle verificável.

TRÊS LIMITES DO BOOSTING · O SINAL, A RESPOSTA PROPORCIONAL E A EVIDÊNCIA DESTA BASE

O boosting troca interpretação direta por flexibilidade. Nomeie a falha primeiro; depois escolha o controle correspondente.

Sobreajuste

Instabilidade

Explicação

Sobreajuste. Sinal: treino melhora; validação piora. Resposta proporcional: early stopping, menor profundidade e folha mínima maior. Na grade do gerador com 60 árvores, a AUC de treino sobe de 0,7588 para 0,9114 ao passar de 4 para 16 folhas, e a de validação vai de 0,6400 para 0,6388.

AUC por número de folhas, 60 árvores, base de 5.000 do gerador

treino sobe; validação e fora do tempo não acompanham

AUC

Folhas por árvore	treino	validação	fora do tempo
4	0,759	0,640	0,689
8	0,820	0,648	0,696
16	0,911	0,639	0,656

● treino

● validação

● fora do tempo

O QUE SE PERDE

COEFICIENTE POR VARIÁVEL

não existe um número que resuma o efeito de utilização sobre a PD

MONOTONICIDADE GARANTIDA

a PD estimada pode subir e descer com a mesma variável, sem hipótese econômica que sustente

EXPLICAÇÃO CURTA DA DECISÃO

a decomposição existe, mas tem tantas parcelas quanto árvores

ESTABILIDADE DA FORMA

reestimar produz outro conjunto de árvores, ainda que com previsões parecidas

O QUE SE FAZ

RESTRIÇÃO DE MONOTONICIDADE

disponível na maioria das implementações. Impõe direção por variável e devolve a hipótese econômica

EFEITO PARCIAL POR VARIÁVEL

mostra a forma da relação estimada, mesmo sem coeficiente

ATRIBUIÇÃO POR OBSERVAÇÃO

decompõe a decisão individual em contribuições por variável, para o motivo de recusa

MODELO DE REFERÊNCIA

manter a logística em produção paralela, e exigir do desafiante ganho demonstrável

A PERGUNTA QUE O COMITÊ FARÁ

O ganho de desempenho compensa a perda de explicação, dada a exigência regulatória de informar o motivo da recusa e a necessidade de sustentar o modelo em inspeção? A resposta depende da magnitude do ganho e da sua significância, e é isso que o capítulo 7 mede.

UMA POSIÇÃO DEFENSÁVEL

Adotar o desafiante quando o ganho for material e demonstrável fora do tempo, com teste apropriado, com monotonicidade imposta nas variáveis que têm direção econômica clara e com atribuição individual disponível para o motivo de recusa. Nenhuma dessas condições é exótica, e todas são verificáveis.

Página 6.18, como aparece na plataforma, onde é interativa.

Prof. Genaro Dueire Lins · FGV · 2026

23 de 28

COMO LER ESTA PÁGINA

Três botões, três fragilidades, e para cada uma um sinal, uma resposta proporcional e uma evidência desta base. Sobreajuste: treino melhora enquanto a validação piora; a resposta é early stopping, menor profundidade e folha mínima maior. A evidência vem da grade com 60 árvores: de 4 para 16 folhas, a AUC de treino sobe de 0,7588 para 0,9114 e a de validação vai de 0,6400 para 0,6388. Instabilidade: pequenas mudanças alteram as árvores; retirar uma proposta de dezesseis muda a primeira árvore, e a resposta é regularização, sementes, validação temporal e análise por segmento. Explicação: muitas correções somadas; escolha 4, 12 ou 40 árvores e veja a PD da proposta #11 decomposta em F_0 mais uma parcela por árvore. A resposta é contribuições locais, efeito parcial com cautela e exemplos concretos. À direita, o que se perde (coeficiente por variável, monotonicidade, explicação curta, estabilidade da forma) e o que se faz (restrição de monotonicidade, efeito parcial, atribuição por observação, modelo de referência). Primeiro nomeie a falha, depois escolha o controle.

O QUE ESTÁ NA TELA

Clique numa fragilidade e veja o sinal e a resposta.

PARA PENSAR NO ESTUDO

Em qual situação você não adotaria o boosting mesmo com ganho de AUC?

A SEGUIR Fechamento do capítulo.

6.19 Síntese: pequenas correções formam o boosting

complementar, de estudo · 6 min

Palpite, correções em log odds e complexidade escolhida fora do treino.

3 IDEIAS PARA LEVAR**A previsão final acumula árvores que atacam erros diferentes.**

1. **Resíduo.** O que a nova árvore tenta prever?

| O erro que o conjunto atual ainda deixa.

2. **Soma.** Onde está a previsão?

| No valor inicial mais todas as correções ponderadas.

3. **Teste.** Como escolher complexidade?

| Pelo desempenho fora do ajuste, com taxa e número de árvores avaliados juntos.

COMO LER ESTA PÁGINA

Três ideias para levar, uma por botão: Resíduo, Soma e Teste. A frase à esquerda resume: a previsão final acumula árvores que atacam erros diferentes. O Resíduo responde o que a nova árvore tenta prever: o erro que o conjunto atual ainda deixa, e não o alvo original. A Soma diz onde está a previsão: no valor inicial mais todas as correções ponderadas pela taxa de aprendizagem, na escala de log odds. O Teste diz como escolher a complexidade: pelo desempenho fora do ajuste, com taxa e número de árvores avaliados juntos. Antes de clicar, escolha uma das três e explique com suas palavras. O Teste é o que o treino não responde: nas 16 propostas, a log loss de treino do boosting cai de 0,47481 com quatro árvores para 0,05444 com duzentas, e isso não diz quantas usar. A página seguinte fecha a aula com os três modelos nas mesmas 16 propostas, e o capítulo 7 responde fora da amostra.

O QUE ESTÁ NA TELA

Explique cada ideia com suas palavras antes de revelar.

PARA PENSAR NO ESTUDO

Se a perda no treino cai a cada árvore acrescentada, por que ela não escolhe quantas árvores usar?

A SEGUIR O fecho da aula: as três PDs das 16 propostas, lado a lado.

6.20 Três modelos, as mesmas 16 propostas

essencial, vista em aula · 6 min

Os três concordam onde o caso é claro e divergem na fronteira; o treino não decide.

FECHO DA AULA 2 · AS MESMAS 16 PROPOSTAS · TRÊS FAMÍLIAS

Os três modelos concordam onde o caso é claro e discordam na fronteira.

Logística

Árvore

Boosting

Proposta #12, utilização 75% e atraso 40 d, deu default: logística 99,6% · árvore 100,0% (folha de 6, 6 defaults) · boosting 66,8%. 33,2 pontos entre a menor e a maior. Os três põem a proposta acima de 50%.

Uma linha por proposta, na ordem da utilização

clique numa linha para ler as três PDs

PROPOSTA

0%

25%

50%

75%

100%

DESFECHO

#1 20% · 25 d

#2 25% · 20 d

#3 30% · 5 d

#4 35% · 10 d

#5 40% · 20 d

#6 45% · 0 d

#7 50% · 0 d

#8 55% · 5 d

#9 60% · 20 d

#10 65% · 0 d

#11 70% · 5 d

#12 75% · 40 d

#13 80% · 5 d

#14 85% · 30 d

#15 90% · 0 d

#16 95% · 20 d

Logística, capítulo 4, coeficientes da aula

Árvore, capítulo 5, profundidade 2

Boosting, capítulo 6, 4 árvores, $\eta = 0,4$

um modelo abaixo de 50% e outro acima

Ver as 16 propostas em tabela

PERDA NO TREINO, LOG LOSS MÉDIA

Logística	0,43282
Árvore	0,18844
Boosting, 4 árvores	0,47481
Boosting, 50 árvores	0,15503

No treino vence quem ajusta mais, e ajustar mais não é prever melhor.

A PERGUNTA DA AULA 3

Qual critério decide entre os três, fora da amostra, e quando a diferença justifica trocar o modelo? Capítulos 7 e 8.

Entrega da aula 2: a comparação conceitual das três técnicas e os exercícios de interpretação.

Página 6.20, como aparece na plataforma, onde é interativa.

ANTES DE LER A EXPLICAÇÃO, RESPONDA

QUESTÃO · ONDE OS TRÊS MODELOS DISCORDAM

Em qual destas propostas os três modelos mais discordam?

a. #10: utilização de 65%, sem atraso, deu default

b. #12: utilização de 75%, atraso de 40 dias, deu default

c. #3: utilização de 30%, atraso de 5 dias, pagou

Na plataforma, cada resposta recebe o diagnóstico: por que a alternativa está certa ou o que se confundiu.

COMO LER ESTA PÁGINA

Uma linha por proposta, na ordem da utilização, de 20% na #1 a 95% na #16, com o desfecho à direita. Em cada linha, o círculo é a logística do capítulo 4, o quadrado a árvore de profundidade 2 do capítulo 5 e o losango o boosting de quatro árvores com $\eta = 0,4$ do capítulo 6; a barra cinza vai da menor à maior PD. A proposta #12, aberta no quadro, mostra a leitura: logística 99,6%, árvore 100% (folha de seis propostas, seis defaults) e boosting 66,8%, os três acima de 50%. Linha tingida quer dizer um modelo abaixo de 50% e outro acima. Desligue uma família de cada vez nos botões do topo e repare no formato de cada uma: a logística sobe em rampa, a árvore salta, o boosting com quatro árvores não passa de 33,4% e 66,8%. Responda à questão antes de abrir a tabela. Depois leia o quadro da perda no treino: a árvore tem a menor, 0,18844, e isso não decide nada. Escolher fora da amostra é o capítulo 7.

Prof. Genaro Dueire Lins · FGV · 2026

25 de 28

O QUE ESTÁ NA TELA

Clique nas linhas em que os três mais se afastam antes de responder.

PARA DISCUTIR EM AULA

Onde os três modelos concordam, e onde discordam?

A SEGUIR *Aula 3, capítulo 7: como escolher entre modelos fora da amostra.*

Fecho do capítulo

Antes da próxima aula, você deve conseguir explicar

- **6.1** Cada árvore aprende o erro que as anteriores deixaram.
- **6.2** Selecionar, combinar em paralelo ou corrigir em sequência.
- **6.5** O resíduo, observado menos previsto, é o que a próxima árvore aprende.
- **6.6** Um toco devolve a correção média de cada lado; somada inteira, passa do ponto.
- **6.7** Cada correção entra multiplicada por η : avanço mais lento e mais estável.
- **6.10** Cada termo da equação é uma parte do mecanismo já visto.
- **6.13** O mesmo procedimento, em classificação: a perda cai a cada árvore.
- **6.17** Mais complexidade sempre melhora o treino; fora do tempo, a partir de um ponto, piora.
- **6.20** Os três concordam onde o caso é claro e divergem na fronteira; o treino não decide.

Erros comuns: o que se confunde

#	Erro	Confusão por trás
6.2	Confundir com média de modelos	Não percebe que as correções são sequenciais e dependentes.
6.3	Querer ajustar uma reta	Traz o instrumento do capítulo 4 para um método que usa outro bloco.
6.4	Escolher o ponto do meio do gráfico	Usa inspeção visual em vez do critério.
6.5	Achar que resíduo com soma zero é ruído	Confunde média nula com ausência de padrão.
6.6	Esperar que a árvore acompanhe cada ponto	Exige de um toco o que só uma árvore profunda faria.
6.7	Escolher η pelo erro de treino com M fixo	Otimiza um hiperparâmetro mantendo o outro fixo, quando os dois são acoplados.
6.7	Achar que η menor é sempre mais seguro	Ignora que η pequeno com M pequeno produz modelo subajustado.
6.8	Achar que as árvores são todas iguais	Imagina que a mesma divisão se repete.
6.8	Somar a árvore sem multiplicar por η	Esquece a taxa de aprendizagem na conta.
6.9	Ver a queda decrescente como esgotamento do método	Interpreta rendimento decrescente como limite de capacidade.
6.10	Achar que η multiplica F_0	Lê a fórmula sem notar que η multiplica só $h_m(x)$.
6.11	Achar que F_0 é sempre zero	Generaliza a partir da base de 50%.
6.12	Confundir $y - p$ com erro de classificação	Espera valores 0 ou 1.
6.12	Achar que a árvore prevê o alvo	Não percebe a troca de alvo.
6.13	Concluir que o boosting é pior	Compara em número de iterações arbitrário e em amostra de treino.

#	Erro	Confusão por trás
6.14	Dizer que boosting não tem explicação	Confunde volume de parcelas com ausência de decomposição.
6.15	Escolher M pela perda de treino	Usa uma curva que só desce como critério de parada.
6.15	Aumentar profundidade para melhorar	Transfere a lógica de árvore única para o ensemble.
6.16	Escolher η e M em grades independentes	Trata dois hiperparâmetros acoplados como separáveis.
6.17	Reportar AUC de treino	Confunde memorização com capacidade.
6.17	Escolher pela AUC fora do tempo	Queima a amostra de teste na escolha.
6.18	Recusar o boosting por princípio	Trata interpretabilidade como tudo ou nada.
6.18	Adotar o boosting por desempenho isolado	Ignora as exigências de governança.
6.19	Escolher o número de árvores pela menor perda de treino	Confunde ajuste com generalização.
6.20	Escolher o modelo pela menor perda de treino	Repete com três modelos a armadilha de c5p18.
6.20	Ler os 50% da árvore nas pontas como risco médio	Uma folha de duas propostas com um default dá 50% sem afirmar nada.